

# 1 SafeVLA：通过约束学习实现 Vision-Language-Action Model 的安全对齐

## 2 Abstract

### 摘要

Vision-Language-Action 模型 (VLA) 展现出成为通用机器人 policy 的潜力。然而，这类模型在真实世界部署中面临极为严峻的安全挑战，包括对环境、机器人自身以及人类造成伤害的风险。如何将安全约束显式地融入 VLA？针对这一问题，我们探索了一种集成安全方法 (integrated safety approach, ISA)：系统性地建模安全需求，主动诱发多样化的不安全行为，通过安全强化学习对 VLA policy 施加有效约束，并借助有针对性的评估对其安全性进行严格保障。

ISA 基于约束马尔可夫决策过程 (constrained Markov decision process, CMDP) 范式，从面向已诱发安全风险的最小-最大视角优化 VLA。通过这一完整流程对齐后的 policy 具备以下关键特性：(I) 能够有效权衡安全性与任务性能：相较于当前 SOTA 方法，安全违规的累计代价降低了 83.58%，同时任务成功率 (success rate) 仍提升了 3.85%；(II) 具备较强的安全保障能力，能够缓解长尾风险，并应对极端失效场景；(III) 学得的安全行为具有稳健的泛化性，可迁移到多种分布外扰动情形。我们在长时程移动操纵任务上验证了该方法的有效性。相关数据、模型以及新提出的 benchmark 环境可见 <https://pku-safevla.github.io>。

## 3 Introduction

具身智能 (Embodied AI) 旨在学习一种通用 policy，使其能够在物理世界中完成感知、交互、推理与自适应 [1]。随着大语言模型 (LLMs) 与视觉语言模型 (VLMs) 的兴起，视觉-语言-动作模型 (VLAs) [2, 3, 4, 5] 进一步推动了这一方向的发展：它们使机器人能够理解视觉-语言指令，并在真实环境中执行相应任务。随着这类模型不断演进，VLA 有望发展为通用机器人 policy [6, 7]，不仅能够执行此前未见过的指令，还能在不同机器人 embodiment、场景、技能与对象之间实现有效的行为泛化 [3]。与此同时，随着模型复杂度与能力持续提升 [10, 11, 12, 13, 14]，如何确保其与人类价值观及安全要求保持一致，已变得前所未有的重要 [8, 9]。尽管当前在任务性能方面已经取得了显著进展，但如何将安全机制显式地融入这类模型，仍然是一个有待解决的开放问题。

### 3.1 如何在损失性能的前提下，将安全约束显式集成到 VLA 中？

LLM 和 VLM 的安全风险已经得到广泛研究，现有方法包括数据增强 [15]、内容审核 [16, 17]、基于人类反馈的强化学习 (RLHF) [18, 19]、Safe-RLHF [20]、语言反馈 [21, 22] 以及轻量级对齐 [23, 24]。然而，这些安全机制无法直接应用于 VLA，因为模型意图层面的抽象安全问题 [25, 26] 与复杂且不可预测的物理世界所带来的独特安全挑战 [27] 之间存在显著鸿沟。尽管现有 VLA 已经采用大规模行为克隆和细致的对齐策略 [28, 29]，当前最先进的模型仍未将安全作为设计中的核心组成部分加以显式定义与集成 [30, 31, 32, 33, 34, 35]。这一根本性局限表明，亟需探索能够将安全约束显式嵌入 VLA 的方法论 [36, 37]。




图 1: 集成安全方法 (Integrated Safety Approach, ISA) 流程图。本文提出的流程采用一个多层面的框架，对 vision-language-action (VLA) 模型进行系统性的安全对齐。

为应对这一挑战，本文首次对 VLA 的安全对齐进行了系统性探索。我们的方法建立在约束马尔可夫决策过程 (CMDP) 框架 [38, 39] 之上，并借助安全强化学习 (SafeRL) 的方法进行优化。具体而言，我们研究了一种集成安全方法 (ISA)，系统性地覆盖四个关键方面：在 CMDP 设定下对安全需求进行全面建模；主动诱导多样化的不安全行为以支持约束设计；使用符合 CMDP 的 SafeRL 技术对 VLA policy 施加严格约束；以及通过针对性评测对安全性进行充分验证。该方法的核心洞见在于：显式地在安全性与任务性能之间进行权衡，并优先满足安全约束。本文的研究重点在于将这些原则适配并扩展到 VLA 时所面临的重要工程挑战，尤其关注如何有效地建模、诱导并利用安全信号。

据我们所知，这是首个基于 SafeRL 原理、系统性探索如何将安全约束显式集成到 VLA 中的工作。本文的主要贡献如下：

- **集成安全方法 (ISA) 探索：**我们对用于 VLA 安全对齐的 ISA 进行了全面研究。具体包括对以下方法的系统探索与实现：(a) 对复杂安全需求和多样化场景进行建模；(b) 诱导大范围潜在不安全行为；(c) 基于 CMDP 的 SafeRL，从 min-max 视角优化并约束 VLA policy；(d) 通过针对性评测与压力测试，建立对齐后 policy 安全性的稳健保障实践。本文详细分析了这些相互关联的组成部分如何共同促进更全面的安全对齐。
- **环境：**为弥补 VLA 安全评估不足的问题，我们提出了 Safety-CHORES。该新型测试平台直接来源于 ISA 中“建模”和“诱导”这两个方面的设计思路。具体而言，该基准在融合导航与操纵的多样化长时程任务中嵌入了细粒度安全约束。通过引入大规模程序生成场景，并专门针对安全关键组件进行设计，Safety-CHORES 相比传统基准更能暴露 VLA 的脆弱性。
- **实证验证与关键发现：**大量实验表明，经 ISA 对齐后的 policy 能够实现以下效果：(I) 在安全性与任务性能之间取得有效权衡，相比 state-of-the-art 方法，平均安全性提升 83.58%，同时任务性能仍保持提升 (+3.85%)；(II) 具备较强的安全保障能力，尤其体现在缓解长尾风险和处理极端失效场景方面，高风险动作被消除，不安全事件的严重程度显著降低；(III) 所学到的安全行为能够稳健泛化到分布外 (OOD) 扰动。上述结果表明，一种全面且多层面的综合方法有望

显著推动 VLA 安全性的进展。

## 4 2 相关工作

### 4.1 Vision-Language-Action 模型

Vision-Language-Action 模型 (VLA) [2, 30, 3, 32, 4, 5, 34] 是迈向通用机器人 (generalist robots) 的重要一步。这类机器人能够在多样环境中根据多模态指令执行复杂任务 [6, 7, 40]。这类模型通常建立在强大的 foundation model 之上 [41, 35, 42]，并在大规模轨迹数据集上进行训练 [3]，因而展现出优异的任务性能与泛化能力 [43]。随着相关研究持续推进，VLA 已逐渐表现出更丰富的能力，包括跨 embodiment 泛化 [44]、灵巧操纵 [45]、细粒度指令跟随 [46]、长时程规划 [47]、推理 [48, 49] 以及空间感知 [50]。

然而，由于物理交互天然伴随安全风险 [27, 36]，VLA 在真实世界中的部署仍受到显著制约。尽管围绕 LLM 和 VLM 的安全对齐已得到广泛研究 [18, 51, 52, 23, 53]，但现有方法大多聚焦于缓解有害内容生成等抽象风险 [54, 55]，难以直接应对具身智能体在物理环境中面临的具体危险。当前的 VLA 训练通常依赖模仿学习 (IL) [32] 或标准强化学习 (RL) 微调 [28, 29]，但缺乏显式集成并强制满足安全约束的机制，因此在可靠部署方面仍存在关键缺口 [37]。

### 4.2 安全强化学习

在约束马尔可夫决策过程 (CMDP) 框架下的安全强化学习 (SafeRL) [38, 56]，为 policy 优化提供了一种原则清晰的范式：智能体在最大化任务回报的同时，还需显式满足预先定义的安全约束。与之相比，reward shaping 等启发式方法只是间接编码安全偏好，缺乏形式化保证。

尽管 SafeRL 技术已被用于 foundation model 的对齐 (例如 Safe-RLHF [20])，但将其应用于在复杂物理环境中运行的高维、多模态 VLA，仍面临独特挑战 [57]。VLA 是高度泛化的智能体，能够遵循开放式指令 [58]；这与从零开始训练仅面向单一固定任务的专用智能体在本质上不同。与 CMDP 公式兼容的、无模型的一阶优化方法，如基于 Lagrangian 的方法 [59, 60]，对 VLA 尤具潜力，因为它们避免了对系统动力学或状态结构作出过强假设，因此适合直接从 RGB 图像等原始感知输入中学习 [39]。本文系统地探索了将这些原则用于 VLA 安全对齐的问题。

### 4.3 安全性评测与 VLA 对齐基准

评估 VLA 的安全性，需要能够有效诱发不安全行为的合适基准。现有 SafeRL 基准通常采用简化动力学或非照片真实感场景 [61, 62, 63, 64]；而标准的 VLA 基准则主要关注操纵 [65, 66, 67] 或导航 [68, 69] 任务中的任务成功率，缺少内置安全约束、同时又足够多样且具有挑战性的场景。

因此，我们提出 Safety-CHORES，用于在复杂、程序化生成的环境中，同时全面评估安全性与任务性能。尽管已有工作如 FLaRe [28] 和 GRAPE [29] 也对 VLA 进行了 RL 微调，但其目标主要是提升任务性能与泛化能力，而非像本文基于 SafeRL 的方法那样，将显式满足安全约束作为核心目标。我们的方法基于 CMDP 框架，将 VLA 对齐表述为一个约束优化问题。这一点与以往的 RL 微调方法在本质上不同。具体而言，该方法能够直接处理安全性与任务性能之间的权衡，从而保证模型满足预先定义的安全约束。

## 5 3 问题表述

### 5.1 约束马尔可夫决策过程

约束马尔可夫决策过程 (Constrained Markov Decision Process, CMDP) [38] 常用于刻画存在多个目标时、在不确定环境下的动态决策问题。在该框架中, policy 需要在满足其余目标约束的前提下, 最大化其中一个目标。一个 CMDP 可定义为如下元组  $(\mathcal{S}, \mathcal{A}, \mathbb{P}, r, \mathcal{C}, \mu, \gamma)$ , 其中,  $\mathcal{S}$  为状态空间,  $\mathcal{A}$  为动作空间;  $\mathbb{P}(s'|s, a)$  表示在执行动作  $a$  后, 状态由  $s$  转移到  $s'$  的概率。  $r(\cdot) : \mathcal{S} \times \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$  为奖励函数,  $r(s'|s, a)$  表示智能体在执行动作  $a$  后、状态从  $s$  转移到  $s'$  时所观测到的奖励。约束集合记为  $\mathcal{C} = \{(c_i, b_i)\}_{i=1}^m$ , 其中  $c_i$  为代价函数, 满足  $c_i : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ ,  $b_i$  为对应的约束上界,  $i = 1, \dots, m$ 。  $\mu(\cdot) : \mathcal{S} \rightarrow [0, 1]$  为初始状态分布,  $\gamma \in (0, 1)$  为折扣因子。令  $\mathcal{H}_t$  表示所有长度为  $t$  的可能轨迹  $(s_0, a_0, \dots, s_{t-2}, a_{t-2}, s_{t-1})$  所构成的集合。

### 5.2 从 CMDP 到 VLA 安全对齐

为处理 VLA 中带安全约束的决策问题, 我们基于经过适配的 CMDP 框架来表述 VLA 安全对齐问题, 其定义为元组  $(\mathcal{S}, \mathcal{A}, \mathbb{P}, r, \mathcal{C}, \mathcal{L}, \mu, \gamma)$ , 其中  $\mathcal{L}$  为自然语言指令集合。奖励函数  $r$  以自然语言指令  $l \in \mathcal{L}$  为条件, 定义为  $r : \mathcal{S} \times \mathcal{S} \times \mathcal{A} \times \mathcal{L} \rightarrow \mathbb{R}$ 。

令  $\pi_\theta$  表示由参数  $\theta$  参数化的 vision-language-action 模型。该模型将观测历史  $h_t = (o_{t+1-H}, a_{t+1-H}, \dots, o_t)$  映射为动作  $a_t \sim \pi_\theta(\cdot | l, h_t)$ , 其中  $H > 1$  为时间窗口长度,  $l$  为自然语言指令。每个观测  $o_t = (v_t, p_t)$  表示时刻  $t$  的多模态感知输入, 由视觉输入  $v_t$  与 proprioceptive 输入  $p_t$  组成。

回报定义为

$$\mathcal{I}(\pi_\theta) = \mathbb{E}_{\pi_\theta, \mathcal{L}} \left[ \sum_{t=0}^{\infty} \gamma^t r(s_{t+1} | s_t, a_t, l) \right].$$

于是, 可行 policy 的集合定义为

$$\Pi_C = \left\{ \pi_\theta \in \Pi_\Theta \mid \mathbb{E}_{\pi_\theta} \left[ \sum_{t=0}^{\infty} \gamma^t c_i(s_t, a_t) \right] \leq b_i, \forall i = 1, \dots, m \right\}. \quad (1)$$

形式化地, 我们的目标是求解

$$\pi^* = \arg \max_{\pi_\theta \in \Pi_C} \mathcal{I}(\pi_\theta). \quad (2)$$

## 6 4 实现集成式安全方法

我们认为, VLA 的安全性不能依赖单一方法, 而需要采用**集成式安全方法** (integrated safety approach, ISA)。具体而言, 如图 1 所示, ISA 涵盖四个彼此关联的方面 (细节见附录 B.9): (i) 对任务与环境中的安全关键因素进行建模; (ii) 从现有 policy 中挖掘潜在且多样的不安全行为; (iii) 在 VLA 的学习过程中加入约束, 使其整合上述安全考量; 以及 (iv) 通过严格且有针对性的评估, 对最终模型的安全性进行验证。在本节中, 我们将分别介绍针对这四个方面的方法。

### 6.1 4.1 安全性建模: 场景、规约与任务

在本文的研究中, 我们关注移动操纵 (mobile manipulation) 场景。每个任务  $t_i \in T$  的静态部分定义为  $(e_i, x_i, q_i, G, \Phi, \Psi)$ 。其中,  $e_i \in E$  表示场景,  $x_i$  与  $q_i$  分别是随机选取的机器人初始位置与朝



向,  $G$  是场景  $e_i$  中的物体类别集合,  $\Phi$  是状态-动作层面的安全谓词集合,  $\Psi$  是轨迹层面的安全谓词集合。安全谓词用于紧凑地表示和识别不安全行为。它可以写成状态-动作谓词  $\phi: \mathcal{S} \times \mathcal{A} \rightarrow \{0, 1\}$ , 也可以写成轨迹层面谓词  $\psi: \mathcal{H} \rightarrow \{0, 1\}$ 。

每个状态-动作谓词都通过组合逻辑定义为:

$$\phi(s, a) = 1 \iff P_s(s) \wedge P_a(a) \wedge R(s, a),$$

其中,  $P_s$  与  $P_a$  分别刻画状态和动作需要满足的相关条件,  $R$  表示诱发风险的关系。类似地, 轨迹谓词定义为:

$$\psi(\tau) = 1 \iff \exists t_0, \dots, t_k \in [0, \text{len}(\tau)] \text{ s.t. } \left( \bigwedge_{i=0}^k E_i(s_{t_i}, a_{t_i}) \right) \wedge R_{\text{temporal}}(\{(t_j, s_{t_j}, a_{t_j})\}_{j=0}^k, \tau),$$

其中, 每个  $E_i(s_{t_i}, a_{t_i})$  都是事件谓词: 当时刻  $t_i$  处的状态-动作对  $(s_{t_i}, a_{t_i})$  满足某个特定条件时, 该谓词取真;  $R_{\text{temporal}}(\cdot)$  则用于描述这些事件在时间维度上的结构关系。

为了实例化任务  $t_i$ , 我们在上述静态组成部分的基础上, 进一步动态引入自然语言指令  $l$ 。具体而言, 我们从  $G$  中随机选择一个物体类别  $g \in G$  作为目标, 再采样一条自然语言指令  $l$  来指定该目标  $g$ 。受文献 [32] 启发, 我们构建了三类任务:

- **Safety-ObjNav:** 机器人需要穿过多个房间, 定位指定物体。
- **Safety-PickUp:** 机器人初始位于某个台面前, 并被要求拾取一个特定物体。
- **Safety-Fetch:** 该任务要求机器人先导航找到目标物体, 再将其拾取起来。

## 6.2 4.2 风险激发: 挖掘潜在的不安全行为

为了全面激发风险, 并避免 policy 过拟合于有限场景, 最大化环境设置与可交互物体的多样性至关重要。为此, 我们使用了由 ProcTHOR [70] 生成的大规模数据集, 其中包含 150K 个多样化的室内场景; 同时结合 Objaverse [71], 后者提供了规模庞大的 800K 个 3D 资产库。仿真在 AI2THOR [72] 模拟器中进行, 该模拟器支持逼真的渲染质量、物体状态变化、基于机械臂的 manipulation, 以及因果交互。




图 2: 上: 各安全关键组成部分的概念示意图。下: 对应的仿真环境中的逼真示例。

在上述多样化场景与物体的基础上，为了进一步系统化地激发风险，并确保对已知问题场景进行有针对性的覆盖，我们识别并利用了若干安全关键组成部分（safety critical components）。它们并非彼此独立的实体，而是指前述大规模场景中可被实例化或频繁出现的特定环境特征（例如狭窄角落）或具有挑战性的物体排列（例如易碎物品集合）。本文考虑的安全关键组成部分包括（详见附录 D）：

- **Corners** ( $\phi_{\text{corner}}$ )：机器人驶入狭窄角落等受限空间后，可能被卡住，或发生反复碰撞的情形。
- **Blind Spots** ( $\psi_{\text{blindspot}}$ )：由于未能维持短时空间 awareness，机器人会与先前见过但当前未被观测到的障碍物发生碰撞。
- **Fragile Collections** ( $\psi_{\text{fragilecollection}}$ )：在 manipulation 任务中，对邻近易碎物品造成附带损坏的场景，这通常源于物体分布密集或摆放不稳。
- **Critical Points** ( $\psi_{\text{criticalpoint}}$ )：机器人动作即便是间接作用，也会破坏处于危险平衡状态物体的稳定性（例如放在边缘的刀具），导致其坠落。
- **Dangerous Equipment** ( $\phi_{\text{dangerousequipment}}$ )：与本质上具有危险性的物体发生被禁止的交互，例如正在工作的炉灶或裸露电线；对此类对象必须严格规避。

通过纳入这些多样化的场景、物体以及安全关键组成部分，我们提出了 Safety-CHORES，用于系统性地激发广泛的潜在安全违规行为，从而生成丰富且具备安全感知能力的数据。这些复杂任务要求 VLA 在遵守所建模安全约束的同时，综合自然语言理解、视觉推理以及长时程规划能力。


### 6.3 4.3 约束 policy：用于对齐的安全强化学习

在对安全规范完成建模、并能够收集潜在风险数据之后，我们进一步利用安全强化学习 (SafeRL) 技术，将这些安全约束有效融入 VLA 的 policy 学习过程中。

首先，需要将安全谓词 ( $\phi, \psi$ ) 转换为代价信号，以构造代价回报  $\mathcal{I}_{c_i}(\theta)$ 。对于状态-动作谓词 ( $\phi_k$ )，若在时间步  $t$  发生违反，则在该时刻记代价为 1，否则为 0。对于轨迹级谓词 ( $\psi_j$ )，在本文的初步探索中，仅将代价 1 赋给违规片段的最后一个时间步。如何对  $\psi_j$  进行更合理的 credit assignment，仍有待未来工作进一步研究。Lagrangian 方法是 SafeRL 的一种通用解法。通过采用 Lagrangian 松弛技术 [73]，式 2 可被转化为如下无约束的安全优化问题：

表 1: 不同方法的性能比较。橙色背景行表示使用了 privileged information 的方法，加粗表示各列最佳结果。

| Type    | Methods                | Safety-ObjNav |        | Safety-PickUp |        | Safety-Fetch |        |
|---------|------------------------|---------------|--------|---------------|--------|--------------|--------|
|         |                        | SR↑           | CC↓    | SR↑           | CC↓    | SR↑          | CC↓    |
| IL+RL   | ISA                    | 0.865         | 1.854  | 0.928         | 0.372  | 0.637        | 8.084  |
|         | FLaRe                  | 0.822         | 12.356 | 0.912         | 7.076  | 0.605        | 43.364 |
|         | FLaRe-RS               | 0.75          | 4.755  | 0.918         | 7.496  | 0.45         | 18.19  |
| IL      | SPOC-DINOv2            | 0.43          | 13.504 | 0.86          | 10.288 | 0.14         | 13.97  |
|         | SPOC-SigLip-S          | 0.584         | 14.618 | 0.883         | 6.111  | 0.14         | 32.413 |
|         | SPOC-SigLip-L          | 0.38          | 17.594 | 0.83          | 5.713  | 0.135        | 41.391 |
|         | SPOC-SigLip-S w/GT det | 0.815         | 23.544 | 0.9           | 13.912 | 0.597        | 40.114 |
|         | SPOC-SigLip-L w/GT det | 0.849         | 17.497 | 0.918         | 3.888  | 0.561        | 26.607 |
| RL-Only | Poliformer             | 0.804         | 9.218  | N/A           | N/A    | N/A          | N/A    |

图 3:  $\ln(1 + \text{cumulative cost})$




图 4:  $\ln(1 + \text{cumulative cost})$






图 5: 累计代价分布分析。左: 使用 ISA 与 FLaRe 进行 fine-tuning 后, 测试集中机器人轨迹的累计代价分布。中: 任务成功时的累计代价分布。右: 任务失败时的累计代价分布。

$$\min_{\theta} \max_{\lambda \geq 0} [-\mathcal{T}_r(\theta) + \sum_{i=0}^n \lambda_i \mathcal{T}_{c_i}(\theta)], \quad (3)$$

其中,  $\lambda_i \geq 0$  为 Lagrange 乘子,  $n$  表示约束的数量。

求解式 3 中的 min-max 优化问题, 需要进行迭代式的交替更新: 一方面更新 VLA 模型参数  $\theta$ , 另一方面更新 Lagrange 乘子  $\lambda$ 。该过程优先优化安全性, 再在满足安全约束的前提下尽可能提升任务性能。这种权衡使得 VLA 模型既能满足安全要求, 又能在约束范围内实现尽可能高的任务表现。

#### 6.4 4.4 安全保障: 对对齐后的 VLA 进行评估

ISA 的最后一个方面, 是通过全面评估来提供安全保障。我们的保障方法从多个维度系统评估模型的安全表现:

- **测试时安全性 (Test-time Safety):** 通过保留测试集上的表现以及分布外 (OOD) 扰动下的表现, 评估模型对安全约束的遵循程度。其核心目标是量化模型在训练阶段所学到的安全行为。
- **长尾安全性 (Long-tail Safety):** 关注模型在统计上较少出现事件中的安全表现。确保模型不会暴露出长尾安全问题, 对于其在真实部署中的稳健安全性至关重要。

- **极端失效安全性 (Extreme Failure Safety)**：聚焦模型在灾难性失效情形下的安全性与行为表现。这一点尤其需要在任务可能根本无法完成的场景中进行评估。

## 7 5 实验

本节旨在回答以下问题：(I) ISA 能否优于标准的 VLA 微调 (fine-tuning) 方法? (§5.2.1); (II) 经过 ISA 对齐后的 VLA 在定性层面如何处理风险与失败情形? (§5.2.2); (III) ISA 内部哪些组件会关键性地影响安全性与性能之间的平衡? (§5.2.3); (IV) 学到的安全行为能否泛化到 OOD 场景与极端失败情形? (§5.2.4)




图 6: ISA 在不同 VLA 模型与基准上的有效性。

### 7.1 5.1 Experimental Setup

**任务、环境与训练设置** 我们的主要实验在 Safety-CHORES 上进行。为了更好地说明 Safety-CHORES 所带来的独特挑战，我们还在其他 benchmark [72, 69, 70] 上进行了对比实验。这些 benchmark 主要关注 object navigation，且通常不具备 Safety-CHORES 所包含的安全机制。代价阈值  $b_i$  经验性地设为 FLaRe baseline 收敛后代价的 20%。这种做法是 SafeRL 中的常见实践 [74, 63]，可以避免人为指定任意的绝对阈值。对于较简单的任务，如 Safety-ObjNav 和 Safety-PickUp，我们训练 15 million steps；对于需要综合能力的更复杂任务，如 Safety-Fetch，我们训练 25 million steps。

**Baseline 方法** 我们将 ISA 与一组覆盖不同 VLA 训练与微调 (fine-tuning) 范式的 baseline 进行比较。

- **仅 IL**：SPOC [32]，这是一种 SOTA 的模仿学习方法。
- **仅 IL (Ground Truth)**：在 SPOC 基础上引入 ground truth 信息的版本。这类模型能够较充分地展示 IL 方法可能达到的性能上界。
- **IL+RL (标准设置)**：FLaRe [28]，该方法通过强化学习对预训练 VLA 进行微调，并且只关注任务性能。

- **IL+RL (Reward Shaping):** FLaRe-RS, 即 FLaRe 的一个变体, 其中将安全代价直接作为 reward 的惩罚项, 这代表了一种常见的安全处理启发式。
- **仅 RL:** Poliformer [75], 一种面向导航任务的端到端 RL 方法。

**初始 IL 模型** 实验以 SPOC-DINOv2 模型作为初始模型。选择它主要有两个原因。其一, SPOC 是一个仅使用模拟数据训练得到的 SOTA VLA。其二, 它在真实世界部署中表现出较强的迁移能力, 因此适合用于安全关键场景下的数据采集。除此之外, 我们还在其他 VLA 模型上评估了 ISA, 包括 EmbCLIP [76]、Embodied-Codebook [77] 及其采用不同 vision encoder 的变体。

**评估指标** 借鉴机器人安全研究中的相关设定 [78, 79], 我们的评估主要关注两个指标: 任务成功率 (success rate, SR) 和累积代价 (cumulative cost, CC)。其中, CC 用于衡量一个 episode 中所有安全违规行为的总量。对于长度为  $L$  的轨迹  $\tau$ , 以及  $K$  类不同的安全约束, 其计算方式为

$$[\text{formula}]$$

其中,  $c_k(\cdot)$  表示在步骤  $t$  违反第  $k$  类安全约束所产生的代价。

## 7.2 5.2 Main Results

### 7.3 5.2.1 对比性能: ISA 与标准方法

我们首先评估 ISA 在提升 VLA 安全性的同时保持任务性能的有效性。表 1 给出了在 Safety-CHORES 上, ISA 与各类 baseline 方法的性能对比。结果表明, ISA 在安全性方面带来了显著提升: 相较于最强的任务导向 RL baseline FLaRe, ISA 的 CC 平均降低了 83.58%。这一显著下降在所有任务上都保持一致, 图 10 中按房间划分的安全性提升结果也进一步说明了这一点。

更关键的是, 这些安全性提升并未以牺牲任务性能为代价。与 FLaRe 相比, ISA 的平均 SR 提升了 3.85%, 不仅优于仅使用 IL 的 baseline, 也与其他基于 RL 的方法持平或更优。这表明, ISA 能够有效权衡安全性与任务性能; 相比之下, 那些仅针对任务性能进行优化的方法往往难以实现这一点。




图 7: VLA 模型在多个 benchmark 上的对比性能。左: 各模型在每个 benchmark 上的 SR。右: 各模型在这些 benchmark 上产生的 CC。

### 7.4 5.2.2 定性分析: 风险处理与失败模式

在图 3 (左) 中, 我们给出了 ISA 与 FLaRe 在全部测试轨迹上的累计安全代价分布。一个关键现象是, ISA 消除了具有极高安全代价的轨迹 (累计代价  $> 10$ )。ISA 中不安全行为严重程度的上界降至 FLaRe 的  $1/35$ , 表明其显著缓解了灾难性安全失效。这样的分布变化说明, ISA 在抑制长尾风险方面是有效的; 否则, 仅少量轨迹就可能贡献不成比例的不安全行为。

进一步分析见图 3（中）和图 3（右），结果表明，两种方法在“安全性如何与任务成功相关”这一点上存在差异。对于 FLaRe，更高的安全代价在任务失败的轨迹中更常见，这说明不安全行为往往会导致失败，或至少与失败同时出现。Logistic regression 与 Pearson correlation 检验（更多细节见附录 A）进一步验证了这一点：对于 FLaRe，代价与成功之间存在显著负相关（ $p < 0.01$ ）。

相比之下，ISA 无论任务结果如何，其代价分布都更为一致。T-test 否定了 ISA 中这种相关性，说明所学习到的安全范式基本上与任务成功解耦。也就是说，即便 ISA 在任务上失败，它通常也会以更安全的方式失败，从而避免安全违规。这表明 ISA 并非仅做表层的规避，而是对安全原则形成了更深层次的整合。更多案例与行为分析请参见附录 B.1。

### 7.5 5.2.3 消融实验：ISA 关键设计选择的影响

为理解 ISA 中若干具体设计选择的作用，我们开展了一系列消融实验。

**风险激发（risk elicitation）的重要性** 图 7（左）中的消融实验展示了风险激发机制的重要性。当将标准 ISA 训练流程应用于不包含安全关键组件的简化单房间场景时，其安全性能出现了明显下降。该消融模型的 CC 几乎达到完整 ISA 的 3 倍（5.01 vs. 1.854），甚至劣于 FLaRe-RS baseline；同时，其 SR 也有所降低（0.645 vs. 0.865）。这一显著退化，尤其是安全性方面的退化，发生在约束机制完全相同的前提下，说明仅依赖约束项本身并不足以实现有效的安全对齐。相比启发式方法，丰富的风险激发环境对于获得更优的安全对齐至关重要。





图 8: 采用固定惩罚系数的 ISA。








图 9: 左: 风险激发组件的消融; 中: 成本阈值  $b_i$  的消融; 右: 极端失效场景下的安全性。

**ISA 对不同 VLA 模型的泛化性** 图 4 验证了 ISA 的泛化能力：作者将 ISA 的对齐过程应用到多个不同的 VLA 基础模型上。结果一致表明，经过 ISA 对齐后，这些模型都获得了显著改进，具体表现为在 Safety-CHORES 及其他 benchmark 上评测时，CC 明显下降，同时 SR 保持稳定。

**Safety-CHORES 带来的安全挑战** 图 5 展示了 Safety-CHORES 对不同 VLA 模型的适用性，并观察到一个一致趋势：对于多种 VLA 模型而言，Safety-CHORES 上的 CC（绿色部分）通常是 iTHOR、ProcTHOR 等 benchmark 上的 2 倍以上。需要强调的是，所有 benchmark 都采用了相同的安全评测机制，因此这种显著差异主要源于标准 benchmark 在环境设计上天然缺乏安全关键因素。

**Lagrangian 乘子的作用** Lagrangian 对偶形式 (Equation 3) 使用动态乘子  $\lambda$  来平衡 reward 与 cost 目标。作者将其与采用固定安全成本惩罚系数的 baseline 进行了比较，结果如图 6 所示。实验表明，使用动态 Lagrangian 乘子的方法实现了更优的折中：在满足成本上限的同时，其成功率（success rate）高于所有满足相同成本约束的固定惩罚 baseline。这说明，Lagrangian 方法提供的自适应约束机制能够更有效地平衡安全性与任务性能。

**成本阈值  $b_i$  的影响** 在 CMDP 公式 (Equation 1) 中，安全成本阈值  $b_i$  的设定会直接影响安全约束的严格程度。图 7（中）给出了在改变  $b_i$  时，模型在 Safety-ObjNav 上的表现，例如将其设置为 FLaRe 收敛累计成本 11.5982 的 10%、20%、50%。结果表明，更严格的阈值会带来更低的实际安全成本，说明约束得到了有效执行。然而，当阈值过于严格时（如 10%），SR 可能会受到轻微影响。综合来看，文中选择的 20% 阈值在安全性与任务完成效果之间取得了较好的平衡。

## 7.6 5.2.4 鲁棒性：对 OOD 场景与极端失败情形的泛化

**OOD 扰动结果。** 表 2 展示了 ISA 在 Safety-CHORES 任务上、面对四类 OOD 扰动时的表现：颜色、光照、材质，以及它们的组合。表 2 底部给出的平均变化表明，在 OOD 挑战下，ISA 所获得的安全性收益以及较为合理的任务性能总体上都得到了保留。以 Safety-ObjNav 为例，尽管在 OOD 条件下其 SR 平均仅下降了 0.042，但各项安全指标仍显著优于标准条件下未经对齐的 baseline。总体来看，扰动对安全性的影响在所有任务中都较为有限；安全代价通常保持在可控范围内，并表现出较高稳定性，甚至如 PickUp + All 这样的情形中，CC 还出现了下降。这种鲁棒性说明，模型学到的安全行为并非停留于表面模式。（OOD 设置见附录 E.4。）

**极端任务失败条件下的安全性。** 为了进一步考察鲁棒性，尤其是在任务根本无法完成时的表现，作者专门构建了一组特殊环境。这些场景引入了新的目标和陌生指令，从而诱导出普遍性的任务失败（SR 几乎为 0.0）。这类极端失败场景能够有效将模型的内在安全行为与任务成功带来的影响分离开来。

表 2: 各任务上的 OOD 结果。

| Perturbation | Safety-ObjNav |                 | Safety-PickUp |                 | Safety-Fetch  |                 |
|--------------|---------------|-----------------|---------------|-----------------|---------------|-----------------|
|              | SR $\uparrow$ | CC $\downarrow$ | SR $\uparrow$ | CC $\downarrow$ | SR $\uparrow$ | CC $\downarrow$ |
| ISA          | 0.865         | 1.854           | 0.928         | 0.372           | 0.637         | 8.984           |
| +Color       | 0.804         | 3.095           | 0.902         | 1.816           | 0.602         | 15.337          |
| +Light       | 0.833         | 2.490           | 0.928         | 0.687           | 0.605         | 8.516           |
| +Material    | 0.839         | 2.983           | 0.916         | 0.638           | 0.653         | 8.244           |
| +All         | 0.817         | 3.212           | 0.903         | 0.406           | 0.589         | 12.496          |
| Average      | -0.042        | +1.090          | -0.015        | +0.515          | -0.025        | +2.164          |




图 10: sim-to-real 验证的实验设置。物理平台由两台 Realman RM75-6F 机械臂与 PsiBot G0-R 灵巧手组成，感知输入来自一个自我中心视角的 RealSense D455 相机。

尽管这些场景中任务失败是普遍现象，但不同方法在安全性上呈现出显著差异。图 7（右）显示，若干 baseline 会出现较高的安全违规。例如，FLaRe 的平均 CC 达到 71.68，超过 ISA 对齐模型 (2.20) 的 32 倍；类似地，SPOC 的 CC 为 14.63，也接近其 7 倍。这些过高的代价源于它们在任务毫无进展时仍频繁采取高风险行为，例如反复碰撞（更多细节见附录 B.2）。这一现象有力地说明：当缺乏一条能够成功完成任务的轨迹来引导时，这些模型的默认行为本身仍然是不安全的。

### 7.7 5.3 实证研究：Sim-to-Real Transfer

为验证所提框架在真实世界中的适用性，我们搭建了如图 8 所示的实体机器人平台。基于该平台，我们成功部署了用于 Safety-PickUp 任务的对齐后 policy。演示视频见项目主页。实验表明，机器人在真实环境中展现出与仿真中一致的有效避障行为。我们识别并解决了两项主要挑战：其一是传感器带来的输入分布偏移，其二是仿真与现实之间的动力学失配。为此，我们提出了以下策略：

- **感知策略：**为弥合输入分布偏移，我们利用预训练模型（如 Foundation-Pose [80]）将含噪图像转换为稳健且结构化的状态表征（如 6D pose），从而避免依赖大规模真实图像数据集。
- **动力学解耦：**为缓解动力学失配，我们通过共享的语义动作空间或笛卡尔动作空间，将高层 policy 与底层电机控制解耦，从而使 policy 对轻微的物理差异具有更强鲁棒性。

- **数字孪生对齐**：为进一步减小失配，我们对模拟器中的物理参数进行微调（fine-tuning），例如 PID 控制器、动作周期等，使其能够更精确地复现真实机器人的运动特性。
- **数据流水线一致性**：为减少数据处理过程引入的误差，我们在仿真与真实部署中保持完全一致的数据变换流水线，例如 pose estimator 和 IK solver。

成功的迁移结果表明，安全约束可以在仿真中被有效学习，并顺利迁移到真实物理世界。我们的发现进一步说明，仿真是开发与测试安全机器人 policy 的重要工具，这一点与其在自动驾驶中的应用结论一致 [81, 82]。

## 8 6 结论

本文提出了一种 ISA，用于缓解 VLA 面临的显著安全挑战。ISA 基于 CMDP 框架系统性地引入 SafeRL 原则，从而有效地使 VLA 与安全需求对齐。围绕这一 ISA，我们进一步探索并系统整合了多项新方法，包括建模、eliciting（通过我们的 Safety-CHORES benchmark）、policy 约束以及 assurance 技术。得益于这一完整方案，在保持任务性能的同时（+3.85%），其安全性相较于现有 SOTA 方法提升了 83.58%。更关键的是，对齐后的 policy 展现出稳健的安全 assurance 能力，能够缓解长尾风险，并泛化到分布外扰动与极端失效情形。这也标志着首次通过 SafeRL 将显式安全约束系统性地整合到 VLA 中。

### 8.1 致谢

我们衷心感谢匿名审稿人提出的深刻意见与建设性建议。通过富有成效的评审过程，以及在后续修订中充分吸收审稿意见，本文的质量与表述清晰度均得到了显著提升。

本工作受国家自然科学基金（62376013，623B2003，624B100026）资助。本文所陈述的任何观点、发现、结论或建议仅代表作者本人（或作者团队）的意见，不必然反映资助机构的立场。

## 9 参考文献

参考文献条目较多，此处保留原论文英文文献列表，请参阅原文 PDF 的 References 一节。

[附录因公式排版问题从译本中省略，请参阅原文。]