

1 GR-RL: 面向长时程机器人操纵的灵巧与精确方法

ByteDance Seed

贡献与致谢部分给出了完整作者列表。

摘要

我们提出 GR-RL, 一种机器人学习框架, 可将通用型 Vision-Language-Action (VLA) policy 转化为适用于长时程灵巧操纵的高能力专用 policy。现有 VLA policy 的一个核心前提, 是默认人类 demonstration 具有最优性。然而, 我们认为, 在高度灵巧且要求高精度的操纵任务中, 人类 demonstration 往往存在噪声, 并非最优。为此, GR-RL 提出了一条多阶段训练流水线, 通过 reinforcement learning 对 demonstration 进行筛选、增强与强化。

首先, GR-RL 学习一个视觉-语言条件下的任务进度函数, 用其过滤 demonstration 轨迹, 只保留那些对任务进度有正向贡献的状态转移。具体而言, 我们表明, 直接在稀疏奖励下应用 offline RL, 得到的 Q-value 可以作为一种鲁棒的进度函数。随后, 我们引入形态对称性增强 (morphological symmetry augmentation), 显著提升了 GR-RL 的泛化能力与性能。最后, 为了使 VLA policy 在高精度控制场景下与其部署时的行为更好对齐, 我们通过学习一个潜空间噪声预测器来执行 online RL。

借助这一训练流水线, 据我们所知, GR-RL 是首个能够自主完成鞋带穿孔系鞋任务的学习型 policy: 机器人需要将鞋带依次穿过多个鞋眼, 任务成功率达到 83.3%。该任务同时要求长时程推理、毫米级精度以及对柔性物体的顺应性交互。我们希望, GR-RL 能为通用机器人基础模型向真实世界中可靠的专用专家模型演化, 提供关键一步。

联系方式: xiao.ma@bytedance.com 项目主页: https://seed.bytedance.com/gr_rl

2 1 引言

大规模 Vision-Language-Action (VLA) 模型的兴起, 迅速推动了通用机器人智能体这一目标的发展: 机器人能够在视觉观测与自由形式自然语言指令的条件下, 执行广泛多样的任务。近期系统 [4, 7–11, 56] 已经在物体、环境以及语义概念层面展现出令人印象深刻的泛化能力, 这表明机器人领域同样有望受益于曾推动 vision-language models 快速进步的 scaling laws。

然而, “通用”并不等同于“可靠”。当前的 VLA policy 在真实部署中, 仍然在两个根本方面存在明显不足: (1) 精密灵巧性: 对于可变形物体的毫米级控制仍未解决; (2) 长时程鲁棒性: 误差会随着操作步骤不断累积, 而当任务同时要求高精度与灵巧操纵时, 这一问题会更加严重。

以穿鞋带任务为例: (1) 机器人需要具备足够的灵巧性, 才能处理鞋带和鞋子这两类可变形对象; (2) 机器人需要达到毫米级控制精度, 才能将鞋带准确穿入鞋孔; (3) 机器人还需要具备长时程 manipulation 能力, 以应对多样且不可预期的情形。

经典方法通常通过带有预定义动作原语和手工设计模式的运动规划来完成鞋带穿引任务 [39–41]。因此, 如何泛化到未见过的构型、如何从失败中恢复, 以及如何获得其他灵巧操作能力, 仍然是一个开放问题。若直接将 behavior cloning 朴素扩展到该任务, 往往只能得到次优且能力有限的鞋带穿引技能 [42]。




图 1: GR-RL 通过一个多阶段训练流水线, 在鞋带穿引任务上实现了长时程、灵巧且高精度的 manipulation。该流水线包括: 1) 结合已学习任务进度的离线筛选式 behavior cloning; 2) 简单但有效的动作增强; 3) 在线 reinforcement learning。

我们的出发点是 GR-3 [12]: 一个利用互联网数据、机器人轨迹以及人类 demonstration 训练得到的大规模 VLA policy。尽管 GR-3 具备很强的泛化能力, 但一旦任务对精度、灵巧性和长时程鲁棒性提出要求, 它仍然会失败。我们观察到, 其中存在两个关键瓶颈: (1) 人类 demonstration 本身是次优的; (2) demonstration 与 inference 之间存在不匹配。

在极高精度、极高灵巧性的操纵场景下, 人类示范者往往会放慢动作、产生犹豫, 并向 policy 中引入带噪声的次优 demonstration。此外, 在标准离线训练过程中, VLA policy 通常通过预测固定长度的 action chunks 来模仿人类示范者; 这些 action chunks 由人类 demonstration 上的滑动窗口构造得到 [14, 65]。然而, 为了实现平滑的 inference 与控制, 系统通常还会对预测轨迹进行后处理平滑, 例如 temporal ensembling [65]、异步 receding horizon control [8, 14, 25] 以及其他控制层面的优化。这些系统级优化方法对于学习式 policy 的平稳执行是必要的, 但也不可避免地导致了模型训练与 inference 之间的不匹配。

3 1 引言 (第二部分)

我们提出了用于长时程灵巧且高精度操纵的 GR-RL。GR-RL 采用一个多阶段、由强化学习增强的训练流水线, 用于筛选、增强并强化那些次优且与任务存在失配的人类 demonstration。首先, 我们并不直接在整个人类 demonstration 数据集上执行 behavior cloning, 而是通过克隆经过筛选的轨迹来初始化基础的 GR-RL VLA policy。具体而言, 我们利用离线强化学习 (offline RL) [17], 在成功轨迹与失败轨迹上共同训练一个 critic 模型。由于奖励仅在 episode 结束时以稀疏形式给出, 预

测得到的 value 会自然反映任务的完成进度；基于这一点，我们进一步只保留那些对任务进展有正向贡献的 transition，并丢弃其余部分。我们采用 distributional critic，并观察到在离线稀疏奖励场景下，它能够带来更加稳健的性能表现。

随后，在离线预训练得到的 checkpoint 基础上，我们继续进行在线强化学习，以进一步探索并修复基础 policy 的失败模式。具体来说，我们通过学习将 denoising 过程引导至高回报区域来实现这一点 [59]。最后，我们设计了一种简单但有效的机器人动作增强方法：对机器人的动作与观测同时进行镜像变换，并配套使用翻转后的文本描述。该方案显著提升了 policy 的整体成功率（success rate）与泛化能力。




图 2: GR-RL 模型。GR-RL 采用 Mixture-of-Transformer (MoT) 架构，并通过 flow-matching 目标在机器人 vision-language-action 轨迹上进行联合训练，同时结合 distributional reinforcement learning 中的 Temporal-Difference (TD) 误差进行优化。

据我们所知，GR-RL 是首个能够以学习方式完成“将鞋带依次穿过多个鞋眼”这一任务的模型，并取得了整体 83.3% 的成功率。我们希望，GR-RL 能为通用机器人基础模型走向专门化，并最终适用于更具挑战性的真实世界场景，提供关键一步。

4 2 GR-RL 模型

GR-RL 采用 Mixture-of-Transformer 架构，由一个 vision-language-action (VLA) 模型 π_θ 和一个多任务 critic Q_ϕ 组成，总参数量为 5B。

Policy. π 通过生成长度为 k 的 action chunk $\mathbf{a}_t = a_{t:t+k}$ 来控制带移动底座的双臂机器人。该 action chunk 以输入语言指令 l 、观测 $\mathbf{o}_t$ 和机器人状态 $\mathbf{s}_t$ 为条件，即

$$\mathbf{a}_t = \pi_\theta(l, \mathbf{o}_t, \mathbf{s}_t).$$

沿用 GR-3 [12] 的架构设计，GR-RL 使用 Qwen2.5-VL-3B-Instruct [3] 作为 Vision-Language Model (VLM) backbone，并采用一个基于 flow matching 目标 [8,34,36] 训练的 action diffusion transformer

(DiT) 来预测 action chunks a_t 。具体而言，我们遵循 GR-3 的做法，仅使用 VLM 后半部分层的 KV cache，以实现快速推理。

Critic. 与 policy π_θ 类似， $Q_\phi(\mathbf{o}_t, l, \mathbf{s}_t, \mathbf{a}_t)$ 也是一个 causal transformer，用于评估每个动作。具体来说，我们遵循 Q-chunking [29,31,52] 的设置，对每个 action chunk $\mathbf{a}_t$ 预测一段 Q-value chunk，并采用 distributional reinforcement learning [5,16,23,52]。不同于无界的、基于回归的 policy 评估方式，distributional critic 将 value 视为具有上下界的离散分布。这种建模方式能够自然刻画真实轨迹中的不确定性。在稀疏奖励设定下，distributional critic 相比非 distributional 方法具有更强的鲁棒性。将上界设为 1、下界设为 0 后，所学习到的 critic 便能够自然反映任务进度，如图 3 所示。

5 3 Training Recipe

人类 demonstration 往往并非最优，且带有噪声。对于长时程、灵巧且高精度的操纵任务，人类示范者常常会出现犹豫、失误，以及以不一致行为完成任务的情况。此外，推理阶段的优化策略，例如 whole-body receding horizon control 和 temporal ensembling [14, 65]，会进一步引入训练与部署之间的分布失配，从而加剧次优 demonstration 的负面影响。

为仅基于人类 demonstration 实现灵巧而精确的机器人操纵，我们提出了一条强化学习增强的训练流程。为避免 policy 在监督学习阶段记忆这些次优行为，我们首先利用 offline RL 学习一个任务进度模型，并据此过滤掉有害数据（第 3.1 节）。随后，我们利用双臂操纵中的对称性对 demonstration 进行增强，以提升 offline policy 的鲁棒性（第 3.2 节）。最后，我们进行在线强化学习，使模型能够在 closed-loop 中通过 trial-and-error 持续学习，从而缓解训练与部署之间的失配，并进一步提升整体性能（第 3.3 节）。

5.1 3.1 使用学习得到的任务进度评估器进行数据过滤

对于鞋带穿孔这类涉及可变形物体的高精度操纵任务，采集完全无瑕疵的 demonstration 极其困难。即便是经验丰富的 teleoperator 所采集的轨迹，也常常包含次优片段，例如错误尝试、短暂停顿等。如果直接模仿全部数据，就会将这些带噪声的多峰动作一并引入训练过程，最终得到性能欠佳的 policy。另一方面，人工标注这些次优片段本身并不容易，而且还可能引入更多带有主观性的噪声先验。

为识别并过滤次优动作，我们提出使用 offline RL 学习一个任务进度模型。具体而言，我们采用 TD3+BC [17] 训练 critic。稀疏奖励定义为

$$r(\mathbf{o}_t, l, \mathbf{s}_t, \mathbf{a}_t) = [\text{formula}] \quad (1)$$

其中， $\mathbb{I}(\cdot)$ 是用于判断轨迹 τ 是否成功的指示函数， T 表示轨迹长度， γ 为折扣因子。由于采集得到的大多数轨迹最终都是成功的，我们在每条 demonstration 中额外标注 retry keyframe，并以 hindsight 的方式构造更多失败轨迹 [1]。设在一条成功轨迹 $\tau_{0:T}$ 中， $m_i, 0 \leq i < M$ 被标记为 retry keyframe，则除原始成功轨迹外，还可额外构造 M 条失败轨迹 $\tau_{0:m_i}, 0 \leq i < M$ 。在成功与失败数据上联合进行 temporal difference 学习后，critic Q_ϕ 就能够作为一个鲁棒的任务进度评估器。

得到任务进度模型后，我们对数据集中所有 transition 计算 Q_ϕ ，并将其类别分布的均值作为进度 ρ ：

$$\rho_t := \text{mean}(Q_\phi(\mathbf{o}_t, l, \mathbf{s}_t, \mathbf{a}_t)). \quad (2)$$

图 3 给出了一个进度预测示例。可以看到，当 **teleoperator** 出现失误时，进度值会突然下降。我们据此定义：若时间步 t 处样本 $(\mathbf{o}_t, l, \mathbf{s}_t, \mathbf{a}_t)$ 对应的序列 $\rho_{t:t+k}$ 中存在超过阈值 δ 的数值下降，则该样本被视为次优样本，并从用于 policy 学习的数据集中剔除。最后，基于过滤后质量更高的数据集，我们只需使用 behavior cloning 便可训练 π_θ 。



5.2 由于抓取过浅导致鞋带掉落



图 4: 学习到的任务进度示例。由于抓取过浅，鞋带在操作过程中掉落。



图 5: 不精确的交接 (imprecise handover)。



图 6: 鞋带在交接过程中出现失稳。



图 7: 成功重新抓取鞋带。



图 8: 交接失败后的后续状态。



图 9: 在鞋面处调整抓取点。




图 10: 为后续穿鞋带操作重新定位抓取姿态。



图 11: 鞋带从鞋眼中滑出。




图 12: (b) 在鞋带交接过程中，GR-RL value 能够捕捉多次失败尝试。




图 13: (c) GR-RL value 能够感知释放鞋带以调整抓取姿态所带来的长期正向作用。

图 3 展示了学习到的任务进度示例。其中，一个典型失败案例是：由于初始抓取过浅，鞋带在交接（handover）过程中掉落。尽管交接不精确并伴随多次失败尝试，GR-RL value 仍能反映这些中间失败状态。另一方面，当策略主动释放鞋带以调整在鞋面上的抓取点，并重新建立更合适的抓取姿态时，即使短期内鞋带从鞋眼中滑出，GR-RL value 依然能够识别这一决策对长期任务完成具有正向作用。

5.3 3.2 基于数据增强的模仿学习

在离线训练阶段，我们采用了一种简单但有效的形态对称数据增强范式，以进一步提升 policy 的性能。该增强范式利用了双臂任务设定中的形态对称性。对于图像观测 $\mathbf{o}_t$ ，我们先将所有图像做水平翻转，再将左腕相机与右腕相机的图像互换。对于本体感觉状态 $\mathbf{s}_t$ 和动作 $\mathbf{a}_t$ ，我们先在世界坐标系下按照镜像对称关系进行变换，再将其转换回各自局部的腕坐标系。与此同时，语言指令中的空间描述也会做相应翻转，例如将“左侧的孔”改为“右侧的孔”。实验结果表明，这种对称数据增强能够有效提升 policy 的性能。

5.4 3.3 用于 policy 部署对齐的在线引导

在部署 action chunking policy 时，通常会在系统层面加入后处理，以保证机器人运动更加平滑，例如 temporal ensembling 和 receding horizon control [14,65]。然而，这类优化技巧会带来训练与部署之间的不一致：policy 在训练阶段看到的是原始动作（raw actions），而在实际部署时执行的却是优化后的动作（optimized actions）。在灵巧且高精度的 manipulation 场景中，这种不匹配已经不可忽略。为适应这一差异，我们发现，让模型在与对齐后动作的 closed-loop 在线交互中自主探索并持续改进是至关重要的。

在长时程、高精度 manipulation 任务中执行在线 RL 仍然并不容易，尤其难点在于探索。由于任务往往需要毫米级精度，仅仅对 wrist pose 或 joint position 添加噪声，几乎不可能带来成功样本。为此，我们转而在 latent space 中进行结构化探索，并对已训练好的 flow policy [59] 进行 steering。具体而言，我们在共享的 VLM backbone 之后加入一个 noise predictor $\pi_{\theta'}$ ，用于为 action DiT 预测初始噪声 ϵ_{t_0} 。 $\pi_{\theta'}$ 中可训练参数的数量为 51.5M。为了避免由超出离线训练分布的噪声生成任意动作，当 noise predictor 的输出偏离原始正态分布超过阈值 β 时，我们会对其施加惩罚。进一步地，遵循 [59]，我们还在噪声空间上蒸馏一个 Q 函数 $Q_{\phi'}(\mathbf{o}_t, l, \mathbf{s}_t, \epsilon_t)$ ，从而在 policy 优化过程中避免通过 flow model 反向传播。原始动作空间中的 critic，即 $Q_{\phi}(\mathbf{o}_t, l, \mathbf{s}_t, \mathbf{a}_t)$ ，则采用标准 TD3 进行训练。noise transformer 与噪声空间 critic 的在线训练目标如下：

$$\mathcal{L}(\pi_{\theta'}) = \mathbb{E}_{(\mathbf{o}_t, l, \mathbf{s}_t) \sim \mathcal{D}} \left[-Q_{\phi'}(\mathbf{o}_t, l, \mathbf{s}_t, \epsilon_t) + c \max\left(\frac{1}{2} \|\epsilon_t\|^2 - \beta, 0\right) \right], \epsilon_t \sim \pi_{\theta'}(\mathbf{o}_t, l, \mathbf{s}_t), \quad (3)$$

$$\mathcal{L}(Q_{\phi'}) = \text{cross_entropy}(Q_{\phi'}(\mathbf{o}_t, l, \mathbf{s}_t, \epsilon_t), Q_{\phi}(\mathbf{o}_t, l, \mathbf{s}_t, \pi_{\theta}(\mathbf{o}_t, l, \mathbf{s}_t | \epsilon_t))), \epsilon_t \sim \{\mathcal{N}(\mathbf{0}, \mathbf{1}) \quad w, p, 0.5, \sqrt{\pi}\}, \quad (4)$$

与原始实现 [59] 不同的是，为了在蒸馏 $Q_{\phi'}$ 时更好地覆盖噪声空间，我们以 0.5 的概率（w.p. 0.5）从原始正态分布中采样输入噪声，其余情况下则从 noise predictor 中采样。

为了实现高样本效率的 offline-to-online 自适应，我们同时维护一个 off-policy buffer 和一个 on-policy buffer，并从两者中均匀采样 batch。训练开始前，我们先使用离线训练得到的 checkpoint 进行在线 rollout，对 off-policy buffer 做预热，这一点与 Warm-start RL [66] 类似。我们特意不将 teleoperation 轨迹混入该 buffer 中，以避免 policy 在不匹配的动力学上进行训练。on-policy buffer 只保存最近两个 checkpoint 生成的轨迹，而更早的陈旧数据则会被转移到 off-policy buffer 中。

5.5 4 机器人与系统

我们用于验证 GR-RL 的机器人平台是 ByteMini-v2，如图 4 所示。ByteMini-v2 是一款轮式移动操纵机器人，配备 7-DoF 双机械臂，并采用了独特的腕部球形关节设计 [58]。GR-3 [12] 的工作已经充分验证了 ByteMini-v1 机器人在操作灵巧性、稳定性、一致性和易用性方面的表现。与此同时，针对 GR-3 中 ByteMini-v1 使用过程中暴露出的局限性，我们在 ByteMini-v2 上进行了以下三项关键设计优化。




图 14: ByteMini-v2 机器人。图中展示了该机器人在传感器、DoF 以及电子设备等方面的配置规格。

更高的操纵负载能力 7-DoF 机械臂的最大负载能力主要受肘部执行器最大输出扭矩的限制。为此，我们将肘部执行器的峰值输出扭矩从 17 Nm 升级到 35 Nm。升级后，ByteMini-v2 上 7-DoF 机械臂的峰值负载由 1.4 kg 提升至 3.15 kg，这将显著扩展机器人的操作能力。

受限空间中的更强机动性 ByteMini-v1 底盘的投影面积为 500 mm × 720 mm。为了提升机器人在狭小空间中的机动性，ByteMini-v2 的投影面积进一步缩减为 450 mm × 650 mm。与此同时，移动平

台中舵轮的设计也进行了相应优化,使其能够在 yaw 和 pitch 两个方向上同步调节转向轮运动 [61],从而增强机器人在受限空间内快速变向的能力。

更完善的工业设计与更好的易用性 如图 4 所示, ByteMini-v2 在整体设计上更加成熟,具备更完善的工业设计 (ID),并对外露电气线束进行了合理封装。为了进一步改善用户体验,便携显示器的位置也由机器人底盘调整至肩部。

6 5 实验

任务描述我们在鞋带穿孔任务上验证 GR-RL。该任务具有长时程、灵巧且高精度操纵等特点,是一个颇具挑战性的场景。观测由三个视角的 RGB 图像、proprioception 状态以及语言指令组成。在模型推理阶段,我们引入了一个轨迹优化模块,通过对 jerk 和时间连续性施加约束,对预测得到的 action chunks 进行进一步细化。在 RL 训练阶段,我们采用二值稀疏奖励设置:只有当鞋带成功穿过正确的鞋孔,并且被完全放置到桌面上时,才会获得正奖励 1。

主要结果图 5 展示了我们多阶段训练方案的效果。基础模型 GR-3 在全部人工 teleoperation 数据上通过 behavior cloning 训练,成功率 (success rate) 为 45.7%。在使用所学习的任务进度模型对数据进行筛选后,成功率提升至 61.6%。这一结果表明,在学习高精度、长时程操纵时,数据清洗机制至关重要。进一步地,加入对称性数据增强后,经过筛选的 behavior cloning policy 的成功率又提升到 72.7%。

“Filtered BC + Aug.” 模型作为在线 steering RL 的起点。为了使离线训练得到的 critic 更好地对齐模型 rollout 的分布,我们首先收集了 673 条由离线模型生成的轨迹;随后冻结 VLM backbone,并利用这些数据继续训练 critic 头 $Q_\phi, Q_{\phi'}$ 。这些 rollout 轨迹也被加入在线 RL 的 on-policy replay buffer 中,以稳定训练过程。之后,每当在线收集到 12 个新 episode,我们就同时对噪声预测器 π'_θ 和两个 critic 头进行 50 步优化。图 5 右侧曲线给出了窗口大小为 24 的成功率滑动平均,所有在线 episode 的二值成功信号则以散点表示。在最初若干轮迭代中,由于从离线 RL 到在线 RL 的分布偏移,成功率出现下降。随后,成功率快速恢复,并进一步超过离线性能,达到 90% 以上。我们选取在线训练 500 步时的 checkpoint 进行评估,其成功率为 83.3%。




图 15: 多阶段训练流程的可视化结果。




图 16: 图 5。左：多阶段训练方案对应的成功率。数据筛选、镜像增强和在线调优都对最终性能有贡献。右：在线微调（fine-tuning）期间，每个 episode 的二值成功信号（散点）以及成功率的滑动平均（曲线）。在经历离线到在线的适配阶段后，性能快速提升。

为了更好地理解不同模型在这一长时程任务中的失效模式，我们进一步评估了模型在若干关键阶段上的成功情况，包括：抓取正确的鞋带、将鞋带穿入正确的鞋孔、将其交接给另一个 gripper，以及将鞋带拉紧。各阶段的详细成功率如图 6 所示。图中的彩色区域表示完成各阶段的成功率，斜线区域表示相较于上一阶段的成功率下降。数据筛选和在线 RL 都能显著减少穿孔阶段的失败。数据增强则在所有阶段均带来性能提升，不过提升幅度相对较小。

进度评估器的消融实验我们通过与回归版本进行比较，验证了基于 RL 的 progress evaluator 的有效性。该回归 baseline 直接对成功轨迹中每个状态 $\mathbf{s}_t$ 的时间进度 $\frac{t}{T}$ 进行回归训练。正如图 3 所示，基于回归的预测器往往会将进度预测过度平滑。它在正常情况下能够给出合理预测，但对细微失败并不敏感，而这类失败往往距离成功只差几毫米，例如鞋带未能完全抽出，或插入位置不够精确。此外，基于回归的预测器也不擅长捕捉那些会产生长期影响的状态转移。当机器人有意先放下鞋带以调整抓取姿态时，GR-RL 的预测值会出现明显跃迁；相比之下，回归模型在这一调整过程中的预测几乎保持平坦。

7 实验（第 2 部分）

我们还采用相同的 TD3+BC 算法训练了一个非分布式 critic，并将其与本文的分布式 critic 进行比较。模型在一条高质量的成功轨迹上进行评估，结果如图 17 所示。由于我们的设定具有长时域特性，且奖励为二值稀疏形式，非分布式 critic 出现了严重的过估计问题，尤其是在轨迹前段奖励监督信号较弱的位置更为明显。相比之下，本文分布式 critic 的 value 预测被约束在预定义范围内，因此能够更稳健地收敛到合理的尺度，并且与真实时间顺序表现出更好的一致性。

7.1 学习到的行为可视化

GR-RL 在多种情形下都表现出较强的鲁棒性。正如图 18 所示，它能够处理颜色和尺寸不同的鞋子。当鞋带意外掉落时（图 18(b)），或鞋带未能穿入鞋眼时（图 18(c)），模型都会自动重试。该模型还能够主动调整场景，使任务更容易完成。在图 18(d) 中，初始抓取点距离鞋带末端较远，模型会先将鞋带放到可变形的鞋面上，再重新抓取一个更靠近末端的位置，然后再执行穿线。在图 18(e) 中，模型首先将鞋子从左侧重新摆正，使其姿态更规整，随后开始穿线。类似地，对于初始放置在桌面远侧的鞋子（图 18(f)），机器人能够先将其拉近，再调整鞋带位置，最后完成任务。在鞋带两端交叉、且应抓取的一端被压在下方的情况下（图 18(g)），模型也能识别出正确的一端并将其拉出。



图 17: 不同模型在完成各个中间阶段时的详细成功率（success rate）。每个斜线阴影区域的高度表示从上一阶段到当前阶段的成功率下降幅度。




图 18: 分布式 critic 与非分布式 critic 的进度预测对比。非分布式 critic 的输出范围无界, 因此无法正确反映成功轨迹中的正向进展。

8 6 Related Work

8.1 通用机器人基础 policy

构建通用的机器人基础操纵 policy 一直是机器人研究与应用中的长期挑战 [4, 6–10, 25, 27, 32, 33, 50, 55, 57]。近年来, vision-language-action (VLA) 模型的发展表明, 可以在基于网络规模数据预训练的 vision-language model (VLM) 中引入 action 模态, 从而将其适配到机器人动作生成任务 [8, 15, 25, 27, 30, 37, 47–]。



图 19: GR-RL 在多种情形下表现出的鲁棒行为。(a) 为不同颜色的鞋子穿鞋带；(b) 当鞋带掉落时重新抓取；(c) 当鞋带未能精确穿过鞋眼时重新尝试；(d) 在鞋面上有意识地调整抓取位姿；(e) 在穿线前重新调整鞋子的朝向；(f) 在穿线前调整鞋子和鞋带的位置；(g) 从交叉鞋带中将位于另一根鞋带下方的鞋带拉出。

9 相关工作（第二部分）

49, 57, 60]。这类方法的核心思想是利用由人类 teleoperator 收集的大规模真实世界机器人轨迹，并将其泛化到潜在的新场景与新任务。GR-RL 建立在 GR-3 [12] 的成功基础之上。GR-3 是一个 generalist policy，通过与 web-scale 数据和人类 demonstration 共同训练得到。GR-RL 则在 GR-3 的基础上进一步提升：通过筛选高质量数据、进行 action augment，以及开展在线真实世界 RL，使其能够完成长时程、灵巧且高精度的 manipulation。

9.1 真实世界强化学习

纯模仿学习的一个核心局限在于，它容易受到误差累积的影响，而且其性能通常无法超过 demonstration 本身。为解决这些问题，大量工作开始探索在线数据采集与真实世界强化学习 (RL)，以期在监督训练之外进一步提升 manipulation 的鲁棒性 [2, 26, 28, 31, 43–45, 53, 54]。在 VLA 的语境下，一些近期工作尝试在仿真中通过 on-policy RL 实现 policy 改进 [13, 35, 38, 51, 63]。然而，要将这类方法的成功迁移到真实世界场景仍然十分困难，因为真实世界交互的样本效率较低，且噪声较大。

另一条研究路线是学习 world model，并通过与所学习的 world model 交互来执行 on-policy

RL [18–22, 46, 62, 67]。World model 在一定程度上缓解了真实机器人交互成本高的问题，但由于视觉预测可能不准确，也会引入新的问题。GR-RL 延续了 [43, 44, 53, 64] 的思路，重点关注真实世界 off-policy RL。这样一来，系统便能高效利用历史轨迹，从而提升样本效率。作者将带噪声的真实世界奖励视为一个分布，并表明：与标准的基于回归的 critic 模型相比，distributional critic 能显著提升系统的鲁棒性。

与本文同期， $\pi_{0.6}^*$ 提出了一条面向高精度 manipulation 的真实世界 RL 流水线 [24]。与 $\pi_{0.6}^*$ 类似，两者都采用了能够学习任务进展的 distributional critic。不过，本文并未采用 advantage-conditioned denoising，而是直接执行经过筛选的 behavior cloning，并同样观察到了显著的性能提升。由于离线 base policy 更强，这种做法还有助于在在线探索时缩小搜索空间。作者希望，GR-RL 能为社区提供一些启发：如何从 generalist policy 出发构建能力更强的 specialist agent，并进一步推动可部署机器人研究的边界。

10 7 局限性与结论

局限性 尽管 GR-RL 在长时程、高精度的灵巧操作任务上表现出较强性能，但其仍然存在明显局限。当前 pipeline 的一个主要问题是行为漂移（behavior-drifting）。在 reward 稀疏且噪声较大的情况下，policy 在 online RL 过程中可能出现行为不稳定。这一现象可能源于轻量级噪声预测器容量有限，也可能与大规模 latent action space 中困难的 credit assignment 问题有关。此外，如何将提升后的 policy 蒸馏回基础 VLA，也是一个值得探索的方向；若能实现，便有望同时获得能力更强且更具泛化性的操纵 policy。上述问题留待未来工作进一步研究。

结论 我们提出了 GR-RL，这是一种面向长时程、灵巧且高精度操纵任务的机器人学习框架，用于构建 specialist VLA policy。GR-RL 的核心洞见在于：数据采集过程与 policy inference 过程之间的失配，需要通过 online 对齐来解决。GR-RL 将基于稀疏 reward 学得的 critic value 视为任务进度预测，并据此学习一个基于 RL 的 evaluator；随后利用该 evaluator 筛选高质量 transition，以训练鲁棒的基础 policy。在这一过程中，我们还提出了一种简单但有效的形态对称性（morphological symmetry）增强方法，以提升整体性能。最后，我们进一步执行 online RL，使 rollout 行为与训练信号保持对齐。据我们所知，GR-RL 是首个能够完成系鞋带任务的学习式 policy。我们希望，GR-RL 能够成为迈向高能力真实世界 specialist 机器人 policy 的一小步。

11 参考文献

参考文献条目较多，此处保留原论文英文文献列表，请参阅原文 PDF 的 References 一节。

12 贡献与致谢

作者按字母顺序排列。

核心贡献者：Yunfei Li, Xiao Ma, Jiafeng Xu

贡献者：Yu Cui, Zhongren Cui, Zhigang Han, Liqun Huang, Tao Kong, Yuxiao Liu, Hao Niu, Wanli Peng, Jingchao Qiao, Zeyu Ren, Haixin Shi, Zhi Su, Jiawen Tian, Yuyang Xiao, Shenyu Zhang, Liwei Zheng

指导教师：Hang Li, Yonghui Wu

致谢：感谢 Yichu Yang 就 morphological mirror augmentation 提供的富有启发性的讨论。感谢 Chilam Cheang、Jinming Guo、Zetian Li、Xin Zhao、Mingyang Wang、Zhiguo Hao、Tianxiang Gong、Yang Zhao、Shuzhai Guo、Ziye Liu 以及所有数据标注人员在数据整理方面提供的帮助。感谢 Degong Yang 和 Yang Liu 在硬件系统开发与维护方面提供的支持。