

1 IG-RFT: 面向长时程机器人操纵的交互引导强化学习 VLA 框架

摘要

Vision-Language-Action (VLA) 模型在构建通用机器人 policy 方面展现出显著潜力；然而，由于分布偏移以及高质量 demonstration 的稀缺，它们在新颖真实场景中的长时程复杂任务上仍难以实现良好泛化。尽管强化学习 (RL) 为 policy 提升提供了一条很有前景的路径，但将其用于真实世界中的 VLA 微调 (fine-tuning) 仍面临探索效率、训练稳定性和样本成本等方面的挑战。为解决这些问题，本文提出 IG-RFT，一种面向基于 flow 的 VLA 模型的全新交互引导强化微调系统。首先，为了促进有效的 policy 优化，我们提出交互引导优势加权回归 (Interaction-Guided Advantage Weighted Regression, IG-AWR)，这是一种可根据机器人交互状态动态调节探索强度的 RL 算法。进一步地，为缓解稀疏奖励或任务特定奖励的局限性，我们设计了一种新的混合稠密奖励函数，将轨迹级奖励与子任务级奖励相结合。最后，我们构建了一个由 SFT、Offline RL 和 Human-in-the-Loop RL 组成的三阶段 RL 系统，用于 VLA 模型的微调。四项具有挑战性的长时程任务上的大量真实世界实验表明，IG-RFT 的平均成功率 (success rate) 达到 85.0%，显著优于 SFT (18.8%) 和标准 Offline RL baseline (40.0%)。消融实验进一步验证了 IG-AWR 与混合奖励塑形的关键作用。总体而言，本文为真实世界机器人操纵中的 VLA 模型建立并验证了一套新的强化微调系统。

索引词—Vision-Language-Action Models, Human-in-the-Loop Learning, Reinforcement Learning, Robotic Manipulation。

2 1. 引言

面向特定真实世界应用的机器人操纵技术已经日趋成熟 [1]–[3]。相比之下，通用型机器人 policy 仍处于欠发达阶段 [4]。近年来，Vision-Language-Action (VLA) 模型作为通用 policy 的一种代表性范式 [5]–[9]，依托基于行为克隆的大规模预训练，展现出令人瞩目的能力与潜力。然而，现有 VLA 模型的泛化能力仍然有限，尚无法在新的真实世界场景中实现 zero-shot 迁移 [10]。因此，利用特定领域的 demonstration 对 VLA 模型进行微调 (fine-tuning) 已成为不可或缺的步骤 [11], [12]。当前 VLA 模型主流的领域自适应方法是监督微调 (SFT)，但该方法难以有效评估和利用 demonstration，从而对训练数据的质量与数量都提出了较高要求。然而，在数据采集过程中，由于操作者熟练度差异、系统误差以及动作不连续等因素，往往会产生次优数据。

相比之下，强化学习 (RL) 能够以更有效的方式探索、评估并利用数据来提升 policy，因此在 VLA 的领域自适应中展现出很大潜力 [13]–[17]。不同于部署在仿真中的多环境并行 RL [18], [19]，VLA 模型需要在真实世界机器人任务中与物理环境直接交互。这就要求方法同时具备较高的样本效率以及风险感知的探索能力，使得直接采用 on-policy RL 并不可行。在真实世界场景中，通过 Human-in-the-Loop 部署 off-policy RL，可以缓解由分布偏移带来的误差累积，并借助及时纠正来引导 policy 学习，从而取得显著效果 [20]–[22]。然而，现有真实世界 RL 系统大多采用稀疏奖励，这主要会导致在线阶段训练不稳定，并引发 credit assignment 问题。此外，在长时程复杂任务中，不同子阶段的状态分布方差差异显著；若在整个执行周期内施加统一的探索噪声，会造成资源利用率低下。

本文提出了一种面向 flow-based VLA 模型的新型强化微调系统，旨在使其掌握真实世界中的长时程复杂机器人操纵任务。如图 1 所示，该系统由 SFT、Offline RL 和 Human-in-the-Loop RL 三个阶段组成，从初始 policy 学习逐步过渡到 policy 演化。我们的核心洞见在于：有效的 policy 优

化需要结构化的交互引导，以及通用的稠密过程奖励。基于此，我们首先提出 Interaction-Guided Advantage Weighted Regression (IG-AWR) 算法，根据机器人的交互状态动态调节探索强度。具体而言，该方法使机器人在非交互阶段（如接近、回撤）优先进行探索，以适应广泛分布场景中的多样性；而在精细交互阶段（如 handover、抓取）则更强调鲁棒性，以习得复杂操纵能力。为了为各个 episode 自动标注交互状态，我们结合开源机器人分割模型与光流估计方法进行自动处理。

此外，我们设计了一种新的稠密奖励函数，将轨迹级奖励与子任务级奖励相结合，为 RL 系统提供全面的过程引导；该奖励仅依赖 episode 长度，因此能够广泛适用于多种任务。已有一些工作针对特定任务，基于视觉相似度或到目标点的距离来设计稠密奖励 [23]–[27]；也有一些工作在真实世界强化学习设置中仍采用稀疏奖励 [20]–[22], [28], [29]。最后，我们构建了一个多阶段训练系统：在 SFT 与 Offline RL 阶段实现稳定而高效的 policy 学习，并借助 Human-in-the-Loop RL 对 policy 进行迭代优化。我们通过大量实验严格验证了所提各组成模块的创新性与有效性，包括针对单个模块的消融实验，以及在真实世界长时程复杂操纵任务上对整个微调系统的全面评测。本文的主要贡献总结如下：

3 引言（第二部分）




图 1: Interaction-Guided Reinforced Fine-tuning System (IG-RFT) 概览。该系统集成了一个基于多头 Q-Former 的 critic 模型，用于提供稠密的价值引导与交互引导。稠密价值的监督目标是我们设计的通用混合价值函数。我们利用交互信号调制 flow matching 的初始噪声，以平衡强化学习中的探索与利用。训练过程分为三个阶段：监督微调（SFT）、基于所提出 IG-AWR 算法的数据高效离线强化学习（Offline RL），以及最终的人在回路（Human-in-the-Loop）精炼，从而掌握长时程真实世界操纵任务。

- 我们提出了 Interaction-Guided AWR (IG-AWR)，这是一种面向基于 flow 的 VLA 模型的新型强化学习微调算法。该方法利用交互信号有效平衡探索与利用。
- 我们构建了一种混合稠密奖励函数，将轨迹级过程奖励与带权重的子任务级奖励结合起来，为长时程任务提供平滑且稠密的反馈。

- 我们设计了一个融合人工干预的多阶段强化微调系统。该系统首先通过 SFT 初始化 policy，随后通过 Offline RL 完成基础 policy 学习，并在人在回路 rollout 过程中进一步提升 policy 性能。

4 II. RELATED WORK

4.1 A. Vision-Language-Action Models

机器人 policy 充当智能体, 将感知到的状态映射为控制动作 [30], [31]。Vision-Language-Action (VLA) 模型是一类具备语义理解能力、可泛化的机器人 policy。其训练方式通常是在机器人 manipulation demonstration 与开放世界数据集上, 对 vision-language model (VLM) 进行适配 [5]–[8], [11], [12], [32]–[35]。RT-1 [34] 和 RT-2 [35] 是较早的代表性方法, 它们采用基于 transformer 的架构来预测离散化动作。与之不同, π_0 [5] 引入了一个独立于预训练 VLM 参数的 action expert, 并通过 flow matching 生成动作。 $\pi_{0.5}$ [7] 则结合 knowledge isolation [36] 进行训练, 并支持子任务分解 [37], 从而在真实世界 manipulation 任务中实现了较强的广泛泛化能力。

尽管近来 VLA 模型发展迅速, 并已展现出显著潜力, 但在部署到全新的真实世界场景时, 其泛化性与鲁棒性仍然有限, 导致在分布外场景中的性能下降。进一步推进微调 (fine-tuning) 方法的发展, 有望显著提升这类模型处理长时程、复杂真实世界任务的能力。

4.2 B. 面向 VLA 模型的 RL 微调

近年来, 利用强化学习 (RL) 对 VLA 模型进行微调 (fine-tuning) 已成为一个重要研究方向。一类方法是在仿真环境中开展 online RL, 并借助大规模并行环境进行模型训练 [14], [38]–[42]。部分研究进一步面向基于 flow 的 VLA 模型开展 RL 训练 [13], [43]–[46]; 值得注意的是, 相比自回归 (auto-regressive) VLA 模型, 基于 flow 的 VLA 模型在 RL 优化上更具挑战。作为比物理世界更高效交互环境, world model 也被用于为 RL 微调提供反馈 [24], [47], [48]。

与此同时, 奖励函数设计也受到越来越多关注 [23], [25], [26], [49]–[52]。其原因在于, 稀疏奖励往往会导致训练不稳定, 而稠密奖励又通常难以泛化。另一类方法则聚焦于真实世界场景下安全且高效的 RL 微调, 主要通过专门设计的 offline-to-online RL 方法, 或引入 human-in-the-loop 引导, 以缓解分布偏移问题 [20]–[22], [29], [53], [54]; 然而, 这些方法缺乏具备阶段感知能力的稠密奖励反馈。

与上述工作不同, 我们设计了一种更高效的、由交互引导的 AWR 算法, 并提出了一种通用且稠密的奖励机制。该方法提升了系统从 Offline RL 到 Human-in-the-Loop RL 全流程的性能。

5 III. PRELIMINARIES

5.1 A. Vision-Language-Action Models

考虑一个由自然语言指令 ℓ 指定的机器人操纵任务。在每个时间步 t , 智能体接收观测 o_t (包括 proprioception 和视觉数据)。VLA 模型利用大规模预训练 VLM 与动作模块构成端到端 policy, 在多模态上下文条件下采样动作 $a_t \sim \pi(\cdot | \ell, o_t)$ 。标准的后训练通常依赖监督微调 (SFT), 并采用 next-token prediction 或 conditional flow matching 等目标; 但这类方法对 demonstration 质量高度敏感, 同时存在数据效率低的问题。更关键的是, SFT 会不加区分地将次优 demonstration 与最优 demonstration 视为等价的监督目标。

5.2 B. 强化学习

机器人操纵任务可表述为一个马尔可夫决策过程(MDP),定义为五元组 $(S, \mathcal{A}, r, \mathcal{P}, \gamma)$ 。其中, 状态 $s_t \in S$ 由机器人的观测 o_t 和任务提示 ℓ 共同构成。VLA 作为 policy $\pi_\theta(\cdot|s_t)$, 用于采样动作 a_t ; 状态转移由动力学 $\mathcal{P}(s_{t+1}|s_t, a_t)$ 决定, 从而得到下一时刻状态。

我们将累计回报定义为 G_t , 其中 $\gamma \in [0, 1]$ 为折扣因子。记 τ 为从该 policy 中采样得到的一条轨迹, 则强化学习的目标是优化参数 θ , 以最大化期望回报 $\mathcal{I}(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^T \gamma^t r_t \right]$ 。相应地, 状态价值函数定义为 $V^\pi(s_t) \triangleq \mathbb{E}_{\tau \sim \pi_\theta} [G_t | s_t]$ 。

6 IV. 方法

6.1 A. 用于 Flow Matching 的交互引导 AWR

在复杂的长时程机器人操纵任务中, 如何在探索与利用之间取得最优平衡, 仍然是一个关键且尚未解决的问题。传统 RL 方法在精细操作阶段往往会出现有害探索, 进而破坏任务执行。为此, 我们将一个 episode 拆分为非交互阶段与接触丰富的交互阶段两类: 在非交互阶段 (如接近、回撤) 鼓励探索, 以提升轨迹多样性; 在交互阶段 (如 handover、抓取) 则优先保证动作的精确性与稳定性。具体而言, 我们首先介绍交互信号的提取方法, 随后说明如何将其用于基于 flow 的 VLA 模型的 RL 微调 (fine-tuning)。




图 2: IG-AWR 中动态不确定性调制 (Dynamic Uncertainty Modulation) 机制示意图。该机制根据提取到的交互信号 I_t 调节 flow ODE 的初始采样噪声 ϵ 。在非交互阶段 (上), 采用较大的方差 σ_{high} , 以鼓励更加多样的轨迹探索; 在交互阶段 (下), 则将方差降低为 σ_{low} , 以保证接触丰富操纵中的精度与稳定性。

6.1.1 1) 交互信号提取

对于处理 VLA demonstration 而言, 高效且自动化的交互标注至关重要。我们利用全局视觉观测, 在每个时间步 t 首先使用机器人分割模型 RoboEngine [55] 生成二值机器人掩码 M_t 。随后, 采用 RAFT [56] 估计稠密光流场 F_t 。交互状态 I_t 定义为

$$I_t = \mathbb{I} \left(\sum_{u,v} (1 - M_t^{(u,v)}) \cdot \mathbb{I} \left(\|F_t^{(u,v)}\|^2 > \delta_{\text{flow}} \right) > \Theta_{\text{pixel}} \right) \quad (1)$$

其中, (u, v) 表示像素坐标, $\mathbb{I}(\cdot)$ 为示性函数。项 $(1 - M_t^{(u,v)})$ 用于排除机器人像素, 从而聚焦于环境中的运动区域。我们统计满足光流模长平方 $\|F_t^{(u,v)}\|^2$ 超过阈值 δ_{flow} 的像素数量; 若该数量超过 Θ_{pixel} , 则将该时间步标记为交互阶段, 即 $I_t = 1$ 。

6.1.2 2) 动态不确定性调制

在 rollout 阶段, 如图 2 所示, 我们根据预测得到的交互信号概率, 动态调节初始采样噪声的方差。基于由视觉观测直接得到的二值交互标签 (第 IV-A1 节), critic 网络预测 $p_{\text{int}}(s) \in [0, 1]$, 即状态对应的交互概率软估计, 并通过监督训练使其逼近真实标签。我们将有效采样温度 $\mathcal{T}(s)$ 定义为:

$$\mathcal{T}(s) = \sigma_{\text{base}} \cdot (1 - \alpha \cdot p_{\text{int}}(s)) + \sigma_{\text{min}} \quad (2)$$

policy 通过从缩放后的噪声分布出发求解 flow ODE 来生成动作。具体地, 初始状态 $\hat{a}_0$ (即 ϵ) 从分布 $\mathcal{N}(\mathbf{0}, \mathcal{T}^2(s)\mathbf{I})$ 中采样。




图 3: 图示。




图 4: 奖励信号与价值函数的可视化。我们以“Parcel Packing”任务展示所提出的 reward shaping 机制。(A) 奖励信号 r_t 由恒定的轨迹级奖励与加权的子任务级奖励 (峰值) 共同构成, 从而在关键里程碑处提供稠密反馈。(B) 价值 (Return-to-Go) 函数 V_t 会随着 agent 在各个子任务中的推进, 从 1.0 单调下降到 0, 可作为 critic 的精确进度指示信号。

6.2 A. 用于 Flow Matching 的交互引导 AWR (第二部分)

这一表述能够对探索过程进行自适应调节: 在非交互阶段, 较高的方差有助于探索更加多样的轨迹; 在交互阶段, 较低的方差则促使策略执行更精确、更稳定。由此, 离散的、由视觉推导得到

的交互信号 I_t 与连续的 policy 不确定性调节被自然地衔接起来。

3) 优势加权的 Flow 更新： 在 policy 优化中，我们采用 Advantage Weighted Regression (AWR) [?] 来最大化基于 flow 的 policy 的期望回报。给定通过交互引导 policy 收集到的 demonstration D ，其优势估计为 [formula] $V_\phi(s_{t+N}) - V_\phi(s_t)$ 。交互引导的优势加权回归 (Interaction-Guided Advantage Weight Regression, IG-AWR) 损失函数定义为：

$$[\text{formula}] \quad (3)$$

其中， β 是 AWR 的温度超参数， $\hat{a}_\tau$ 表示时刻 τ 的 flow 轨迹。该目标函数会对估计优势更高的数据赋予更大的权重，同时保留 flow ODE 的结构，从而实现稳定的 policy 精炼。

6.3 B. 通用混合奖励函数

奖励建模对于 VLA 模型的 RL 微调至关重要。设计一种通用奖励函数有助于模型适配更广泛的任務。为了在多阶段、长时程任务中有效引导智能体，我们设计了一种混合奖励函数，同时结合轨迹级成功激励与阶段级子任务反馈，如图 3 所示。

1) 轨迹级奖励： 为了在不同机器人操纵任务之间实现泛化，我们将轨迹级奖励定义为：

$$r_t^{\text{traj}} = [\text{formula}] \quad (4)$$

其中， T 表示一个 episode 的总时间步数。该定义在任务成功完成时，将总回报 1.0 均匀分配到整条轨迹上。

2) 子任务级奖励： 由于轨迹级奖励无法为复杂的长时程任务提供细粒度反馈，我们在子任务层面采用基于势函数的奖励塑形 (potential-based reward shaping)。这一连续且单调递增的势函数既能避免 reward hacking，又能提供足够的局部引导信号。为了在保证平滑性的同时模拟子任务完成过程，我们采用加权混合模型来突出更复杂的子任务，其形式为：

$$\Phi(\rho) = C \sum_{i=1}^K w_i \cdot \sigma\left(\frac{\rho - k_i}{\epsilon}\right) \quad \text{s.t.} \sum w_i = 1 \quad (5)$$

$$r_t^{\text{sub}} = \Phi(\rho_t) - \Phi(\rho_{t-1}) \quad (6)$$

其中， $\rho_t = t/T$ 表示归一化后的时间进度， $\sigma(\cdot)$ 为标准 sigmoid 函数。参数 k_i 和 w_i 分别表示第 i 个子任务的完成时间步及其重要性权重。其中， ϵ 控制函数的陡峭程度， C 为归一化常数。

3) 奖励聚合： 最终奖励由轨迹级奖励与子任务级奖励加权求和得到：

$$\mathbf{r}_t = \omega_{\text{traj}} \cdot \mathbf{r}_t^{\text{traj}} + \omega_{\text{sub}} \cdot \mathbf{r}_t^{\text{sub}} \quad \text{s.t.} \quad \omega_{\text{traj}} + \omega_{\text{sub}} = 1 \quad (7)$$

据此，我们可得到 return-to-go：

$$G_t = \sum_{k=t}^T r_k$$

这里假设折扣因子 $\gamma = 1$ 。随着 episode 的推进，该值会自然地 1.0 衰减到 0。

7 C. RL 微调系统（第 1 部分）

由于纯在线 RL 的数据效率较低，我们采用一种多阶段微调（fine-tuning）方法：先利用预先采集的离线数据进行训练，为模型提供更强的先验；再在在线阶段引入人类反馈，为 RL 微调提供高质量且高效率的指导，从而缓解高维空间中的探索难题。基于这一范式，我们设计了一个面向长时程复杂任务的系统，其中结合了 IG-AWR 算法与稠密奖励函数。

7.1 1) 模型架构

我们采用 $\pi_{0.5}$ 模型 [7] 作为 actor 模块 π_θ 。该模型是具有代表性的基于 flow 的 VLA，并已在真实场景中验证出优越性能。基于在当前观测 o_t 条件下由 VLM backbone 产生的 KV cache，我们训练一个 critic 网络，用于回归状态价值 V_t^π 并预测交互信号 I_t 。

具体而言，若直接使用所有 transformer 层的 KV cache，会带来较高的计算开销以及信息冗余。因此，我们选择性地聚合较深层的特征，因为这些层包含最丰富的语义信息。该网络架构建立在 Q-Former (Query Transformer) [58] 之上，其通过可学习的 queries，经由 cross-attention 从 KV cache 中自适应提取相关的多模态特征。随后，Q-Former 的输出分别送入三个独立参数化的 head，以产生轨迹级价值、子任务级价值以及交互信号。

Critic Module 的损失不应影响动作生成，因此我们阻断其梯度向 VLM 传播。关于 critic 网络架构的更多细节见附录 A。

7.2 2) 训练方案

在上述架构基础上，我们进一步说明其优化流程。获得状态价值函数后，我们使用 N-step advantage estimation [22] 来估计优势 $\hat{A}(s_t, a_t)$ ，并通过 IG-AWR 算法更新 policy。具体来说，我们为 VLA 模型设计了一个三阶段的 RL 训练课程，如算法 1 所总结：

- **阶段 I: Warm-up 与 SFT。**我们采集 demonstration 数据，并利用大规模 VLM 标注子任务信息，进而获得交互信号、奖励和值。随后，我们使用 Knowledge Isolation [59] 训练 $\pi_{0.5}$ （其中包含子任务预测损失）。在经过少量 warm-up steps 后，我们再同步训练 critic module，其中价值回归采用 MSE loss，交互预测采用 BCE loss。
- **阶段 II: Offline RL。**我们使用 IG-AWR 算法对 VLA 执行 RL 训练，并同时更新 critic module。在这一阶段中，agent 学会对数据进行评估和利用，从而实现高效的 policy 学习。

7.3 C. RL Fine-tuning System（第 2 部分）

算法 1: 用于 VLA 微调的交互引导 AWR (Interaction-Guided AWR, IG-AWR)

输入: 预训练 VLA $\pi_{0.5}$, demonstration buffer $\mathcal{D}_{\text{demo}}$

输出: 微调后的 policy π_θ , critic V_ϕ

1. **数据标注:** 为 $\mathcal{D}_{\text{demo}}$ 标注子任务、交互信号 I_t 、奖励和 value。
2. // **阶段 I: Warm-up 与 SFT**
3. 通过 SFT 由 $\pi_{0.5}$ 初始化 actor π_θ 。
4. 在 $\mathcal{D}_{\text{demo}}$ 上最小化 $\mathcal{L}_{\text{MSE}}$ (状态 value) 和 $\mathcal{L}_{\text{BCE}}$ (交互信号)，以初始化 critic V_ϕ 。

```

5. // 阶段 II: Offline RL
6. for iteration  $k = 1, \dots, K_{\text{offline}}$  do
7.   在  $\mathcal{D}_{\text{demo}}$  上估计 advantage  $\hat{A}$ 。
8.   通过 IG-AWR 更新  $\pi_{\theta}$ , 并更新  $V_{\phi}$ 。
9. end for
10. // 阶段 III: Human-in-the-Loop RL
11. 初始化 replay buffer  $\mathcal{D}_{\text{real}} \emptyset$ 
12. while 未收敛 do
13.    $s_0 \leftarrow \text{env.reset}()$ 
14.   for  $t = 0, \dots, T$  do
15.     观测状态  $s_t$ , critic 输出  $V(s_t), I(s_t)$ 
16.     if  $V(s_t)$  停滞, 或人类判断即将失败 then
17.        $a_t \leftarrow \text{HumanTeleop}(s)$  ▷ 人类接管
18.     else
19.        $a_t \sim \pi_{\theta}(\cdot | s_t)$  ▷ 自主执行
20.     end if
21.     执行  $a_t$ , 并观测  $s_{t+1}$ 
22.   end for
23.   将该 episode 存入  $\mathcal{D}_{\text{real}}$ 。
24.   if 到达更新间隔 then
25.     采样 batch  $B_{\text{real}} \sim \mathcal{D}_{\text{real}}$ 。
26.     采样等规模 batch  $B_{\text{demo}} \sim \mathcal{D}_{\text{demo}}$ 。
27.     构造混合数据集  $B_{\text{hybrid}} = B_{\text{real}} \cup B_{\text{demo}}$ 。
28.     在  $B_{\text{hybrid}}$  上通过 IG-AWR 更新 policy  $\pi_{\theta}$ 。
29.     以更低频率更新 critic  $V_{\phi}$ 。
30.   end if
31. end while

```

阶段 III: Human-in-the-Loop RL. 我们将基础 policy 部署到真实环境中, 在 Human-in-the-Loop 干预下采集 rollout。通过收集高质量的人类纠正数据, policy 能逐步逼近其能力上限, 从而在长时程复杂任务上获得更显著的性能提升。

7.3.1 3) Human-in-the-Loop 机制

在真实世界执行过程中，机器人按照 policy π_θ 自主运行，同时由人类操作员监控整个过程。当 critic 模块输出的 value 出现停滞，或者操作员判断系统可能即将失败时，操作员会通过 teleoperation 接口介入，直接覆盖当前动作。此类干预数据会被存入 replay buffer，其中既包含接管前的低 value 状态，也包含后续高质量的纠正轨迹。

系统会周期性地从预先收集的 demonstration buffer 中采样数量相同的 episode，与真实交互数据共同构成混合数据集。随后，使用该数据集通过 IG-AWR 算法对 policy 模块进行微调，同时以较低频率更新 critic 模块。该 Human-in-the-Loop RL 方法能够有效缓解分布偏移问题，并使系统掌握那些仅依赖 offline 学习难以解决的复杂长时程任务。

8 V. 实验

本节通过全面的真实世界实验，评估所提出的强化微调系统的有效性。实验旨在回答以下三个关键研究问题：

- **Q1 (整体性能)**：所提出的强化微调系统能否在长时程、复杂的真实世界任务中保持稳健表现，并优于 SFT/RL baseline？
- **Q2 (消融研究)**：各个组成模块分别带来了哪些贡献，尤其是 IG-AWR 算法与混合稠密奖励函数的作用是什么？
- **Q3 (系统演化)**：policy 的性能在三个训练阶段——SFT、Offline RL 和 Human-in-the-Loop RL——中是如何演化的？

8.1 A. 实验设置

1) 硬件与环境：我们的全部实验均在真实机器人平台上进行。该平台由一台配备平行夹爪的 Galaxea A1 双臂机器人构成。视觉观测由一个头部安装的 Orbbec Gemini 2L 相机以及两个腕部安装的 RealSense L515 相机获取。控制频率设为 30 Hz，与数据采集频率保持一致。我们将 action chunk size 设为 30，并采用 RTC 方法 [60] 实现实时控制。policy 的推理与训练均在配备 NVIDIA A100 GPU 的云端服务器上执行。底层控制流水线运行在本地 PC 上，其配置为 Intel Core i7-12700KF 3.6GHz CPU、32GB RAM 和 RTX 4070 GPU。本地部署端与云端推理端之间通过基于 socket 的网络通信进行连接。更详细的训练超参数与配置见附录 B。

2) 任务：我们选取了四个具有挑战性的长时程操纵任务，这些任务涉及多阶段推理、接触丰富交互、双臂协同，以及关节型与可变形物体操纵。任务概要如下，并在图 4 中进行了可视化展示；更完整的任务描述，包括子任务拆解、成功判据与平均步数，见附录 C。

- **Parcel Packing**：机器人需要拾取盘子上的物品，将其放入包裹箱中，随后将盘子移开，并通过双臂协作同步折叠箱盖并完成封箱。该任务要求精确的双臂协同能力以及接触丰富操纵能力。
- **Fruit Bagging**：智能体需要打开帆布袋盖，依次拾取姜、苦瓜和香蕉，并将它们放入袋中，最后再将袋盖关闭。该任务涉及关节型与可变形物体操纵、对物体类别的语义理解，以及从随机位置进行顺序抓取。

表 1: 真实世界长时程任务上的主要结果。我们比较了所提系统与各 baseline 在四个任务上的成功率 (%)。每个任务的结果均在 20 次试验上取平均。最优结果以粗体标出。

Method	Parcel Packing	Fruit Bagging	Block Stacking	Drink Shelving	Avg.
SFT	15.0	30.0	25.0	5.0	18.8
IQL	40.0	50.0	45.0	20.0	38.8
AWR	35.0	55.0	45.0	25.0	40.0
Ours	85.0	95.0	90.0	70.0	85.0

- **Block Stacking:** 机器人需要按照红、黄、绿、蓝的顺序，从桌面上拾取不同颜色的积木，并依次将其堆叠到盘子上。该任务用于测试颜色语义理解能力以及精确堆叠能力。
- **Drink Shelving:** 机器人需要从一个杂乱堆放的容器中取出饮料：距离更近的机械臂先从上方抓取物品，并将其交接给另一只机械臂；后者再从侧面将饮料放入狭窄的货架中。该任务考察双臂协同交接、杂乱环境下的 bin-picking，以及受限货架空间中的精确放置能力。

3) **Baseline:** 我们将完整系统与以下 baseline 进行比较：

- **SFT ($\pi_{0.5}$ -Base):** 基础的基于 flow 的 VLA 模型，仅通过 demonstration 数据集上的行为克隆进行微调 (fine-tuning)。其中，action generation 使用 Knowledge Isolation [59] 进行训练，同时并行执行子任务预测。
- **Offline RL (IQL/AWR):** 将标准 Offline RL 方法 [57], [61] 应用于 $\pi_{0.5}$ 模型，但不包含我们提出的特定交互引导、稠密奖励塑形以及人工干预机制。

4) **数据采集与指标:** 对于每个任务，我们首先通过 teleoperation 采集 60 条专家 demonstration，构成初始数据集 $\mathcal{D}_{\text{demo}}$ 。在人类参与闭环(Human-in-the-Loop)阶段，每次训练更新执行 10 次 rollout，并将其加入 $\mathcal{D}_{\text{real}}$ 用于 IG-AWR 更新；该过程共迭代 4 次，总计 40 次 rollout。为保证比较公平，不使用 Human-in-the-Loop 的 baseline 方法统一采用 100 条专家 demonstration。评价指标为成功率 (Success Rate, SR)，定义为成功试验次数占总尝试次数的比例。

8.2 B. 主要结果

我们在表 I 中给出了对比结果。所提出的系统在四项任务上均取得了最高成功率 (success rate)，表明该方法具有更强的泛化能力与鲁棒性。

1) **相较于 SFT 的优势:** 尽管 VLA 模型在预训练阶段通过 SFT 学习了多样化的操纵技能与语义理解，从而成为一种通用 policy，但当前 SOTA 方法仍然难以仅依靠少量任务特定 demonstration (例如 100 条)，就将已有知识迁移到新的真实世界场景中，包括新的 embodiment 和新任务，并完成长时程复杂任务。此外，SFT 通常受限于人工预先采集数据的质量，也更容易收敛到次优分布。相比之下，使用 RL 对 VLA 模型进行面向新场景的微调 (fine-tuning)，能够表现出更强的适应能力。

如表 I 所示，SFT policy 在我们的真实世界复杂任务中取得了最低的成功率，表现劣于所有采用 RL fine-tuning 的方法。尤其是，我们的方法相较于 SFT policy 显著提升了成功率。上述结果表

明, 利用 RL 对 VLA 模型进行微调, 确实能够使 policy 学到更优的动作分布, 从而避免由微小偏差不断累积所导致的误差, 并增强其在新真实世界场景中处理长时程任务的能力。



图 5: 长时程任务的执行序列。自上而下, 我们可视化了四项挑战性任务的成功执行流程: Parcel Packing、Fruit Bagging、Block Stacking 和 Drink Shelving。箭头表示子目标的推进过程。需要说明的是, 为了便于可视化, 每个阶段上方的文字标签均做了缩写, 因此与模型实际使用的自然语言指令并不完全一致。各任务对应的子任务指令详细序列见附录 C。

2) 相较于 Offline RL 的优势: 采用标准的 Offline RL baseline (IQL/AWR) 对 VLA 模型进行微调, 相比 SFT 的确能够学到更好的任务特定动作分布; 但这类方法仍然受到分布偏移问题的影响。与此同时, 在真实世界 embodiment 上直接进行纯在线 RL, 则面临探索效率低以及安全性不足等挑战。与之相比, Human-in-the-Loop 方法能够引入人类先验指导, 从而更高效地推动 policy 演化。

与 Offline RL 相比 (表 I), 我们的多阶段 RL 微调系统取得了显著更高的性能增益, 并在真实世界中表现出更强的鲁棒性。在我们的实验设置下, 该方法在四项长时程复杂任务上的整体性能提升约为 40%。这验证了所提强化微调系统的有效性与实用性, 也由此回答了 Q1。

8.3 C. 消融实验

为验证各项设计选择的有效性, 我们在对复杂操纵能力要求最高的 Parcel Packing 和 Drink Shelving 两项任务上开展了消融实验。本节回答 Q2。

1) Interaction-Guided AWR 的作用 我们将提出的 IG-AWR 与标准 AWR 实现进行比较。两者均遵循三阶段训练方案, 但后者采用均匀探索噪声。表 II 的结果表明, 去除由 interaction guidance 引导的动态不确定性调制后, 性能大约下降了 15%。定性分析显示, 若缺少 interaction guidance, 机器人在精细的 “flap folding and box closing” 阶段更容易出现抖动。进一步地, 我们观察到, 在没

有 interaction guidance 的情况下, 智能体在非交互阶段缺乏足够探索, 因而对物体位置的泛化能力较差。测试时一旦遇到分布外 (OOD) 情形, 它往往会偏向预采集数据中出现过的物体位置, 最终导致任务失败。

表 2: 消融实验结果。我们在两个最具挑战性的任务上评估 Interaction Guidance (IG) 和奖励函数的贡献。

Configuration	Parcel Packing	Drink Shelving	Avg. Drop
Ours (Full System)	85.0	70.0	
w/o Interaction Guidance	70.0	55.0	↓ 15.0
w/o Trajectory-level Reward	75.0	60.0	↓ 10.0
w/o Subtask-level Reward	55.0	45.0	↓ 27.5

表 3: 子任务完成进度。不同于二值成功率 (success rate), 这里报告归一化进度分数 (0.0–1.0), 表示每个 episode 中平均完成的子任务比例。该指标能够揭示 policy 具体在哪个阶段失败。

Reward Configuration	Parcel Packing	Drink Shelving	Avg. Progress
Ours (Hybrid)	0.96	0.88	0.92
w/o Trajectory Reward	0.84	0.78	0.81
w/o Subtask Reward	0.68	0.54	0.61

除最终性能外, 我们还在图 5 中进一步分析了 IG 对数据效率的影响。其中, 红色曲线表示 IG-RFT, 蓝色曲线表示带 dense reward 的 baseline AWR, 灰色曲线表示不带 dense reward 的 AWR。我们的方法呈现出显著更陡峭的学习曲线: IG-RFT 仅需 40 次人工干预即可达到 77.5% 的平均成功率, 最终收敛到 82.5% 的成功率。相比之下, 带 dense reward 的 AWR 学习速度更慢, 在同样 40 次人工干预条件下仅达到 62.5%。这表明, 我们的方法能够以显著更低的人力成本获得更优性能。

即便将数据规模扩展到 70 个 episode, 不带 IG 的 baseline 仍无法达到 IG-RFT 的峰值性能。这说明, 基于视觉交互信号调制探索, 不仅可以提升 policy 性能, 还能显著减少微调 (fine-tuning) 所需的人力投入。另一条 baseline, 即不带 dense reward 的 AWR, 也进一步验证了这一结论, 并表明在 Human-in-the-Loop 学习中, 我们设计的 dense reward 对 policy 提升同样至关重要。

8.3.1 混合稠密奖励的作用

我们在表 II 中比较了仅使用轨迹级奖励、仅使用子任务级奖励, 以及混合稠密奖励 (Trajectory + Subtask) 三种设置下的系统表现, 并在表 III 中结合子任务完成进度指标进一步分析了失败模式。结果表明, 仅依赖单一奖励信号会降低任务成功率, 这一点在本文所关注的长时程复杂任务场景中尤为明显。

具体而言, 缺少子任务级奖励会导致成功率大幅下降 27%, 进度得分也显著下降 0.31。这说明, 稠密的激励信号对于推动一系列顺序子目标的完成至关重要。相比之下, 缺少轨迹级奖励会使成功率下降 10%, 但进度得分仅小幅下降 0.11。这表明, 即使任务最终失败, 子任务奖励仍有助于中间子目标的完成。

我们观察到，轨迹级奖励能够为最终目标提供长期引导，从宏观层面保障智能体学习到任务的终极目标；而子任务级奖励则为短期目标提供即时引导，使智能体能够逐步掌握一系列顺序子目标。综合来看，这些结果表明，混合奖励结构对强化微调（reinforced fine-tuning）系统具有显著收益。




图 6: Human-in-the-Loop 微调中的数据效率分析。图中报告了 Parcel Packing 与 Drink Shelving 两个任务上的平均成功率（success rate）均值。曲线表明，IG-RFT（本文方法）具有更优的样本效率，在仅有 40 次 intervention 的情况下便收敛到 77.5% 的成功率，显著优于各类 baseline。阴影区域表示不同任务之间的最小值至最大值范围。

8.4 D. 训练阶段分析

我们在表 IV 中分析了三阶段 RL 训练系统中的 policy 演化过程，考察各阶段对最终性能的贡献。本节回答问题 Q3。各阶段的详细分析如下。

- **阶段 I (SFT)**：监督微调阶段主要完成对新领域的适配，使模型获得基础操纵技能与语义理解能力。但其在长时程执行中的鲁棒性仍然有限，平均成功率（success rate）仅为 18.8%。这表明，在真实世界场景中，VLA 模型的泛化能力与通用性仍有较大提升空间。
- **阶段 II (Offline RL)**：在预先收集的数据集上，利用交互引导目标对 policy 进行优化后，智能体能够区分高价值动作与次优动作，成功率显著提升至 40.0%。尽管在真实环境 rollout 过程中仍然存在分布偏移问题，从而限制了最终成功率，但该阶段为后续在线阶段提供了关键的预热。
- **阶段 III (完整系统 vs. 直接 HIL)**：引入人工干预能够为 OOD 状态提供关键修正。表 IV 显示，完整系统（阶段 I → II → III）的成功率达到 85.0%。值得注意的是，若跳过阶段 II，直接在 SFT 模型上执行 Human-in-the-Loop（即阶段 I → III），其成功率仅为 63.8%，明显低于完整系统。

两者 21.2% 的性能差距表明，阶段 II 中 actor 与 critic 模块所学习到的基础分布，对于最大化人工修正的样本效率至关重要。上述结果说明，我们提出的三阶段 RL 微调系统对于 policy 演化是不可或缺的。

表 4: Policy 演化与阶段分析。我们比较了不同训练阶段下的性能。每个任务的结果均在 20 次试验上取平均。HIL 表示 Human-in-the-Loop。最佳结果以加粗标出。

训练阶段 / 配置	Parcel Packing	Fruit Bagging	Block Stacking	Drink Shelving	Avg.	Avg. Drop
阶段 I: SFT	15.0	30.0	25.0	5.0	18.8	↓ 66.2
阶段 II: Offline RL	40.0	55.0	45.0	20.0	40.0	↓ 45.0
SFT → HIL (不含阶段 II)	65.0	75.0	70.0	45.0	63.8	↓ 21.2
阶段 III: 完整系统	85.0	95.0	90.0	70.0	85.0	


8.5 E. 定性分析

为更直观地理解 IG-RFT 的内部机制，我们对真实执行过程中交互信号的提取结果以及价值估计的动态变化进行了可视化分析。

首先，我们在图 6 中验证了视觉交互提取模块的有效性。系统结合全局 RGB 观测、dense optical flow 以及机器人区域 masking，能够准确量化环境变化的强度。根据式 1，我们通过计算运动像素数量，并施加阈值 $\Theta_{\text{pixel}} = 400$ ，从而判定交互状态 I_t 。图中展示了 Parcel Packing 和 Drink Shelving 两个任务在交互阶段选取的四个代表性帧。该方法能够便捷且自动地提取交互信息。在交互阶段，通过降低探索噪声来提升稳定性与鲁棒性；而在非交互区域，则采用更高方差的探索以促进轨迹多样性和泛化能力。总体而言，这一流程在强化学习 (RL) 中有效平衡了 exploration 与 exploitation。

进一步地，我们通过可视化图 7 中预测状态价值 V_t 的轨迹，分析 critic 对 policy 性能的评估能力。红色曲线表示 critic 的实时预测，灰色虚线表示参考价值。在成功的 rollout 中，预测价值能够紧密跟随参考值，并随着各个子任务的完成而单调下降。更关键的是，critic 对次优动作表现出很高的敏感性。如蓝色阴影区域所示，当智能体执行了次优动作时，预测价值会出现波动或异常上升，这反映的是潜在风险，而非显式失败。以 Parcel Packing 任务为例，“轻微抓取偏移”或“过早运动”都会立即导致价值偏离；类似地，在 Drink Shelving 任务中，“饮料抓取不稳定”或“与货架碰撞”等事件也会触发明显的价值峰值。这些结果表明，我们的 dense value function 不仅能够引导 policy 朝目标推进，还可作为执行质量的有效指示器，提供关键的 dense feedback，从而显著促进强化学习过程中的 policy 优化。

8.5.1 A. Parcel Packing



B. Drink Shelving




图 7: 交互信号提取的可视化。我们展示了交互强度的量化过程。对于每个示例帧，左侧为全局相机视角下的原始 RGB 观测，右侧为将机器人本体 mask 掉（黑色区域）后的 dense optical flow。“Moving Pix”计数表示环境运动幅度 $\sum (1 - M_t) \cdot \mathbb{I}(\|F_t\|^2 > \delta_{\text{flow}})$ ，其作为阈值判定指标，用于确定二值交互信号 I_t 。

9 VI. 结论

本文提出了 IG-RFT，这是一套面向基于 flow 的 VLA 模型的完整强化微调（reinforced fine-tuning）系统，旨在使其掌握真实世界中的长时程复杂操纵任务。为在 RL 训练中平衡 exploration 与 exploitation，我们创新性地提出：交互状态蕴含了针对长时程任务的强先验引导信息。

9.1 A. Parcel Packing




图 8: 包裹装箱 (Parcel Packing) 任务示意图。

9.2 B. Drink Shelving




图 9: 长时程任务中单次 rollout 期间的 Value 可视化。我们绘制了任务 (A) Parcel Packing 和 (B) Drink Shelving 中由 critic model 预测的状态价值 (Return-to-Go) 轨迹。灰色虚线表示第 IV-A 节设计的参考 value function, 红色实线表示真实世界执行过程中的预测 value。图中从左到右依次展示一次成功任务的关键图像; 蓝色高亮图像对应 value 峰值, 表明该时刻 policy 采取了次优动作。对于每个次优案例, 我们在图像上方用文字说明其可能原因; 时间轴上各子任务阶段以灰色斜体标注。

接触丰富操纵中的一个关键挑战在于: 如何让 policy 在复杂交互过程中持续获得有效改进。基于这一认识, 我们提出了 Interaction-Guided Advantage Weighted Regression (IG-AWR) 算法, 在噪声层面对 flow model 进行动态调制。针对 RL 中稀疏奖励带来的训练困难, 以及任务特定稠密奖励需要精心人工设计、难以扩展的问题, 我们进一步提出了一种混合稠密奖励函数。该奖励同时包含轨迹级和子任务级信号, 兼顾了奖励密度与泛化能力。

此外, 我们的多阶段训练范式清晰展示了 policy 性能的逐步演化过程: 首先通过 SFT 建立基础的域适应能力与 value function 估计能力; 随后利用 Offline RL 进行优化, 实现更高效的 policy 学习; 最后借助 Human-in-the-Loop 修正, 在保持稳健泛化的同时推动 policy 持续演进。四项具有挑战性的真实世界任务实验表明, 该方法相较于 SFT 和标准 RL baseline 均有显著优势, 性能提升约为 40%。我们还开展了全面的 ablation 实验, 以验证各项设计选择的有效性。

作为一种强大且有效的 policy 改进技术, RL 有潜力帮助 SFT 模型突破其表征能力的上限。然而, 现有研究 (包括本文) 更多将 RL 作为一种 fine-tuning 手段, 用于弥合域间差距并提升任务成功率, 而不是像 Large Language Models (LLMs) [62], [63] 那样将 RL 用于大规模训练。我们认为这主要有两方面原因。其一, 在真实世界高维动作空间中, 基于 policy gradient 的 online RL (如 GRPO、PPO) [64], [65] 的采样与探索成本极高; 而仿真又面临显著的 sim-to-real gap, Human-in-the-Loop 引导则高度依赖人工, 因而难以扩展。其二, 目前仍缺乏一种可直接适用于完全 on-policy、online 且面向全新真实世界场景的通用 Reward Model; 缺少这类模型提供的实时反馈, 会给真实机器人上的 on-policy 学习带来巨大挑战。

未来工作将重点沿两个方向展开。首先, 将 RL 用于多任务、跨多种 embodiment 的大规模 VLA post-training。鉴于当前人类反馈仍然不可或缺, 如何高效提供反馈, 从而帮助机器人自主逼近 on-policy exploration, 是一个极具前景的研究问题。其次, 结合 world model 训练大规模 reward model, 尤其是通过 physics-aware video generation 等范式, 将成为推动真实世界机器人可扩展 RL 的关键路径 [66]。

[附录因公式排版问题从译本中省略, 请参阅原文。]