

机器人操纵中 Vision-Language-Action 模型强化学习的综述

Haoyuan Deng*, Zhenyu Wu*, Haichao Liu*, Wenkai Guo, Yuquan Xue, Ziyu Shan, Chuanrui Zhang

2026 年 8 月 17 日

1 机器人操纵中 Vision-Language-Action 模型强化学习的综述

摘要

构建能够执行多样化操纵任务的通用机器人系统，一直是机器人领域的重要愿景。Vision-Language-Action 模型（VLA）通过大规模预训练，并借助模仿学习获得通用的视觉-运动先验，显著推动了这一目标的发展。然而，现有预训练 VLA 在适配真实世界部署时，通常仍需要进一步微调（fine-tuning）。在这一过程中，传统模仿学习由于依赖覆盖有限状态与动作空间的采集数据集，往往难以应对分布外（out-of-distribution, OOD）泛化问题。强化学习（reinforcement learning, RL）则通过自主探索与结果驱动的优化，为提升 VLA 的 OOD 泛化能力提供了可行路径。

本文系统梳理了 RL 如何弥合 VLA 从预训练到真实部署之间的鸿沟，并对 RL-VLA 的训练范式进行了全面综述。我们沿着四个核心维度构建分类体系，以覆盖从学习到部署的完整生命周期：RL-VLA 架构、训练范式、真实世界部署，以及基准与评测。首先，我们介绍 RL-VLA 各组成部分的关键设计原则，包括 action、reward 与 transition 建模。其次，我们回顾 online、offline 与 test-time RL 三类范式，并分析它们在提升 VLA 泛化能力方面的有效性与面临的挑战。再次，我们讨论真实世界部署框架，内容涵盖 sim-to-real 迁移、安全探索、自主恢复以及 human-in-the-loop 对齐。最后，我们总结现有基准测试方法，指出尚未解决的关键挑战，并展望通向通用机器人系统的发展路径。项目主页见原文链接。

索引词——Vision-Language-Action 模型，强化学习，分布外泛化，机器人操纵。

2 1. 引言

长期以来，构建能够在非结构化环境中执行多样化操纵任务的通用型机器人系统，一直是机器人学与人工智能研究的核心目标。近年来，vision-language model (VLM) [1], [2] 的规模化发展，以及大规模机器人学习 [3] 的突破，推动了 VLA [4]–[8] 的出现。这类方法利用异构 teleoperation 数据集与多模态预训练，学习由语言指令条件化的通用视觉-运动先验。当前 VLA 已在跨物体类别、任务变化以及不同 embodiment 的场景中展现出显著的 zero-shot 与 few-shot 泛化能力，这与传统机器人学习中占主导地位的任务专用 policy 形成了明显对比 [9]。然而，现有 VLA 系统大多仍局限于模仿学习，只是在重复预训练数据集中的专家 demonstration。受限的动作空间，以及缺乏失败恢复 demonstration [10]，使得预训练 VLA 在实际部署时面对 OOD 场景往往表现不佳。此外，纯粹的模仿目标也使智能体无法探索原始 demonstration 中未出现的替代策略，甚至更优策略。

为克服这些局限，RL [11]–[15] 已被引入机器人学习，将 policy 学习表述为一种以结果为导向、通过试错进行优化的过程，并借助奖励引导的优化 [16]–[18] 赋予 VLA 在 OOD 场景中的泛化能力。

在此基础上, 基于 RL 的 post-training 也已在 Large Language Models (LLMs) 中表现出显著收益, 不仅提升了模型性能, 还增强了与目标行为的对齐效果, 从而提高其在数学、代码等复杂领域中逐步推理的准确性与连贯性 [19], [20]。这些进展表明了一条清晰路径: 利用 RL 有效增强 VLA 模型的泛化能力。近期的 RL-VLA 工作 [21]–[27] 已展现出二者之间的协同关系: 一方面, VLA 模型蕴含丰富的多模态表征, 可显著提升 RL 方法的样本效率; 另一方面, RL 又使 VLA 能够突破预训练阶段的次优行为。经验结果表明, 经过 RL 优化的 VLA 模型在代表性 benchmark 上取得了显著提升 [24], 且基于 RL 训练得到的 policy 相比仅通过监督微调 (Supervised Fine-Tuning, SFT) 训练的 policy, 具有更强的泛化能力 [28]。这些代表性的 RL-VLA 工作覆盖了多种范式, 包括 offline RL [21], [22]、online RL [23]–[25], 以及 test-time RL [26], [27]。因此, 有必要对这一新兴方向的文献进行系统梳理, 以总结 RL 技术带来的关键启发。然而, 尽管已有综述分别讨论了 RL 在 LLM [29]–[31] 与机器人学 [32], [33] 中的应用, 学术界目前仍缺乏一篇专门聚焦 RL 在 VLA 模型中应用的系统性综述, 而这对于推动该方向更快、更稳健地发展至关重要。

在本文综述中, 我们将全面回顾 RL-VLA, 并阐明从预训练 VLA 模型走向稳健、可部署系统的技术路径。我们提出了一套分类体系 (Fig. 1), 用于组织两类研究: 一类是直接推动 RL-VLA 发展的工作, 另一类是能够为未来框架设计提供启发的互补性机器人学习研究。本文首先介绍 RL 与 VLA 的基础背景, 并概述二者结合面临的关键挑战 (Section II)。随后, 我们分析 RL-VLA 设计中的核心权衡, 包括动作表征、奖励设计与转移建模 (Section III); 接着总结 online 与 offline RL 范式中的关键洞见, 重点关注 policy 的稳健性与自适应能力 (Section IV)。之后, 我们回顾从 sim-to-real transfer 到直接真实世界 RL 的部署框架 (Section V), 并进一步总结 benchmark、评测指标以及现有 RL-VLA 方法 (Section VI)。最后, 我们讨论该领域面临的开放问题与值得关注的未来研究方向 (Section VII)。

3 II. 背景

3.1 A. VLA Models

VLA 代表了机器人学习中的一种新范式: 它在单一端到端框架内统一了视觉感知、语言理解与动作生成 [4], [34]。不同于传统机器人系统中彼此分离的感知、规划与控制模块, VLA 利用大规模预训练 VLM, 直接根据视觉观测与语言指令预测机器人动作。

VLA 的核心架构 [4]–[8] 将 VLM backbone 与动作模块结合, 通常包含三个关键组成部分: 1) 视觉 encoder, 用于将多视角 RGB 图像或深度信息编码为 visual tokens; 2) 语言 encoder, 用于将任务指令嵌入为语义表征; 3) policy decoder, 用于将融合后的视觉–语言表征映射为连续或离散化的机器人动作。代表性工作包括 RT-1 [35], 其采用基于 Transformer 的架构预测离散化动作; 以及 RT-2 [36], 其利用 PaLI-X 实现互联网规模知识迁移。其他模型如 OpenVLA [4], 提出了一个开源 VLA, 在 Llama 2 [37] 基础上结合视觉 encoder, 并融合来自 DINOv2 [38] 与 SigLIP [39] 的特征。在此基础上, OpenVLA-OFT [40] 提出一种优化微调 (Optimized Fine-Tuning, OFT) 方案, 通过引入并行解码与连续动作表征, 显著提升了模型在新场景下的性能与推理效率。此外, π_0 [34] 基于预训练 VLM 构建了一种新的 flow matching 架构, 从而继承互联网规模的语义知识, 并在多种机器人平台上展示出复杂的灵巧操纵能力。进一步地, $\pi_{0.5}$ [5] 在 π_0 的基础上, 通过对异构任务进行联合训练, 实现了更广泛的泛化能力, 并能够在全新的真实世界环境中完成复杂的长时程操纵任务。通过将语言指令锚定到视觉观测上, VLA 支持更加直观的人机交互, 同时能够利用预训练 VLM 中蕴

含的语义知识。借助大规模数据采集、预训练与后训练，VLA 在广泛的任务、物体与环境上展现出很强的泛化能力。

VLA 模型当前占主导地位的训练范式是 IL，通常以监督微调 (SFT) 或 Behavioral Cloning (BC) 的形式实现。

该方法利用大规模、异构的 teleoperation 数据集训练模型，其目标是在给定相应多模态观测的条件下，学习一个能够最大化 expert actions 似然的 policy。然而，这一范式受限于 demonstration 数据的质量与覆盖范围。因此，尽管 VLA 具备端到端框架与一定的涌现能力，它们在发生 domain shift 的场景中仍面临显著挑战，同时对高质量数据有较高要求。这也进一步促使研究者将其与 RL 技术结合，以提升模型的自适应性与鲁棒性。

3.2 B. 面向 VLA 的强化学习

为说明将 RL 方法扩展到 VLA 模型时仍存在的差距，我们首先形式化 RL-VLA 问题，并具体描述其状态表征、动作空间、奖励函数以及环境动力学。我们将机器人操纵任务形式化为一个马尔可夫决策过程 (MDP)，记为元组 $(S, \mathcal{A}, p, r, \gamma)$ 。RL 的目标是学习一个由参数 θ 参数化的 policy $\pi_\theta(a_t|s_t)$ ，使其最大化期望折扣回报 $J(\pi)$ ：

$$J(\pi) = \mathbb{E}_{\tau \sim \pi} \left[\sum_{t=0}^T \gamma^t r(s_t, a_t) \right] \quad (1)$$

其中， $\tau = (s_0, a_0, s_1, a_1, \dots)$ 表示由该 policy 生成的轨迹， T 为任务时域。在 RL-VLA 语境下 [41], [42]，上述形式化具有鲜明的专门化特征。状态 S 是多模态且高维的，通常定义为 $s_t = (o_t^{\text{vis}}, o_t^{\text{prop}}, l_{\text{task}})$ ，其中包含视觉观测（例如 RGB 图像、点云）、proprioception 信息（例如关节角、end-effector 位姿）以及语言指令。动作 $\mathcal{A}$ 中的 $a_t \in \mathbb{R}^d$ 由 VLA 的 decoder 基于其内部隐藏状态生成。值得注意的是，VLA 往往不会输出单步动作，而是借助 diffusion decoder 或 action tokenizer 等机制，输出 action chunk $a_{t:t+k-1}$ [43]。奖励 $r(s_t, a_t)$ 是优化过程的关键，通常会用于表征任务是否成功的稀疏二值信号，与基于过程的稠密奖励（例如到目标的距离）结合起来，从而提供更丰富的学习信号 [28]。最后，转移模型 $p(s_{t+1} | s_t, a_t)$ 要么在仿真环境中显式定义，要么在真实机器人场景中由机器人所感知的物理交互隐式决定 [44]。

为求解最优决策而发展的 RL 算法大体可以分为三类。第一类是基于价值的方法，例如 Deep Q-Network (DQN) [45]，其核心在于估计价值函数，以判断每个状态或状态-动作对所对应的期望累计奖励。第二类是 policy gradient 方法，例如 Proximal Policy Optimization (PPO) [46]，其通过计算期望回报相对于 policy 参数的梯度，直接优化 policy。本质上，第三类 actor-critic 方法，例如 Soft Actor-Critic (SAC) [47]，结合了前两者的思想，同时学习价值函数 (critic) 与 policy (actor)。此外，这些方法还可进一步分为 model-free 与 model-based 两类：前者直接通过与环境交互学习 policy，后者则先学习转移模型 p 。另一个常见划分维度是 on-policy 与 off-policy：前者使用当前 policy 采集的数据进行学习，后者则依赖 replay buffer 中的数据。

3.3 B. 用于 VLA 的强化学习（第 2 部分）

尽管强化学习 (RL) 已经取得了显著进展，但将 RL 与 VLA 模型结合仍面临一系列独特挑战，尚需进一步研究。现有早期的 RL-VLA 工作已经奠定了重要基础，并展示出很有前景的发展方向。这些方法覆盖了多种范式，包括 offline、online 和 test-time RL。

在 offline RL 设定中, policy 仅从固定、预先收集的数据集中学习。ReinboT [21] 通过预测稠密 return 来引入 RL 思想, 从而更好地利用质量混杂的数据; CO-RFT [22] 则提出了 Chunked RL, 这是一种新的框架, 将时序差分 (temporal difference, TD) 学习扩展为能够兼容许多 VLA 中固有的 action chunking 机制。

对于 online RL, 其核心是在试错过程中主动收集新经验以持续改进 policy。VLA-RL [23] 提出了 trajectory-level 的 RL 建模方式, 并使用 VLM 作为机器人过程奖励模型 (robotic process reward model), 以缓解稀疏奖励带来的困难。类似地, SimpleVLA-RL [24] 提供了一个高效的 RL 框架, 并结合了能够增强探索的策略, 使 policy 可以发现 demonstration 数据之外此前未见的行为模式。

最后, test-time 方法关注在部署阶段提升 policy 性能。V-GPS [26] 提出了 Value-Guided Policy Steering, 在不更新任何模型权重的情况下, 利用通过 offline 学习得到的 value function 对 policy 产生的动作进行重排序; Hume [27] 则实现了一个双系统模型, 在运行时通过采样多个动作候选并从中选择最佳动作, 执行 value-guided 的 System-2 thinking。

尽管 VLA-RL 已经取得了开创性进展并展现出令人瞩目的效果, 但要让这类系统能够在动态、开放式的物理环境中实现稳健运行, 仍然存在诸多关键挑战, 也为后续研究留下了大量空间。

4 III. RL-VLA 的架构

尽管基于模仿学习的预训练已经使 VLA 模型在多种操纵任务上取得了较强性能, 但其泛化能力仍然受限于离线数据覆盖范围不足, 尤其是在 OOD 状态下更为明显。为缓解这一问题, 近期研究开始将预训练 VLA 模型与 RL 相结合, 把原本的 open-loop inference 转化为由在线反馈驱动的 closed-loop 优化过程。在这一设定下, policy 与环境持续交互, 收集 trajectory, 并在奖励引导的更新过程中逐步调整自身行为。

基于这一思路, 本节将介绍 RL-VLA 的整体架构, 重点说明 Action、Reward 与 Transition Modeling 如何协同组织, 从而联合优化感知、决策以及环境动力学建模。

4.1 A. Action

在 RL-VLA 中, action model 是连接视觉观测与物理交互动作的桥梁。预训练 VLA 通常以 open-loop 的方式生成动作, 而 RL 进一步引入任务级监督, 使 policy 能够通过交互与反馈不断调整, 从而获得更强的泛化能力。按照操纵动作空间的预测方式划分, RL 在动作生成优化中可扮演不同角色: 既可以对自回归动作模型施加 token 级监督, 也可以对生成式动作模型进行序列级优化, 还可以在结合高层推理与底层控制的双系统 VLA 中承担分层协调的作用。

1) 自回归模型: 自回归 VLA 遵循语言建模范式, 将机器人 manipulation 表述为离散 token 空间中的序列决策过程, 并通过 next-token prediction 逐步生成动作。RL 可以直接利用自回归 VLA 输出的 token 预测概率, 结合 token 级监督与奖励驱动机制, 实现更稳定的 policy 优化。该范式已在机器人场景中展现出更好的任务适应性与泛化性, 并推动了一系列后续工作 [22]–[24], [28], [48], 分别探索面向 online 微调 (fine-tuning) 与 offline policy 改进的自回归 RL-VLA。具体而言, TGRPO [48] 将 policy gradient 目标重写为由 advantage 加权的 token 级 cross-entropy loss, 从而在不改变 action head 形式的前提下, 实现对 VLA 动作生成的稳定 RL 微调。CO-RFT [22] 则进一步利用动作概率的时空动态特性, 缓解自回归 VLA 在离散动作预测中轨迹一致性较差的问题。

潜在挑战: 尽管自回归 VLA 能为 RL 训练目标直接提供动作预测概率, 但离散动作 token 使其在灵巧操纵任务中面临困难。较粗粒度的 token 设计会削弱 VLA 的精细控制能力; 而更细粒度的

tokenization 又会降低不同动作 token 之间的可区分性，显著增加动作预测的难度。

2) 生成式动作 VLA: 为解决离散动作预测时序一致性不足的问题，近年来研究者开始关注利用基于 diffusion 的 [133]–[135] 或 flow matching 的 [5], [34], [136] action head, 直接生成动作轨迹。然而，生成式 action head 无法显式给出动作预测概率，这使得生成式 RL-VLA 的优化目标难以直接构造。近期工作主要通过对生成式 action head 的输出进行重参数化，近似得到动作预测概率，从而使 RL 能够对 VLA 进行监督。 π_{RL} [25] 采用 Flow-SDE 或 Flow-Noise 干预对过程进行去噪，生成动作分配的近似概率，以适配现有 RL 的 policy 更新方式。为进一步提升 RL-VLA 的训练稳定性，一些研究开始分析训练过程中 sample 的影响。FPO [49] 以每个 sample 的变化量替代动作概率，缩小了 flow-matching head 与 RL 更新 policy 之间的差距，同时增强了收敛稳定性。ARFM [50] 提出动态缩放因子调节策略，用于更新各个 sample 的权重，从而提高 sample 利用效率，并实现更稳定的 RL-VLA 训练。

潜在挑战: 生成式 VLA 依赖近似密度或基于 loss 的 agent，而这些 agent 往往仅在高奖励区域内进行调节，因此其更新并非由全局动作分布驱动，而是依赖局部采样且并不完美的信号。结果是，agent 与预训练行为之间的微小失配，可能在多步生成和迭代更新过程中不断累积，最终导致原始动作分布的部分区域发生扭曲，甚至塌缩。

4.1.1 双系统模型

3) 双系统模型: 为了进一步提升 VLA 理解人类指令并执行长时程任务的能力，研究者提出了双系统的 VLM-VLA 架构。具体而言，高层任务规划 VLM 负责理解人类意图，并生成分步子任务；低层动作控制 VLA 则负责输出操纵轨迹。然而，VLM 与 VLA 之间的价值错位 (value misalignment) 会导致双系统性能下降。近期研究采用 RL 促进两个系统之间的双向价值对齐，从而确保 VLM 生成的子任务能够被 VLA 实际执行。Hume [?] 使用 RL 训练高层任务规划系统，使其能够从多个采样动作中选择最优动作，从而显著提升了低层控制的可行性。




图 1: RL-VLA 的分类体系，覆盖 VLA 模型的完整 RL 优化流程。图中以粗体标出的参考工作表示直接推动 RL-VLA 发展的研究，其余工作则属于机器人学习中的补充性研究，为未来 RL-VLA 框架设计提供参考。

潜在挑战 双系统 VLA 的核心挑战之一，是在高层 VLM 规划器与低层 VLA 控制器之间实现可靠的价值对齐。由于二者在表征形式和时间尺度上具有异质性，来自语言规划层的价值估计往往会与控制层的实际回报发生偏离，进而导致联合 RL 训练不稳定，并使系统协同效果欠佳。

4.2 B. Reward

强化学习 (RL) 中的 reward 是最基本的学习信号：它用于量化任务是否成功，并指导 policy 优化；同时，它还决定了梯度方差与所学 policy 的收敛效率，从而影响整体学习动态。RL-VLA 借助 reward 驱动的反饋机制，能够突破模仿学习的局限，实现对 OOD 场景的高效泛化。然而，reward 的稀疏性与延迟性会使 VLA 在 policy 优化时面临困难，这也严重阻碍了 RL-VLA 的实际部署。为应对上述挑战，近期方法通常通过构造稠密且信息丰富的 reward 信号来有效引导 policy 优化。按照 reward 的来源，这些方法大致可分为内在奖励 (intrinsic rewards) 与外在奖励 (extrinsic rewards) 两类。




图 2: RL-VLA 对动作的优化方式。自回归 VLA 在 token 级别优化动作；生成式 VLA 沿着动作生成过程在序列级别进行优化；双系统 VLA 则在桥接层（bridge-level）进行优化，其中 RL 决定将哪个高层动作 proposal 传递给快速控制器，因此它能够补充前两类动作 policy。

4.2.1 1) 内在奖励 (Intrinsic Rewards)

内在奖励是基于规则的自监督信号，通常来源于数据集，或来源于 agent 与环境交互过程中产生的信号，用于鼓励 agent 主动探索并构建自身行为。通过提供自驱动反馈，内在奖励使 RL-VLA 即便在外在奖励稀疏或延迟的情况下，仍能保持稳定学习，并探索具有意义的行为。根据奖励动机，现有方法大致可以分为基于势函数的 reward shaping 和探索驱动奖励两类。

基于势函数的奖励塑形 (Potential-based Reward Shaping, PBRs) PBRs 提出利用辅助势函数 (potential function) 来修正原始 reward 信号： $r'(s, a, s') = r(s, a, s') + \gamma \Phi(s') - \Phi(s)$ 其中， Φ 表示势函数 [16], [137]。PBRs 通过势差重塑 reward 分布，在不改变最优 policy 的前提下提供更稠密、信息量更高的反馈，因此能够显著提升训练稳定性与收敛效率。近期方法中的势函数既可以人工设计，例如采用 distance-to-goal [138]、能量下降等启发式信号；也可以从数据中学习得到，例如近似价值函数 [139] 或潜在进度估计器 (latent progress estimator)。前者具有更好的可解释性和简洁性，而后者适应性更强，但也可能引入不稳定的 shaping 效应。

探索驱动奖励 (Exploration-driven Rewards) 探索驱动奖励通过为探索行为赋予额外的内在价值，鼓励 agent 访问新颖或不确定的状态，从而增强其发现未知动力学的能力，并避免过早收敛到次优 policy。基于好奇心 (curiosity-driven) 的方法 [140], [141] 会在 agent 访问预测误差较高的状态时给予奖励，因为这类状态通常意味着环境中存在新的动力学信息。Random Network Distillation (RND) [51], [142] 将这一思想扩展到更大规模的设置中：它通过 agent 在一个固定随机网络上的预测误差来衡量其对当前状态的熟悉程度。类似地，基于计数 (count-based) 的方法 [52] 会对访问次数不足的状态给予奖励，以保证对状态空间进行更系统的覆盖。

潜在挑战 (Potential Challenges) 尽管内在奖励具有较强的自主性，但它们通常缺乏与任务目标的显式对齐。这可能导致不恰当且不一致的行为，例如 reward hacking [143]、高维空间中的 reward collapse [144]，或者 policy 倾向于利用那些容易获得内在奖励的行为模式，却并未真正推动任务进展。此外，内在奖励依赖于自主探索，因此在长时序操纵任务中往往效率较低，因为大多数新颖状态与任务本身并不相关。

4.3 外部奖励 (Extrinsic Rewards)

外部奖励利用外部感知信息来引导智能体行为，例如语言指令、视觉观测和人类反馈。这类奖励能够促进 policy 与任务目标之间的对齐。不同于来源于内部探索动态的内在奖励，外部奖励通过外部反馈或结构化解释直接编码任务目标，因此 policy 优化过程更具落地性，也更易解释。现有方法按监督来源大致可分为两类：人类对齐奖励 (human-aligned rewards) 和模型生成奖励 (model-generated rewards)。

4.3.1 人类对齐奖励 (Human-aligned Rewards)

人类对齐奖励用于表征人类偏好，使智能体在 policy 更新过程中与人类价值和需求保持一致，从而更有效地完成面向人的任务要求。Reinforcement Learning from Human Feedback (RLHF) [145] 通过对行为对之间的人类偏好比较进行训练，学习一个 reward model。SEED [146] 将 RLHF 用于缓解奖励稀疏问题，通过评价式反馈提供监督。

除静态偏好数据集外,交互式方法还会在训练过程中主动查询人类反馈。DemPref [17] 在 policy 生成的轨迹上迭代查询偏好标签,从而提升人类反馈闭环中的样本效率。Sirius [110] 和 Transic [106] 则允许人在训练过程中持续修正已学习的 reward function, 从而实现 human-in-the-loop 的奖励塑形 (reward shaping)。

4.3.2 模型生成奖励 (Model-generated Rewards)

模型生成奖励主要依赖预训练基础模型,而非人类直接反馈。这类方法能够使智能体行为与基础模型中蕴含的常识保持一致,并在多样环境中提供可扩展的监督。Reward Translator [147] 将语言指令和交互数据翻译为参数化的奖励代码,建立从自然语言任务描述到机器人强化学习的桥梁。Eureka [18] 则结合 LLM 生成的候选奖励代码与环境反馈,迭代进化奖励函数,并且在多种 manipulation 技能上常常优于人工设计的奖励。

近期工作 [148] 还表明,可以将 LLM/VLM 作为代理,在无人干预的情况下学习有效的 reward function。DVD [149] 通过判别人类视频与机器人视频之间的任务相似性来学习多任务奖励,并实现 zero-shot 泛化。视频生成模型提供了另一条路径:VIPER [54] 从专家 demonstration 中学习视频预测 transformer,并将模型似然作为奖励;TeViR [150] 使用 text-to-video diffusion model 生成预测图像序列,再通过与真实观测进行比较来计算奖励。

还有一些方法利用 VLM 进行时序推理与对比学习。GVL [55] 将奖励估计建模为视频帧的时间排序问题;ReWiND [151] 通过向任务序列中加入回退帧 (rewinding frames) 来提升对失败情形的鲁棒性;VLAC [53] 则通过引入负样本的对比学习增强奖励的可解释性。另一类基于查询的方法,如 RoboCLIP [56]、RL-VLM-F [152] 和 RG-VLM [153], 直接向 VLM 查询图像观测和文本任务描述对应的奖励,展示出强大的生成能力,能够有效捕捉任务进度。

这些方法共享一个核心思想,即奖励分布对齐 (distributional alignment): 当智能体行为与专家数据或互联网规模视频中学习到的行为分布更一致时,就会获得更高奖励。

4.3.3 潜在挑战 (Potential Challenges)

尽管外部奖励能够提供直接的任务监督,但在可扩展性、可靠性和对齐性方面仍面临持续挑战。无论是人类对齐奖励还是模型生成奖励,都容易受到奖励误设定 (mis-specification)、领域偏移 (domain shift) 以及感知噪声的影响,这限制了它们在复杂真实场景中的实际效果。

4.4 C. Transition Modeling

强化学习 (RL) 中的 transition modeling 旨在刻画以动作为条件的环境动力学,使智能体能够根据真实物理后果及其对应奖励来推断动作序列。对于 RL-VLA 系统而言,transition modeling 进一步赋予 VLA 进行预测性 rollout 并借助 simulator 评估动作序列的能力,从而弥补传统 VLA 在长时程动力学以及动作-结果因果关系推理上的不足。现有 transition modeling 方法大体可分为两类: physics-based simulator, 以及基于未来预测范式的 neural world model。

1) Physics-based Simulator physics-based simulator 通过精确的物理建模显式复现环境动力学。具体而言,这类方法定义环境中各个物体的属性及其相互作用,从而在给定特定动作时预测精确的状态转移。现有研究通常利用物体与场景资产 (assets), 将真实世界中的场景结构和物体参数迁移到 simulator 中。这种对齐方式能够显著提升 RL-VLA policy 从仿真环境到真实物理环境的迁移能

力。借助精细的力学与动力学引擎, Isaac Sim [?] 和 Gazebo [?] 等 simulator 能够在动作序列条件下高精度地生成环境转移。

潜在挑战 构建高保真 simulator 往往需要大量人工投入以及准确的物理标注; 同时, 基于物理的 rollout 计算开销仍然较高, 这限制了其在数据需求较大的学习系统中的可扩展性。

2) Learning-based World Model learning-based world model 采用数据驱动的 transition modeling 方式。与依赖显式物理规则不同, 这类方法直接从大规模操纵 demonstration 中学习预测未来状态。world model 将环境动力学编码到潜在表征或像素级观测中, 并能够在当前状态与动作条件下生成合理的 rollout。当前的 world model 在 VLA 框架中主要包括三类: 基于状态的方法、基于观测的方法, 以及两者的融合形式。

State-based Methods 基于状态的方法将环境编码到紧凑的潜在状态空间中, 以高效建模状态转移。这样, 模型可以直接预测长时程动力学和奖励, 而不必重建完整的视觉观测。PlaNet [?] 采用 Recurrent State-Space Model 构建动态 world model, 从而能够针对给定动作序列预测未来潜在状态和奖励。Dreamer [?] 与 DreamerV2 [?] 进一步提升了潜在状态空间的表达能力, 因此增强了长时程规划质量以及 model-based reinforcement learning (MBRL) 的整体性能。TransDreamer [?] 则用基于 transformer 的模型替代 recurrent 架构, 以获得更稳定的长时程预测。

然而, 这类方法通常将图像重建视为辅助目标, 因此对精确视觉观测建模的重视程度有限。结果是, 它们在真实世界场景中的生成能力较弱, 也无法充分利用大规模视频数据。

4.5 C. Transition Modeling (第 2 部分)

基于观测的方法 基于观测的方法直接对像素级观测的状态转移进行建模, 因此能够生成兼顾几何一致性与视觉保真度的真实环境 rollout。相比之下, 这一范式更适合表征真实世界物理过程, 也使奖励能够与视觉预测结果对齐。iVideoGPT [60] 利用大规模自回归视频预测模型 [157], 并将预训练模型微调 (fine-tuning) 到机器人场景中。该预训练视觉 world model 在结合学习得到的奖励模型后, 可作为 MBRL 任务中的神经模拟器。GWM [61] 和 iMoWM [62] 进一步引入多模态数据, 以更好地表征环境的三维几何结构, 从而提升 MBRL 任务性能。由于奖励在反映对物理世界的理解时与视觉保真度天然耦合, 这类模型通过同时提升视觉质量和奖励预测精度, 展现出跨多样任务的较强泛化能力, 并显著增强了 MBRL 的性能。

然而, 如果仅依赖真实世界数据分布进行学习, 而忽略强物理先验, 这类模型的可靠性会下降, 尤其是在复杂场景或分布外场景中更为明显。EmbodiedDreamer [63] 针对这一局限引入了 PhysAligner 和 VisAligner。前者融合基于物理模拟器的先验, 以提供物理一致的转移动力学; 后者则利用视频修复技术提升生成观测的真实性。尽管该方法改善了物理精度, 但由于引入了物理模拟器, 其计算效率低于通常依赖学习的 world model 所具备的效率优势。

面向 VLA 设计的方法 将 world model 集成到 VLA 框架中, 有助于打通语言条件推理与物理环境理解之间的鸿沟。在这一设定下, world model 负责预测未来观测的状态转移, 而奖励模型则通过 RL 对 VLA 生成的动作进行评估与优化。VLA-RFT [65] 基于 VLA 的动作序列生成多个 rollout, 并采用 GRPO 优化框架 [19], 利用 world model 预测的奖励来更新 VLA 模型。World-Env [66] 构建了一个 RL-VLA 流水线: 由 VLA 模型生成动作序列, world model 预测未来观测, 视觉语言模型产

生语义反思 (semantic reflections)，再通过 LOOP 优化策略 [158] 进行 policy 精炼。WMPO [67] 则提出了一个基于 world model 的 policy 优化框架：它通过生成像素级的 imagined trajectories，并利用学习得到的奖励模型所预测的奖励，借助 GRPO 对 policy 进行优化，从而在无需与真实环境交互的情况下，为 VLA 模型实现强化学习。

潜在挑战 尽管近年来已经取得了一定进展，world model 在跨多样场景、不同 embodiment 形式以及不同机器人形态上的泛化能力仍然有限。为了提升模型可靠性，引入来自人类知识或高保真模拟器的物理先验至关重要；但如何在数据驱动学习与物理一致动力学之间取得平衡，仍然是构建鲁棒且可迁移模型的核心挑战。

5 IV. RL-VLA 的训练范式

RL 训练是使 VLA 能够基于大规模预训练数据实现 OOD 泛化的关键步骤。现有 RL-VLA 的训练范式可以根据智能体获取并利用环境反馈的方式分为三类：Online RL-VLA，即训练过程中直接与环境交互；Offline RL-VLA，即在不再与环境进一步交互的情况下，从静态数据集进行学习；以及 Test-time RL-VLA，即模型在部署阶段自适应地调整自身行为，但不改变其参数。我们还在表 I 中总结了具有代表性的 RL-VLA 工作细节。

5.1 A. Online RL-VLA

Online RL-VLA 范式支持交互式 policy 学习：智能体持续与环境交互，收集 trajectory，并依据观测到的奖励与状态转移不断更新自身。在线 RL-VLA 中基于试错的学习过程，使预训练 VLA 具备了自适应的 closed-loop 控制能力，从而能够更有效地将 VLA 扩展到真实世界中的 OOD 环境。现有关于 online RL-VLA 的研究主要沿 5 个方向推进：policy optimization、样本效率、训练稳定性、学习框架以及主动探索。

1) Policy Optimization Policy optimization 决定了 VLA 如何依据环境奖励更新其 policy，因而直接影响 online RL-VLA 的稳定性与效率。过于激进的优化会破坏预训练 action space 中已有的结构，导致训练不稳定；而过于保守的策略又需要大量环境交互，从而显著抬高训练成本。近期工作通常采用 PPO 的变体来缓解这一权衡，同时提升学习效率与训练稳定性。

一方面，FLaRe [68] 将 PPO 算法用于 VLA 模型的 post-training，是该方向的奠基性工作之一；随后，RLRC [69] 同样采用 PPO 对 VLA 模型进行微调 (fine-tuning)。更近期的 RIPT-VLA [41] 在 post-training 中结合了 Leave-One-Out (RLOO) 优势估计与 PPO，使模型在无需 shaped reward 或 value function 的情况下实现高效学习。

另一方面，VLA-RL [23] 使用 PPO 对自回归 VLA 模型进行微调，并引入 Robotic Process Reward Model 提供稠密奖励，从而提升学习效率。SimpleVLA-RL [24] 将 GRPO 引入更稳定的 policy 更新过程中，并在 LIBERO benchmark 上取得了显著的性能提升。尤其值得注意的是，实证研究 RL-VLA [42] 对 DPO、PPO 和 GRPO 在 VLA 模型 online RL 微调中的表现进行了系统比较，并给出了有力证据：相比标准的监督式微调，基于强化学习的微调能够显著增强模型在 OOD 场景下的泛化能力。DeepThinkVLA [72] 引入带有 causal attention 的 CoT，并采用 GRPO 进行 policy optimization，以在因果层面对完整的推理-动作序列与目标结果进行对齐。

对于基于 flow matching 的 VLA 模型，也有一些工作探索了专门的 policy optimization 算法。FPO [49] 提出了 Flow Policy Optimization 算法，在基于 flow matching 的 VLA 模型中实现 importance sampling，以提高 policy optimization 的效率。 π_{RL} [25] 则面向基于 flow matching 的 VLA 模型提出了两种新的 online RL 算法：其一是 Flow-Noise，将去噪过程建模为离散时间 MDP；其二是 Flow-SDE，将去噪过程与智能体-环境交互统一建模。还有一些工作从 RL alignment 的角度展开研究。例如，GRAPE [71] 通过生成定制化 cost，并在 trajectory 级别数据上优化 policy，实现了基于偏好的 VLA 对齐。RobustVLA [73] 提出一种轻量级的 online RL post-training 方法，通过引入 Jacobian regularization 和 smoothness regularization 项，提升 VLA 模型在扰动下的鲁棒性与可靠性。

潜在挑战 真实世界任务的需求多样且动态变化，这会显著扩大 action space，从而给 online RL-VLA 中的 policy optimization 带来挑战。同时，真实环境通常具有非平稳动力学与多模态噪声，而现有 policy optimization 方法大多面向仿真环境或静态 benchmark 设计，因此往往难以在这类环境中维持稳定、可靠的更新。

5.2 Sample Efficiency

样本效率用于衡量 RL-VLA 在有限预算下学习有效 policy 的能力。对于在线 RL-VLA 而言，这一点尤为关键，因为真实交互的成本通常很高。现有方法主要从两个方向提升样本效率：一是利用 demonstration 先验知识，二是设计更稠密的监督信号。

RLDG [75] 将人类专家 demonstration 与在线 RL 微调（fine-tuning）相结合，以提升样本效率。该方法通过蒸馏在多样化数据集上训练得到的通才 policy 的知识，在新任务中借助有针对性的探索以及对先验知识的利用来加速学习。

iRe-VLA [74] 采用两阶段训练流程：首先进行监督微调 warmup，随后再开展在线 RL。该策略显著减少了在复杂 manipulation 任务中达到熟练性能所需的交互次数。

VLAC [53] 在单个 VLM 模型内集成了 actor-critic 架构，使模型在生成动作的同时，还能预测稠密的 progress delta 和 done 信号，从而显著提升训练过程中的样本效率。

- 类型 (Type): MB 表示 Model-based, MF 表示 Model-free。
- 动作 (Action): AR 表示 Autoregressive, Diffusion 表示扩散, Flow 表示 Flow-matching。
- 奖励 (Reward): D 表示 Dense Reward, S 表示 Sparse Reward。
- 算法 (Algorithm): CQL 表示 Conservative Q-Learning, AC 表示 Actor-Critic, Cal-QL 表示 Calibrated Q-Learning, BC 表示 Behavior Cloning, DT 表示 Decision Transformer, RTG 表示 ReturnToGo, TD3 表示 Twin Delayed Deep Deterministic Policy Gradient, ARFM 表示 Adaptive Reinforced Flow Matching, PA-RL 表示 Policy-Agnostic RL, SACfD 表示 Soft Actor-Critic from Demonstrations, TPO 表示 Trajectory-wise Preference Optimization, LOOP 表示 Leave-One-Out Proximal Policy Optimization, GRPO 表示 Group Relative Policy Optimization, DPO 表示 Direct Preference Optimization, FPO 表示 Flow Policy Optimization, SAC 表示 Soft Actor-Critic。

5.3 A. Online RL-VLA（第 3 部分）

表 1: Online RL-VLA（第 3 部分）方法汇总。Sim. 表示仿真环境，Real 表示真实环境；Action 中，AR 表示自回归，Diffusion 表示扩散式动作生成，Flow 表示 flow matching 类动作生成；Reward 中，S 表示稀疏奖励，D 表示稠密奖励；Type 中，MF 表示 model-free，MB 表示 model-based。个别原表存在字符缺失或排版截断，以下尽量按原文忠实整理。

范式	方法	日期 ↑	Sim.	Real	基座 VLA 模型	Action	Reward	Algorithm	Type
Offline RL	Q-Transformer [90]	202310	✓	x	Transformer	AR	S	CQL [159]	MF
	PAC [91]	202402	✓	✓	Perceiver-Actor-Critic	AR	S	AC	MF
Offline RL	ConRFT [85]	202504	x	✓	Octo-small [133]	Diffusion	S	Cal-QL + BC	MF
	ReinboT [21]	202505	✓	✓	ReinboT	AR	D	DT + RTG	MF
	CO-RFT [22]	202508	x	✓	RoboVLMs [160]	AR	D	Cal-QL + TD3 [161]	MF
	ARFM [50]	202509	✓	✓	$\pi 0$	Flow	D	ARFM	MF
Online RL	RECAP [88]	202511	x	J	$\pi 0.6$	Flow	D	RECAP	MF
	NORA-1.5 [89]	202511	✓	✓	NORA-1.5	AR / Flow	D	DPO	MB
	FLaRe [68]	202409	✓	✓	SPOC [162]	AR	S	PPO	MF
	PA-RL [86]	202412	✓	✓	OpenVLA	AR	S	PA-RL	MF
	RLDG [75]	202412	x	✓	OpenVLA / Octo	-	-	-	-
	iRe-VLA [74]	202501	✓	✓	iRe-VLA	AR	S	SACfD [164] + SFT	MF
	GRAPE [71]	202502	✓	✓	OpenVLA	AR	D	TPO	MF
	SafeVLA [120]	202503	✓	x	SPOC	AR	S	PPO	MF
	ConRFT [85]	202504	x	✓	Octo-small	Diffusion	S	Cal-QL + BC	MF
	RIPT-VLA [41]	202505	✓	x	QueST [165] / OpenVLA-OFT	AR	S	LOOP [158]	MF
	VLA-RL [23]	202505	✓	x	OpenVLA	AR	D	PPO	MF
	RLVLA [42]	202505	✓	x	OpenVLA	AR	S	PPO / GRPO / DPO [166]	MF
	RFTF [76]	202505	✓	x	GR-MG [167], Seer [168]	AR	D	PPO	MF
	Online RTGRPO [48]	202506	✓	x	OpenVLA	-	-	-	-
	RLRC [69]	202506	✓	x	OpenVLA	AR	S	PPO	MF
	SimpleVLA-RL [24]	202509	✓	V	OpenVLA-OFT	AR	S	GRPO	MF
	Dual-Actor FT [77]	202509	✓	✓	Octo / SmolVLA	Diffusion	S	QL + BC	MF
	Generalist [78]	202509	✓	✓	PaLI 3B [169]	AR	D	REINFORCE [170]	MF
	VLAC [53]	202509	x	✓	VLAC	AR	D	PPO	MF
	AC PPO [70]	202509	✓	x	Octo-small	AR	S	PPO + BC	MF
	VLA-RFT [65]	202510	✓	x	VLA-Adapter [171]	Flow	D	GRPO	MB
	RLinf-VLA [28]	202510	1	✓	OpenVLA / OpenVLA-OFT	AR	S	PPO / GRPO	MF
	FPO [49]	202510	✓	x	$\pi 0$	Flow	S	FPO	MF
	ReSA [95]	202510	✓	x	OpenVLA	AR	D	PPO + SFT	MF
	π RL [25]	202510	V	x	$\pi 0 / \pi 0.5$	Flow	S	PPO / GRPO	MF
	PLD [81]	202510	✓	✓	OpenVLA / $\pi 0$ / Octo	AR / Flow	S	Cal-QL + SAC	MF
	DeepThinkVLA [72]	202510	✓	x	$\pi 0$ -Fast	AR	S	GRPO	MF
	World-Env [66]	202511	✓	—	OpenVLA-OFT	AR	D	PPO	MB
	RobustVLA [73]	202511	✓	x	OpenVLA-OFT	AR	D	PPO	MF
	WMPO [67]	202511	✓	✓	OpenVLA-OFT	AR	S	GRPO	MB
	SRPO [79]	202511	✓	✓	OpenVLA* / $\pi 0$ / $\pi 0$ -Fast	AR / Flow	D	SRPO	MF
Test-time RL	V-GPS [26]	202410	✓	✓	Octo / RT-1 / OpenVLA	AR	D	Cal-QL	MF
	Hume [27]	202506	✓	✓	Hume	Flow	S	Value Guidance	MF
	VLA-Reasoner [96]	202509	✓	✓	OpenVLA / SpatialVLA [172] et al.	AR / Diffusion	D	MCTS	MB

5.4 A. Online RL-VLA（第 4 部分）

在线 RL 微调方面，DAFT [77] 将人类反馈引入探索过程中的干预环节，构建了语言-干预配对数据集，从而显著加速了在线 RL-VLA 中的 policy 学习。Generalist [78] 提出了一种多阶段训练流程，将 SFT 与在线 RL 自我提升结合起来，并利用精心设计的奖励函数来保证无监督学习。SRPO [79]

提出一种自参照 RL 框架，将 policy 自身的成功轨迹作为自参考信号来获得渐进式奖励，无需额外的奖励标注。

潜在挑战： 尽管现有工作已经取得了一定进展，但当前在线 RL-VLA 方法在样本效率方面仍然难以兼顾可扩展性与泛化能力。多数方法主要关注于提升特定任务或环境中的数据利用效率，却难以将已学到的行为高效迁移到不同目标或不同域中。这限制了大规模 RL-VLA 利用共享经验，在新环境中进一步扩展学习能力。

5.4.1 3) 主动探索

主动探索 (active exploration) 的目标，是设计高效的探索 policy，引导智能体 rollout 出能够带来更高性能增益的动作样本，从而缓解传统 RL-VLA 中随机 rollout 所带来的冗余成本。现有方法可以利用语义信息、latent-level 表征以及信息差异来引导探索 policy。

Plan-Seq-Learn [80] 使用 LLM 生成高层任务规划，将其转换为运动规划中的 way-point，并训练一个基于视觉的低层 RL policy 去跟随这些 way-point，从而将探索动作引导到与任务相关的空间中。SIME [173] 在 RL 微调阶段引入 modal-level 探索，使机器人能够在推理空间中生成多样化的多模态交互行为，而不局限于预训练 policy 的典型输出。SOE [83] 学习任务相关因素的 latent representation，并将探索约束在有效动作的流形上，从而同时保证安全性、多样性和有效性。ASID [82] 利用主动探索 policy 高效采集少量但信息量高的真实世界数据，以识别环境中未知的物理参数，进而构建更精确的模拟器，用于训练鲁棒控制 policy。RESample [84] 能够自动生成具有挑战性的分布外数据，通过探索式采样构造失败轨迹与恢复轨迹，迫使模型学习如何从标准离线数据集中通常不会出现的错误中恢复。PLD [81] 采用一种混合 rollout 机制，使残差干预更偏向于 base policy 经常访问的状态；这样既能让采集到的轨迹与 generalist 的实际部署分布保持一致，又能够捕捉恢复行为。

潜在挑战： 当前方法生成探索策略时，往往依赖高维 latent representation，而这类表征中常常混入与任务无关的噪声，从而降低引导质量并限制探索效果。此外，在真实环境中实现安全的主动探索仍然十分困难，因为这类引导机制通常既缺乏充分可解释性，也缺少严格约束，因而可能产生具有风险的行为，进而损害环境或机器人本体。

5.5 在线 RL-VLA (第五部分)

4) 训练稳定性 稳定的在线 RL-VLA 训练能够保证 policy 更新的一致性，从而避免在 policy 训练过程中因振荡式收敛而导致的泛化能力下降。现有研究主要通过扩大 sample buffer 的规模、降低样本分布方差来实现稳定的在线训练。RIPT-VLA [41] 采用 Dynamic Rollout Sampling，这是一种拒绝采样机制，用于缓解在线 RL 微调过程中由于 rollout return 高方差带来的不稳定性。ConRFT [85] 引入离线 RL 预训练，在基于 HII-SERL [44] 框架进行在线微调之前先稳定初始 policy。与此类似，PA-RL [86] 提出统一框架，从一个通用损失函数出发，直接优化 action 并进行在线微调，从而将 policy 改进与模型参数更新解耦，提升训练稳定性。TGRPO [48] 则进一步提出轨迹级估计方法，即 Trajectory-wise Group Relative Policy Optimization，以降低 policy 更新中的方差并增强训练过程的稳定性。除此之外，基于 world model 的 RL 也是提升训练稳定性的另一条路径。World-Env [66] 和 VLA-RFT [65] 都将学习得到的 world model 作为模拟器来生成合成 rollout，从而降低真实世界交互带来的方差与不稳定性。

潜在挑战 现有用于稳定在线 RL-VLA 训练的方法，大多仍局限于简单的短时域操纵任务（例如抓起一个方块），尚无法扩展到复杂的长时域任务（例如制作三明治）。原因在于，长时域任务要求 VLA 在整个时间序列上保持一致且连贯的交互，而任意一次局部错误都可能导致整体失败。随着任务复杂度和时序深度不断增加，实现训练稳定性的难度也会显著上升。

5) 在线 RL-VLA 基础设施 受 RL 在 LLM/VLM 微调中优异表现的启发，最新研究也开始关注在线 RL-VLA 学习流水线的基础设施建设。RLinf [87] 及 RLinf-VLA [28] 提出了灵活的基础设施，用于支持大规模 VLA 模型的高效在线 RL 微调，并兼容多种 policy 优化算法与模型架构。这些框架不仅提升了训练效率，还能够纳入额外的学习信号，例如人类反馈和安全约束。来自 LLM 领域的学习框架，如 vLLM [174] 和 VeRL [175]，也已被适配到 VLA 中，以进一步增强其能力。

潜在挑战 现有在线 RL-VLA 基础设施通常绑定于特定架构或特定优化方法，因而限制了跨框架适配能力。自回归式 VLA 与生成式 VLA 在 reward 获取方式上的差异，也进一步增加了统一支持的难度。尽管部分面向 LLM 的 RL 系统已经被迁移到 VLA 场景，但由于 VLA 涉及多模态观测、实时控制以及物理约束，这类迁移仍然面临较大挑战。因此，如何构建一个更通用、更灵活的在线 RL-VLA 基础设施，仍是一个有待解决的开放问题。

5.6 B. Offline RL-VLA

Offline RL 在不与环境交互的条件下，基于静态数据集训练 VLA 模型，因此特别适用于高风险或资源受限的场景。与仅模仿 demonstration 的基于 IL 的 VLA 不同，offline RL-VLA 会利用多样化历史经验中的长期回报来优化策略，从而提升 OOD 泛化能力。为此，它通常需要包含完整 MDP tuple 的大规模数据集 [176]–[178]。然而，现有许多可用数据集来自 IL 或 SFT 流水线，缺少丰富的奖励、动力学信息以及失败样本，这会限制 value estimation 和 policy 泛化。当前 offline RL-VLA 的研究主要沿两个方向推进：数据利用与目标修改。

5.6.1 1) 数据利用

数据利用关注的是：在 offline 学习约束下，如何高效利用静态数据集来改进 policy。由于无法采集新的交互数据，offline RL-VLA 的效果在很大程度上取决于训练算法如何利用已有轨迹来逼近最优策略。现有研究主要探索两个互补方向：一是通过定制化表征增强奖励信号，二是通过保守约束保证训练稳定性。

定制化表征 定制化表征方法会主动调整 offline 数据集或其相关奖励信号，使其更好地与 policy 优化目标对齐。通过重塑轨迹，或生成任务相关的代价信号，这类方法使 VLA 模型能够从静态数据集中提取更有信息量的训练信号。ReinboT [21] 通过修改 offline 数据集以最大化累计回报，从而提升 VLA 性能，并获得比标准 behavior cloning 更稳健的决策能力。 π^* [88] 借助预训练 value function 提供的二值化 value 对 VLA 进行条件建模，同时利用失败与成功数据。NORA-1.5 [89] 引入 offline Direct Preference Optimization，使用模型生成的奖励来优化 VLA。

保守约束 保守约束方法通过限制 policy 更新，防止其偏离 offline 数据集所覆盖的数据分布。通过抑制对未见状态或动作的外推，这类方法能够减轻分布偏移，从而更可靠地学习 policy，并提升静态数据的利用效率。ConRFT [85] 将 behavior cloning 与 Cal-QL [179] 结合，以实现稳定的 value

estimation, 从而支持在小规模数据集上学习。类似地, CO-RFT [22] 利用 Cal-QL 的校准机制, 将 policy 训练约束在训练数据支持的范围内, 以缓解 distributional shift。

潜在挑战 offline RL-VLA 面临的挑战往往源于数据集构建过程。由于 VLA policy 高度依赖数据质量与数据结构, 不均衡的数据集会加剧 distributional shift, 并限制学习效果。如果缺乏细致的数据整理与筛选, offline 数据集通常会表现出任务覆盖不均、行为分布偏置以及奖励信号不完整等问题, 进而导致模型在 OOD 环境中的泛化能力较差。

5.6.2 2) 目标修改

目标修改方法通过调整 RL 目标, 使学习信号与新型架构更匹配, 或支持数据集扩增。现有工作主要集中在两个方面: 面向架构的目标设计, 以及数据驱动的目标自适应。

面向架构的目标设计 随着 VLA 不断融合更多样的模型架构, 针对不同结构设计合适的 RL 目标, 对于释放其全部潜力至关重要。受到 offline RL 在 Q-Transformer 和 PAC [90], [91] 等基于 transformer 的模型上成功应用的启发, 当前研究开始关注如何通过 offline RL 优化不同结构的模型。ARFM [50] 为 VLA 上的 offline RL 提出了一种基于 flow 的训练目标, 并通过自适应平衡因子来控制 RL 信号的影响强度。

数据驱动的目标自适应 这类方法利用 RL 目标对 offline 数据集进行扩增, 生成额外的高质量轨迹, 以改进后续的 VLA 优化过程, 从而提升 offline 数据集的多样性与覆盖度。RL-100 [92] 使用 offline RL 目标对一个在线 PPO agent 进行保守 gating, 生成新的高质量数据; 这一技术也有望用于 VLA 的后训练。另一种策略是基于模型的 offline RL (MBRL), 即利用从静态数据集中学习得到的 dynamics model 生成合成 rollouts。

5.7 B. Offline RL-VLA (第 2 部分)

潜在挑战: 尽管面向架构设计的目标函数能够扩展不同模型结构的能力, 但在缺乏统一的 offline RL-VLA 框架时, 这类方法也会引入额外复杂性, 且迁移性较差。另一方面, 数据驱动的目标函数自适应还存在分布漂移风险: 当生成器不够准确时, 可能产生低质量样本, 从而污染训练 buffer, 并导致学习过程不稳定。这些局限表明, 未来仍需要更具泛化性的目标函数设计, 以及更稳健的数据筛选与整理策略。

5.8 C. 测试时 RL-VLA

测试时 RL-VLA 训练范式, 是指 VLA 在部署阶段通过轻量级更新或 adapter 模块对自身行为进行自适应, 从而有效规避真实部署中对完整模型进行 fine-tuning 的高昂成本。该范式使 VLA 能够快速适应新状态, 在无需大规模额外训练的前提下提升鲁棒性与泛化能力。现有方法按其适应机制大致可分为三类: value guidance、memory buffer guidance, 以及 structured planning。

Value Guidance value guidance 方法通过利用预训练的 reward 或 value function, 在测试时直接影响动作选择, 从而使 VLA 在不更新完整 policy 的情况下高效适应新任务。例如, V-GPS [26] 利用预训练 value function 对基础 policy 生成的动作候选进行重新排序, 最终选择预测 value 最高

的动作，以将模型行为调整到更优方向。Hume [27] 框架则在双系统架构中引入了“value-guided thinking”过程：它先生成多个动作候选，再通过专门设计的 value-query head 基于估计的状态-动作 value 选出最有前景的动作。

Memory Buffer Guidance 为了进一步提升测试时探索的有效性，近期工作提出了 memory buffer guidance：在推理阶段检索相关历史经验，以提高探索效率并促进知识复用。STRAP [93] 构建了一个紧凑且表达力强的模式库，用于存储包含历史、结构与语义信息的代表性时空模式；在推理时，它根据当前输入的相似性检索轨迹子片段。RA-DT [94] 将过往经验存入外部 memory，并仅检索与当前决策相关的子轨迹，以支持 in-context 决策。ReSA [95] 则通过内在质量评估，从 replay buffer 中识别并有选择地模仿高质量的成功轨迹，从而保证智能体始终与最终任务目标保持一致。

Planning-guided Adaptation planning-guided adaptation 方法通过显式推理未来可能的动作序列来提升测试时性能，从而选择更有可能达成任务目标的动作。这类方法通常将基础 VLA 的输出作为初始提案，并结合模拟 rollout 或基于 value 的评估进一步优化动作。VLA-Reasoner [96] 提出了一种可插拔框架，在测试时为 VLA 模型增强规划能力。该方法采用在线 Monte Carlo Tree Search (MCTS)，以基础 policy 的初始动作预测作为探索起点，通过模拟未来结果来搜索更优动作。value function 的另一种用法不是主动选择动作，而是用于任务进度监控。Bellman-Guided Retrials (BGR) [97] 就是一个代表性例子：它使用一个单独训练的 value function 来估计任务完成时间。在测试时，该函数会持续监控自身预测中的不一致性，从而检测机器人何时偏离成功轨迹，并触发纠正动作。

潜在挑战 现有 planning-guided adaptation 方法通常需要在正式推理前预先推断未来动作序列，这会带来显著的计算开销，并限制其实时部署能力。此外，还需要对大量动作候选进行评估，进一步增加了系统负担，降低了其在动态环境中的响应速度。

6 V. 真实世界部署

真实世界部署是指将 RL-VLA 模型运行在物理机器人上，使其在真实世界动力学条件下工作，从而在非结构化环境中实现安全、自主的操作。近期工作通常根据训练交互数据的来源，结合 sim-to-real transfer 与真实世界 RL，来应对样本效率、安全性以及硬件约束等方面的挑战。

6.1 A. Sim-to-Real Transfer

sim-to-real transfer 使得在仿真中训练的 VLA 能够有效泛化到物理机器人上，从而缓解分布偏移问题。当前用于弥合 sim-to-real gap 的方法大体可以分为 domain randomization 和 digital twin 两类；二者分别在感知以及环境动力学层面促进了高效迁移。

Domain Randomization Domain Randomization (DR) 通过在仿真中随机化参数，逼近真实部署时可能遇到的感知多样性，目标是缩小仿真与真实世界之间的差距。具体而言，DR [180] 在 policy 训练 [98] 与数据采集 [99] 过程中，对大量仿真参数进行随机化，以显式建模不确定性，例如光照条件、背景纹理以及执行器噪声等。比如，SimpleVLA-RL [24] 表明，在多样化任务仿真中应用 DR 后，所学 policy 可以零样本迁移到真实机器人上，而无需额外 fine-tuning。

Digital Twin Digital Twin (DT) 通过构建与物理系统同步的虚拟副本, 在降低 sim-to-real gap 的同时, 支持安全且可扩展的 policy 训练。Real-Is-Sim [100] 维护了一个动态 DT, 并利用真实传感器流持续校正, 使 policy 始终工作在熟悉的 simulator-domain 状态分布内。RialTo [101] 利用少量真实数据在线构建仿真环境, 并结合 inverse-distillation RL 提升操纵 policy 的鲁棒性。RoboTwin [102] 采用生成式框架, 结合 3D 生成模型与 LLM, 将单张 2D 图像转换为多样且可交互的 DT, 并将其作为双臂操纵的 benchmark。进一步地, DT-CycleGAN [104] 将 digital twin 与 CycleGAN [181] 结合起来, 以缩小仿真机器人与真实机器人之间在视觉和动作一致性上的差距, 从而实现面向视觉抓取的有效零样本 sim-to-real transfer。最后, DREAM [103] 提出了一种 real-to-sim-to-real 框架, 利用可微 Gaussian Splat 构建高保真 DT, 从而能够同时完成物体质量辨识以及具备 force-aware 能力的抓取 policy 训练。

潜在挑战 尽管这一方向已经取得了显著进展, 迁移后的 policy 表现仍普遍弱于其仿真环境中的对应版本。例如, SimpleVLA-RL [24] 仍呈现出明显的 sim-to-real gap: 其在物理机器人上的成功率 (success rate) 显著低于仿真结果。这说明, 仅依赖仿真仍不足以支撑 VLA 在真实世界中的可靠部署。

6.2 B. 真实世界 RL

真实世界 RL 旨在直接在物理机器人上训练 manipulation policy, 使其能够在真实传感器反馈与物理动力学条件下获得稳定可靠的技能。与仿真环境相比, 真实世界 RL 能提供更贴近实际的学习信号, 但也带来了显著挑战, 尤其体现在 rollout 效率受限以及安全风险较高。为应对样本效率、环境重置和安全性等问题, 现有方法提出了 human-in-the-loop RL、可逆性 (reversibility)、自主恢复 (autonomous recovery) 以及安全探索等思路。

1) Human-in-the-loop RL: Human-in-the-loop (HiL) RL 将人类专家知识引入 policy 学习过程, 以加速真实世界 RL。与完全依赖自主探索不同, HiL 方法利用人工干预来纠正机器人动作, 并对学习任务进行调度, 从而更快地促进 policy 收敛。大量实证研究表明, 通过人工纠错干预 (human corrective interventions) [?, ?]、人工恢复辅助 (human recovery assistance) 或人工课程设计 (human curriculum design) [?, ?] 融入人类经验, 能够稳定学习过程、减少不安全探索并加快收敛, 从而在脆弱的纯自主学习与物理环境所要求的结构化自适应能力之间架起桥梁。

Human Corrective Intervention: 人工纠错干预通过实时反馈在学习过程中引导机器人, 借助有针对性的纠正帮助系统从错误中恢复, 并细化复杂行为, 从而实现更快的技能习得与更安全的探索。HIL-SERL [?] 提出了 human-in-the-loop reinforcement learning, 利用人工纠错反馈快速学习精确且灵巧的 manipulation 技能。CR-Dagger [?] 引入了一种顺应性 (compliant)、力敏感的人际接口, 以实现平滑的人类纠正; 同时利用 force feedback 学习 residual policy, 从而提升 contact-rich manipulation 的能力。TRANSIC [?] 被提出为一个 sim-to-real 框架, 通过在线人工纠正学习自适应的 policy 迁移。Genie Centurion [?] 则借助 VLM 检测任务失败, 并在必要时请求人工协助, 从而将纠错干预扩展到多机器人场景。最近, ConRFT [?] 率先将 human-in-the-loop 干预整合到面向 VLA 的真实世界机器人 manipulation RL 中, 结合离线与在线的人工纠错 RL fine-tuning。DAFT [?] 进一步将纠错干预扩展到面向 VLA 的 RL 中, 可将自然语言反馈转化为具有语义落地能力的纠

正动作。VLAC [?] 则进一步探索了人类引导探索 (human-guided exploration): 在人工监督下, 多机器人在真实环境中学习关键行为, 从而加快 policy 的自适应与稳定化。

Human Recovery Assistance: 人工恢复辅助指的是: 在真实世界 RL 中, 当自主恢复不可靠时, 机器人或环境在失败后需要人工介入完成重置。早期机器人 RL 研究 [?, ?] 高度依赖频繁的人工重置, 这严重限制了需要精确环境重置的长期、contact-rich manipulation 任务的可扩展性。为缓解这一问题, 后续工作探索了半自动恢复流水线, 将 human-in-the-loop 与脚本化重置或运动原语相结合, 使系统能够在人工监督下实现自主恢复, 同时保留安全保障 [?]. ARMADA [?] 和 RaC [?] 进一步集成了基于学习的恢复模块, 使机器人能够检测失败状态, 并在无法自恢复时请求人工引导恢复。最近, 在真实世界 RL-VLA 中, Generalist [?] 通过将人工干预限制为仅在机器人进入不可逆状态、或在较长时间内未能完成任务时执行重置, 从而将人工参与降到最低。类似地, VLAC [?] 让人类观察 VLA policy 容易频繁失败的位置, 并手动重置机器人和操作对象, 以实现有针对性的重新初始化, 从而继续开展 RL 探索。

6.3 B. 真实世界 RL (第二部分)

人工课程任务设计 这一路线将课程学习的思想引入任务组织过程, 按照从简单到复杂的顺序构造任务, 以促进 policy 的稳定、高效习得。在真实世界 RL 中, 人类监督者通常通过选择子任务或调整难度边界来设计课程, 从而在安全性与学习效率之间取得平衡 [185]。近期研究开始走向半自动化课程设计, 即利用大语言模型辅助人类分解复杂任务。CurricuLLM [186] 借助大语言模型, 将复杂机器人技能自动分解为分层子任务, 并使任务推进过程与人类指定的难度等级对齐。与此同时, Sirius [110] 提出了一种 human-in-the-loop autonomy 框架, 其中人类操作员可在真实世界任务上动态设计并 gate 部署课程, 判断哪些技能可以在无需人工干预的情况下安全尝试。在大规模机器人集群场景中, MT-Opt [111] 将课程任务设计进一步工程化: 它优先关注表现较差的技能, 并依据性能指标控制部署阈值。VLA-RL [23] 则在仿真环境中, 将人工课程设计原则纳入面向 VLA 后训练的 RL 流程。然而, 在真实世界 RL-VLA 中, 课程任务设计仍基本处于未被充分探索的阶段, 尤其是在物理约束下, 如何由人类指导者组织多模态目标以及设定部署阈值, 仍缺乏系统研究。

潜在挑战 现有 human-in-the-loop RL 方法仍然高度依赖人工干预样本, 以保证学习过程的安全性与稳定性, 这导致人力成本高、可扩展性差 [187]。这种依赖关系限制了持续训练能力, 也阻碍了方法在真实世界中的大规模部署。因此, 亟需更自主、可自我维持的学习机制。

2) 可逆性与自主恢复 可逆性 (reversibility) 与自主恢复使机器人能够自行处理失败状态, 并在无需外部干预的条件下继续学习, 从而减少真实世界 RL 中的人工重置和人力成本。当任务失败后, 机器人若能自主恢复到可行状态, 就可以持续与环境交互, 进而提升样本效率以及长期自适应能力。现有方法按照恢复机制, 大致可分为三类: Reset-free Learning、Functional Reversibility 和 Semantic-aware Recovery。

Reset-free Learning Reset-free learning 的目标是在不依赖外部重置的情况下进行训练, 其基本思路是鼓励智能体始终停留在状态空间中可恢复的区域内。一种自然的做法是引入辅助 reset policy: 当任务失败时, 该 policy 将智能体驱动回某些初始状态, 从而在无需人工协助的情况下继续训练。LNT [112] 训练 goal-conditioned reset policy, 使智能体恢复到初始状态分布。VaPRL [188] 结

合课程学习，以处理难度逐步增加的任务；LSR [189] 则通过判别器驱动的学习机制促进技能多样性。MEDAL [113] 进一步在统一框架下利用 demonstration 同时指导任务 policy 与 reset policy。IBC [114] 在此基础上继续拓展，直接从 demonstration 中学习 reset goal，而不依赖稠密监督。除显式学习 reset policy 外，R3L [115] 采用 multi-start 训练策略，使智能体能够反复访问多样化的初始条件，从而提升其对探索失败的鲁棒性。MTRF [190] 则将 reset-free RL 视为一个多任务学习问题，其中任务的设计满足：某个任务的终止状态可以作为其他任务的有效初始状态。

6.4 B. 真实世界 RL（第三部分）

功能可逆性 (Functional Reversibility): 功能可逆性强调机器人在受到扰动后，能够反转其动作，并将环境恢复到可恢复或任务可继续执行的状态。一些方法学习恢复技能，以处理常见失败情形，例如物体掉落或抓取打滑，从而使任务目标的推进能够在中断后继续进行 [191]。Sharma 等人提出了 State Entropy Maximization [113]，通过内在正则化鼓励多样但可逆的探索。Recovery RL [118] 学习一个 recovery policy，在机器人进入不安全或不可逆状态之前进行干预。PAINT (Proactive Agent Interventions) [192] 在此基础上进一步扩展，通过训练分类器预测潜在失败，并提前触发纠正动作或安全重置。除显式的可逆性标注之外，Lynch 等人 [191] 针对物体掉落、抓取打滑等操纵失败学习恢复技能，从而实现任务进展的无缝恢复。近期的多模态模型还将语义引导进一步融入恢复过程——例如，像 PaLM-E [116] 这样的语言条件 policy 能够根据高层指令生成纠正行为。

语义感知恢复 (Semantic-aware Recovery): 语义感知恢复强调对操纵中的时空动态进行推理，使机器人能够在持续进行的任务上下文中解释失败原因，并规划合适的恢复行为。例如，Matsuoka 等人 [193] 构建了一个带有时间依赖效用的失败本体 (failure ontology)，用于在打滑或位移发生时选择恢复动作。DAS [194] 利用语义场景图理解失败发生时的空间与关系上下文，并据此进行纠正规划。RECOVER [117] 结合本体、逻辑与语言模型，实现在线失败检测并生成可解释的恢复计划。Ahmad 等人 [195] 则将 vision-language model 与行为树结合，用于实时推理与自主纠正。

潜在挑战 (Potential Challenges): 尽管自主失败恢复是可行的，但由于长时程训练不稳定、部分可观测性，以及真实世界交互天然存在的不可逆性，可逆性与恢复仍然十分困难。这些问题会阻碍复杂环境中的可靠失败检测、因果推理与恢复执行 [188]。

3) 安全探索 (Safe Exploration): 真实世界 RL 必须确保智能体在收集经验的过程中避免与物理环境发生不安全交互。安全探索通过将 policy 搜索约束在状态空间中与任务相关且可逆的区域内，在避免灾难性后果的同时保证学习有效进行。现有方法大体可分为保守安全 critic、结构化任务分解和实时安全约束三类，它们在安全保证与学习效率之间实现权衡。

保守安全 Critic (Conservative Safety Critics): 保守安全 critic 为真实世界探索中动作提议的风险评估提供了一种有原则的机制，通常做法是训练一个辅助 critic，以估计违反安全约束的可能性。Recovery RL [118] 引入了学习得到的 recovery zone，即状态空间中机器人能够安全返回正常操作的区域。此外，SLAC [119] 先在低保真仿真中预训练一个与具体任务无关的 latent action space，从而建立一个安全且具有时间结构的行为先验，用于约束真实世界中的探索。

结构化任务分解 (Structured Task Decomposition): 结构化任务分解将复杂的机器人训练任务拆解为更简单的子任务，以便进行可管理的安全检查。例如，GRAPE [71] 利用 vision-language model 将复杂操纵任务分解为可解释的阶段，并基于语义关键点自动导出时空安全约束。类似地，文献 [196] 采用 critic 机制，在整个训练过程中以概率方式判断安全约束是否得到满足。

6.5 B. 真实世界 RL（第 4 部分）

实时安全约束执行：实时安全约束执行通过在执行层直接施加基于控制理论的安全约束，来保证 RL 在探索过程中的安全性。以阻抗控制器（impedance controller）[?] 为例，结合参考值限制（reference limiting）后，可以在实时运行中约束 end-effector 的作用力与速度；即使 RL policy 给出较为激进的动作，也能避免发生不安全接触。进一步地，借助约束马尔可夫决策过程（Constrained Markov Decision Process, CMDP）范式，SafeVLA [?] 提出了一种集成式安全方法（Integrated Safety Approach, ISA），从 minmax 视角针对已识别的安全风险优化 VLA，从而在安全性与性能之间取得权衡。

潜在挑战：一个长期存在的核心挑战，是如何将高层语义推理与底层安全保证真正打通。现有框架往往难以把抽象的、基于语义的规则（例如“要小心处理易碎物体”）映射到必须落实物理约束的具体底层控制 policy 上（例如明确的 torque 或速度上限）。这种割裂在分布偏移（distribution shift）条件下尤为突出：当智能体遇到新的状态时，想要同时满足语义层面的任务目标与物理层面的安全要求，会变得异常困难。

7 VI. 基准测试与评估

基准测试与评估对于衡量 RL-VLA 的研究进展至关重要。由于这类系统同时具有具身性与多模态特征，标准化评估不仅要考察算法性能，还需要综合考虑交互保真度以及真实世界部署能力。现有工作大体可分为两类：基于仿真的基准与真实世界基准；与此同时，还配套了一系列评估指标，用于量化系统的效率、安全性与自主性。本节将综述这两个方向上的代表性 benchmark 与数据集，并总结支持 RL-VLA 系统可复现、可扩展评估的常用指标。

7.1 A. 仿真数据集与基准

通过 RL 优化机器人基础模型，需要与环境进行大规模交互。为支持这一过程，研究中广泛采用各类仿真基准来评估 RL 算法的有效性。这些基准通常涵盖合成场景、基于物理的仿真、物体操纵任务、任务执行流程以及智能体与环境的交互。

单臂操纵基准：主要操纵基准的概览见表 II。对于 VLA 中可扩展的 RL 训练而言，基准至关重要：并行环境能够快速收集 rollout，并缩短实际训练耗时；类似 Gym 的 API 可保证评测过程标准化且可复现；GPU 加速渲染则能够在大规模条件下提供高保真观测与真实动力学。LIBERO [121] 和 Meta-World [122] 是两类常用 benchmark suite，支持多任务与长时程控制下的 RL 训练。ManiSkill [123], [197] 是一个接触丰富（contact-rich）且物理精确的仿真套件，并配有 expert demonstrations，用于扩展 RL 数据规模。BEHAVIOR [198] 和 RoboVerse [199] 都提供了大规模且多样化的任务，可用于可扩展的 RL 训练与高挑战性测试。面向家庭场景，RoboCasa [200] 提供了更真实的场景，以支持机器人学习鲁棒且可迁移的 policy。Colosseum [124] 构建于 RL Bench [201] 之上，系统性地遍历多种扰动维度（如外观、光照）；Franka Kitchen [125] 则基于 MuJoCo [202] 中的厨房环境，通过组合诸如旋转炉灶开关、打开橱柜等原子目标，研究长时程操纵。CALVIN [126] 提供了一个标准评测协议：在三个环境上训练、在剩余一个环境上测试，从而既支持 RL 训练，也可检验跨场景泛化能力。SIMPLER [127] 提供了经过专门校准的仿真环境，用于贴近常见机器人配置，并在不构建完

整 digital twin 的前提下缩小 sim-to-real 差距；其配套的 sim-and-real 研究表明，SIMPLER 中的性能与真实机器人成功率之间具有很强的相关性。

双臂操纵基准： RoboTwin [102] 是一个双臂操纵 benchmark，它将真实 teleoperation demonstrations 与由单张图像生成的 digital-twin 场景相结合，从而提供对齐的 sim/real 任务定义与评测指标。进一步地，RoboTwin2.0 [99] 通过自动化 expert 数据流水线、包含多个实例的精选物体集合，以及覆盖多种机器人 embodiment 的双臂 benchmark，对该平台进行了扩展。结构化 domain randomization（如杂乱度、光照、背景）以及多模态 LLM 进一步增强了 RL 训练的鲁棒性。

7.2 B. 真实世界数据集与基准测试

VLA 算法的发展在很大程度上依赖于高质量真实世界数据集的可获得性。随着时间推移，研究者构建了多种数据集，覆盖不同传感模态、任务类型与环境条件，已成为推动真实世界机器人研究进展的关键资源。这些数据集记录了机器人与环境之间的多模态交互，包括视觉、proprioception 和 tactile feedback 等感知输入，以及与之对应的动作和上下文信息。

通用 RL Suite. LeRobot [?] 提供了一个通用、开源的基础框架，将面向 RL 的数据集组织、数据采集工具以及训练-评估一体化 pipeline 统一起来，并将可部署的 policy 产物一并打包，从而降低真实硬件实验的成本。SERL [?] 是一个面向真实机器人的 RL suite，它将强大的 off-policy、基于视觉的学习器，与 reward specification、自动 reset 和安全控制等实用组件集成在一起，从而支持 PCB insertion、cable routing 等标准化任务。该工作表明，在真实硬件上也可以高效训练出鲁棒的 policy。

特定领域基准. 这类基准面向特定任务，在可复现条件下重点考察长时程控制、泛化能力以及 sim-to-real 保真度。RoboTwin2.0 [?] 支持在多种双臂 embodiment 和广泛任务集合上进行标准化的机器人实机评测，并发布了数据生成器、精心整理的多实例物体库以及相应协议，以促进可复现的真实世界研究。FurnitureBench [?] 对家具装配任务进行了标准化，提供可重复的硬件配置、可 3D 打印的部件，以及清晰的实验协议，覆盖单项技能（如 grasping、insertion、screwing）和完整装配流程。与此同时，RoboCup@Home [?] 将家庭服务机器人组织为一个持续演进的竞赛平台，同时跟踪其物理技能与更高层认知能力的进展。FMB [?] 则聚焦于可复现的、基于 3D 打印物体的操纵任务，这些任务需要分阶段技能，例如 grasping、借助夹具的重定向（fixture-assisted reorientation）以及精确 insertion。该数据集基于 Franka Panda 采集，并发布了多条 expert 轨迹、多视角 RGB-D 数据以及 CAD 资产，用于通过标准化的长时程评测，考察模型对未见几何形状与放置位置的泛化能力。

7.3 B. 真实世界数据集与基准（第 2 部分）

表 2: RL-VLA 方法主要 manipulation 基准概览

数据集	数据集规模	具身形态	机器人形态	EEF	并行 rollout	Gym 兼容	GPU 加速	模态
LIBERO [121]	130 个任务	Franka	单臂	默认 gripper		V		RGB-D; Language
Meta-World [122]	50 个任务	Sawyer	单臂	默认 gripper		✓		RGB; Language
ManiSkill2 [123]	20 个任务	Franka	单臂	默认 gripper		✓		RGB-D; 点云
ManiSkill3 [197]	100+ 个任务	Franka	单臂	默认 gripper; Allegro Hand	V	V		RGB-D; 点云
BEHAVIOR [198]	1k 个任务	Galaxea	Humanoid	默认 gripper		V		RGB-D; 点云; Language
RoboVerse [199]	1k+ 个任务	Franka; Fetch; 等	单臂; 轮式	默认 grippers	V	1	V	RGB-D; 点云; Language
RoboCasa [200]	100 个任务	Franka	轮式	默认 gripper		✓		RGB-D; Language
The Colosseum [124]	20 个任务	Franka	单臂	默认 gripper	x	x		RGB-D; 点云; Language
Franka Kitchen [125]	6 个任务	Franka	单臂	默认 gripper	x	✓	x	RGB
CALVIN [126]	34 个任务	Franka	单臂	默认 gripper	x	x	x	RGB-D; Language
SIMPLER [127]	8 个任务	Google robot; WidowX	单臂	默认 gripper	✓	✓	J	RGB-D; Language
RoboTwin [102]	14 个任务	Aloha	双臂	默认 gripper	x	x	x	RGB-D; Language
RoboTwin2.0 [99]	50 个任务	Franka; Piper; UR5; 等	双臂	默认 grippers	1	V	V	RGB-D; Language




图 3: RL-VLA 方法在 LIBERO Benchmark 上的成功率 (success rate)。各方法按平均成功率从高到低逆序排列。

7.4 C. 评估指标

评估 RL-VLA 系统的性能，需要同时覆盖传统强化学习目标，以及真实世界机器人所特有的多模态与具身挑战。不同于仅关注累计回报的传统 benchmark，RL-VLA 的评估还应考虑可解释性、物理效率，以及人机交互动态等因素。本节总结了若干常用评估指标，并概述它们在近期工作的代表性用法。

- 成功率 (success rate):** 用于衡量 agent 在多少比例的 episode 中达成目标，通常由任务完成情况或与指令的语义一致性来定义。该指标能够直接反映 policy 的整体能力，已广泛用于仿真与真实场景中的评估。
- 平均 episode 回报 (Average Episodic Return):** 该指标评估每个 episode 的期望累计 reward，能够同时反映学习过程的效率与稳定性。在大多数强化学习建模中，它仍是标准优化目标之一，也包括视觉语言条件控制 [23]。
- 安全代价 (Safety Cost):** SafeVLA [120] 引入了这一指标，用于度量训练与部署过程中风险或约束违反的程度。它对不安全动作、碰撞或可能损害机器人及环境的状态转移进行量化，因此是衡量真实世界运行中 policy 安全性与可靠性的关键指标。
- 周期时间 (Cycle Time):** RLDG [75] 和 CO-RFT [22] 引入了周期时间，用于量化真实世界学习循环的时间效率，即系统完成数据采集、policy 更新与部署所需的速度。该指标为评估真实世界训练吞吐量和系统级可扩展性提供了重要依据。

5. **Episode 长度 (Episode Length)**: ConRFT [85] 将 episode 长度作为任务鲁棒性的代理指标, 用于判断 agent 能否在不发生提前失败或终止的情况下维持连贯的动作序列。平均 episode 长度较短通常意味着 policy 不稳定, 或存在不安全探索。
6. **干预率 (Intervention Rate)**: ConRFT [85] 引入了该指标, 用于衡量人工监督者在真实世界训练或部署过程中介入的频率。干预率越低, 通常意味着系统具有更强的自主性和更安全的探索能力; 这也是物理环境中具身 RL-VLA 的关键目标。

潜在挑战 当前真实世界 RL 的评估协议通常更关注任务级指标, 如成功率和 episode 回报, 而对能够反映实际部署性能的系统级指标关注不足。更全面的评估框架还应纳入诸如推理延迟 [92] 和运行时稳定性等因素, 因为这些指标对于衡量 policy 在具身环境中运行的效率与安全性更加关键。

8 VII. 开放挑战与未来方向

尽管 RL-VLA 已取得令人瞩目的进展, 但在这类系统能够稳健地运行于动态、开放式的物理环境之前, 仍面临诸多关键挑战。

8.1 扩展到长时程任务

当前的 RL-VLA 系统在长时程任务上仍表现不足, 其中一个核心原因在于: RL 通常只对最终动作提供监督, 而缺乏对中间推理过程的明确引导。一个有前景的方向是引入类似 chain-of-thought 的监督方式, 以及 memory-retrieval 机制 [93], [94], [203], [204]。这类方法将结构化推理与序列建模结合起来, 帮助智能体回忆先前经验, 并在较长轨迹上维持时间一致性。

8.2 面向 VLA 的基于模型强化学习

由于奖励稀疏、反馈延迟以及样本效率有限, 当前 RL-VLA 系统整体上仍然较低效, 往往需要依赖大规模仿真 rollout 来更新 policy。一个值得重点关注的方向是 model-based RL: 通过学习环境动力学的预测式 world model, 系统可以生成更有信息量的奖励信号与合成状态, 从而实现更快、可扩展性更强的训练 [65]–[67]。

8.3 高效且可扩展的真实机器人训练

在真实机器人上训练 RL-VLA 仍然效率低、成本高。这主要源于并行化能力受限, 以及系统在安全 rollout 和任务重置过程中高度依赖人工监督 [44], [53]。潜在的解决思路包括: 使用 reason agent 自动处理失败情形, 利用 reactive agent 支持安全探索, 以及通过多机器人共享训练并结合 real-to-sim 的模拟器 rollout, 在减少人工干预的同时提升样本效率 [78]。

8.4 可靠且可复现的 RL-VLA

RL-VLA 系统往往存在优化不稳定、可复现性差的问题, 其根源在于多模态 RL 对设计选择、超参数以及环境随机动力学高度敏感 [22], [205]。要提升系统可靠性, 需要建立一致的训练流程、受控的评测环境, 以及标准化的算法设置报告方式, 从而保证跨机器人平台的公平比较与结果复现。

8.5 安全且具风险感知能力的 RL-VLA

在真实世界中部署 RL-VLA 时，安全性仍是一个突出挑战。这是因为在探索过程中，不完美感知、控制延迟以及监督不足都可能带来不可逆风险 [118]。一个有前景的方向是联合使用预测式风险建模、基于约束的 policy 优化，以及语言条件下的安全推理，以实现具身智能体的安全、可靠部署 [120], [206]。

9 VIII. 结论

本文综述了面向机器人操纵的 RL-VLA，系统概括了其研究进展，并突出说明了它在应对 OOD 情形时，相较于 IL 所具有的优势，即能够突破 IL 的根本性局限。首先，我们给出了统一的问题定义与细致的分类体系；随后，系统分析了 RL-VLA 架构的核心组成部分，包括 action representation、奖励设计以及 transition modeling 中的关键权衡。围绕 online、offline 与 test-time RL 三类训练范式，我们进一步提炼了其中的核心认识与算法演进趋势，尤其关注如何利用数据提升模型的泛化能力。

此外，对真实世界部署的分析表明，相关研究正沿着一条清晰路径持续推进：从早期的 sim-to-real transfer，逐步转向真实世界 RL 的核心难题。这一趋势也进一步凸显出以下能力的重要性：安全探索、自主恢复，以及有效的人在回路对齐。通过梳理基准数据集、仿真环境与评测指标，我们为从预训练 VLA 模型走向鲁棒、可部署系统的技术路径提供了更结构化的认识。

尽管 RL-VLA 已取得显著进展，但仍面临一系列关键挑战。未来的 RL-VLA 研究必须进一步突破可扩展性与样本效率不足这两大瓶颈。这不仅要求研究重心更多转向 model-based RL，以提升学习效率，也需要发展具备 memory augmentation 的框架，从而支持多阶段任务所需的鲁棒长期推理能力。更为关键的是，这些进展必须与严格的安全约束相结合，才能保证系统在脱离仿真环境后仍具备可靠的运行能力。

归根结底，只有切实解决上述挑战，才能真正释放 VLA 模型的潜力：在真实世界中实现自主、通用的机器人操纵。

10 参考文献

参考文献条目较多，此处保留原论文英文文献列表，请参阅原文 PDF 的 References 一节。