

1 Improving Vision-Language-Action Model with Online Reinforcement Learning




图 1: 本文动机示意图。我们借鉴大语言模型(LLMs)的微调流程来提升机器人领域的 Vision-Language-Action (VLA) 架构: 先进行监督微调 (SFT), 再进行强化学习 (RL)。然而, 我们观察到, 将标准在线 RL 直接应用于大规模 VLA 模型时往往极不稳定。为此, 本文提出了一种迭代式 RL 方法 iRe-VLA。

摘要

近期研究通过使用专家机器人数据集进行监督微调(SFT),成功将大型视觉-语言模型(VLMs)集成到机器人底层控制中,从而形成了本文所称的 Vision-Language-Action (VLA) 模型。尽管 VLA 模型表现出较强能力,但如何在与环境交互过程中进一步提升这类大模型,仍然是一个尚未解决的问题。本文研究如何利用强化学习(RL)进一步改进 VLA 模型;RL 也是当前大模型中常用的一种微调技术。然而我们发现,将在线 RL 直接应用于大规模 VLA 模型会带来显著挑战,包括训练不稳定,这会严重损害大模型性能,以及计算开销过大,超出多数本地机器的承载能力。为应对这些问题,本文提出 iRe-VLA 框架,在强化学习与监督学习之间交替迭代,从而有效提升 VLA 模型。该方法既利用了 RL 的探索优势,又保留了监督学习的稳定性。我们在两个仿真 benchmark 和一套真实世界操纵任务上进行了实验,结果验证了该方法的有效性。

2 1. 引言

近年来,将强大的预训练大语言模型(LLM)与视觉-语言模型(VLM)用于其原始适用范围之外的各类高级任务,已成为一种趋势。这些任务包括对话系统 [1], [2], [3]、代码生成 [4]、任务规划 [5], [6], 甚至低层机器人控制 [7], [8]。在机器人数据集上结合显式动作建模对 VLM 进行微调 (fine-tuning) 后,已有工作进一步发展出大型视觉-语言-动作 (VLA) 模型 [9], 例如 RT-2 [8]、HiRT [10]、Roboflamingo [11] 等。这类模型能够直接输出低层机器人控制信号,同时受益于大型预训练模型中编码的常识知识与推理能力 [12]。

VLA 模型的微调通常采用监督微调 (SFT) 范式 [8], 其优势在于稳定且具备良好的可扩展性。然而, SFT 依赖高质量专家数据集,而这类数据在机器人领域获取成本高、难度大 [13]。此外,由于分布偏移问题 [14], [15], 监督学习未必能使 VLA 模型与真实物理环境充分对齐。因此,我们关心的是:除了监督学习之外,是否可以通过与物理环境的交互,进一步提升这类大型 VLA 模型。值得注意的是,基于人类反馈的强化学习 (RLHF) [1], [16], [17] 在提升大语言模型与人类偏好之间的一致性方面已取得显著成功,如图 1 左上所示。

受 RLHF 成功经验的启发,我们尝试利用在线强化学习 (online RL) 来提升 VLA 模型,并使其更好地与物理环境对齐。然而,聊天机器人与具身机器人所面对的环境存在显著差异。聊天机器人通常基于离线、人工标注的数据集进行优化,其动态过程相对明确 [1];而具身机器人则需要在长

时程、稀疏奖励的任务中进行在线探索。进一步地，已有研究表明，当在线强化学习应用于大型神经网络时，训练过程可能极不稳定 [18], [19], [20]。从经验上看，我们也观察到：将标准 RL 算法直接用于大型 VLA 模型，会导致训练不稳定，并带来性能下降，如图 1 右侧所示。

为稳定 RL 过程并有效增强 VLA 模型，本文提出一种新的 iRe-VLA 方法，在在线强化学习阶段与监督学习阶段之间交替迭代。具体而言，在 RL 阶段，我们冻结 VLM 参数，仅训练轻量级 action head，以维持训练稳定性。随后在监督学习阶段，我们使用成功轨迹对整个模型进行微调，从而充分利用大模型的表征能力。实验结果表明，这种两阶段方法能够稳定地提升 VLA 的性能、增强训练稳定性，并且具有更高的计算效率。我们通过全面实验验证了 iRe-VLA 的有效性，实验覆盖模拟环境 MetaWorld [21]、Franka-Kitchen [22] 以及真实世界 Panda 操纵任务集。在这些场景中，我们的方法不仅能使 VLA 模型更好地适配原始任务，还能够自主解决未见过的任务。进一步地，通过与环境的在线交互，VLA 模型的泛化能力也得到了提升。

3 II. 相关工作

用于具身控制的基础模型。在网页规模数据上训练的大语言模型(LLMs)与视觉语言模型(VLMs)编码了关于物理世界的知识，并展现出显著的推理能力。借助这类先验知识，LLMs 和 VLMs 能够从多个方面促进具身控制任务，包括为智能体提供 reward 或 value [23], [24], [25]、建模世界动力学 [26], [27]，以及直接充当 policy [5], [6], [28], [29], [30], [31], [32]。

对于将 LLMs/VLMs 直接用作智能体 policy 的研究，大致可以分为两类：高层规划与低层控制。前一类工作利用 LLM 的推理能力，自回归地生成文本步骤序列 [5], [6], [28] 或代码 [33]，从而将长时程任务分解为可执行的计划。然而，这些方法输出的是文本形式的计划，尚未直接扎根于物理世界，因此仍然依赖强大的低层技能。另一条研究路线则利用 VLM 直接输出低层控制信号，并验证了低层技能本身同样可以受益于预训练 VLM 中编码的先验知识 [7], [8], [10], [34], [11]。由于 VLM 的原始输出位于语言空间，这类方法通常需要额外的动作建模模块，例如添加 action head [10], [11]，或用动作替换语言 token [8]。

使用 RL 微调大模型。强化学习已经成功应用于自然语言处理的下游任务，以更好地使生成文本与人类偏好对齐 [1], [35], [36]。在基于人类反馈的强化学习 (Reinforcement Learning from Human Feedback, RLHF) 框架中，通常先基于预先收集的人类偏好数据集训练 reward model，随后在约束模型不要过度偏离原始模型的前提下，在 bandit 环境中优化 LLM [1]；这一过程可视为一种离线风格的 RL [37]。与面向对话系统的 RLHF 不同，VLA 模型的微调需要面对未知动力学，并要求在线探索 [38], [39], [40]。例如，GLAM [38] 通过在线 RL 将 LLM 生成的文本计划落地到简化的 grid-world 环境中；LLaRP [39] 则在具有稠密奖励的重排任务中，将 VLM 生成的高层计划与具体执行相对齐。

然而，这些方法都假设低层技能（如 pick、goto）已经可用，其目标只是更好地将高层计划落地。与之不同，本文尝试利用 RL 直接提升 VLA policy 输出的低层控制信号；这类控制在稀疏奖励的物理环境中往往具有更长的时程，通常需要数百甚至上千步。

4 III. 预备知识

强化学习 (Reinforcement Learning)。我们采用标准的深度强化学习部分可观测马尔可夫决策过程 (POMDP) 框架，将任务建模为 [formula] $(\mathcal{S}, \mathcal{A}, P_T, R, \gamma, \mathcal{O}, P_E)$ 。其中， $\mathcal{S}$ 和 $\mathcal{A}$ 分别表

示任务的状态空间与动作空间, O 表示机器人的观测, 例如视觉图像。 $P_T : S \times A \times S[0, 1]$ 表示状态转移概率函数, $R : S \times A \times S \mathbb{R}$ 表示任务的奖励函数。在机器人任务中, 奖励信号通常较为稀疏, 因此本文采用二值奖励: 若机器人成功完成任务, 则 $R = 1$; 否则 $R = 0$ 。 $P_E : S \times O \rightarrow [0, 1]$ 表示观测发射概率。 policy $\pi_\theta : OA$ 给出了由参数 θ 参数化的动作空间概率分布。参数 θ 的优化目标是在折扣因子 γ 下最大化 policy π_θ 的期望回报:

$$J(\theta) = \mathbb{E}_{((s_0, o_0, a_0), (s_1, o_1, a_1), \dots) \sim p_\theta} \left[\sum_t \gamma^t R(s^t, a^t) \right] \quad (1)$$

视觉-语言模型 (Vision-Language Model). 近年来, 大量视觉-语言模型 (VLM) 已被提出, 这类模型能够同时处理视觉输入与语言输入。根据 [8], 它们大体可以分为两类: 一类是表征学习模型, 例如 CLIP [41]; 另一类是生成式模型, 例如 Blip-2 [42] 和 InstructBlip [43]。遵循 [8], [34], [11], 本文主要采用输入输出形式为 $\{\text{vision}, \text{text}\} \rightarrow \{\text{text}\}$ 的生成式 VLM。形式化地, 生成式 VLM 从条件分布 $p(x^{1:K}|I, c)$ 中采样 token $\hat{x}^{1:K}$, 其中条件为输入图像 I 与指令 c 。由于原始生成式 VLM 的输出是自然语言, 因此要将其集成到机器人控制任务中, 还需要额外的动作建模模块, 具体将在下一节介绍。

5 IV. 方法

我们的目标是提出一种学习方法, 使 VLA 模型能够通过在线交互得到有效提升, 同时将计算开销控制在机器人系统可承受的范围内。我们以一个在机器人 demonstration 数据上完成微调 (fine-tuning) 的 Vision-Language-Action (VLA) 模型为起点。第 IV-A 节将详细介绍 VLA 的架构, 第 IV-B 节将概述 iRe-VLA 方法的学习流程。

5.1 A. 模型架构

我们的 VLA 模型将视觉输入 $o \in O$ 与自由形式的语言指令 $i \in \mathcal{L}$ 映射为底层机器人动作 $a \in A$, 可表示为 $O \times \mathcal{L} \rightarrow A$ 。如图 2 左侧所示, 该模型由一个预训练的大规模 VLM 和一个轻量级 action head 组成。




图 2: (a) 我们的 VLA 模型由预训练的 VLM backbone 和轻量级 action head 组成。(b) 在微调 (fine-tuning) 过程中, 我们在探索与监督学习 (SL) 两个阶段之间交替迭代, 以有效提升 VLA 模型。探索阶段冻结 VLM, 以稳定训练; SL 阶段则开放 VLM 参数进行训练, 从而更充分地利用预训练 VLM 的能力。

我们采用 BLIP-2 3B 模型 [42] 作为 backbone VLM。由于预训练 VLM 输出的是语言空间中的文本 token, 因此需要额外设计一个 action head 来生成底层控制动作。这些动作通常包括 end-effector 位姿的变化以及 gripper 的状态。遵循 [11], [34] 的设计, 我们将 VLM 最后的全连接层替换为一个重新初始化的 action head。在该 action head 中, token learner [44] 首先将 VLM 的最后一层隐藏表征 $h \in \mathbb{R}^{m \times d}$ 映射为 $h' \in \mathbb{R}^d$ 。随后, Multi-Layer-Perceptron (MLP) [45] 再将 h' 映射为动作 $a \in \mathbb{R}^{d_a}$ 。其中, m 和 d 分别表示 VLM 的 token 数量和 embedding 维度, d_a 表示动作维度。

Low-Rank Adaptation (LoRA) [46] 我们的 VLA 模型由大规模 VLM backbone 和轻量级 action head 组成。然而, 对整个模型进行微调时, 由于其参数规模达到十亿级, 计算资源开销很大。此外, 已有研究 [47], [48] 表明, 在数据量有限的设定下, 对整个大型预训练模型进行全参数微调容易导致过拟合。按照 [47] 的做法, 我们采用参数高效的 LoRA 方法对 VLM 部分进行微调。最终, 可训练参数由 LoRA 参数 θ 和 action head 参数 ϕ 共同构成。

5.2 B. 学习流程

本节介绍整体学习流程。首先, 我们在机器人数据集上对 VLA 模型进行监督微调 (stage 0); 随后, 在在线 RL (stage 1) 与监督学习 (stage 2) 之间交替迭代。

Stage 0: 在专家数据集上进行监督学习。 我们首先使用专家机器人数据集对 VLA 模型 π_θ 进行标准的监督微调。专家数据集记为 $\{(o_1, l_1, a_1), (o_2, l_2, a_2), \dots, (o_i, l_i, a_i)\}$ 。形式上, 其学习目标定义为均方误差 (MSE):

$$J^0(\theta, \phi) = \mathbb{E}_{(o, l, a) \sim D_e} \left[\|\pi_{\theta, \phi}(o, l) - a\|_2^2 \right] \quad (2)$$

监督微调完成后, 我们得到初始 VLA 模型 $\pi_{\theta, \phi}^0$ 。其性能与专家数据集 D_e 的规模和质量高度相关。随后, 我们通过在线 RL 进一步提升 $\pi_{\theta, \phi}^0$ 的性能。

算法 1: 用于 VLA 模型的迭代式 RL (iRe-VLA) 已知: 专家数据集 D_e , 一个经过监督微调的 VLA 模型 $\pi_{\theta, \phi}^0$, 其中 θ 表示 VLM 参数、 ϕ 表示 action head 参数; 以及未见任务集合 $\{T_1, \dots, T_n\}$ 。

1. 初始化在线数据集 $D_{RL} \emptyset$, 并将 $\pi_{\theta, \phi}^0$ 的权重复制到 $\pi_{\theta, \phi}^1, \pi_{\theta, \phi}^2$
2. 对于 $\{T_0, T_1, \dots, T_n\}$ 中的每个 T_i :
3. # Stage 1: RL
4. 将 $\pi_{\theta, \phi}^2$ 的权重复制到 $\pi_{\theta, \phi}^1$, 并初始化一个 critic head。
5. 根据式 (3) 使用在线强化学习优化 ϕ , 直至收敛。
6. 将成功轨迹 x_i 收集到 D_{RL} 中: $D_{RL} = D_{RL} \cup x_i$
7. # Stage 2: SL
8. 将 $\pi_{\theta, \phi}^1$ 的权重复制到 $\pi_{\theta, \phi}^2$ 。
9. 根据式 (4), 在 $D_e \cup D_{RL}$ 上通过监督学习优化 θ, ϕ 。
10. 结束循环

Stage 1: 冻结 VLM 的在线 RL。 经过 SFT 的模型 $\pi_{\theta,\phi}^0$ 在新任务上未必能达到最优性能。但由于它已经在机器人数据集中的多种任务上接受过训练，因此可作为一个有价值的初始化。为了进一步提升该 SFT policy 的性能，我们采用在线强化学习（RL）。

在 RL 过程中，我们引入了一个 critic head，其结构与 action head 相同，但输出维度设为 1。为防止模型坍塌并加快学习过程，在该阶段我们冻结 VLM 参数 θ 。因此，仅优化 action head 的参数 ϕ ：

$$J^1(\phi) = \mathbb{E}_{((s_0, o_0, a_0), (s_1, o_1, a_1), \dots) \sim p_\phi} \left[\sum_t \gamma^t R(o^t, a^t) \right] \quad (3)$$

在线 RL 之后，机器人可能会发现一些可用于解决新任务的新轨迹 x_i 。随后，我们将这些成功轨迹收集到在线数据集 D_{RL} 中，即 $D_{RL} = D_{RL} \cup x_i$ 。

Stage 2: 在专家数据与在线采集数据上进行监督学习。 在 stage 1 中，agent 在新任务上执行 RL 时，存在遗忘先前已学习任务的风险。因此，在 stage 2 中，我们同时使用新采集的在线数据 D_{RL} 和原始专家数据集 D_e 对整个模型进行监督训练，以缓解灾难性遗忘（catastrophic forgetting）[49]。其目标函数可写为：

$$J^2(\theta, \phi) = \mathbb{E}_{(o, l, a) \sim D_e \cup D_{RL}} \left[\|\pi_{\theta, \phi}(o, l) - a\|_2^2 \right] \quad (4)$$

5.3 B. 学习流水线（第 2 部分）

在 Stage 1 与 Stage 2 之间交替迭代。前文已经指出，Stage 1 中的智能体会针对新任务探索新的解决方案；而在 Stage 2 中，智能体则对当前所有可用的成功轨迹进行模仿学习。通过在 Stage 1 和 Stage 2 之间交替进行训练，大规模 VLA 模型能够逐步覆盖更广泛的范围，同时避免在已见任务上发生灾难性遗忘。进一步地，已有工作 [50], [13] 表明，通过模仿更加多样的任务，VLA 模型还可能获得更强的泛化能力。整个流水线见算法 1。

6 V. 实验

本节在两个仿真基准环境 Metaworld 和 FrankaKitchen，以及真实世界的 Panda 操纵任务上开展大量实验，以验证 iRe-VLA 框架的有效性。我们主要希望回答以下问题：

- 为什么采用两阶段迭代式 RL 过程，而不是标准 RL？
- iRe-VLA 是否能够稳定训练过程，并在 expert 任务与未见任务上有效提升 VLA 模型的性能？
- iRe-VLA 是否能够带来更好的 VLA 模型泛化能力？

6.1 A. 实验设置

我们在三个领域开展实验：Metaworld [21]、Franka Kitchen [22]，以及真实世界的 Panda 操纵，如图 3 所示。需要特别指出的是，在每个领域中，我们都使用同一个由文本条件控制的 VLA 模型来求解该领域内的全部任务。每个领域中的任务分为三类：第一类是 demonstration 数据集中已经观测到的 expert tasks；第二类是通过在线 RL 提升的 RL-trained tasks；第三类是此前训练过程中从未

出现过的 hold-out tasks。首先，我们使用 expert 数据集对 VLA 模型进行监督微调（fine-tuning）。随后，通过在线 RL 提升 VLA 模型在第二类新任务上的性能。最后，利用第三类任务评估训练后 VLA policy 的泛化能力。

在 Metaworld 领域中，expert 数据集包含 25 个任务，每个任务对应 50 条轨迹。第二类和第三类任务则引入了新的任务设置，其变化体现在物体的形状、颜色和位置上。在 Franka Kitchen 领域中，我们遵循文献 [47] 的设置：expert 数据集包含 5 个任务，而第二类和第三类任务则包含物体外观与位置的未见变化。对于真实世界任务，我们通过 teleoperation 和脚本采集了 2,000 条轨迹，涵盖 picking (grasp)、placing、button-press、cable-route 和 drawer-open 等任务。真实世界实验中的未见任务包括抓取未见过的物体。

6.2 B. 为什么采用两阶段迭代优化？

稳定训练过程。我们观察到，使用标准强化学习（RL）算法直接对大规模 VLA 模型进行微调（fine-tuning）往往不稳定，并且可能导致性能下降。如图 3 所示，在 Metaworld 基准中，5 个稀疏奖励任务里有 4 个出现了性能下降。这一现象在先前研究 [18] 中也有报道：该工作在基于 transformer 的 RL policy 上遇到了类似的不稳定问题，不得不修改 transformer block 以避免训练崩溃。然而，这类修改并不兼容预训练 VLM。因此，我们在 RL 阶段冻结 VLM，以防止模型崩溃。

控制模型训练负担。对具有数十亿参数的 VLA 模型进行全量微调，已经超出大多数本地机器的算力能力；而若将完整模型全部部署到远程服务器，又会带来参数传输问题，并降低控制频率。我们提出的两阶段 iRe-VLA 框架通过分摊计算负载来应对这些挑战。在第一阶段的 RL 过程中，iRe-VLA 冻结高层 VLM，仅适配轻量级 action head，从而将本地计算需求控制在可承受范围内。第二阶段优化则交由能够处理更大计算负载的远程服务完成。以我们的真实世界实验为例（见第 V-D 节），RL 过程在本地使用单张 NVIDIA 4090 显卡完成，而第二阶段则在配备 4 张 NVIDIA A100 显卡的远程服务器上执行。

6.3 C. 仿真操纵实验

我们首先在仿真的 Metaworld 和 Franka Kitchen 基准上开展实验，其中先分别在 25 个任务和 5 个任务上对 VLA 模型进行监督训练。图 4 表明，VLA 模型能够为 RL 任务提供一个有效的初始化，相比从零开始学习（learn-from-scratch）的方式，可以显著加速 RL 过程。随后，我们采用 iRe-VLA 方法逐个学习 RL 任务，并持续提升 VLA 模型的性能。我们将该方法与标准 PPO 算法 [51] 进行比较。为保证公平性，我们也按任务逐个执行 PPO，并在每个任务后采用相同的 expert data replay 策略，记为 PPO-Replay。




图 3: 我们在三个领域中开展实验。每个领域均包含三类任务：expert 数据集中已观测到的任务、通过强化学习处理的新任务，以及保留的未见任务。不同任务在所需技能、物体形状和外观上均存在差异。每个任务中物体的初始位置在每个 episode 开始时都会被随机化。




图 4: 新任务中的强化学习过程。与从零开始学习的 policy 相比，SFT policy 可以作为新 RL 任务的良好起点。我们还观察到，对 VLA 模型进行完全微调会导致性能退化（橙色曲线）；而冻结其中的 VLM 部分则可以避免训练崩溃。

表 1: Metaworld 上的成功率（success rate）比较

Metaworld	Original 25 tasks	Button-Press-new	Drawer-Open-new	Door-Open-new	Window-Open-new	Window-Close-new	Unseen 10 tasks
SFT Policy	0.83	0.56	0.48	0.40	0.32	0.28	0.51
PPO-Replay	0.69	0.80	0.24	0.32	0.04	0.36	0.39
iRe-VLA (Ours)	0.83	1.00	0.84	0.84	0.80	0.96	0.80

表 2: Franka Kitchen 上的成功率（success rate）比较

Franka Kitchen	Knob-on	Light-on	Microwave-open	Slide-door-open	Left-door-open	Slide-door-open-red	Slide-door-open-yellow
SFT Policy	0.84	0.96	0.70	0.86	0.43	0.46	0.98
PPO-Replay	0.48	0.64	0.35	0.96	0.12	0.30	0.64
iRe-VLA (Ours)	0.90	0.98	0.82	0.99	0.83	0.99	1.00

表 I: Metaworld 和 Franka Kitchen 基准上的成功率结果，覆盖三类任务：expert 任务、经 RL 训练的任务以及未见任务。标准在线 RL 算法的表现甚至低于 SFT policy，而 iRe-VLA 在三类任务上都带来了性能提升。

分析 结果见表 I。正如图 4 所示，标准 PPO 算法在引入 RL 任务后往往表现出明显的不稳定性。这种不稳定不仅会影响 RL 任务本身的性能，还会削弱模型在先前已学习任务上的表现，即便使用了 experience replay 也是如此。这种退化很可能源于带噪声的 RL 梯度，它们会对 VLA 模型内部的预

训练表征产生不利影响。相比之下，我们提出的两阶段 iRe-VLA 方法能够稳定 RL 过程，并在已见任务和未见任务上都有效提升性能。iRe-VLA 的优势主要体现在以下三个方面：

1. **原始任务性能提升。**通过在线交互，我们可以持续提升模型在已见 expert 任务上的表现。例如，在 Franka Kitchen 基准中，由于 demonstration 数量有限，监督训练得到的 VLA 模型在 expert 任务 left-door-open 上仅取得了较低的成功率。采用 iRe-VLA 后，该任务的成功率从 0.43 提升到了 0.83。
2. **RL 任务性能提升。**对于智能体而言，能够自主适应 expert 数据中未包含的任务至关重要。我们探索了多种 RL 任务（详见图 3 第二列），并利用迭代式 RL 算法逐一解决这些任务。表 3 的结果表明，iRe-VLA 能够在每个领域中成功处理新任务，同时避免灾难性遗忘（catastrophic forgetting）[49]。

6.4 C. 仿真操纵实验（第二部分）

(3) 在未见任务上的泛化能力提升。除了通过在线迭代提升在 RL 训练任务上的性能外，我们还观察到模型在未见任务上的成功率（success rate）也有所提高，这表明其泛化能力更强。随着智能体能够自动处理的任务类型不断增多，其泛化能力也会相应增强。例如，在 Metaworld 中掌握了四类 window 任务后，智能体能够有效泛化到颜色和形状均未见过的 window。

消融实验。在 iRe-VLA 方法中，第二阶段监督学习时，整个 VLM 都是可训练的。我们进行了消融实验，在两个阶段中都冻结 VLM，记为 iRe-VLA-freeze。这样一来，在线迭代产生的数据就无法影响 VLM 的 latent 表征。图 5 的结果表明，始终冻结 VLM 会导致性能下降。这可能是因为，相比完整的 VLA 模型，仅有 action head 的表达能力有限。此外，在线机器人动作数据能够增强高层 VLM 表征，从而提升 VLA 模型在未见任务上的泛化能力；而在两个阶段都冻结 VLM 时，VLM 表征无法得到改进。




图 5: 消融实验。始终冻结 VLM 会导致性能下降。

6.5 D. 真实世界操纵实验

实验设置. 我们的真实世界实验遵循 SERL [52], [53] 中的设置。SERL 是一个面向真实世界强化学习 (RL) 的实用软件套件。首先, 我们基于 2,000 条由人工采集的 expert 数据训练一个 VLA 模型, 这些数据覆盖多类任务, 包括 pick (抓取)、place、button-press、cableroute 以及 drawer 操作。

我们观察到, 得益于 VLA 模型的泛化能力, 该模型在未见过的物体上已经表现出一定的成功率 (success rate)。在此基础上, 我们进一步采用 online RL, 以继续提升模型在未见物体上的成功率。考虑到大规模 Vision-Language-Action (VLA) 模型的特点, 我们做了若干关键设计, 以同时提高样本效率并控制计算开销。

为提升样本效率, 我们采用了 SACfD 算法 [54], [55]。具体而言, 当系统接触一个新任务时, 我们首先利用 zero-shot 迁移得到的 VLA 模型采集一个 demonstration buffer, 其中包含 20 条成功轨迹。在训练过程中, 按照 [52] 的做法, 我们从 demonstration buffer 中采样 50% 的 transition, 并从 online buffer 中采样另外 50% 的 transition。

为控制计算成本, 每个图像观测仅经过一次 VLM 处理, 并将得到的 latent 输出存入 buffer。随后, 我们在该 latent 空间中执行 SACfD 算法。




图 6: 真实世界实验中 Panda 机械臂的操作示意。




图 7: 使用 Panda 机械臂开展的真实世界实验结果。由于直接对整个 VLA 模型进行 fine-tuning 超出了本地计算设备的能力范围，我们未报告真实世界任务中的标准 RL 结果。

结果. 在 expert 的 pick demonstration 中，训练数据仅包含四种颜色的方块；而在 online RL 阶段，我们进一步将任务扩展到茄子、胡萝卜等不规则形状物体。每个新任务的真实世界 RL 训练大约耗时 1 小时，这与 SERL [52] 中报告的时间开销相近。

RL 前后的成功率如图 6 所示。我们的 iRe-VLA pipeline 将抓取茄子或胡萝卜的成功率从 0.35 提升到了 0.80。与此同时，原始任务的成功率保持稳定；对于未见物体，抓取成功率也从 0.37 提升至 0.61。

7 VI. 结论与局限性

本文探讨了通过在线强化学习进一步提升 VLA 模型能力的途径。对大规模 VLA 模型进行微调 (fine-tuning) 面临多方面挑战, 而本文提出的 iRe-VLA 方法能够稳定训练过程, 并显著降低计算开销。在仿真与真实世界操纵任务上的实验结果均验证了 iRe-VLA 的有效性。其潜在局限在于: 该方法只能提升已见技能类型范围内的能力; 在稀疏奖励的在线强化学习条件下, 它尚无法学习全新的技能。

8 结论与局限性 (第二部分)

参考文献

- [1] M. Andrychowicz, A. Raichuk, P. Stanczyk, M. Orsini, S. Girgin, R. Marinier, L. Hussenot, M. Geist, O. Pietquin, M. Michalski, et al., “What matters for on-policy deep actor-critic methods? a large-scale study,” in *International Conference on Learning Representations*, 2020.
- [2] K. Ota, D. K. Jha, and A. Kanezaki, “Training larger networks for deep reinforcement learning,” *arXiv preprint arXiv:2102.07920*, 2021.
- [3] T. Yu, D. Quillen, Z. He, R. Julian, K. Hausman, C. Finn, and S. Levine, “Meta-World: A benchmark and evaluation for multi-task and meta reinforcement learning,” in *Conference on Robot Learning*. PMLR, 2020, pp. 1094–1100.
- [4] A. Gupta, V. Kumar, C. Lynch, S. Levine, and K. Hausman, “Relay policy learning: Solving long-horizon tasks via imitation and reinforcement learning,” *arXiv preprint arXiv:1910.11956*, 2019.
- [5] Y. J. Ma, W. Liang, G. Wang, D.-A. Huang, O. Bastani, D. Jayaraman, Y. Zhu, L. Fan, and A. Anandkumar, “Eureka: Human-level reward design via coding large language models,” *arXiv preprint arXiv:2310.12931*, 2023.
- [6] L. Fan, G. Wang, Y. Jiang, A. Mandlekar, Y. Yang, H. Zhu, A. Tang, D.-A. Huang, Y. Zhu, and A. Anandkumar, “MineDojo: Building open-ended embodied agents with internet-scale knowledge,” *Advances in Neural Information Processing Systems*, vol. 35, pp. 18 343–18 362, 2022.
- [7] A. Adeniji, A. Xie, C. Sferrazza, Y. Seo, S. James, and P. Abbeel, “Language reward modulation for pretraining reinforcement learning,” *arXiv preprint arXiv:2308.12270*, 2023.
- [8] J. Lin, Y. Du, O. Watkins, D. Hafner, P. Abbeel, D. Klein, and A. Dragan, “Learning to model the world with language,” *arXiv preprint arXiv:2308.01399*, 2023.
- [9] A. W. Hanjie, V. Y. Zhong, and K. Narasimhan, “Grounding language to entities and dynamics for generalization in reinforcement learning,” in *International Conference on Machine Learning*. PMLR, 2021, pp. 4051–4062.

- [10] A. Zeng, A. Wong, S. Welker, K. Choromanski, F. Tombari, A. Purohit, M. Ryoo, V. Sindhwani, J. Lee, V. Vanhoucke, et al., “Socratic models: Composing zero-shot multimodal reasoning with language,” *arXiv preprint arXiv:2204.00598*, 2022.
- [11] D. Driess, F. Xia, M. S. Sajjadi, C. Lynch, A. Chowdhery, B. Ichter, A. Wahid, J. Tompson, Q. Vuong, T. Yu, et al., “PaLM-E: An embodied multimodal language model,” *arXiv preprint arXiv:2303.03378*, 2023.
- [12] Y.-J. Wang, L. Zha, Z. Jiang, and J. Chen, “DoReMi: Grounding language model by detecting and recovering from plan-execution misalignment,” *arXiv preprint arXiv:2307.00329*, 2023.
- [13] I. Dasgupta, C. Kaeser-Chen, K. Marino, A. Ahuja, S. Babayan, F. Hill, and R. Fergus, “Collaborating with language models for embodied reasoning,” *arXiv preprint arXiv:2302.00763*, 2023.
- [14] Y.-J. Wang, B. Zhang, J. Chen, and K. Sreenath, “Prompt a robot to walk with large language models,” *arXiv preprint arXiv:2309.09969*, 2023.
- [15] J. Liang, W. Huang, F. Xia, P. Xu, K. Hausman, B. Ichter, P. Florence, and A. Zeng, “Code as policies: Language model programs for embodied control,” *arXiv preprint arXiv:2209.07753*, 2022.
- [16] W. Chen, O. Mees, A. Kumar, and S. Levine, “Vision-language models provide promptable representations for reinforcement learning,” *arXiv preprint arXiv:2402.02651*, 2024.
- [17] N. Stiennon, L. Ouyang, J. Wu, D. Ziegler, R. Lowe, C. Voss, A. Radford, D. Amodei, and P. F. Christiano, “Learning to summarize with human feedback,” *Advances in Neural Information Processing Systems*, vol. 33, pp. 3008–3021, 2020.
- [18] R. Ramamurthy, P. Ammanabrolu, K. Brantley, J. Hessel, R. Sifa, C. Bauckhage, H. Hajishirzi, and Y. Choi, “Is reinforcement learning (not) for natural language processing: Benchmarks, baselines, and building blocks for natural language policy optimization,” *arXiv preprint arXiv:2210.01241*, 2022.
- [19] S. Levine, A. Kumar, G. Tucker, and J. Fu, “Offline reinforcement learning: Tutorial, review, and perspectives on open problems,” *arXiv preprint arXiv:2005.01643*, 2020.
- [20] T. Carta, C. Romac, T. Wolf, S. Lamprier, O. Sigaud, and P.-Y. Oudeyer, “Grounding large language models in interactive environments with online reinforcement learning,” in *International Conference on Machine Learning*. PMLR, 2023, pp. 3676–3713.
- [21] A. Szot, M. Schwarzer, H. Agrawal, B. Mazouze, R. Metcalf, W. Talbott, N. Mackraz, R. D. Hjelm, and A. T. Toshev, “Large language models as generalizable policies for embodied tasks,” in *The Twelfth International Conference on Learning Representations*, 2023.

9 结论与局限性（第三部分）

- [40] Y. Zhai, H. Bai, Z. Lin, J. Pan, S. Tong, Y. Zhou, A. Suhr, S. Xie, Y. LeCun, Y. Ma, et al., “Fine-tuning large vision-language models as decision-making agents via reinforcement learning,” arXiv preprint arXiv:2405.10292, 2024.
- [41] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, et al., “Learning transferable visual models from natural language supervision,” in International conference on machine learning. PMLR, 2021, pp. 8748–8763.
- [42] J. Li, D. Li, S. Savarese, and S. Hoi, “Blip-2: Bootstrapping languageimage pre-training with frozen image encoders and large language models,” in International conference on machine learning. PMLR, 2023, pp. 19730–19742.
- [43] W. Dai, J. Li, D. Li, A. M. H. Tiong, J. Zhao, W. Wang, B. Li, P. N. Fung, and S. Hoi, “Instructblip: Towards general-purpose visionlanguage models with instruction tuning,” Advances in Neural Information Processing Systems, vol. 36, 2024.
- [44] J. Lee, Y. Lee, J. Kim, A. Kosioerek, S. Choi, and Y. W. Teh, “Set transformer: A framework for attention-based permutation-invariant neural networks,” in International conference on machine learning. PMLR, 2019, pp. 3744–3753.
- [45] M. Riedmiller and A. Lernen, “Multi layer perceptron,” Machine Learning Lab Special Lecture, University of Freiburg, vol. 24, 2014.
- [46] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, “Lora: Low-rank adaptation of large language models,” arXiv preprint arXiv:2106.09685, 2021.
- [47] Z. Liu, J. Zhang, K. Asadi, Y. Liu, D. Zhao, S. Sabach, and R. Fakoor, “Tail: Task-specific adapters for imitation learning with large pretrained models,” arXiv preprint arXiv:2310.05905, 2023.
- [48] K. Bousmalis, G. Vezzani, D. Rao, C. Devin, A. X. Lee, M. Bauza, T. Davchev, Y. Zhou, A. Gupta, A. Raju, et al., “Robocat: A selfimproving foundation agent for robotic manipulation,” arXiv preprint arXiv:2306.11706, 2023.
- [49] M. McCloskey and N. J. Cohen, “Catastrophic interference in connectionist networks: The sequential learning problem,” in Psychology of learning and motivation. Elsevier, 1989, vol. 24, pp. 109–165.
- [50] O. M. Team, D. Ghosh, H. Walke, K. Pertsch, K. Black, O. Mees, S. Dasari, J. Hejna, C. Xu, J. Luo, et al., “Octo: An open-source generalist robot policy,” 2023.
- [51] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, “Proximal policy optimization algorithms,” arXiv preprint arXiv:1707.06347, 2017.
- [52] J. Luo, Z. Hu, C. Xu, Y. L. Tan, J. Berg, A. Sharma, S. Schaal, C. Finn, A. Gupta, and S. Levine, “Serl: A software suite for sample-efficient robotic reinforcement learning,” arXiv preprint arXiv:2401.16013, 2024.
- [53] J. Luo, C. Xu, F. Liu, L. Tan, Z. Lin, J. Wu, P. Abbeel, and S. Levine, “Fmb: a functional manipulation benchmark for generalizable robotic learning,” arXiv preprint arXiv:2401.08553, 2024.
- [54] M. Vecerik, T. Hester, J. Scholz, F. Wang, O. Pietquin, B. Piot, N. Heess, T. Rothorl, T. Lampe, and M. Riedmiller, “Leveraging demonstrations for deep reinforcement learning on robotics

problems with sparse rewards,” arXiv preprint arXiv:1707.08817, 2017.

[55] T. Haarnoja, A. Zhou, P. Abbeel, and S. Levine, “Soft actor-critic: Offpolicy maximum entropy deep reinforcement learning with a stochastic actor,” in International conference on machine learning. PMLR, 2018, pp. 1861–1870.