

# 1 ConRFT: 一种基于一致性 policy 的 VLA 模型强化微调方法

## 摘要

Vision-Language-Action (VLA) 模型在真实世界机器人操纵中展现出显著潜力。然而, 受限于 demonstration 数量不足以及数据本身存在不一致性, 尤其是在接触丰富 (contact-rich) 环境中, 仅通过监督学习对这类模型进行微调往往难以获得鲁棒性能。为应对上述挑战, 本文提出一种面向 VLA 模型的强化微调方法 ConRFT。该方法由离线与在线两个微调阶段组成, 并采用统一的、基于一致性的训练目标。在离线阶段, 我们将 behavior cloning 与 Q-learning 结合起来, 从少量 demonstration 中有效提取 policy, 并稳定 value 估计。在在线阶段, 我们进一步通过 consistency policy 对 VLA 模型进行微调, 同时引入人工干预, 以保证探索过程的安全性和较高的样本效率。我们在八个多样化的真实世界操纵任务上评估了该方法。结果表明, 仅需 45–90 分钟的在线微调, ConRFT 即可取得平均 96.3% 的成功率 (success rate); 相较于已有监督方法, 成功率提升 144%, episode 长度缩短为原来的 1/1.9。该工作表明, 将强化学习与 VLA 模型结合, 有望显著提升其在真实机器人应用中的性能。视频与代码见项目主页: <https://cccedric.github.io/conrft/>。

## 2 1. 引言

近年来, 基于 Vision-Language-Action (VLA) 模型训练通用机器人 policy 的研究取得了显著进展, 展现出对多种操纵任务的理解与执行能力。这些成功主要归因于大规模模仿式预训练以及机器人动作的 grounding [1, 2, 3]。尽管预训练 policy 能够学习到强大的表征, 但在应对真实世界场景的复杂性时往往仍显不足 [4]。因此, 利用领域特定数据进行微调 (fine-tuning) 对于提升模型在下游任务上的性能至关重要 [3, 5]。目前, 主流的适配方式仍是基于人工 teleoperation 数据对 VLA 模型进行监督微调 (Supervised Fine-Tuning, SFT); 但这一过程面临明显挑战: 模型性能高度依赖任务特定数据的质量与规模。然而, 由人工采集的数据集由于次优数据与动作不一致等内在问题 [6], 未必总能提供最优轨迹。

Large-Language-Models (LLMs) 与 Vision-Language-Models (VLMs) 的快速发展表明, 强化学习能够有效弥合 policy 能力与人类偏好之间的差距 [7, 8, 9], 或提升模型的推理能力 [10]。此外, 利用任务特定奖励函数, 在在线交互数据上部署强化学习 (RL) 也是一个很有前景的方向 [11, 12, 13]。然而, 将这些思路直接扩展到 VLA 模型并不容易。与 LLMs 不同, VLA 模型在真实机器人任务中需要直接进行物理交互。接触丰富环境中的数据采集同时受到安全性与成本约束, 因此要求方法具备较高的样本效率以及风险感知的探索能力, 这使得直接应用 RL 变得不可行。近期已有工作尝试利用 RL 来缓解 SFT 所面临的问题 [6, 14], 但这些方法主要将 RL 用于数据增强或数据质量提升, 而非通过 RL 目标直接优化 VLA 模型本身。这限制了 policy 对 demonstration 数据集之外状态的探索能力, 从而削弱了基于 RL 的微调在真实场景中的潜在优势。

为了利用基于 RL 的方法, 通过在线交互数据高效微调 VLA 模型, 我们提出了一种 reinforced fine-tuning (RFT) 方法。该方法包含离线与在线两个阶段, 并采用统一的、基于 consistency 的训练目标。虽然这一设计与 offline-to-online 方法 [15, 16, 17] 相似, 但我们发现, 专家 demonstration 的稀缺性会限制其离线训练阶段的性能。受 CPQL [18] 启发, 我们提出了一个统一训练目标: 在离线阶段将监督学习与 Q-learning 结合, 并在在线阶段通过 consistency policy 进一步对 VLA 模型进行 RL 微调。在离线训练中, 我们的方法能够利用先验 demonstration, 并处理 out-of-distribution (OOD) 状态, 从而在与真实环境交互之前有效提取 policy 和 value function。在随后在线阶段中, 我们结合 Human-in-the-Loop (HIL) 学习 [19, 20] 下的人类干预, 并基于 CPQL [18] 利用任务特

定奖励，解决样本效率与真实世界安全性这两个关键问题。

本文的主要贡献如下：

1. 我们提出了一种基于 consistency 的 reinforced fine-tuning 方法 ConRFT。该方法构建了一个新颖的流程，并在离线与在线微调阶段采用统一的训练目标。
2. 通过将离线 RL 与基于 consistency 的 behavior cloning (BC) 损失相结合，我们提出了 Cal-ConRFT。该方法侧重于高效提取 policy 与 value function，从而在 demonstration 数量较少的情况下仍能提供稳定的初始化。
3. 在在线微调阶段，我们提出了 HIL-ConRFT。该方法保留了离线阶段相同的损失结构，以实现快速的 policy 适应；同时借助人类干预，确保真实环境中的安全探索与高样本效率。

### 3 引言（第二部分）

我们在八项真实世界操纵任务上评估了该方法，结果表明其性能优于现有的 SOTA 方法。该框架仅需 45–90 分钟的在线微调 (online fine-tuning)，即可达到平均 96.3% 的成功率 (success rate)，体现出很高的样本效率。

此外，与基于监督微调 (SFT) 的方法相比，无论后者训练时使用的是人工数据还是 RL policy 数据，我们的方法都表现更优：平均成功率提升了 144%，同时 episode length 缩短为原来的 1.9 $\times$ 。

## 4 II. RELATED WORK

### 4.1 A. 大模型的强化微调

RL 已被广泛用于 LLM 和 VLM 的微调。早期工作主要聚焦于结合人类反馈的 RL [7, 8, 9, 21, 22]：要么从人类偏好中学习，要么在不显式使用人类偏好的情况下，引入任务特定的奖励信号 [11, 12, 13, 23]。这类方法中有相当一部分采用 on-policy 算法（例如 PPO [24]）来微调预训练 policy [12, 25, 26]，但通常需要大量交互数据，才能达到理想性能 [27, 28]。尽管 RL 已在诸多领域取得成功，但其学习过程通常发生在模型自生成的合成环境中，而非真实世界环境。对于需要真实世界交互的 VLA 模型而言，这一差距使得相关方法难以直接迁移。本文针对这一不一致性，提出了面向高效真实世界 VLA 微调的 RL 框架。

### 4.2 B. 真实世界 RL 系统

真实世界中的机器人 RL 系统需要同时满足两方面要求：一方面，算法要能够以较高的样本效率处理高维输入；另一方面，还要足够灵活，以适应奖励设计、环境重置等实际问题 [20]。已有多项工作已经在真实物理环境中直接验证了 policy 学习的可行性 [29, 30, 31, 20]，其中既包括 off-policy 方法 [32, 33, 34, 35]，也包括 on-policy 方法 [36, 37]，还有一些工作将“RL 视为监督学习”来处理 [14, 38]。

尽管取得了这些进展，许多真实世界 RL 系统仍然需要较长时间的训练，或依赖大规模交互数据 [39]。这在接触丰富任务中往往既不现实，也伴随着较高风险。不同于以往从零开始训练的方法，我们的工作重点在于利用预训练 VLA 模型提供高质量的 policy 初始化。这样可以有效减少 RL 早期阶段中不必要的探索行为，从而同时提升 policy 学习效率与训练过程中的操作安全性。

### 4.3 C. Offline-to-online 方法

Offline-to-online RL 的目标是利用离线数据集对 policy 进行初始化，再通过在线交互进一步微调，从而提升样本效率 [15]。现有工作通常采用“离线预训练 + 在线微调”的两阶段范式 [15, 40, 41, 16]，并在训练过程中混合使用离线数据与在线数据。该 offline-to-online 流水线与我们提出的两阶段微调方法相似：先利用预先收集的数据完成 policy 训练的冷启动，再在真实世界任务中对 policy 进行微调 [32]。

不过，大多数 offline-to-online 方法都假设可以获得大规模且多样化的数据集，并且这些数据对状态空间具有充分覆盖 [42, 43]；而这一条件在真实部署中很少能够满足。为此，我们探索将预训练 VLA 模型作为基础 policy，以实现高样本效率的 policy 精修；即使在 demonstration 数据极为受限的严格条件下，该方法仍能取得更优的微调性能。

## 5 III. 问题设定与预备知识

我们关注如何将预训练 VLA 模型微调（fine-tuning）到下游任务上。具体而言，设可访问一个预训练 VLA 模型  $\pi_{\phi_{\text{pre}}}$ ，该模型能够从视觉输入（如 RGB 图像）与语言指令中编码高层表征。在监督微调（SFT）中，我们的目标是利用少量带标注的 demonstration，将参数  $\phi_{\text{pre}}$  适配为  $\phi$ ，同时尽可能保持模型原有的通用特征提取能力。形式化地，设  $\tau = (s_0, a_0, \dots, s_H)$  表示目标任务的一条轨迹，则 VLA 模型微调需要求解

$$\min_{\phi} \mathcal{L}(\tau, \phi),$$

其中， $\mathcal{L}$  可以取负对数似然（NLL）或均方误差（MSE），用于度量模型预测动作与 demonstration 中动作之间的偏差。该过程使我们能够有效利用模型在机器人任务中压缩存储的知识，同时引导 VLA 模型适应下游环境。

然而，在实际中 demonstration 往往数量有限、风格不一致，且可能并非最优，因此 policy 难以覆盖多样化的状态空间。这使得 SFT 在真实世界、接触丰富（contact-rich）的机器人任务中表现受限。为解决上述问题，我们将每个机器人任务建模为一个马尔可夫决策过程（MDP）。在该框架下，强化学习（RL）的目标是在 MDP

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{P}, r, \rho, \gamma)$$

中找到最优 policy，其中  $s \in \mathcal{S}$  表示状态空间， $a \in \mathcal{A}$  表示动作空间。 $\mathcal{P}(s'|s, a)$  表示由系统动力学决定的环境状态转移概率， $\rho(s)$  表示初始状态分布， $r(s, a)$  和  $\gamma \in (0, 1)$  分别表示奖励函数与奖励折扣因子。

policy  $\pi$  通过最大化累积期望回报进行估计，其状态价值函数定义为

$$V^{\pi}(s) = \mathbb{E}_{\pi} \left[ \sum_{t=0}^H \gamma^t r(s_t, a_t) \mid s_0 = s, a_t \sim \pi(s_t), s_{t+1} \sim p(\cdot | s_t, a_t) \right].$$

给定 policy  $\pi$ ，其 Q-function 定义为

$$Q^{\pi}(s, a) = \mathbb{E}_{\pi} \left[ \sum_{t=0}^H \gamma^t r(s_t, a_t) \mid s_0 = s, a_0 = a, s_{t+1} \sim p(\cdot | s_t, a_t) \right].$$

其中， $H$  表示一条轨迹中 episode 的最大步数。通过将 VLA policy 与学习得到的 Q-function 结合，RFT 能够使 VLA 模型基于试错交互以及任务特定反馈进一步优化其行为。

## 6 IV. METHOD

所提出的流程 ConRFT 由两个阶段组成：首先进行离线微调（fine-tuning），随后进行在线微调，以优化机器人 policy，如图 1 所示。下文将详细介绍这两个阶段；完整的流程示意图见附录 A。




图 1: ConRFT 总览。该图展示了我们针对预训练 VLA 模型提出的强化微调方法的整体架构。该方法包含两个阶段：离线的 Cal-ConRFT 和在在线的 HIL-ConRFT。两个阶段均采用统一的、基于一致性的训练目标。在离线阶段，我们仅使用预先采集的 demonstration 进行微调；在在线阶段，人类操作者可以通过 teleoperation 工具（例如 SpaceMouse）对机器人 policy 进行干预。此时，我们同时利用预采集 demonstration、policy transition 以及人工干预数据进行微调。

### 6.1 A. Stage I: Offline Fine-tuning with Cal-ConRFT

由于预训练 VLA 模型通常缺乏对新型机器人构型的 zero-shot 泛化能力，因此在离线阶段，我们首先使用一个预先采集的小规模离线数据集（20–30 条 demonstration）训练 policy，随后再过渡到在线强化学习。我们以预训练 VLA 模型作为强化学习的 policy 初始化，从而降低探索负担，并缩短整体在线训练时间。考虑到需要高效利用离线数据，我们选择 Calibrated Q-Learning (Cal-QL) [16] 作为基础的 offline RL 方法，因为我们希望 Q-function 对分布外（OOD）动作具有鲁棒性。具体而言，Cal-QL 在预先采集的数据集上训练 Q-function，其目标由两部分组成：一是减小 temporal difference (TD) 误差，二是引入一个额外的正则项。该正则项会在 OOD 动作的 Q 值高于参考 policy 的价值  $V^\mu(s)$  时对其进行惩罚；与此同时，对于离线数据集中实际观测到的动作，则通过补偿项抵消这种惩罚。Cal-QL 中 critic 的训练目标定义为：

$$[\text{formula}] \quad (1)$$

其中,  $Q_\theta$  表示参数为  $\theta$  的已学习 Q-function,  $\bar{Q}_{\bar{\theta}}$  表示参数为  $\bar{\theta}$  的延迟目标 Q-function。  $B^{\pi} \bar{Q}(s, a) = r(s, a) + \gamma \mathbb{E}_{a' \sim \pi(\cdot|s')} (\bar{Q}(s', a'))$  为 Bellman backup operator。  $\alpha$  是用于控制保守惩罚强度的超参数,  $\mathcal{D}$  是用于存储 demonstration 的 demo buffer。

然而，尽管 Cal-QL 通常能够较高效地利用离线数据集，但当 demonstration 数量很少（例如仅有 20–30 条）时，它往往难以训练出有效的 policy。在这种情况下，受限的状态覆盖会导致价值估计质量较差，进而使 policy 难以泛化到未见状态。相比之下，典型的 offline RL 数据集通常由多个



行为 policy 采集而成，因此能够覆盖更广泛的状态空间，从而减轻分布偏移问题。在缺乏这种覆盖广度时，仅依赖 Cal-QL loss 往往不足以充分引导学习过程，最终导致性能不佳。

为解决这一问题，我们提出在离线训练过程中引入 BC loss 作为补充。BC loss 直接最小化 policy 生成动作与 demonstration 动作之间的差异。通过加入 BC loss，我们鼓励模型模仿 demonstration 中的行为，从而在离线阶段提供额外的监督信号。这有助于 VLA 模型在仅有少量 demonstration 的条件下学习到更有效的 policy，并初始化一个更稳定的 Q function；这一点在接触丰富的 manipulation 任务中尤为重要，因为此类任务对控制精度要求很高。

## 6.2 A. 第一阶段：基于 Cal-ConRFT 的离线微调（第 2 部分）

受在一致性目标下将 BC loss 与 Q guidance 结合起来的思路 [18] 启发，我们在离线阶段引入 Cal-ConRFT。该方法采用 consistency policy 作为动作头，对 VLA 模型进行微调，主要针对两个关键问题：1) 它能够更好地利用预采集数据中常见的不一致且次优的 demonstration；2) 相较于基于 diffusion 的动作头，基于 consistency 的动作头在计算上更轻量，因此推理效率更高 [18,44,45]。consistency policy 是一种基于 diffusion model 的 policy [46]，其学习目标是在当前状态条件下，将从单位高斯中采样得到的随机动作映射为服从 expert 动作分布的动作。对于 consistency policy，我们将 diffusion horizon  $[\epsilon, K]$  离散为  $M$  个子区间，其边界为  $k_1 = \epsilon \leq k_2 \leq \dots \leq k_m = K$ ，其中  $\epsilon = 0.002$ 。具体而言，以 consistency policy 作为动作头的 VLA 模型可写为：




图 2: 所有真实世界实验任务概览。真实任务包括抓取与放置：(a) 香蕉、(b) 勺子、(d) 和 (f) 面包；设备操作：(c) 抽屉和 (e) 烤面包机；以及复杂物体装配，例如 (g) 椅子轮和 (h) 中国结。

$$\pi_{\psi}(a|s) = f_{\psi}(a^k, k|E_{\phi}(s)) \quad (2)$$

其中， $f$  表示参数为  $\psi$  的 consistency policy；下标  $k$  表示 diffusion step； $a^k \sim \mathcal{N}(0, kI)$ ； $E_{\phi}(s)$  表示由参数为  $\phi$  的预训练 VLA 模型编码得到的状态表征。用于 VLA 模型微调的基于 consistency 的训练目标定义为：

$$\mathcal{L}_{\pi}^{offline}(\psi) = \beta \mathcal{L}_{\pi}^{BC} + \eta \mathcal{L}_{\pi}^Q \quad (3)$$

其中, BC loss 为

$$\mathcal{L}_{\pi}^{BC} = \mathbb{E}_{(s,a) \sim \mathcal{D}, m \sim \mathcal{U}[1, M-1]} [d(f_{\psi}(a + k_m z, k_m | E(s)), a)], \quad z \sim \mathcal{N}(0, \bar{I})$$

这里,  $d$  表示欧氏距离,  $d(x, y) = \|x - y\|_2$ 。Q loss 为

$$\mathcal{L}_{\pi}^Q = -\mathbb{E}_{s \sim \mathcal{D}, a \sim \pi_{\psi}} [Q(s, a)].$$

$\beta$  和  $\eta$  是两个超参数, 用于平衡 BC loss 与 Q loss。通过将二者结合起来, 该方法即使在 demonstration 数量较少时, 也能实现高效的 policy 学习和稳定的 value estimation: 一方面, 它通过将 value estimate 与 expert 动作对齐来提升训练稳定性; 另一方面, 它在离线训练过程中进一步改善 policy 性能。此外, 该方法还能为在线阶段提供可靠的初始化, 从而支持更安全、更有效的探索。

### 6.3 B. Stage II: 基于 HIL-ConRFT 的在线微调 (第 1 部分)

离线阶段虽然能够基于少量 demonstration 数据得到一个初始 policy, 但其性能仍受限于预先采集 demonstrations 的覆盖范围与质量。因此, 在第二阶段中, 我们引入 HIL-ConRFT, 通过 consistency policy 让 VLA 模型与真实环境持续交互, 并在线进一步微调。在线训练过程中, 离线阶段的 demonstration buffer  $\mathcal{D}$  会被保留。同时, 我们额外维护一个 replay buffer  $\mathcal{R}$  用于存储在线采集的数据, 并采用 symmetric sampling [27]: 在每个 batch 中, 从这两个 buffer 中等量采样, 共同组成训练 batch。由于 VLA 模型会依据当前 policy 持续收集新的 transition, 数据分布也会随 policy 自然演化。这种持续交互能够缓解离线阶段面临的 distribution shift 问题。因此, 在线 critic 的更新采用标准的 Q loss:

$$\mathcal{L}_Q^{online}(\theta) = \mathbb{E}_{(s,a,s') \sim (\mathcal{D} \cup \mathcal{R})} [(Q_{\theta}(s, a) - \mathcal{B}^{\pi} \bar{Q}(s, a))^2] \quad (4)$$

用于 VLA 模型微调的、基于 consistency 的训练目标定义为:

$$\mathcal{L}_{\pi}^{online}(\psi) = \beta \mathcal{L}_{\pi}^{BC} + \eta \mathcal{L}_{\pi}^Q \quad (5)$$

其中, BC loss 为

$$\mathcal{L}_{\pi}^{BC} = \mathbb{E}_{(s,a) \sim (\mathcal{D} \cup \mathcal{R}), m \sim \mathcal{U}[1, M-1]} [d(f_{\psi}(a + k_m z, k_m | E(s)), a)], \quad z \sim \tilde{\mathcal{N}}(0, I).$$

这里,  $d$  表示欧氏距离, 即  $d(x, y) = \|x - y\|_2$ 。Q loss 为

$$\mathcal{L}_{\pi}^Q = -\mathbb{E}_{s \sim (\mathcal{D} \cup \mathcal{R}), a \sim \pi_{\psi}} [Q(s, a)].$$

需要注意的是, 该目标与离线阶段中的式 (3) 在形式上高度一致, 因此能够较快适配到在线微调过程。

通常, 在在线阶段我们会逐步降低 BC loss 的权重  $\beta$ , 同时逐步提高 Q loss 的权重  $\eta$ , 但我们仍保持其余训练设置不变。

## 6.4 B. 第二阶段：基于 HIL-ConRFT 的在线微调（第二部分）

**表 1:** 不同离线与在线微调方法的全部实验结果。我们汇报了多种 baseline 在离线微调 (SFT [?]) 和 Cal-ConRFT) 后, 以及在线微调 (HG-Dagger [?], PA-RL [?] 和 HIL-ConRFT) 后的 policy 表现, 包括各任务的成功率 (success rate) 与平均 episode length。具体而言, 在在线微调阶段, HG-Dagger 和 PA-RL 均从 SFT baseline 开始训练, 而 HIL-ConRFT 从 Cal-ConRFT baseline 开始训练。表中的性能提升幅度均相对于对应的离线结果计算。所有方法都使用相同数量、带有人类干预的在线 episode 进行训练。所有指标均基于每个任务 20 次试验统计得到。

| Task                   | Training Time (mins) | Success Rate (%) |            |               |             |              | Episode length |            |               |             |             |
|------------------------|----------------------|------------------|------------|---------------|-------------|--------------|----------------|------------|---------------|-------------|-------------|
|                        |                      | SFT [?]          | Cal-ConRFT | HG-Dagger [?] | PA-RL [?]   | HIL-ConRFT   | SFT [?]        | Cal-ConRFT | HG-Dagger [?] | PA-RL [?]   | HIL-ConRFT  |
| Pick Banana            | 45                   | 40               | 50         | 60 (+50%)     | 80 (+100%)  | 90 (+80%)    | 63.7           | 57.8       | 67.5 (0.9x)   | 56.1 (1.1x) | 51.2 (1.1x) |
| Put Spoon              | 45                   | 50               | 55         | 90 (+80%)     | 80 (+60%)   | 100 (+82%)   | 49.9           | 57.2       | 50.9 (1.0x)   | 45.3 (1.1x) | 22.6 (2.5x) |
| Open Drawer            | 15                   | 35               | 30         | 80 (+129%)    | 60 (+71%)   | 100 (+233%)  | 63.6           | 61.7       | 48.4 (1.3x)   | 57.1 (1.1x) | 32.4 (1.8x) |
| Pick Bread             | 45                   | 65               | 55         | 65 (+0%)      | 80 (+23%)   | 100 (+82%)   | 53.2           | 49.1       | 65.6 (0.8x)   | 51.7 (1.0x) | 31.6 (1.6x) |
|                        | 30                   | 30               | 30         | 75 (+116%)    | 100 (+233%) | 100 (+233%)  | 51.2           | 50.7       | 43.4 (1.2x)   | 34.3 (1.5x) | 22.1 (2.3x) |
| Open Toaster Put Bread | 60                   | 5                | 20         | 60 (+1100%)   | 75 (+1400%) | 100 (+400%)  | 102            | 84.8       | 74.2 (1.4x)   | 72.1 (1.4x) | 36.6 (2.3x) |
| Insert Wheel           | 60                   | 35               | 35         | 40 (+14%)     | 30 (-14%)   | 80 (+129%)   | 42.7           | 43.4       | 53.0 (0.8x)   | 47.4 (0.9x) | 21.9 (2.0x) |
| Hang Chinese Knot      | 90                   | 55               | 40         | 50 (-10%)     | 65 (+18%)   | 100 (+150%)  | 52.6           | 54.9       | 47.5 (1.1x)   | 44.4 (1.3x) | 26.8 (2.0x) |
| Average                | 48.8                 | 39.4             | 39.4       | 65 (+65%)     | 71.3 (+81%) | 96.3 (+144%) | 59.9           | 57.5       | 56.3 (1.1x)   | 51.1 (1.2x) | 30.7 (1.9x) |

引入 BC loss 主要有两个原因。

第一, 它能够保证 policy 持续与 demonstration 数据保持一致, 避免出现过于剧烈的偏移, 从而导致性能崩溃。在接触丰富 (contact-rich) 的操纵任务中, 这一点尤其重要, 因为 policy 的突然变化可能带来不安全或低效的行为, 进而破坏动作质量。

第二, 强化学习本身需要进行探索, 因此在高维状态-动作空间中往往容易出现不稳定。BC loss 可以对探索过程起到稳定作用 [?], 防止 policy 偏离其离线 baseline 过远, 从而降低产生低效或不安全行为的危险。这一点对于真实机器人训练尤为关键, 特别是在物理环境中, 不安全动作可能导致设备损坏或引发其他危险。

## 6.5 B. 第二阶段：基于 HIL-ConRFT 的在线微调（第三部分）

此外, 我们在在线阶段通过 Human-in-the-Loop 学习引入人工干预。具体而言, HIL 学习允许人工操作员在探索过程中及时介入, 提供纠正动作; 此时, 机器人的控制权将从 VLA 模型切换给人工操作员。这些人工纠正会被加入 demonstration buffer  $D$  中, 为探索提供高层指导, 使其朝着更安全、更高效的方向推进 [49]。

当机器人出现具有破坏性的行为时, 人工干预尤为关键, 例如与障碍物发生碰撞、施加过大的作用力, 或对环境造成损坏。除保障探索过程的安全性之外, 人工干预还能够加速 policy 的收敛。在一些场景中, policy 可能会将机器人带入不可恢复或不理想的状态; 或者机器人陷入局部最优, 如果没有外部帮助, 需要耗费大量时间和交互步数才能摆脱。在这类情况下, 人工操作员可以介入, 纠正机器人的动作, 并将其引导到更安全、更有效的行为轨迹上。

因此, 相比仅依赖自主探索, 人工干预能够带来更稳定的学习过程, 使 VLA 模型以更快且更安全的方式完成微调 (fine-tuning)。



## 7 V. 实验与结果

本节通过真实世界实验验证所提出的微调（fine-tuning）框架。我们首先介绍实验设置，并给出不同 baseline 的实验结果；随后对这些结果及其意义进行讨论。

### 7.1 A. 实验概览

我们的实验旨在评估所提方法在真实场景中微调（fine-tuning）VLA 模型的有效性与效率。为此，我们在八个具有代表性的真实世界操纵任务上开展实验，如图 2 所示。这些任务覆盖了多种操纵挑战，包括物体放置任务（如将面包放入烤面包机、将面包放到白色餐盘上）、精确且接触丰富的操纵任务（如对齐并将轮子插入椅子底座），以及动态物体处理任务（如悬挂中国结）。为验证我们的微调方法，我们选用 Octo-small 模型 [47]，其在性能与推理效率之间具有较好的平衡；同时，在一台 7-DoF 的 Franka Emika 机械臂上采用 consistency policy [45] 作为 action head。

对于所有任务，状态观测由两路 RGB 图像和机械臂的 proprioceptive 状态组成。两路图像分别来自腕部相机 ( $128 \times 128$ ) 和侧视相机 ( $256 \times 256$ )。机械臂的 proprioceptive 状态包括 end-effector 位姿、twist、力/力矩以及 gripper 状态。动作空间定义为以下两种形式之一：其一是用于下游阻抗控制器的 6 维 end-effector 增量位姿；其二是在涉及抓取的任务中，使用 7 维动作目标，其中额外包含 1 维二值 gripper 动作。数据采集与 policy 控制频率均为 10Hz。训练开始前，由人工操作员采集正例与负例 demonstration，用于训练一个二分类器；该分类器为每个任务提供二值反馈，以判断对应任务是否成功完成。此外，每个任务的初始状态都会被随机化，具体通过预设的机器人运动脚本或人工操作员手动重置来实现。关于各个真实世界实验任务的描述，以及任务设置、训练流程和评估过程的更多细节，见附录 B。




图 3: 在线训练过程中的学习曲线。图中展示了 HIL-SERL [20]、HG-Dagger [19]、PA-RL [14] 以及我们的方法在五个代表性真实世界任务上的成功率（success rate）、干预率和 episode 长度，结果以 20 个 episode 的滑动平均形式呈现。PA-RL 的实现不包含人工干预。需要注意的是，人工干预可能会将 policy 引导至成功结果，因此在存在干预时，policy 的真实成功率可能低于图中曲线所反映的数值。



## 7.2 B. 实验结果

本节给出所有任务的实验结果，如图 2 所示。对于每个任务，我们在表 I 中报告结果指标，包括成功率（success rate）、episode length 以及总训练时间。训练时间包括 scripted motions、policy rollouts 和机载计算的耗时，所有实验均使用 NVIDIA RTX A6000 GPU 完成。在线下阶段，我们比较 Cal-ConRFT 与 SFT，其中 SFT 使用基于行为克隆的 NLL loss [47]。在线上阶段，我们将 HIL-ConRFT 与多个 baseline 进行比较，包括：HG-Dagger [19]，其通过引入人工纠正并采用监督学习对 policy 进行微调（fine-tuning）；PA-RL [14]，其通过与 policy 无关的 Q-function 优化动作，并使用优化后的动作通过监督学习微调 policy。我们还比较了 HIL-SERL [20]，该方法从零开始在人工干预下训练 RL policy；以及 RLDG [6]，其利用由 RL policy 收集的 demonstrations，通过 SFT [47] 对 VLA 模型进行微调。

### 7.2.1 1) ConRFT 优于监督式方法

我们在表 I 中比较了不同监督式与强化式方法，并在图 3 中给出了对应的在线学习曲线。我们的方法 ConRFT 在所有任务上仅经过 45 到 90 分钟的真实世界训练后，平均成功率达到最高的 96.3%，相较监督式 baseline 提升了 144%。它也优于 HG-Dagger 和 PA-RL 等 SOTA 方法，后两者的平均成功率分别为 65% 和 71.3%。

尽管 HG-Dagger 利用人工纠正并通过监督学习对 VLA 模型进行微调，但其并未带来显著的 policy 提升，甚至在部分任务上还出现了性能下降。这主要是由于人工纠正本身存在次优性与不一致性。例如，在需要精确、谨慎操作的接触丰富任务中，如 Insert Wheel 和 Hang Chinese Knot，HG-Dagger 在线微调后的 policy 提升十分有限。具体而言，在 Hang Chinese Knot 任务中，对软物体的细致处理要求控制过程既一致又精确。然而，人工纠正天然存在波动，例如插入角度上的差异，这会在训练过程中引入噪声和相互冲突的信息。这样的不一致性削弱了 policy 学习精确灵巧行为的能力。此外，接触动力学本身较为复杂，policy 的微小偏差就可能导致性能显著下降，这进一步放大了人工纠正不一致带来的挑战。

在没有人工纠正的情况下，PA-RL 通过一个使用 Cal-QL 训练得到的、与 policy 无关的 Q-function 直接优化动作。基于奖励信号进行动作优化后，PA-RL 避免了人工纠正的次优问题，并在 Pick Banana 和 Put Spoon 等较简单任务中表现出更稳定的 policy 改进。然而，在 Insert Wheel 这类需要精确、谨慎操作的接触丰富任务中，它无法进一步提升 policy 性能。Insert Wheel 任务对精确对齐和受控插入力有很高要求。但由于 demo buffer 和 replay buffer 对状态空间的覆盖有限，该 policy-agnostic Q-function 难以有效泛化到不同的 wheel 与 slot 位置。这限制了 policy 对成功插入所需细微状态转移变化的处理能力，从而在复杂操纵场景中导致次优表现。因此，尽管 PA-RL 在简单环境中展现出一定潜力，但在需要高精度与高灵巧性的复杂任务上，其扩展性仍然受限。

### 7.3 B. 实验结果（第二部分）

**表 2:** 从零开始训练（HIL-SERL [20]）与微调 VLA（HIL-ConRFT）的实验结果。两种 policy 在训练时均使用相同数量、带有人类干预的 episode。所有指标均基于每个任务 20 次试验统计得到。

| 任务                | 训练时间（分钟） | 成功率（%）         |             | Episode length |            |
|-------------------|----------|----------------|-------------|----------------|------------|
|                   |          | HIL-SERL [20]  | HIL-ConRFT  | HIL-SERL [20]  | HIL-ConRFT |
| Pick Banana       | 45       | 0 → 15         | 50 → 90     | 30.6           | 51.2       |
| Put Spoon         | 45       | 0 → 60         | 55 → 100    | 56.1           | 22.6       |
| Open Drawer       | 15       | 0 → 10         | 30 → 100    | 67.5           | 32.4       |
| Pick Bread        | 45       | 0 → 45         | 55 → 100    | 22.0           | 31.6       |
| Open Toaster      | 30       | <b>0 → 100</b> | 30 → 100    | 28.1           | 22.1       |
| Put Bread         | 60       | 0 → 5          | 20 → 100    | 62.0           | 36.6       |
| Insert Wheel      | 60       | 0 → 5          | 35 → 80     | 42.0           | 21.9       |
| Hang Chinese Knot | 90       | 0 → 15         | 40 → 100    | 57.3           | 26.8       |
| Average           | 48.8     | 0 → 31.9       | 39.4 → 96.3 | 45.7           | 30.7       |

这些观察结果进一步凸显了我们方法的优势：它能够有效缓解强化学习中由人类纠正不一致以及状态覆盖不足所带来的问题。ConRFT 能够以有效且安全的方式探索更广泛的状态空间，并基于任务特定奖励直接优化 policy，因此同时展现出较高的样本效率，并减弱了不一致人类纠正的负面影响。这种稳定性与性能表明，在真实机器人应用中，我们的方法能够有效突破现有微调方法的局限。

评估 policy 性能的另一个关键指标是 episode length，即 policy 完成任务所需的总步数。表 I 显示，采用 HIL-ConRFT 微调后的 VLA 模型平均 episode length 为 30.7 步，相比离线 baseline 缩短了 1.9 $\times$ 。相比之下，HG-Dagger 的平均 episode length 为 56.3 步，仅比离线 baseline 缩短了 1.1 $\times$ 。类似地，PA-RL 的平均 episode length 为 51.1 步。由于其 policy-agnostic Q-function 较为保守，该方法缺乏有效的 policy exploration，因而无法充分优化“如何更快完成任务”或尝试更高效的行为模式。

这些结果表明，ConRFT 能够有效利用 MDP 的动态特性，通过 consistency policy 优化 VLA 模型，从而最大化折扣奖励和。结果同时也揭示了监督式方法在处理次优数据以及进行高效 policy exploration 方面的局限。由于我们的方法鼓励 policy 更快获得奖励，因此相较于仅依赖模仿 demonstration 的监督式方法，能够带来更短的 episode length。更高的样本效率与更短的 episode length 共同说明，ConRFT 在真实机器人场景下微调 VLA 模型方面具有显著优势。

### 7.4 Fine-tuning VLA 优于从头训练

从头开始进行强化学习通常需要与环境进行大量交互，并伴随频繁的人类干预，这不仅会显著拉长训练周期，也会带来较高的安全风险。以 HIL-SERL [20] 为例，该方法通过带有人类干预的从头 RL 训练 policy，但在与我们方法相同的训练时长内，无法收敛到有效 policy；如表 II 所示，其平均成功率（success rate）仅为 31.9%。图 3 的学习曲线进一步表明，HIL-ConRFT 在 online 阶段能够持续提升 policy 性能。尽管 HIL-SERL 最终也可能学到较优 policy，但通常需要超过两个小时

的 online 训练，并且每个任务都需要更高的干预频率，从而在探索过程中引发更多破坏性行为（如与环境发生碰撞），这一问题在训练早期尤为明显。

相比之下，以预训练 VLA 模型为起点并进行离线微调（fine-tuning），能够有效缩短 online 训练时间并提升样本效率。在离线初始化 policy 的基础上，ConRFT 进一步加快了 policy 的收敛速度，并提升了最终性能。因此，基于 consistency policy 对 VLA 模型进行微调，可以使其相较于完全从头训练，以更少的人类干预、更快的速度达到更高的成功率。这一结果表明，在真实机器人应用中，充分利用预训练 VLA 模型具有明显优势。

### 7.5 3) Analysis: (第 1 部分)

#### a) 为什么从 Cal-ConRFT 开始微调，而不是从 SFT 或 Cal-QL 开始？

如表 I 所示，我们观察到：在 offline 阶段，Cal-ConRFT 的性能与 SFT baseline 接近。由此自然会产生一个问题：既然两者在 offline 阶段表现相近，为什么还要在这一阶段引入 Q loss？

原因在于：如果 offline 阶段仅依赖 SFT，那么微调后的 policy 虽然能够从模仿学习中获益，但一旦在 online 阶段遇到 offline 数据集中未覆盖的状态与动作，往往仍需进行大量 online fine-tuning 才能有效处理。相比之下，在 offline 阶段引入 Q loss，可以让早期的 Q-value 估计为后续 policy improvement 提供更好的初始化，从而加快 online fine-tuning 阶段的适应过程。这样不仅有助于缓解潜在偏差，也能使学习过程更加稳定。

此外，在 demonstration 数量较少的场景下，我们发现仅依赖 Cal-QL 并不足以训练出有效的 policy：在所有任务上，其成功率（success rate）均为 0%。数据不足会直接影响 policy 对 Q-value 的准确估计，进而导致 offline 阶段结束后的性能较弱，并延长 online 阶段所需的训练时间。






图 4: 从 SFT [47] 与 Cal-ConRFT baseline 出发进行 HIL-ConRFT online fine-tuning 的学习曲线。图中展示了两个代表性任务上的成功率与干预率，并以 20 个 episode 的滑动平均进行呈现。

表 3: 不同 demonstration 设置下的实验对比。Diffusion Policy (DP) [50] 与 SFT [47] 使用 150 条由人工 teleoperation 采集的 demonstration 进行训练；RLDG [6] 使用 150 条由 RL policy 生成的 demonstration 进行训练；Cal-ConRFT 使用 20 条人工 teleoperation demonstration 进行训练；HIL-ConRFT 则使用 20 条 demonstration 以及 80–120 条由 policy 生成的 rollout trajectory 进行训练。所有指标均在每个任务 20 次试验上统计。

| Task         | Success Rate (%) |         |         |            |            |
|--------------|------------------|---------|---------|------------|------------|
|              | DP[50]           | SFT[47] | RLDG[6] | Cal-ConRFT | HIL-ConRFT |
| Put Spoon    | 60               | 70      | 100     | 55         | 100        |
| Put Bread    | 30               | 65      | 100     | 20         | 100        |
| Insert Wheel | 35               | 40      | 50      | 35         | 80         |
| Average      | 41.7             | 58.3    | 83.3    | 36.7       | 93.3       |

为进一步分析引入 Q loss 的作用，我们在两个代表性任务上对比了从 Cal-ConRFT 与从 SFT baseline 开始进行 online fine-tuning 的学习曲线，如图 4 所示。尽管两条曲线在初始阶段具有相近的成功率，但从 SFT baseline 开始训练时，训练过程中出现了更高的干预率。这表明：由 SFT 训练得到的 policy 在 online 训练早期存在较为严重的 policy forgetting 问题。上述结果说明，Cal-ConRFT 通过在 offline 阶段引入 Q loss，为 online 学习提供了更好的起点，因此能够在少量 demonstration 数据下实现更快的适应，并带来更有效、更稳定的 policy improvement。

#### b) 增加 demonstration 数量是否能够提升 SFT 的 policy 性能？

**表 4:** ConRFT 在不同 VLA 模型上的实验结果。我们使用本文方法，对采用两种 VLM backbone 的 RoboVLM [51] 进行 fine-tuning。具体而言，我们仅微调 action head，同时冻结 visual encoder 与 transformer backbone。所有指标均在每个任务 20 次试验上统计。

| Task              | Success Rate (%) |                |
|-------------------|------------------|----------------|
|                   | Kosmos-2 (1.6B)  | PaliGemma (3B) |
| Pick Banana       | 60→100           | 65→100         |
| Put Spoon         | 55→100           | 30→100         |
| Hang Chinese Knot | 45→100           | 60→100         |
| Average           | 53.3→100         | 51.7→100       |

### 7.6 3) 分析：第二部分

在 45–60 分钟的在线微调（fine-tuning）阶段，policy 大约收集了 80 到 120 条成功与失败轨迹。为保证本文方法与监督训练方法之间的比较公平，我们进一步在三个具有代表性的任务上进行对比：使用 150 条 demonstration 训练 Diffusion Policy (DP) [50]，以及对 VLA [47] 进行监督微调（supervised fine-tuning, SFT）。这一设置与本文方法使用的 demonstration 总数保持一致。此外，我们还将 RLDG [6] 与另一种设置进行比较：使用由 RL policy 收集的 150 条 demonstration 进行微调。

如表 III 所示，尽管 DP 和 SFT 使用了更多 demonstration，其成功率（success rate）仍然无法达到本文方法的性能，尤其是在 Insert Wheel 这类接触丰富（contact-rich）任务上更为明显。这表明，仅仅增加由人工收集的 demonstration，并结合监督学习进行训练，并不一定能够带来更高性能；其原因在于人工采集数据中天然存在动作不一致和次优的问题。与此同时，RLDG 利用由 RL policy 收集的更优数据取得了更高的成功率，这说明 RL 采集数据的一致性有助于提升最终性能。相比之下，本文方法通过优化基于一致性的训练目标，直接对 policy 进行微调，从而获得了最高的成功率。

#### 7.6.1 c) ConRFT 在不同 VLA 模型上的实用性

ConRFT 具有很强的通用性，可应用于任何带有 action head 的、基于 VLM 的架构。这种灵活性来源于它能够独立于底层视觉 encoder 来优化动作生成过程，因此可以适配不同的 VLA 框架。为了进一步验证其适用性与泛化性，我们在具有两种不同 VLM backbone 的 RoboVLM [51] 上测试了本文方法的微调效果。

如表 IV 所示，实验结果表明，ConRFT 能够稳定提升多种 VLA 的性能，并在多个机器人任务

上提高成功率。它能够在保留预训练视觉模块优势的同时，对动作生成过程进行有效微调，这进一步说明了 ConRFT 具有广泛的适用性。

## 8 VI. 局限性

尽管本文方法在真实世界操纵任务中对 VLA 模型进行微调 (fine-tuning) 时表现出较强的性能与样本效率，但仍存在若干局限性。

### 8.1 A. 对奖励工程的敏感性

在本文中，我们通过一个任务特定的二分类器为 RL 计算奖励。然而，分类器训练数据与 RL 探索过程中产生的状态-动作分布之间天然存在分布偏移 (distributional shift)，这会带来一个关键脆弱性：已学习的 policy 可能出现 reward hacking，即利用分类器奖励不准确的非预期行为。比如，机器人可能将 end-effector 移动到某个特定位置，从而触发一个假阳性，使 policy 最终收敛到错误的行为模式。

此外，这类奖励分类器通常只能提供稀疏反馈，因此即使有人类干预的辅助，policy 的学习速度仍可能较慢。另一方面，这种由奖励驱动的方法往往会得到高度专门化的 policy，它们与任务的具体条件紧密绑定，从而限制了其在新环境中的泛化能力。尽管引入多任务的稠密奖励信号有望提升样本效率并加快 policy 收敛，但这也意味着在真实世界应用中需要更加复杂的奖励工程。

### 8.2 B. 冻结编码器与 Transformer backbone

当前实现中，交互过程与 policy 学习过程运行在不同线程中；在保持视觉 encoder 和 Transformer backbone 冻结的同时，仅对 action head 网络进行微调 (fine-tuning)，并维持一致的 policy。这样的设计能够提升实时性能，但也限制了 policy 在在线训练过程中进一步优化其感知与表征模块的能力，尤其是在未见过的场景中更为明显。若允许对这些冻结组件进行部分或全部更新，并结合参数高效微调 (parameter-efficient fine-tuning) 技术，例如 LoRA [52]，则有望在不牺牲安全性和速度的前提下，进一步提升最终任务性能与自适应能力。

## 9 VII. 结论

本文提出了一种面向真实机器人应用、用于强化式微调 VLA 模型的两阶段方法 ConRFT。首先，我们利用少量 demonstration 进行离线微调 (Cal-ConRFT)，在基于一致性的统一训练框架下联合 Q loss 与 BC loss，从而初始化得到可靠的 policy 和 value function。随后，在在线微调阶段 (HIL-ConRFT)，我们进一步结合任务特定奖励与人工干预，通过 consistency policy 对 VLA 模型进行微调。

在八项多样化的真实世界任务上的实验表明，该方法在成功率 (success rate)、样本效率以及 episode length 等指标上均优于 SOTA 方法。总体而言，这项工作展示了一条在保证安全与效率的前提下，利用强化学习对 VLA 模型进行微调的实用途径。

## 9.1 致谢

本工作得到国家自然科学基金 (NSFC) 项目 (批准号: 62136008) 的资助, 并部分得到中国科学院国际伙伴计划项目 (批准号: 104GJHZ2022013GC) 的支持。

[1] Abby O’Neill, Abdul Rehman, Abhinav Gupta, Abhiram Maddukuri, Abhishek Gupta, Abhishek Padalkar, Abraham Lee, Acorn Pooley, Agrim Gupta, Ajay Mandlekar, et al. Open X-Embodiment: robotic learning datasets and RT-X models. In International Conference on Robotics and Automation, ICRA, 2024.

[2] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choromanski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, et al. RT-2: vision-language-action models transfer web knowledge to robotic control. Conference on Robot Learning, CoRL, 2023.

[3] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolò Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al.  $\pi_0$ : A vision-language-action flow model for general robot control. arXiv preprint arXiv:2410.24164, 2024.

[4] Joshua Jones, Oier Mees, Carmelo Sferrazza, Kyle Stachowicz, Pieter Abbeel, and Sergey Levine. Beyond sight: Finetuning generalist robot policies with heterogeneous sensors via language grounding. arXiv preprint arXiv:2501.04693, 2025.

[5] Lirui Wang, Xinlei Chen, Jialiang Zhao, and Kaiming He. Scaling proprioceptive-visual learning with heterogeneous pre-trained transformers. In Neural Information Processing Systems, NeurIPS, 2024.

[6] Charles Xu, Qiyang Li, Jianlan Luo, and Sergey Levine. RLDG: robotic generalist policy distillation via reinforcement learning. arXiv preprint arXiv:2412.09858, 2024.

[7] Paul F. Christiano, Jan Leike, Tom B. Brown, Miljan Martic, Shane Legg, and Dario Amodei. Deep reinforcement learning from human preferences. In Neural Information Processing Systems, NeurIPS, 2017.

[8] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, and other. Training language models to follow instructions with human feedback. In Neural Information Processing Systems, NeurIPS, 2022.

[9] Luong Quoc Trung, Xinbo Zhang, Zhanming Jie, Peng Sun, Xiaoran Jin, and Hang Li. ReFT: reasoning with reinforced fine-tuning. In Association for Computational Linguistics, ACL, 2024.

[10] Richard Yuanzhe Pang, Weizhe Yuan, Kyunghyun Cho, He He, Sainbayar Sukhbaatar, and Jason Weston. Iterative reasoning preference optimization. In Neural Information Processing Systems, NeurIPS, 2024.

[11] Rajkumar Ramamurthy, Prithviraj Ammanabrolu, Kianté Brantley, Jack Hessel, Rafet Sifa, Christian Bauckhage, Hannaneh Hajishirzi, and Yejin Choi. Is reinforcement learning (not) for natural language processing: Benchmarks, baselines, and building blocks for natural language policy optimization. In International Conference on Learning Representations, ICLR, 2023.

[12] Hao Bai, Yifei Zhou, Mert Cemri, Jiayi Pan, Alane Suhr, Sergey Levine, and Aviral Kumar. DigiRL: training in-the-wild device-control agents with autonomous reinforcement learning. In



Neural Information Processing Systems, NeurIPS, 2024.

[13] Thomas Carta, Clement Romac, Thomas Wolf, Sylvain Lamprier, Olivier Sigaud, and Pierre-Yves Oudeyer. Grounding large language models in interactive environments with online reinforcement learning. In International Conference on Machine Learning, ICML, 2023.

[14] Max Sobol Mark, Tian Gao, Georgia Gabriela Sampaio, Mohan Kumar Srirama, Archit Sharma, Chelsea Finn, and Aviral Kumar. Policy agnostic RL: offline RL and online RL fine-tuning of any class and backbone. arXiv preprint arXiv:2412.06685, 2024.

[15] Seunghyun Lee, Younggyo Seo, Kimin Lee, Pieter Abbeel, and Jinwoo Shin. Offline-to-online reinforcement learning via balanced replay and pessimistic qensemble. In Conference on Robot Learning, CoRL, 2021.

[16] Mitsuhiko Nakamoto, Simon Zhai, Anikait Singh, Max Sobol Mark, Yi Ma, Chelsea Finn, Aviral Kumar, and Sergey Levine. Cal-QL: Calibrated offline RL pre-training for efficient online fine-tuning. In Neural Information Processing Systems, NeurIPS, 2023.

[17] Zhiyuan Zhou, Andy Peng, Qiyang Li, Sergey Levine, and Aviral Kumar. Efficient online reinforcement learning fine-tuning need not retain offline data. arXiv preprint arXiv:2412.07762, 2024.

## 10 致谢（第二部分）

[18] Yuhui Chen, Haoran Li, and Dongbin Zhao. Boosting continuous control with consistency policy. In International Conference on Autonomous Agents and Multiagent Systems, AAMAS, 2024.

[19] Michael Kelly, Chelsea Sidrane, Katherine Rose Driggs-Campbell, and Mykel J. Kochenderfer. HG-Dagger: interactive imitation learning with human experts. In International Conference on Robotics and Automation, ICRA, 2019.

[20] Jianlan Luo, Charles Xu, Jeffrey Wu, and Sergey Levine. Precise and dexterous robotic manipulation via human-in-the-loop reinforcement learning. arXiv preprint arXiv:2410.21845, 2024.

[21] Stephen Casper, Xander Davies, Claudia Shi, Thomas Krendl Gilbert, Jérémy Scheurer, Javier Rando, Rachel Freedman, Tomasz Korbak, David Lindner, Pedro Freire, et al. Open problems and fundamental limitations of reinforcement learning from human feedback. Transactions on Machine Learning Research, 2023.

[22] Yuexiang Zhai, Hao Bai, Zipeng Lin, Jiayi Pan, Shengbang Tong, Yifei Zhou, Alane Suhr, Saining Xie, Yann LeCun, Yi Ma, et al. Fine-tuning large vision-language models as decision-making agents via reinforcement learning. In Neural Information Processing Systems, NeurIPS, 2024.

[23] Kimin Lee, Laura M. Smith, and Pieter Abbeel. PEBBLE: feedback-efficient interactive reinforcement learning via relabeling experience and unsupervised pretraining. In International Conference on Machine Learning, ICML, 2021.

[24] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. arXiv preprint arXiv:1707.06347, 2017.

[25] Abhishek Gupta, Vikash Kumar, Corey Lynch, Sergey Levine, and Karol Hausman. Relay

policy learning: Solving long-horizon tasks via imitation and reinforcement learning. In Conference on Robot Learning, CoRL, 2019.

[26] Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Y Wu, et al. DeepSeekMath: pushing the limits of mathematical reasoning in open language models. arXiv preprint arXiv:2402.03300, 2024.

[27] Philip J Ball, Laura Smith, Ilya Kostrikov, and Sergey Levine. Efficient online reinforcement learning with offline data. In International Conference on Machine Learning, ICML, 2023.

[28] Boyu Li, Haobin Jiang, Ziluo Ding, Xinrun Xu, Haoran Li, Dongbin Zhao, and Zongqing Lu. SELU: self-learning embodied MLLMs in unknown environments. arXiv preprint arXiv:2410.03303, 2024.

[29] Martin A. Riedmiller, Thomas Gabel, Roland Hafner, and Sascha Lange. Reinforcement learning for robot soccer. *Autonomous Robots*, 27(1):55–73, 2009.

[30] Tobias Johannink, Shikhar Bahl, Ashvin Nair, Jianlan Luo, Avinash Kumar, Matthias Loskyll, Juan Aparicio Ojea, Eugen Solowjow, and Sergey Levine. Residual reinforcement learning for robot control. In International Conference on Robotics and Automation, ICRA, 2019.

[31] Jianlan Luo, Zheyuan Hu, Charles Xu, You Liang Tan, Jacob Berg, Archit Sharma, Stefan Schaal, Chelsea Finn, Abhishek Gupta, and Sergey Levine. SERL: A software suite for sample-efficient robotic reinforcement learning. In International Conference on Robotics and Automation, ICRA, 2024.

[32] Tony Z. Zhao, Jianlan Luo, Oleg Sushkov, Rugile Pevceviciute, Nicolas Heess, Jon Scholz, Stefan Schaal, and Sergey Levine. Offline meta-reinforcement learning for industrial insertion. In International Conference on Robotics and Automation, ICRA, 2022.

[33] Jianlan Luo, Perry Dong, Yuexiang Zhai, Yi Ma, and Sergey Levine. RLIF: interactive imitation learning as reinforcement learning. In International Conference on Learning Representations, ICLR, 2024.

[34] Zheyuan Hu, Aaron Rovinsky, Jianlan Luo, Vikash Kumar, Abhishek Gupta, and Sergey Levine. REBOOT: reuse data for bootstrapping efficient real-world dexterous manipulation. In Conference on Robot Learning, CoRL, 2023.

[35] Russell Mendonca, Emmanuel Panov, Bernadette Bucher, Jiuguang Wang, and Deepak Pathak. Continuously improving mobile manipulation with autonomous real-world RL. In Conference on Robot Learning, CoRL, 2024.

[36] Henry Zhu, Abhishek Gupta, Aravind Rajeswaran, Sergey Levine, and Vikash Kumar. Dexterous manipulation with deep reinforcement learning: Efficient, general, and low-cost. In International Conference on Robotics and Automation, ICRA, 2019.

[37] Ziwen Zhuang, Zipeng Fu, Jianren Wang, Christopher G. Atkeson, Soren Schwertfeger, Chelsea Finn, and Hang Zhao. Robot parkour learning. In Conference on Robot Learning, CoRL, 2023.

## 11 ACKNOWLEDGMENTS (第3部分)

[38] Jan Peters and Stefan Schaal. 用于 operational space control 的基于 reward-weighted regression 的强化学习. 载于 International Conference on Machine Learning, ICML, 2007.

[39] Henry Zhu, Justin Yu, Abhishek Gupta, Dhruv Shah, Kristian Hartikainen, Avi Singh, Vikash Kumar, and Sergey Levine. 真实世界机器人强化学习的关键要素. 载于 International Conference on Learning Representations, ICLR, 2020.

[40] Rishabh Agarwal, Max Schwarzer, Pablo Samuel Castro, Aaron C. Courville, and Marc G. Bellemare. Reincarnating reinforcement learning: 复用已有计算以加速进展. 载于 Neural Information Processing Systems, NeurIPS, 2022.

[41] Rafael Rafailov, Kyle Beltran Hatch, Victor Koley, John D. Martin, Mariano Phielipp, and Chelsea Finn. MOTO: 从离线预训练到在线微调 (fine-tuning) 的基于模型的机器人学习. 载于 Conference on Robot Learning, CoRL, 2023.

[42] Aravind Rajeswaran, Vikash Kumar, Abhishek Gupta, Giulia Vezzani, John Schulman, Emanuel Todorov, and Sergey Levine. 结合深度强化学习与 demonstration 学习复杂灵巧操纵. 载于 Robotics: Science and Systems, RSS, 2018.

[43] Ashvin Nair, Bob McGrew, Marcin Andrychowicz, Wojciech Zaremba, and Pieter Abbeel. 通过 demonstration 克服强化学习中的探索难题. 载于 International Conference on Robotics and Automation, ICRA, 2018.

[44] Xing Fang, Qichao Zhang, Haoran Li, and Dongbin Zhao. 面向自动驾驶的带 categorical critic 的 consistency policy. 载于 International Conference on Autonomous Agents and Multiagent Systems, AAMAS, 2025.

[45] Aaditya Prasad, Kevin Lin, Jimmy Wu, Linqi Zhou, and Jeannette Bohg. Consistency policy: 通过 consistency distillation 加速 visuomotor policy. 载于 Robotics: Science and Systems, RSS, 2024.

[46] Haoran Li, Yaocheng Zhang, Haowei Wen, Yuanheng Zhu, and Dongbin Zhao. 结合动态规划与转移可行性的稳定扩散模型机器人控制方法. IEEE Transactions on Artificial Intelligence, 5(9):4585–4594, 2024.

[47] Dibya Ghosh, Homer Rich Walke, Karl Pertsch, Kevin Black, Oier Mees, Sudeep Dasari, Joey Hejna, Tobias Kreiman, Charles Xu, Jianlan Luo, You Liang Tan, Lawrence Yunliang Chen, Quan Vuong, Ted Xiao, Pannag R. Sanketi, Dorsa Sadigh, Chelsea Finn, and Sergey Levine. Octo: 一个开源的通才机器人 policy. 载于 Robotics: Science and Systems, RSS, 2024.

[48] Haoran Li, Zhennan Jiang, Yuhui Chen, and Dongbin Zhao. 将 consistency policy 泛化到视觉强化学习, 并结合 prioritized proximal experience regularization. 载于 Neural Information Processing Systems, NeurIPS, 2024.

[49] Huihan Liu, Soroush Nasiriany, Lance Zhang, Zhiyao Bao, and Yuke Zhu. 在岗机器人学习: 部署过程中的 human-in-the-loop autonomy 与学习. 载于 Robotics: Science and Systems, RSS, 2023.

[50] Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, and Shuran Song. Diffusion policy: 通过 action diffusion 学习 visuomotor policy. 载于 Robotics: Science and Systems, RSS, 2023.

[51] Xinghang Li, Peiyan Li, Minghuan Liu, Dong Wang, Jirong Liu, Bingyi Kang, Xiao Ma, Tao Kong, Hanbo Zhang, and Huaping Liu. 面向通才机器人 policy: 构建 Vision-Language-Action 模型时哪些因素最关键. arXiv preprint arXiv:2412.14058, 2024.

[52] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: 大语言模型的低秩适配. 载于 International Conference on Learning Representations, ICLR, 2022.

[附录因公式排版问题从译本中省略, 请参阅原文。]