

RL 能为 VLA 泛化带来什么？一项实证研究

Jijia Liu^{1*} Feng Gao^{2*} Bingwen Wei¹ Xinlei Chen¹ Qingmin Liao¹ Yi Wu² Chao Yu^{1†}

¹ 清华大学深圳国际研究生院 ² 清华大学交叉信息研究院 ³ 清华大学电子工程系

2026 年 8 月 17 日

1 RL 能为 VLA 泛化带来什么？一项实证研究




图 1: 本文研究概览：从视觉（Vision）、语义（Semantics）与执行（Execution）三个维度评估 RL 对 VLA 泛化能力的提升作用。在分布外测试中，RL 在执行维度上带来显著增益，在语义维度上取得中等幅度提升，而在视觉维度上的表现与 SFT 基本持平。

摘要

大规模 Vision-Language-Action (VLA) 模型在具身智能中展现出显著潜力。然而，这类模型目前主要依赖监督微调 (supervised fine-tuning, SFT) 进行训练；在分布偏移条件下，SFT 容易受到误差累积的影响，因此其泛化能力受到限制。强化学习 (reinforcement learning, RL) 通过试错方式直接围绕任务目标进行优化，为突破上述局限提供了一条可行路径；但相较于 SFT，RL 究竟能在多大程度上提升 VLA 的泛化能力，目前仍缺乏系统性认识。

为此，我们提出了一个用于评估 VLA 泛化能力的综合 benchmark，并从视觉、语义和执行等多个维度，系统研究了 RL fine-tuning 的影响。大量实验表明，相比 SFT，RL fine-tuning，尤其是基于 PPO 的方法，能够在保持相当视觉鲁棒性的同时，显著提升模型在语义理解和执行鲁棒性方面的泛化表现。我们进一步发现，对于 VLA 而言，PPO 是比 DPO、GRPO 等源自 LLM 的方法更有效的 RL 算法。基于此，我们还总结出一套面向 VLA 的高效 PPO 训练方案，并验证了其在提升 VLA 泛化能力方面的实际效果。项目主页见 <https://rlvla.github.io>。

2 Introduction

Vision-Language-Action (VLA) 模型是一类新兴的基础模型 (foundation model) (Ma et al., 2024; Firoozi et al., 2023)，旨在统一感知、语言理解与具身控制。VLA 通常利用在互联网规模数据上预训练的 vision-language model，并进一步在大规模、异构的机器人 demonstration 数据集上训练 (Collaboration et al., 2023; Khazatsky et al., 2024)，从而能够理解传感器观测与自然语言指令，并将其直接映射为机器人动作。这一范式已在多种任务上展现出良好的泛化能力，包括单臂、双臂与移动操纵 (Team et al., 2024; Kim et al., 2024; Liu et al., 2024; Wen et al., 2025)、导航 (Shah et al., 2022)，甚至还能在未见场景中完成厨房或卧室清洁这类复杂的长时程活动 (Black et al., 2024; Intelligence et al., 2025)。

尽管前景可观，当前 VLA 的训练仍主要依赖监督微调 (SFT)，即通过对 demonstration 标签进行 behavioral cloning 来学习 (Kim et al., 2025)。无论是在预训练阶段还是 few-shot 适配阶段，这种方法在分布偏移 (distribution shift) 下都天然容易受到误差累积的影响：相对于专家轨迹的轻微偏离，都会在后续执行中不断放大，使 policy 进入训练中未充分覆盖的状态区域，进而削弱系统的鲁棒性能 (Ross and Bagnell, 2010; De Haan et al., 2019; Belkhale et al., 2023; Foster et al., 2024)。训练分布与测试分布之间的这种失配，从根本上限制了模型的鲁棒性；已有研究指出，在这类条件下，regret 甚至会随任务时域呈二次增长 (Ross and Bagnell, 2010)。

相比之下，强化学习 (RL) 通过 trial-and-error 直接优化任务的累计回报，为另一种训练范式提供了可能。它使 policy 不再局限于狭窄的专家数据分布，而能够主动探索并学习纠偏行为。更重要的是，在更广泛的基础模型研究中，尤其是 Large Language Model (LLM) 与 Vision-Language Model (VLM) 领域，近期研究已强调 RL 在泛化方面的优势 (Ouyang et al., 2022; Zhai et al., 2024; Huang et al., 2025)。越来越多的证据表明，SFT 往往更倾向于记忆训练数据，而 RL 微调则能够显著提升分布外性能，并进一步释放模型的推理能力 (Chu et al., 2025; Huang et al., 2025; Ma et al., 2025)。受益于 RL 在机器人中的既有成功，以及其在其他大规模模型上的积极结果，RL 微调正逐渐被应用到 VLA 中 (Collaboration et al., 2023; Walke et al., 2023; Khazatsky et al., 2024)。相关方法包括引入人类反馈 (Chen et al., 2025)、采用 offline RL 更新 (Zhang et al., 2024b)，或使用 PPO (Schulman et al., 2017) 等算法，有时还会与模仿学习结合，构成多阶段训练流程 (Guo et al., 2025b)。

然而，尽管已有这些开创性工作，目前我们仍缺乏系统性的认识：相较于 SFT baseline，RL 微调究竟能为 VLA 带来哪些具体的泛化收益？二者各自的优势又体现在哪些方面？这些问题仍未得到充分回答 (Hu et al., 2024; Mark et al., 2024)。例如，尽管 FLaRe (Hu et al., 2024) 等近期工作展示了 PPO 在 VLA 微调中的有效性，但其主要关注点并不是对所得模型泛化能力进行全面分析。

本文旨在弥补这一关键空白。我们开展了一项系统性研究，对比分析经过 RL 微调与 SFT 微调后的 VLA 在泛化性质上的差异。

具体而言，我们重点从经验上回答如下问题：与监督微调相比，RL 能为 VLA 的泛化带来哪些独特收益？

3 Introduction (第 2 部分)

为回答这一问题，我们将研究聚焦于具有代表性的 pick-and-place 任务。围绕该任务，我们首先评估面向大规模模型的主流 RL 算法（PPO (Schulman et al., 2017; Ouyang et al., 2022)、DPO (Rafailov et al., 2023; Zhang et al., 2024b)、GRPO (Shao et al., 2024; Guo et al., 2025a))，以识别有效的 VLA 微调 (fine-tuning) 策略。随后，我们仍在 pick-and-place 任务上开展大范围对比评测，明确 RL 微调在哪些方面优于 SFT。如图 1 所示，该综合评测从三个关键维度对泛化能力进行严格考察：1) 视觉 (Vision)：通过引入新的背景（未见过的桌面），以及在前景或整张图像上叠加未见过的纹理，测试具有挑战性的视觉泛化能力。2) 语义 (Semantics)：通过未见过的物体、新的容器，以及不同表述方式的指令，考察模型的语言敏感性与目标识别能力。3) 执行 (Execution)：通过改变机器人的初始状态、物体/容器的位置，并在 episode 中引入诸如随机重置物体位置等动态扰动，检验模型的鲁棒性。

通过大量实验与深入分析，我们的主要贡献如下：

- 建立了一个严格且具有挑战性的 benchmark，用于评估不同 VLA 微调方法在视觉、语义与执行等多种维度上的泛化表现。
- 识别出 PPO 是优于 GRPO 和 DPO 的首选 VLA 微调 RL 算法；同时，我们也讨论了将这些源自 LLM/VLM 范式的 RL 算法适配到 VLA 独特需求时面临的关键挑战。
- 提出了一套高效的、基于 PPO 的 VLA 微调方案，其核心包括共享的 actor-critic backbone、VLA 模型 warm-up，以及尽可能少的 PPO 训练 epoch。
- 证明了相较于 SFT，RL 在 VLA 的语义理解与具身执行方面具有更强的泛化能力，同时保持了可比的视觉鲁棒性。

4 2 Related works

4.1 Vision-Language-Action (VLA) models

在同时使用视觉与语言输入的机器人任务中，近期研究表明，相比参数规模较小的模型 (Zhao et al., 2023; Chi et al., 2023)，引入预训练 LLM 或 VLM 中的知识 (Chen et al., 2023; Driess et al., 2023; Karamcheti et al., 2024; Beyer et al., 2024) 能够带来更强的 policy 泛化能力。基于这类 foundation model 的能力，并结合大规模机器人数据集，VLA 模型 (Brohan et al., 2023b,a; Team et al., 2024; Kim et al., 2024; Liu et al., 2024; Wu et al., 2023; Cheang et al., 2024; Black et al., 2024; Intelligence et al., 2025) 为具身智能体提供了坚实的基础。我们的工作建立在 VLA 之上，旨在进一步提升其泛化能力。

4.2 大规模 (Vision-) Language Models 的 RL 微调

对大规模语言模型进行微调已展现出良好效果 (Stiennon et al., 2020; Ouyang et al., 2022; Achiam et al., 2023)，尤其是在使用高质量监督数据时更为明显 (Zhang et al., 2024a; Zhu et al., 2023; Zhang

et al., 2023b)。部分工作致力于使 LLM 与人类在有用性和安全性方面的偏好保持一致 (Kaufmann et al., 2023; Bai et al., 2022), 并采用 online RL 算法 (Schulman et al., 2017; Ramamurthy et al., 2023; Zheng et al., 2023) 或 offline 更新方法 (Rafailov et al., 2023; Ivison et al., 2024; Xu et al., 2024) 来实现这一目标。

另一些研究表明, 在数学与代码任务上进行 online RL 微调 (Shao et al., 2024; Guo et al., 2025a), 能够显著提升 LLM 的推理能力 (Guo et al., 2025a; Jaech et al., 2024; Team et al., 2025)。尽管 RL 在 LLM 中已经得到了广泛研究 (Chu et al., 2025), 但对于规模相近的 VLA 模型, 其泛化潜力仍缺乏充分探索。

4.3 面向机器人任务的 policy 微调

VLA 的微调在很大程度上依赖监督数据 (Kim et al., 2025; Liu et al., 2025; Zhao et al., 2025; Zheng et al., 2024)。然而, 大规模高质量数据的稀缺性常常限制 VLA 对未见场景或扰动的泛化能力 (Collaboration et al., 2023; Walke et al., 2023; Khazatsky et al., 2024)。为了突破单纯模仿学习的范式, 并实现由奖励驱动的学习, 研究者开始在多种设定下探索 RL 微调: 包括小规模模型 (Ren et al., 2024)、引入人类干预的大模型 (Chen et al., 2025), 以及基于离线更新的方法 (Zhang et al., 2024b)。Guo et al. (2025b) 提出使用 PPO (Schulman et al., 2017) 对 VLA 模型进行微调, 并在两阶段流程中结合模仿学习。尽管已有这些尝试, RL 微调在 VLA 模型中的泛化能力仍缺乏充分研究 (Hu et al., 2024; Mark et al., 2024)。此外, 我们发现, VLA 可以直接通过在线 PPO 进行微调, 而不需要额外的训练阶段或模仿学习, 这进一步表明 RL 对机器人任务具有良好的可扩展性。

5 3 Preliminaries

5.1 3.1 问题形式化

我们将每个由语言条件指定的机器人任务 $T \in \mathcal{T}$ 建模为一个部分可观测马尔可夫决策过程 (POMDP), 记为元组 $\mathcal{M} = (S, \mathcal{A}, \mathcal{P}, R, \mathcal{O}, \mathcal{L}, P(s_0), \gamma)$ 。其中, 状态空间 S 包含机器人状态与环境状态, $\mathcal{A}$ 表示控制指令的动作空间, $\mathcal{O}$ 表示传感器输出构成的观测空间。状态转移满足 $s_{t+1} \sim \mathcal{P}(\cdot | s_t, a_t)$, γ 为折扣因子。每个任务 T 对应一组自然语言指令 $\mathcal{L}_T \subset \mathcal{L}$, 并定义奖励 $\dot{R}(s, l) \in \mathbb{R}$, 当状态 s 完成任务阶段或满足指令 l 时给出相应回报。每个 episode 开始时, 首先采样指令 $l \sim \mathcal{L}_T$ 以及初始状态 $s_0 \sim P(s_0)$, 二者共同确定机器人的初始位姿与环境配置。policy π 以最近 H 步观测 $O_{t-H+1:t}$ 和语言指令 l 作为输入, 输出动作 $a_t \sim \pi_\theta(a_t | o_{t-H+1:t}, l)$, 从而生成轨迹 $\tau = (o_0, a_0, \dots)$ 。

监督微调 (SFT) SFT 基于专家收集的 demonstration 数据集 $\mathcal{D}_T = \{(\tau^{(i)}, l^{(i)})\}_{i=1}^N$ 进行学习, 其中每条轨迹为 $\tau^{(i)} = (o_0^{(i)}, a_0^{(i)}, \dots, o_{K_i-1}^{(i)}, a_{K_i-1}^{(i)})$, N 表示轨迹总数。VLA policy π_θ 通过最小化下式进行训练:

$$\mathcal{L}_{\text{SFT}}(\theta) = \sum_{(\tau^{(i)}, l^{(i)}) \in \mathcal{D}_T} \sum_{t=0}^{K_i-1} \ell_{\text{SFT}}(\hat{a}_t^{(i)}, a_t^{(i)}), \quad \hat{a}_t^{(i)} = \pi_\theta(o_{t-H+1:t}^{(i)}, l^{(i)}),$$

其中, ℓ_{SFT} 为损失函数, 其具体形式取决于 VLA 架构与动作表征, 例如 next-token prediction、 L_1 回归或 diffusion (Kim et al., 2025)。

RL 微调 RL 微调通过与环境直接交互，最大化标量奖励或偏好信号。在基于奖励的设定下，其目标是最小化长度为 M 的 episode 上的负折扣回报：

$$\mathcal{L}_{\text{RL}}(\theta) = -\mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^{M-1} \gamma^t R(s_t, l) \right],$$

实际优化中通常采用 policy-gradient 的替代目标：

$$\mathcal{L}_{\text{PG}}(\theta) = -\mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^{M-1} A_t^\pi \log \pi_\theta(a_t \mid o_{t-H+1:t}, l) \right],$$

其中使用优势估计量 A_t^π 。在基于偏好的设定下，诸如 Direct Preference Optimisation (DPO) [?] 的方法会利用成对或排序反馈，对 π_θ 进行优化，使其更倾向于生成被偏好的轨迹。

5.2 3.2 Vision-Language-Action models

我们以 OpenVLA (Kim et al., 2024) 为研究基础(图 2)。该模型基于 Prismatic VLM (Karamcheti et al., 2024) 构建，是一个开源模型：它将由 SigLIP (Zhai et al., 2023) 与 DI-NOv2 (Oquab et al., 2023) 组成的融合视觉 encoder，与 Llama-2 7B 语言 backbone (Touvron et al., 2023) 配对，在多个任务上取得了 SOTA 性能。对于每个时间步，policy 接收一张 RGB 图像 o_t 和一条指令 l ，即历史长度 $H = 1$ 。图像首先被嵌入为视觉 token，指令则通过 Llama-2 tokenizer 进行 token 化，随后得到的 token 序列被送入 causal transformer decoder。




图 2: OpenVLA 模型架构 (Kim et al., 2024)，根据其官方开源代码与 checkpoints 复现。

OpenVLA 采用了 RT-2 的离散化方案 (Brohan et al., 2023a)：将连续控制命令 $a_t \in \mathbb{R}^{d_a}$ 中的每个标量，映射到 256 个 bin 中的一个；这些 bin 在训练集中该标量的第 1st 百分位与第 99th 百分位之间做均匀划分，由此生成 action-token 向量 $\mathbf{u}_t \in \{0, \dots, 255\}^{d_a}$ 。这些 action token 会覆盖 Llama-2 词表中 256 个使用频率最低的 token，从而使语言模型能够直接输出动作 token。随后，网络使用标准的 next-token cross-entropy 目标进行训练，并且 cross-entropy loss 仅在预测得到的 action token 上计算。




图 3: VLA 微调 (fine-tuning) 方法概览及性能比较。(a) 不同微调方法示意: SFT 从离线 demonstrations 学习, 而 DPO、GRPO 和 PPO 则采用基于强化学习的更新, 分别对应 preference alignment、group-relative advantage estimation, 以及结合 generalized advantage estimation (GAE) 的标准 actor-critic PPO; (b) 不同 RL 微调算法的性能对比。

6 VLA 模型的高效 RL 微调

我们首先研究如何利用强化学习对 VLA 模型进行微调。由于这类模型继承了其预训练 LLM/VLM backbone 在规模与结构上的相似性, 我们先考察: 面向 LLM/VLM 等大规模模型的常见 RL 算法, 是否也能有效迁移到 VLA 上。在第 4.1 节中, 我们将表明, Proximal Policy Optimization (PPO) [?] 能够稳定提升性能; 相比之下, Direct Preference Optimization (DPO) [?, ?] 和 Group Relative Policy Optimization (GRPO) [?] 在 POMDP 机器人任务上难以学到有效策略。基于这一发现, 我们进一步在第 4.2 节中对 PPO 内部的关键设计选择进行消融研究, 从而提炼出一套适用于 VLA 模型的高效微调方案。

6.1 4.1 RL 算法: PPO、GRPO、DPO

这里我们考虑三种具有代表性的 RL 算法: PPO (Schulman et al., 2017)、GRPO (Shao et al., 2024) 和 DPO (Rafailov et al., 2023; Zhang et al., 2024b)。所有模型均采用 Low-Rank Adaptation (LoRA) (Hu et al., 2022) 进行微调 (fine-tuning), 其中 rank 设为 32。

- PPO 采用 on-policy 更新: 基于新采集的 rollouts, 结合裁剪的重要性比率 (clipped importance ratios) 和 Generalised Advantage Estimation (GAE) 来计算 policy gradient。近期工作 Open-

Reasoner-Zero (ORZ) (Hu et al., 2025) 表明, 在大模型微调时, 禁用 GAE (即设 $\gamma = 1$ 且 $\lambda = 1$) 能够提升性能。因此, 在实验中, 我们同时评估标准算法 (PPO) 及其变体 (PPO-ORZ)。

- GRPO 使用一组样本来估计 baseline, 因此无需显式的 value estimation 即可直接计算 advantage。尽管自然语言生成任务与机器人多步 MDP 任务在本质上存在差异, 我们仍按照 GRPO 的设定 (Shao et al., 2024), 从相同初始状态采样轨迹, 每个 group 包含 8 条 trajectory。
- DPO 利用带有成对偏好标注的离线数据集。然而在机器人任务中, 很难从同一初始状态获得具有对比性的轨迹。按照 (Zhang et al., 2024b) 的做法, 我们根据 reward signal 推断 trajectory-level preference。为保证比较公平, 我们仅使用第 5.1 节中介绍的基于阶段的稀疏奖励 (stage-based sparse reward), 而不采用 (Zhang et al., 2024b) 原始实现中更丰富的奖励设计。

这些算法如图 3(a) 所示, 更详细的说明与实现细节见第 A.1 节。我们在第 5.1 节描述的 pick-and-place 任务上评估其性能。

结果见图 3(b), 每组实验均使用两个不同的随机种子重复进行。实验结果表明, PPO 始终优于 GRPO。我们认为, 这主要源于自然语言任务与机器人任务在环境动力学上的根本差异 (Li et al., 2024b)。我们的假设是: 在机器人任务的 POMDP 中, 每个动作都会以时序方式改变环境状态, 且这种变化是非平稳的, 这可能会破坏 GRPO 的 advantage 估计稳定性。此外, PPO 的表现也优于 DPO。我们推测, 这一现象一方面是由于稀疏奖励结构难以区分不同轨迹的优劣, 另一方面则来自离线数据分布与交互式执行分布之间显著的 distribution shift (Prudencio et al., 2023)。




图 4: actor-critic OpenVLA 的模型架构。




图 5: 性能对比。




图 6: PPO 中共享 actor-critic backbone 的结构, 其中 $V(s)$ 由一个三层 MLP 预测。我们比较了不同 critic 设计, 以及独立 actor-critic 架构的性能。




图 7: VLA warm-up。




图 8: PPO epoch 对比 (以环境步数 env. steps 计)。




图 9: PPO epoch 对比 (以 wall-clock time 计), 用于验证我们提出的高效训练设计。




图 10: PPO epoch 对比 (以 env. steps 计), 用于验证我们提出的高效训练设计。

6.2 4.2 PPO 的设计因素

我们采用了若干关键设计, 使 PPO 能够在 OpenVLA 上有效工作。在这些设计的支持下, 我们的主实验在单张 NVIDIA A100 GPU 上约需 42 小时即可收敛。下面将依次介绍这些设计选择, 并通过 ablation 实验评估其影响。每组实验均使用两个不同的随机种子运行。

共享的 actor-critic backbone。 由于 PPO 以及大多数现代强化学习方法都采用 actor-critic 形式 (Konda and Tsitsiklis, 1999), 我们将预训练的 VLA policy 视为 actor, 并额外接入一个轻量级 critic, 用于估计状态价值 $V(s)$ 。为保持架构紧凑, actor 与 critic 共享整个 Transformer backbone; 一个三层 MLP value head (见图 4a) 接收最终 Transformer block (Vaswani et al., 2017) 在第一个 action-token 位置产生的隐藏向量 h^0 , 并将其回归为一个标量价值。

为验证这一设计的有效性, 我们评估了多种 critic 方案。实验表明, 以第一个 action-token 的 embedding $\tilde{h}^0$ 作为 value head 输入时, 能够获得最高且最稳定的回报, 优于使用最后一个 token 的输入 h^n , 以及使用拼接向量 $[h^0, \dots, h^n]$ 的方案 (见图 4b)。采用独立 Transformer backbone 的 critic 虽然能达到相近的奖励水平, 但训练速度慢了 35%, 且 VRAM 占用增加了 83% (81.3 GB vs. 44.4 GB)。这些结果表明, 共享 backbone 并使用 h^0 是效率最高的选择。

VLA warm-up。 我们的所有实验均基于官方 OpenVLA checkpoint (Kim et al., 2024), 该模型预训练于 OXE 数据集 (Collaboration et al., 2023)。由于这一 checkpoint 在我们的 benchmark 上初始表现较差, 我们使用由 Octo-Small (Team et al., 2024) 和运动规划器采集的 140 条 demonstration 轨迹对其进行 warm-up (见 Sec. A.2)。如图 5a 所示, 经过 warm-up 的模型以大约少 50% 的环境交互步数达到收敛; 而在给予足够交互后, 两种初始化最终都能达到相近的渐近回报。除非另有说明, 后续所有实验都使用 warm-up 后的 OpenVLA 模型进行初始化。

最小化 PPO epoch。 我们发现, update-to-data ratio 是决定高效微调 (fine-tuning) 的关键因素之一。在 PPO 中, 这一比率由 epoch 超参数控制, 即每个 batch 会经历多少次梯度更新。图 5b 和图 5c 表明, 当 PPO epoch 增加到 1 以上时, 无论在回报还是样本效率上都没有收益, 但 wall-clock 时间却几乎线性增长。因此, 在其余所有实验中, 我们统一设定 epoch = 1, 从而在不牺牲性能的前提下实现最快训练。




图 11: 数据规模对 SFT 在训练阶段表现的影响。报告指标包括抓取准确率、连续抓取准确率以及任务成功率 (success rate)。子图 (a) 为 SFT@Training。




图 12: 数据规模对 SFT 在 OOD 评测中的表现影响。报告指标包括抓取准确率、连续抓取准确率以及任务成功率 (success rate)。子图 (b) 为 SFT@OOD Eval。




图 13: 数据规模对 RL 在训练阶段表现的影响。报告指标包括抓取准确率、连续抓取准确率以及任务成功率 (success rate)。子图 (c) 为 RL@Training。




图 14: 数据规模对 RL 在 OOD 评测中的表现影响。报告指标包括抓取准确率、连续抓取准确率以及任务成功率 (success rate)。子图 (d) 为 RL@OOD Eval。

7 5 评估微调 (fine-tuning) 方法对 VLA 泛化能力的影响

7.1 5.1 环境与数据集

为了系统考察 VLA 的泛化能力, 我们聚焦于一个典型的 pick-and-place 任务 (Kim et al., 2025; Li et al., 2024a): 智能体需要根据指令, 将桌子上的物体放入某个容器中。受已有工作 (Fan et al., 2025; Stone et al., 2023) 以及 Vision-Language-Action 模型设定的启发, 我们将泛化划分为三个维度: 视觉 (Vision)、语义 (Semantics, Language) 和执行 (Execution, Action), 如图 1 所示。

- **视觉 (Vision):** 我们同时考虑前景变化 (Dynamic Textures) 和背景变化 (Unseen Table), 以及图像层面的 Dynamic Noise; 这些扰动均以弱或强两种强度施加。
- **语义 (Semantics):** 我们考虑训练中未见过的物体 (Objects)、容器 (Receptacles) 以及指令表述方式 (Instruction Phrasings) 变化。此外, 我们还设计了新的任务: 在两个物体中选择其中一个进行抓取 (Multi-Object), 其中物体集合既包括 seen 集, 也包括 unseen 集。我们还引入了带有干扰容器的任务 (Distractive Receptacle), 以及要求将物体放入两个未见容器之一的任务 (Multi-Receptacle)。
- **执行 (Execution):** 我们考察物体与容器初始位置的变化, 以及机器人初始位姿的变化。进一步地, 我们还引入了一个新场景: 任务执行过程中物体位置发生改变 (Mid-Episode Object Reposition)。

为检验泛化能力, 我们在训练阶段沿三个轴对每个任务进行随机化: 视觉 (16 张桌面)、语义 (16 个物体) 以及执行 (物体与容器位姿扰动)。在测试阶段, 我们令上述因素中至少有一个处于分布外 (out-of-distribution) 状态, 从而引入 9 个新物体、16 个未见容器、5 种新的桌面环境以及 16 种干扰纹理。相关资产来自 Objaverse (Deitke et al., 2023) 及其他公开来源; 额外的桌面外观则通

过 Stable Diffusion (Rombach et al., 2022) 和 ControlNet (Zhang et al., 2023a) 合成, 以保证桌面表面外观发生变化, 同时不改变桌子的全局位姿。关于资产获取与任务定义的更多细节见 Secs. A.3 和 A.4。

基于这些资产, 我们在 ManiSkill (Tao et al., 2024) 中构建任务环境, 并使用一台 8-DoF 的 WidowX-250S 机械臂。每个时间步, 智能体接收一帧 640×480 的 RGB 图像和一条自然语言指令, 并输出 Cartesian end-effector 增量以及一个二值 gripper 信号。奖励采用稀疏设计: 当成功抓取并持续持有正确物体时给予 0.1 的奖励; 当成功将其放置到目标位置时给予 1.0 的奖励。对于监督微调 (fine-tuning), 我们使用 MPLib motion planner (Guo et al., 2024) 采集 demonstration 轨迹, 并采用 LoRA (Hu et al., 2022) 进行微调; 更多数据集细节见 Sec. A.2。

7.2 5.2 SFT 性能随数据规模的变化

按照 Lin et al. (2025) 的设定, 我们研究监督微调 (SFT) 性能如何随 demonstration 数量扩展。我们在不同规模的数据集上将 OpenVLA 训练至收敛, 数据规模从数百条到 64k 条 expert trajectory (约 1.26M 个 transition) 不等, 并在分布内环境以及未见过的物体/桌面设置上, 报告 3 个随机种子的平均得分 (见图 6a 和图 6b)。结果表明, 在这两种设置下, 性能均在约 16k 条 trajectory 时趋于饱和。因此, 在后续比较 RL 微调方法时, 我们采用基于 16k 条 trajectory 训练得到的 SFT checkpoint 作为 baseline。

7.3 5.3 RL 与 SFT 的性能对比

在前文分析的基础上, 我们进一步绘制了 RL 训练过程中在训练分布与 OOD 物体/桌面划分上的成功率曲线, 如图 6(c) 和 6(d) 所示, 并与不同数据规模下的 SFT 分数进行对比。在 OOD 任务上, RL 在大约 0.4 M 个环境步之后便超过了最强的 SFT checkpoint (SFT-16k)。收敛后, RL 在训练分布下的表现与 SFT-16k 相当, 而在未见过的物体和桌面上则高出 42.6%。这表明, 强化学习不仅能够提升 policy 在训练分布上的性能, 还能带来显著更强的泛化能力。




图 15: 图 7 的子图。




图 16: 图 7(b)。



图 17: 图 7(a)。




图 18: 图 7(c)。图 7: 不同任务上 SFT 与 RL 的性能对比。(a) 报告成功率 (success rate) 与相对性能下降; (b) 成功率雷达图; (c) 分布外 (OOD) 与分布内 (IND) 性能比值的雷达图。

我们进一步评估了收敛后的 RL policy 与表现最好的 SFT policy (SFT-16k, 后文简称 SFT) 在 OOD 任务上的泛化性能, 如图 7 所示。这里报告的是 3 个随机种子下的平均成功率和平均性能下降, 更完整的详细结果见 Sec. B.3。相对性能下降定义为 $\frac{\text{SFT Success Rate} - \text{RL Success Rate}}{\text{SFT Success Rate}}$ 。结果表明, 在 Vision 任务上, RL 与 SFT 表现相近; 在 Semantics 任务上, RL 明显更优; 在 Execution 任务上, RL 的优势则更加显著。


对于 Vision, 我们推测, 无论是 RL 还是 SFT, 都没有学到超出训练时所施加视觉随机性范围之外的视觉鲁棒性 (例如训练中仅使用随机桌面), 因此两种方法的表现较为接近。对于 Semantics 任务, 在面对 OOD 物体时, 无论是单物体场景还是多物体场景, RL 都显著优于 SFT。我们认为, 这可能是因为 RL 通过 trial-and-error 学到了对物体类型依赖更弱的 “grasp” 技能, 从而获得了更好的泛化能力。对于 Execution 任务, 在所评估的三个场景中, RL 都全面超过了 SFT: 包括 OOD 物体与容器位置、OOD 机器人初始位姿, 以及 episode 中途的物体重定位。

7.4 5.4 剖析 RL 对泛化能力的贡献


为考察这两种方法在行为层面的定性差异, 我们对四个具有代表性的任务上的 policy roll-out 进行了可视化 (见图 9)。在 Vision/Dynamic-Noise (strong) 设置下, SFT 智能体在抓取后会反复立即掉落物体, 这表明强视觉扰动使其无法准确定位容器; 相比之下, RL 智能体能够完成放置任务。在

Semantics 中的 Unseen Object 场景下, SFT 会持续尝试抓取自己已经拿在手中的物体, 最终陷入停滞, 而 RL 则能够将其提起并完成任务。这可能归因于 RL 在训练过程中积累了大量 trial-and-error 经验, 因此在与未见过的物体交互时具备更细粒度的控制能力。RL 还学会了从抓取失败以及 episode 中途物体位姿变化中恢复; 这两种情况都出现在两个 Execution 测试中。相较而言, SFT 即使已经出现位置误差, 仍会继续按原有动作执行, 这很可能是因为 demonstration 数据中从未出现过这类情况。

训练过程中遇到的轨迹分布 (图 8) 也印证了这一差距: RL 的轨迹覆盖了更广的工作空间, 以及更丰富的 end-effector 姿态范围; 而 SFT 的 roll-out 则集中在数据集中 motion planner 轨迹附近。更宽的覆盖范围, 似乎正是 RL 在 Execution 任务上取得更强泛化能力的关键原因。



(a) SFT






图 20: 若干具体示例的可视化结果。

8 6 结论

本研究提出了一个具有挑战性的 benchmark，用于检验 RL 微调如何影响 VLA 模型的分布外泛化能力。我们将多种 RL 方法适配到 VLA 后发现，一种精简的 PPO 变体取得了最强且最高效的性能提升。该变体采用共享的 actor-critic backbone、简单的 warm-up 策略，以及极少的 PPO 训练轮数。相较于监督微调，这种 RL 方法在分布偏移条件下显著提升了语义 grounding 与动作执行能力，同时在视觉扰动下保持了与监督微调相当的鲁棒性。这些结果表明，强化学习有望成为构建更具泛化能力的具身智能体的重要路径。

局限性. 尽管本文取得了上述结果,但仍存在若干局限。首先,我们在监督微调阶段仅使用由 motion planner 生成的 demonstration,这可能无法充分覆盖人类采集数据中的多样性。其次,本文评测仅限于 pick-and-place 任务;如何扩展到更广泛、更复杂的多任务场景,仍是未来的重要研究方向。第三,所有实验均在仿真环境中完成,因此,将 RL 微调与 sim-to-real 迁移结合,并在真实机器人上验证 VLA 的泛化能力,是下一步的关键工作。我们希望本文的发现能够为后续研究提供参考,并推动这一方向的发展。

8.1 致谢

本研究得到国家自然科学基金 (No.62325405,62406159)、清华大学自主科研计划、清华大学-埃夫特具身智能计算与感知联合研究中心、北京信息科学与技术国家研究中心 (BNRist)、北京未来芯片创新中心、空天网络与通信全国重点实验室以及北京中关村学院项目 C20250301 的支持。

我们衷心感谢时良智,他完成了在 Franka Panda 机械臂上的部署工作,并提供了宝贵的 sim-to-real 评测结果。我们同时感谢臧泓志在 GRPO 性能调优方面提出的深刻建议,这些建议显著提升了本文工作的质量。

9 参考文献

参考文献条目较多,此处保留原论文英文文献列表,请参阅原文 PDF 的 References 一节。

[附录因公式排版问题从译本中省略,请参阅原文。]