

SOP: 一种面向 Vision-Language-Action 模型的可扩展在线后训练系统

Mingjie Pan¹ Siyuan Feng¹ Qinglin Zhang¹ Xinchun Li¹ Jianheng Song¹
Chendi Qu¹ Yi Wang^{1,2} Chuankang Li¹ Ziyu Xiong¹ Zhi Chen¹
Yi Liu¹ Jianlan Luo^{1,2}

¹Agibot Research

²Shanghai Innovation Institute

2026 年 8 月 17 日

1 SOP: 一种面向 Vision-Language-Action 模型的可扩展在线后训练系统

摘要

Vision-Language-Action (VLA) 模型凭借大规模预训练展现出很强的泛化能力,但在真实世界部署中,除了广泛的通用性之外,还需要具备专家级的任务熟练度。现有 VLA 模型后训练方法通常是离线的、面向单机器人系统的,或仅针对特定任务设计,因此难以支持有效的 on-policy 自适应,也无法实现基于真实世界交互的可扩展学习。

本文提出一种可扩展在线后训练 (Scalable Online Post-training, SOP) 系统,使通用型 VLA 模型能够直接在物理世界中进行在线、分布式、多任务后训练。SOP 通过闭环架构将执行与学习紧密耦合:机器人集群持续将 on-policy 经验和人工干预信号流式传输至中心化云端学习器,并异步接收更新后的 policy。该设计能够支持及时的 on-policy 校正,借助并行部署提升经验采集规模,并在自适应过程中保持模型的通用性。

SOP 与具体后训练算法解耦;本文分别基于交互式模仿学习 HG-DAGger 和强化学习 RECAP 对其进行了实例化。在一系列真实世界操纵任务上,包括布料折叠、箱体组装和货架补货,实验表明:SOP 能够在维持单一共享 policy 跨任务工作的同时,显著提升大规模预训练 VLA 模型的性能。仅需数小时的真实世界交互,即可实现有效后训练;同时,系统性能会随着机器人数量增加而近似线性提升。

上述结果表明,将在线学习与集群级部署紧密结合,是在物理世界中实现高效、可靠且可扩展的通用机器人 policy 后训练的关键。

2 1. 引言

在人类漫长的历史中,那些最善于协作与随机应变的群体,最终得以胜出。

Charles Darwin, *The Descent of Man*

大规模部署通用机器人正变得越来越可行 [57, 7, 22, 17, 31]。然而,仅有通用性还不足以支撑真实世界部署。真实部署所需要的是高性能的通才系统:它不仅能够在多样任务之间泛化,还必须

在落地到任何具体场景时都具备专家级熟练度。以家用机器人为例，它既要能叠衣服、整理置物架、组装家具，又要展现出人们对专用家电所期待的可靠性与精度。




图 1: 可扩展在线后训练 (Scalable Online Post-training, SOP)。机器人集群在多样任务上持续收集经验，将交互数据流式传输到中心化云服务器，并异步接收更新后的控制 policy，从而使 VLA 模型在保持通用性的同时，持续提升各项任务上的熟练度。

单独具备通用性或熟练度都无法满足这一要求；这两种能力必须在同一个系统中同时存在。

Vision-Language-Action (VLA) 模型为满足这一需求中的“通用性”部分带来了重要进展 [57, 50, 22, 7, 17]。VLA 将视觉感知、语言理解与动作生成统一到同一架构中；在互联网规模数据上训练后，这类模型在任务、物体以及 embodiment 之间都表现出很强的泛化能力 [8, 57, 42]。剩下的关

键问题在于：如何在不牺牲这种来之不易的通用性的前提下，为模型赋予专家级熟练度。

答案在于后训练（post-training），即让预训练模型适配具体的下游部署场景 [43, 3, 30, 39]。在大语言模型（LLM）等领域，基于在线强化学习（RL）和人类反馈的后训练已被证明非常有效 [43, 12]，使模型能够通过大规模分布式训练持续提升 [54, 15]。然而，在物理世界中，面向 VLA 后训练、结合分布式数据采集的在线学习系统级实现仍然基本未被充分探索。

尽管后训练算法本身已经取得了显著进展，现有 VLA 方法在根本上仍受制于一个事实：缺少一个能够将分布式机器人集群与中心化在线学习统一耦合起来的系统。因此，既有工作大多仍停留在离线、单机器人、任务特定的设定中 [11, 56, 7, 57]，在这种设定下，数据采集与 policy 改进在结构上是相互分离的。在这种场景中，基于预先收集 demonstration 的离线训练不可避免地会遭受分布偏移，而微小的执行误差会在长时域决策过程中不断累积。以 DAgger 为代表的迭代式模仿学习方法，通过引入人工纠正，在一定程度上缓解了这一问题 [44, 25, 26, 18, 16]；但其基于 batch 的更新周期会在执行与纠正之间引入延迟，从而限制其在实时序列决策中的效果，即便是在 HG-DAgger [21] 这类完全在线的变体中也是如此。这一现象也与相关理论结果一致：若要缓解分布偏移，及时的、on-policy 的纠正至关重要 [19, 1]。此外，单机器人数据采集还会进一步限制经验多样性与学习速度，而面向单一任务的微调（fine-tuning）虽然往往能提升熟练度，却常常以牺牲通用性为代价 [11, 56, 22, 50]。总的来看，这些挑战反映的并非某一类具体算法本身的缺陷，而是底层学习设定存在局限。因此，当前尚不存在一种 VLA 后训练方法，能够在单一通才模型中同时支持及时的 on-policy 纠正、可扩展的经验采集，以及多任务适配。

3 I. 引言（第二部分）

为应对上述挑战，我们提出了一个可扩展的在线后训练（post-training）系统 SOP（Scalable Online Post-training）。该系统利用大规模真实世界交互，直接在物理世界中对通用型 VLA 模型进行后训练。其核心洞见在于：将学习与执行紧密耦合，可以形成一个统一的反馈闭环，从而实现及时的 on-policy 纠偏，通过并行经验扩展探索，并在适应过程中保持模型的通用性。SOP 通过一种 closed-loop 架构将这一思想落地：机器人集群与中心化云端学习器持续交换 on-policy 轨迹和人工干预信号。这样的“采集-训练-部署”循环既支持低时延适应，也能够随着机器人规模扩大而自然扩展。

尽管从原理上讲，SOP 与具体采用何种后训练算法无关，我们在本文中分别结合 HG-DAgger [21] 和 RECAP [3] 对其进行实例化，它们分别代表交互式模仿学习与强化学习。实验表明，SOP 能够显著提升预训练 VLA 模型在多种真实世界操纵任务上的表现，包括衣物折叠、箱体装配和货架补货。更关键的是，这些性能增益并非以牺牲通用性为代价：我们使用单一模型在全部任务上进行联合后训练，其中货架补货任务还涉及大量且高度多样的物体。

或许最令人惊讶的是，SOP 使得大型 VLA 模型能够直接在真实世界中完成高效后训练，其时间尺度仅为数小时，而不再需要持续数天的长周期训练。这样的效率主要来自及时的 on-policy 纠偏：系统能够针对已部署 policy 的失效模式快速修正，并通过分布式经验采集进一步放大这一优势。此外，SOP 表现出近线性的扩展特性：随着机器人数量增加，达到目标性能水平所需的实际用时（wall-clock time）近似按比例下降。在 HG-DAgger 和 RECAP 两种设定下，SOP 都稳定优于其非 SOP 对应版本，成功率（success rate）通常可提升 2× 或更多；在若干任务上，系统性能接近近乎完美的水平，同时吞吐量也显著提高。在长时程评测中，衣物折叠和箱体装配等任务可以连续运行超过 36 小时且无性能退化，这表明 SOP 带来的收益并不只是算法层面的后训练改进，而是一种

更系统性的优势。

本文的主要贡献是提出 SOP：这是首个面向物理世界中 VLA 模型的在线、分布式、多任务后训练框架。SOP 使机器人集群能够通过中心化学习器持续共享真实世界经验，从而在不牺牲通用性的前提下，让模型快速提升任务熟练度。更重要的是，我们证明了：现有后训练算法在 SOP 框架下实例化之后，仅依赖有限的真实世界交互，便可以稳定且高效地提升大型预训练 VLA 模型在高挑战性灵巧操纵任务上的性能。

从更广泛的意义上看，SOP 为基于机器人集群共享经验的可扩展机器人学习提供了一个具体而可行的方向。通过将部署与学习紧密耦合，SOP 使一组机器人能够直接依托真实世界交互，共同维护并持续优化一个不断演化的 VLA。这种耦合关系建立了一个反馈回路：扩大机器人集群规模不仅能提升后训练效率，还能增加可用于学习的经验的多样性与相关性，从而支撑持续适应以及长时程真实世界部署中的鲁棒表现。这些结果表明，除算法与数据本身的进展之外，集群规模的部署能力也可以成为推动机器人学习系统发展的一个重要且互补的因素。

4 II. 相关工作

SOP 本质上是一个高度整合的系统框架：它将在线学习、分布式数据采集与多任务训练结合起来，从而弥补了现有 VLA 后训练方法的局限性。因此，我们从这三个维度对相关工作进行综述。

4.1 A. VLA Post-training

VLA 模型通过在大规模、多样化的多模态数据上进行预训练，获得了广泛的泛化能力 [8, 57, 22, 50, 17, 6, 51, 2, 34, 47]。为了使这类模型适配实际部署场景，post-training 方法大体可以分为两类：监督微调（supervised fine-tuning）和强化学习。监督微调利用特定任务的 demonstration 对 VLA 模型进行适配 [7, 33, 22]。这类方法稳定且有效，但依赖静态数据集，因此难以应对分布偏移，也无法突破 demonstration 覆盖范围继续提升性能。

强化学习（RL）[49] 则通过与环境交互并利用反馈来改进 policy，既包括 online RL，也包括 offline RL [24, 28]。PPO [45]、GRPO [46] 等 online RL 算法已在机器人 locomotion、LLM 等领域取得了显著效果，但在真实机器人操纵中仍面临实际挑战，例如高方差和训练不稳定 [35, 32, 29, 9, 55]。基于行为正则化（behavior-regularized）的 RL 方法可以提升稳定性 [10, 27]，但往往会对渐近性能（asymptotic performance）产生偏置，而且通常是任务特定的，因此难以直接应用于通用型（generalist）场景。

在 offline RL 方法中 [41, 23, 52]，与本文最相关的是 RECAP [3]。RECAP 将奖励反馈与人工干预结合起来，通过迭代式 offline 训练实现性能提升，其重点在于面向特定任务的专门化。尽管它在单个任务上效果良好，但并不能直接支持一个通用 policy 在多任务上的持续在线改进。RLDG [53] 采取了互补策略：先利用任务特定的 RL 生成高质量轨迹，再通过 behavior cloning 将这些轨迹蒸馏到一个通用 policy 中。虽然这一步蒸馏有助于保留通用性，但 RLDG 的数据生成过程仍然是 offline 的、单机器人设置，并且需要为每个任务分别训练独立的 RL policy，因此可扩展性受限。相比之下，SOP 通过分布式、多任务数据采集下的持续 online 学习，直接更新一个通用 policy，从而在保持通用性的同时持续提升性能。




图 2: SOP 总览。SOP 是一个可扩展的 actor-learner 框架，用于通用 policy 的在线、多任务 post-training。机器人集群将 on-policy rollout 持续流式传输到云端 learner。在失败或不确定情形下，系统可选地触发人工干预，以提供修正后的轨迹或动作，并将其纳入流式经验缓冲区（streaming experience buffer）。云端 learner 通过混合 online buffer 与静态 offline buffer，构造任务均衡的更新；随后应用可插拔的 post-training 模块（例如 HG-Dagger/RECAP），并以异步方式将更新后的权重广播回所有 actor，从而形成一个低延迟的在线训练闭环。

4.2 B. 交互式与在线学习

在线学习通过在当前 policy 实际访问到的状态上训练来缓解分布偏移问题，而不是仅依赖预先收集的专家数据。交互式模仿学习方法，如 DAgger [44]，会迭代地从已学习的 policy 中收集状态，并查询专家标注；而 HG-Dagger [21] 则进一步转向实时干预机制：只有当 policy 即将失败时，专家才接管控制。这样既减轻了人工负担，也能够直接纠正 on-policy 错误。

高样本效率的在线强化学习方法则利用 demonstration 来加速学习过程。RLPD [4] 将离线数据与在线交互经验混合使用；SERL [36] 将 demonstration 与面向机器人任务的在线 RL 相结合；HIL-SERL [37] 则进一步引入人工干预，在复杂的长时程任务上达到了专家级性能。然而，这类方法仍然局限于单机器人场景，因而数据收集吞吐受限；同时也具有较强的任务专属性，通常需要为每个任务分别训练。SOP 将在线学习扩展到分布式多任务设定中，使机器人集群能够并行覆盖状态空间，同时保持方法的通用性。

4.3 C. 分布式与多任务机器人学习

若要将数据采集规模从单机器人扩展到更大范围，就需要分布式架构；而多任务学习则有助于避免模型过拟合于狭窄的目标。Gorila [5]、A3C [40] 和 IMPALA [13] 等分布式强化学习（RL）系统率先提出了 actor-learner 架构，以加速训练过程；但它们主要面向仿真环境，在这类环境中 reset 十分容易，因此并未处理现实世界部署中伴随人工监督的问题。Fleet-DAgger [14] 是与本文最接近的已有工作，它构建了一个支持可扩展人工监督的多机器人交互式学习系统。该方法能够实现在线分布式学习，但仍然仅限于仿真环境，既不是为大规模 VLA 模型设计，也只支持单任务学习。

多任务机器人学习 [48, 20, 38] 已经表明, 不同任务之间共享经验能够带来明显收益; 但这些方法并未将在线学习与分布式数据采集结合起来, 用于 VLA 的后训练 (post-training)。综上, SOP 是首个能够在物理世界中, 同时为通才模型 (generalist models) 提供在线、分布式、多任务后训练的框架。

5 III. 预备知识与问题定义

5.1 A. 预备知识

我们将所考虑的机器人控制问题表述为一个马尔可夫决策过程 (MDP) $\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathbf{T}, \mathbf{r}, \gamma)$, 其中, s 表示状态空间, A 表示动作空间, $T(s'|s, a)$ 与 $r(s, a)$ 分别表示在 (s, a) 处的状态转移动态和环境奖励, $\gamma \in (0, 1]$ 为折扣因子。对于 VLA 模型, 状态 s 通常由视觉观测、语言指令以及机器人的 proprioception 信息构成。policy $\pi_\theta(a|s)$ 定义了给定状态 s 时动作的分布; 在每一个时间步, 智能体从 $a \sim \pi_\theta(\cdot|s)$ 中采样动作, 并转移到下一状态 $s' \sim T(\cdot|s, a)$ 。

5.2 B. 问题表述

考虑一个分布式机器人系统。共有 N 个机器人部署在不同环境中, 并执行不同任务。我们用域变量 ϕ 来刻画这种异质性, 它诱导出一族 MDP, 即 $\mathcal{M}(\phi)$ 。具体而言, 第 i 个机器人的交互过程由 $\mathcal{M}^i := \mathcal{M}(\phi_i)$ 决定, 其中 $\phi_i \sim p(\phi)$, $i = 1, 2, \dots, N$ 。后训练 (post-training) 的目标是利用机器人集群在线收集的交互数据, 将预训练的基础 policy π_{θ_0} 适配到各个部署域中。这通常需要一个多轮优化过程。在第 k 次迭代时, 机器人执行当前 policy π_{θ_k} 并收集轨迹数据, 其中既包括自主 rollout, 也可能包含人工干预, 将其汇总为数据集 $\mathcal{D}_k$ 。随后, 通过最小化基于所收集样本定义的后训练目标来更新 policy:

$$\theta_{k+1} = \arg \min_{\theta} \mathbb{E}_{(s,a) \sim \mathcal{D}_k} \mathcal{L}_{PT}(\pi_\theta; s, a). \quad (1)$$

其中, $\mathcal{L}_{PT}$ 表示与所选后训练算法 $\mathcal{G}$ 对应的后训练损失。该损失可以采用 log-likelihood loss, 也可以采用基于 diffusion / flow 的损失形式。

5.2.1 算法 1: 面向 VLA 的可扩展在线后训练

输入: 初始 policy π_{θ_0} , 离线 buffer $\overline{B_{\text{off}}}$; 后训练算法 $\mathcal{G}$, 自适应采样器 s 。

1. 初始化在线 buffer: $B_{\text{on}} \leftarrow \emptyset$ 。
2. 将 π_{θ_0} 广播给所有 actor。
3. **Actor i (并行):**
 - a. 当持续执行任务时:
 - i. 执行 policy π_θ , 收集 rollouts τ_π^i ;
 - ii. 若当前由人类接管控制, 则收集干预轨迹 τ_H^i ;
 - iii. 将 $\tau_\pi^i \cup \tau_H^i$ 上传至 B_{on} 。
4. **Cloud Learner (异步):**

- a. 当持续训练时：
 - i. 采样一个训练 batch: $\xi \sim S(B_{\text{on}} \cup B_{\text{off}})$;
 - ii. 更新 policy 参数: $\theta \leftarrow \mathcal{G}(\theta, \xi)$;
 - iii. 将更新后的 policy π_θ 流式发送给所有 actor。

6 IV. 可扩展的在线后训练

我们提出可扩展在线后训练 (Scalable Online Post-training, SOP)。它是一个 closed-loop 的 actor-learner 框架, 用于利用异构机器人集群在真实世界中持续交互产生的数据, 对预训练 VLA policy 进行自适应。SOP 由三部分组成:

1. 机器人 actor 执行分布式 on-policy 数据采集;
2. 云端基于在线与离线混合数据进行集中式优化;
3. 将模型以低时延方式同步回各个 actor。

需要强调的是, SOP 与具体算法无关: 它规定的是系统层面的数据流与同步机制, 而具体的参数更新方法可以替换为任意后训练算法。本文中, 我们将 SOP 分别实例化为两种已有的后训练方法——HG-DAGger [21] 和 RECAP [3], 并表明: 通过持续流式接入最新交互经验, 并频繁执行异步模型更新, SOP 能将它们扩展为实用的 on-policy 在线后训练方案。

6.1 A. Algorithm Framework

算法 1 总结了 SOP 的整体流程。我们从一个预训练 policy π_{θ_0} 出发 (更多细节见附录 C), 并将其广播到全部 N 个机器人 actor。每个 actor i 在其本地域 $\mathcal{M}^i$ 中持续执行当前最新可用的 policy π_θ , 并并行地将轨迹上传到共享的在线经验缓冲区。轨迹既包括自主 rollout 产生的 τ_π^i , 也包括在可获得时用于纠正的人类干预轨迹 τ_H^i 。与此同时, 中心化的云端 learner 会持续从在线缓冲区与静态离线缓冲区的混合数据中采样训练 batch, 并通过后训练算法 $\mathcal{G}$ 更新共享参数。更新后的参数随后会以异步方式回传给所有 actor。

具体而言, 记 $\tau^i(t)$ 为截至墙钟时间 t 时, 机器人 i 已上传到云端的全部 episode。则在时间 t 之前可用的聚合在线经验为 $B_{\text{on}}(t) = \cup_{i=1}^N \tau^i(t)$ 。在训练步 j (对应墙钟时间 t_j) 时, 云端 learner 采样得到的训练 batch 记为

$$\xi_j := S_j(B_{\text{on}}(t_j) \cup B_{\text{off}}), \quad (2)$$

其中, S_j 是专门设计的自适应数据采样器, 可通过可配置的加权方案动态调节在线/离线数据的组成比例 (设计细节见第 IV-C 节)。 B_{off} 是一个静态离线缓冲区, 其中存放了已有的人类 demonstration。基于 ξ_j , learner 按照下式更新模型参数:

$$\theta \leftarrow \arg \min_{\theta} \mathbb{E}_{(s,a) \sim \xi_j} \mathcal{L}_{PT}(\pi_\theta; s, a).$$

随后, 最新的模型参数 θ 会被流式传输到所有 actor。

6.2 B. 系统基础设施

如图 7 所示，我们构建了一套面向真实机器人集群的分布式 actor-learner 数据基础设施。每个机器人 actor 在边缘侧运行一个客户端，用于在本地缓存 episode，并在 episode 结束时异步上传到对象存储。上传后的 episode 会被追加到云端托管的在线 buffer 中；learner 通过通知机制与按需拉取的方式独立消费这些数据。

为形成闭环，更新后的模型参数会由云端 learner 通过轻量级的发布-订阅通道，以较短时间间隔同步到各个机器人 actor。actor 获取最新 checkpoint 的端到端延迟通常为数秒到数十秒量级，并会随模型规模增大而增加；参数更新仅在安全边界处生效（例如两个 episode 之间），从而避免在 episode 中途切换 policy，导致记录的轨迹被破坏。这样的解耦设计使 actor 与 learner 能够独立扩展，同时对暂时性的网络中断也具有良好的鲁棒性。更多设计细节见附录 B。

6.3 C. 自适应采样策略

为了在快速适应新收集的 on-policy 数据的同时保持多任务覆盖，我们在 learner 第 j 步采用任务均衡的自适应采样策略 S_j 。设训练数据被划分为 M 个任务，任务索引记为 $m \in \{1, 2, \dots, M\}$ 。在任务间层面，我们施加均匀的任务权重 $\omega^m = 1/M$ ，使每个任务的贡献相同。在任务内层面，对于任务 m ，我们依据近期训练损失来调整该任务的 online buffer B_{on}^m 与 offline buffer B_{off}^m 之间的采样比例。

对于每个任务，我们维护 online 与 offline 损失的滑动窗口估计，窗口大小为 $W = 200$ ：

$$\bar{l}_{\text{on}}^m = \frac{1}{W} \sum_{i=j-W}^{j-1} l_{\text{on}}^{m,i}$$

以及

$$\bar{l}_{\text{off}}^m = \frac{1}{W} \sum_{i=j-W}^{j-1} l_{\text{off}}^{m,i}.$$

online 采样比例 ω_{on}^m 的计算方式为：

$$\omega_{\text{on}}^m = \frac{\exp(\alpha \cdot \bar{l}_{\text{on}}^m)}{\exp(\alpha \cdot \bar{l}_{\text{on}}^m) + \exp(\bar{l}_{\text{off}}^m)} \quad (3)$$

其中， $\alpha > 1$ 是增益因子，用于在分布偏移条件下优先考虑 online 数据，从而加速适应。为避免出现极端分配，我们将 ω_{on}^m 裁剪到区间 $[0.2, 0.8]$ 。给定任务 m 后，以概率 ω_{on}^m 从 B_{on}^m 中采样，以概率 $1 - \omega_{\text{on}}^m$ 从 B_{off}^m 中采样。该采样策略在保证各任务覆盖均衡的同时，还能根据损失动态调整 online/offline 数据混合比例。

6.4 D. 后训练学习模块

SOP 将系统层（分布式数据流与同步机制）与算法层（如何基于一个 batch 更新 θ ）解耦。算法 1 中的后训练模块 G 正体现了这一点。任何能够消费已记录经验、并输出更新后参数的现有后训练方法，都可以无缝接入 SOP。下面我们先概述 HG-Dagger 和 RECAP 的原始特性，再说明 SOP 如何通过持续数据流与异步更新，将二者转化为 on-policy 的在线后训练流程。

a) HG-Dagger HG-Dagger [21] 是一种交互式模仿学习方法：当机器人即将失败时，由人类监督者实时介入，从而在困难的、on-policy 的状态上提供纠正性监督；与全程 teleoperation 相比，这种方式所需的人力更少。在 SOP 中，这些人工介入片段（连同自主 rollout 和离线 demonstration）会被持续写入共享 buffer，并由云端 learner 读取，用于高频异步更新。这样一来，HG-Dagger 被转化为一种适用于大规模 robot fleet 的、实用的 on-policy 在线后训练方案，因为它缩短了从失败发生、人工纠正到模型更新之间的时延。

b) RECAP RECAP [3] 是一种面向大型 VLA policy 后训练的离线强化学习（offline RL）方法，其目标是基于经验提升 policy 性能，这些经验包括自主 rollout，以及可选的人类纠正。在标准用法中，RECAP 采用迭代式离线闭环：先收集经验，再离线训练，最后重新部署。SOP 将这一工作流在线化：系统持续把由最新部署 policy 收集到的新轨迹纳入 buffer，同时在不断演化的数据集上异步执行 RECAP 风格的更新。这样可以降低 policy 与数据之间的陈旧性（staleness），并在保持 RECAP 方法本身不变的前提下，实现持续的、on-policy 的性能提升。

7 V. 实验评估

我们通过两种具有代表性的后训练算法对 SOP 进行实例化评估：HG-Dagger [21] 和 RECAP [3]。实验在由 10 台双臂机械臂组成的 fleet 上进行，覆盖图 3 所示的三类具有挑战性的操纵任务。这些任务旨在同时考察模型的细粒度灵巧操作能力与语义泛化能力。我们的实验主要围绕以下三个问题展开：

1. SOP 在真实世界操纵任务中提升预训练 VLA 性能的效果如何？与离线替代方案相比表现如何？
2. 模型性能如何随 fleet 规模变化而扩展？
3. 对于初始质量不同的预训练模型，SOP 是否都能带来稳定的性能增益？

据此，我们将实验结果组织为三个部分：多任务后训练、fleet 规模扩展，以及预训练质量/数据效率。

7.1 A. 实验任务

我们在三类同时要求灵巧操纵与语义理解的任务上进行评测：Grocery Restocking、Laundry Folding 和 Box Assembly。任务示意如图 3 所示。下面我们对具体任务设置与评测协议进行说明。




图 3: 三类任务的示意图。(A) Grocery Restocking 场景：(A-1) 平面货架补货；(A-2) 错放商品纠正；(A-3) 涉及开关门操作的 freezer 补货；以及 (A-4) 需要处理纸盒包装的 open-cooler 补货。(B) Laundry Folding: 机器人双臂协同完成衣物展平与折叠的序列任务。(C) Box Assembly: 两条机械臂协同将扁平纸板折叠为三维纸箱结构的过程。

Grocery Restocking. 该任务用于评估 policy 在杂乱零售环境中的泛化能力，要求模型能够在大规模商品目录与多样化货架布局下进行语义理解。预训练阶段，机器人学习执行多种操作，包括补货、抓取、悬挂以及商品重排等。该任务族的预训练语料覆盖了超过 500 个不同物体。

评测时，我们从该物体池中均匀采样一个固定的 40 个物体集合，并在所有实验中保持不变。四个任务变体分别为：1) 平面货架补货，2) 错放商品纠正，3) 带门操作的 freezer 补货，以及 4) 带纸盒处理的 open-cooler 补货。每个变体都从上述评测集合中选取 10 个物体进行测试，每个物体执行 5 次试验。

后训练阶段，物体从完整物体池中采样。因此，一次典型的后训练过程通常会与评测物体集合有大约三分之二 ($\sim 70\%$) 的重叠，同时仍能保持超出评测子集的物体多样性。任务成功需要同时满足两点：一是遵循指令，即从杂乱物体集合中选择正确商品；二是完成任务，即在时间限制内将其放置到目标位置。

Laundry Folding. 该任务要求对可变形物体进行灵巧的双臂操纵。训练阶段，机器人学习从篮筐中抓取、折叠并堆放衣物。评测时，我们提供一件处于无序状态的 T 恤；成功标准是在 500 s 内将其正确折叠，并放置到指定堆叠位置。

Box Assembly. 该任务评估精确的多步程序化执行能力。机器人需要通过一系列折叠动作，将一张平整的纸板转变为三维纸箱。成功标准是在 300 s 内完成组装，且不出现折叠错误。

对于 Laundry Folding 和 Box Assembly，我们的数据采集与部署过程可能包含完整流程的连续操作，例如先从篮筐中取出衣物并重新摆放，再进行折叠；或在组装前先对纸板进行准备。在定量评测中，我们聚焦于核心的长时程操纵技能（折叠/组装），因此不将上游的抓取、堆放或准备步骤

计入 trial 定义。每个 trial 都从一个随机化的无序初始状态开始：衣物或纸板被放置在机器人工作空间内，其位姿与构型具有自然变化；trial 在成功、失败或超时后结束。

指标 (Metrics)。我们报告成功率 (success rate, 成功 episode 的比例) 和吞吐率 (throughput, 每小时完成的 episode 数)。当一个 episode 因成功、失败或超时而终止时，即视为已完成。因此，吞吐率同时反映了在固定时间预算下的执行速度与可靠性 (Laundry Folding 为 500 s, Box Assembly 为 300 s; Grocery Restocking 采用与任务相关的时间限制)。需要特别说明的是，吞吐率度量的是 policy 侧吞吐率，不包含 trial 之间环境重置或场景布置所需的人工操作时间；这一排除项在所有对比方法中保持一致。

7.2 B. 实验设置

我们在三类任务上，使用一组 Agibot G1 双臂操纵机器人评估 SOP：杂货补货 (Grocery Restocking)、衣物折叠 (Laundry Folding) 和纸箱组装 (Box Assembly)。在主要的多任务设定中，我们训练一个共享 learner，并将由 10 台机器人组成的 actor 集群按任务划分：4 台机器人为杂货补货采集 on-policy 经验，3 台用于衣物折叠，另外 3 台用于纸箱组装；随后汇总所有 actor 的经验，用于联合训练 SOP。

所有 post-training 实验都从一个预训练的基础 policy π_{θ_0} 开始，该 policy 由 π [17] 初始化。更多细节见附录 C。SOP 通过持续的 on-policy 交互对其进行改进。除非另有说明，每个实验均分配 3 小时 (180 分钟) 的实际运行时间预算，并选择 SOP+HG-DaGger 作为 post-training 算法。

在实验中，我们使用 NVIDIA H100 GPU 训练 learner。在 10 个 actor 的实验设定下，为适应更高的数据吞吐量，我们配置 8 张 GPU；在其他实验中则使用 4 张 GPU。这是我们的实验资源分配选择，并不意味着 SOP 固定需要这样的硬件配置。

在额外的 ablation 实验中，我们仅关注杂货补货任务，并使用一个更小的、由 4 台机器人组成的 actor 集群，同时改变活跃 actor 的数量 ($N \in \{1, 2, 4\}$)。预训练基础 policy 与 SOP post-training 的实现细节见附录 C。

7.3 C. 多任务后训练

如图 4 所示，我们报告了采用 SOP 与未采用 SOP 的后训练模型在成功率 (success rate) 和吞吐量 (throughput) 上的结果。对于 Laundry Folding 和 Box Assembly，文中报告的每个数值均基于 50 次试验得到。对于 Grocery Restocking，其四个变体中的每一个都评测了 50 次 (10 个物体 $\times$ 5 次试验)，因此该任务族总计包含 200 次试验。

对于 RECAP，其原始实现并未针对多任务后训练而设计。因此，我们将任务语言 prompt 同时作为 policy 和 value function 的条件输入，从而构造出 RECAP 的多任务变体。为验证这一改动不会导致性能下降，我们还在两个具有代表性的 grocery restocking 变体上额外训练了单任务 RECAP 模型：open-front cooler replenishment 和 freezer replenishment。单任务 RECAP 在这两个任务上的成功率分别为 0.86 和 0.75，而多任务 RECAP 分别达到 0.80 和 0.75 (每项均为 50 次试验)。这些结果表明，多任务条件化并不会显著削弱 RECAP 的性能，从而保证了比较的公平性。SOP + RECAP 的实现细节见附录。

在所有任务上，后训练模型都稳定优于预训练 baseline。进一步地，无论与 HG-DaGger 还是 RECAP 结合，加入 SOP 后的性能都明显高于对应的不含 SOP 版本。其中，SOP + HG-DaGger 取得

了最强结果，在三个任务族上的成功率分别达到 0.94、0.96 和 0.98。在 grocery restocking 中，SOP + HG-Dagger 与 SOP + RECAP 之间的性能差距最大，这与该任务对语义泛化能力的强需求是一致的。在这类设定下，要学习一个足够准确且覆盖范围充分的 value function 仍然具有挑战；相比之下，交互式模仿学习能够更直接地从纠正性监督中获益。

从吞吐量来看，SOP 在所有预训练模型上都带来了显著提升，通常约为 $2\times$ 。这一增益源于基于 prompt 的 on-policy 纠正，它能够直接针对已部署 policy 的失败模式进行修正。以 laundry folding 为例，一种常见失败模式是反复抓取失败；SOP 能通过 on-policy 反馈快速纠正这一行为，从而显著缩短单次循环时间。

总体而言，这些结果表明，SOP 为通过可扩展的机器人部署对通用型 VLA 模型进行后训练提供了一种简单而有效的系统级机制。

7.4 D. 扩展机器人部署规模

一个自然的问题是：后训练效率会如何随机器人 fleet 规模变化而扩展。为此，我们通过改变活跃机器人 actor 的数量 ($N \in \{1, 2, 4\}$)，研究后训练效率随机器人 fleet 规模的变化，并同时评估最终性能与达到目标性能所需时间 (time-to-target)。所有实验的训练时长上限均设为 180 分钟。我们报告训练结束时的最终成功率 (success rate)，以及首次达到目标成功率所需的实际墙钟时间；在我们的实验中，目标成功率设为 0.8。我们将这一指标记为 time-to-target，并将其作为训练效率的度量。

如表 I 所示，增加机器人 actor 的数量能够稳定提升可达到的性能上限与学习速度。当 fleet 规模从 1 个 actor 扩展到 4 个 actor 时，180 分钟时的最终成功率由 0.805 提升至 0.925。这一结果表明，在多机器人间并行采集数据能够提供更多样的 on-policy 经验，从而减轻单机机器人设定下对特定工作站噪声及其特有偏差的过拟合。

除了提高性能上限，扩大 fleet 规模还显著加快了学习过程。表 I 的结果显示，time-to-target 从单 actor 时的 173.6 分钟，下降到双 actor 时的 126.5 分钟（加速 $1.4\times$ ），并进一步下降到 4 个 actor 时的 71.7 分钟（加速 $2.4\times$ ）。在所测试的范围 ($N \in \{1, 2, 4\}$) 内，这表明其墙钟时间加速比近似呈线性增长，说明 SOP 能够较充分地将机器人的并行性转化为更快的 on-policy 后训练，而不会明显受限于中心化学习或通信开销带来的瓶颈。

总体而言，这些结果表明，SOP 使后训练效率能够随机器人 fleet 规模实现良好的扩展，同时提升数据效率与墙钟训练速度。进一步地，对于真实世界 VLA 的后训练而言，扩大机器人部署规模在加速学习方面的作用，可能与算法层面的改进同样重要。

7.5 E. 预训练质量与数据效率分析

为考察 base policy 的初始能力如何影响在线自适应，我们评估了以三种预训练变体为起点的 SOP: Base-1/8、Base-1/2 和 Base-Full。这三种模型采用相同的架构，但分别在全部多任务预训练数据的 1/8、1/2 以及完整数据集上完成预训练；其中，完整数据集覆盖所有任务，总计约 160 小时的数据。结果汇总于图 5。




图 4: 三个操纵领域中的成功率 (success rate) 与吞吐量对比。在所有领域中, 我们的方法都展现出更优的效率与可靠性。在本文的评测协议下 (policy 侧吞吐量, 不计入人工 reset/setup 时间), SOP w/ HG-Dagger 相比离线方法稳定实现了 2-4 $\times$ 更高的吞吐量, 并显著降低了失败率。

表 1: 随 actor 数量扩展的可伸缩性分析。比较不同 actor 数量 (N) 下最终成功率与训练效率的扩展表现。性能增益与加速比均相对于单 actor baseline 报告。Time-to-target 表示首次达到目标成功水平 (0.8) 所需的实际墙钟时间。

Actor Number	Success Rate @180min	Time-to-target (min)
1	0.805	173.6
2	0.887 (+0.082)	126.5 (1.4 $\times$ faster)
4	0.925 (+0.12)	71.7 (2.4 $\times$ faster)

在所有设置下, SOP 相对于预训练 baseline 都能稳定提升性能。然而, post-training 之后所能达到的最终性能, 仍与预训练规模强相关。以更大规模预训练数据初始化的模型, 不仅起点更高, 而且会收敛到更高的渐近性能。这表明, 大规模预训练为 SOP 提供了关键的表征先验 (representational priors); SOP 的在线 post-training 主要是在已有知识之上进行细化与专门化, 而不是替代广泛预训练本身的作用。

离线数据扩展与 on-policy 经验之间的对比进一步突出了这一点。对于 Base-1/2 模型, 在离线 demonstration 数据集中额外加入 80 小时人工采集数据后, 成功率仅从 0.576 小幅提升到 0.612。相比之下, 采用 SOP 仅需 3 小时的 on-policy 交互, 就能将性能从 0.571 显著提升到 0.800。该差距反映出静态专家 demonstration 的收益会逐渐递减, 因为这类数据无法预先覆盖部署后 policy 所诱发的特定误差分布。SOP 通过直接收集并学习由 policy 自身生成的失败样本, 将学习能力集中分配到状态-动作空间中最相关的区域, 因此在弥合最终性能差距时展现出明显更优的扩展行为。

8 VI. 讨论与未来工作

我们的结果表明，在 post-training 场景中，执行与学习之间的系统级耦合，与底层算法本身同样关键。SOP 使机器人 fleet 能够持续流式传输 on-policy 经验，并接收更新后的 policy，从而将原本离散、阶段性的微调 (fine-tuning) 转变为可扩展的、closed-loop 学习。我们还观察到，on-policy 纠错带来的边际收益显著高于继续增加 offline 数据，这再次印证了一个反复出现的结论：静态数据集无法充分覆盖已部署 policy 所诱导出的状态分布 [44]。SOP 则在系统规模上将这一认识落到了实处。

尽管 SOP 已表现出良好效果，但当前系统仍依赖人工干预或任务特定的奖励信号。如何借助学习式奖励模型，或基于 foundation model 的成功检测机制，进一步降低监督负担，仍是一个重要研究方向。除此之外，近似线性扩展是否能够延续到规模显著更大的机器人 fleet，以及如何在不发生灾难性遗忘的前提下持续习得新技能，仍然是尚未解决的开放问题。



图 5: 预训练数据规模对 SOP 的影响。更大规模的预训练数据集能够带来更高的初始成功率 (success rate)，并在在线 post-training 后取得更高的最终性能。

展望未来，我们设想由机器人 fleet 通过部署过程中的经验，共同维护一个持续改进、不断演化的共享 policy。在这一图景下，扩大机器人部署规模本身就相当于扩大用于学习的计算资源——每新增一台机器人，都能够进一步加速 policy 的改进。要实现这一愿景，仍需要在系统设计、算法以及人机交互等多个层面取得进一步突破；但本文结果表明，这一目标所需的基础条件已经初步具备。

9 参考文献

参考文献条目较多，此处保留原论文英文文献列表，请参阅原文 PDF 的 References 一节。

[附录因公式排版问题从译本中省略，请参阅原文。]