

1 World-VLA-Loop: Video World Model 与 VLA Policy 的闭环学习

<https://showlab.github.io/World-VLA-Loop/>




图 1: 论文配图。




图 2: (a) 基于 world model 的 VLA 强化学习范式。图中比较了现有方法：当前方法通常依赖于在三维世界中重建环境，或训练能够模拟环境的 video world model。为解决现有基于视频的 simulator 在动作跟随方面存在的不精确问题，本文提出 World-VLA-Loop。该方法围绕两个基础设计展开，并进一步构建了一个更高层次的协同演化范式。(b) 实验表明，在 VLA 模型与 world model 进行两轮联合优化后，真实世界中两项任务的 policy 成功率 (success rate) 分别提升了 36.7% 和 26.6%。

摘要

强化学习 (RL) 能够将 VLA policy 的性能进一步提升到超越行为克隆的水平，但现实世界中的 RL 代价仍然很高，原因在于其需要大量 rollouts、环境重置、监督信号，并伴随着安全风险。以动作为条件的视频 world model 为在虚拟环境中训练提供了一种可行方案，但这类方法在动作跟随上往往不够精确，尤其在那些“接近成功但最终失败”的细微情形下更为明显。此外，它们通常不具备可直接用于 RL 的原生奖励信号。若基于不准确的视觉预测来计算奖励，其可靠性

也难以保证。

我们提出 World-VLA-Loop，其核心包括两个基础性设计以及一个更高层的协同演化范式。首先，我们构建了 SANS 数据集，专门混合成功轨迹与近成功轨迹，以提升动作与结果之间的对齐能力。随后，我们训练了一个状态感知 (state-aware) 的视频 world model，使其能够从 diffusion latents 中联合预测未来帧与二值奖励。该设计将奖励估计直接耦合到生成器中，而非依赖一个独立模块；同时，这种耦合反过来也有助于提升视觉预测质量。

考虑到 VLA 的行为会在 RL 过程中不断变化，固定不变的模拟器可能逐渐与更新后的 policy 失配。因此，World-VLA-Loop 通过精化后的 world model 对 VLA 进行迭代式 post-training，从而形成闭环；与此同时，还将每一轮改进后 policy 产生的 rollouts 反馈回来，用于扩充并微调 world model。仿真与真实机器人实验表明，World-VLA-Loop 能够显著提升 VLA 的性能，同时减少对高成本物理交互的依赖。

2 1 引言

Vision-Language-Action (VLA) 模型已成为机器人操纵中的主流范式之一。这类方法利用大语言模型的先验，将自然语言指令直接映射为底层控制信号 [3, 18, 17, 24]。除行为克隆之外，近期工作 [25, 19, 12] 还进一步结合强化学习 (RL)，通过与环境交互来优化 policy。尽管这一方向前景可观，但现有的 RL 后训练大多仍局限于仿真环境 [22, 31]。原因在于，真实世界中的 RL 代价高昂：既需要大量物理 rollouts，探索过程中还伴随着安全风险，同时重置环境与人工监督也会带来显著的运维开销。

一种有前景的思路是将已学习的 world model 视作虚拟环境。如图 1 所示，我们将此类模型归纳为三种范式：(1) 手工构建的数字孪生 (digital twins) [22, 6]。这类方法依赖人工资产创建与物理引擎建模，但通常难以同时满足真实世界适配所需的照片级真实感与物理保真度；(2) 基于 3D 重建的方法 [26, 33]。它们使用几何 3D 表征，但在跨多样化环境泛化时往往存在困难，也很少支持丰富的随机探索；(3) 以动作为条件的视频 world model [37, 20, 34]。这类方法能够利用大规模视频预训练得到的先验，因此具备较高的真实感以及更强的场景泛化能力。

尽管视频 world model 很有吸引力，但它们仍存在两个关键局限。首先，我们的实证分析表明，这类模型对动作的跟随往往不够精确，导致预测轨迹与真实执行结果产生偏差。这一问题在“近成功但失败”的情形中尤为突出：机器人仅因细微的动作误差而未能达到目标。如图 2 所示，Cosmos-Predict 2 [1] 等模型即使在动作存在错误时，也经常“幻觉”出成功结果，这反映出它们对细粒度物理动力学的 grounding 较弱。其次，这类模型本身并不能原生提供 RL 所需的 reward 信号。尽管近期工作 [34] 尝试从视觉预测中构造 reward，但当底层视频预测本身不准确时，这类 reward 也会变得不可靠，尤其是在（近）成功样本中更是如此。

为解决上述问题，我们提出了两个相互补充的基础性设计。具体而言，为了提升动作与结果之间的一致性，我们构建了 SANS 数据集，将 Successful And Near-Success 轨迹共同纳入其中，使模型能够学习更清晰的成功与细微失败边界。为了为 RL 提供可靠的学习信号，我们进一步提出一种 state-aware 视频 world model，使其能够联合预测未来视频帧以及二值 reward 信号（成功或失败）。在训练阶段，视频与 reward 的联合监督会进一步增强模型的动作跟随能力，因为它在 latent space 中显式鼓励形成清晰的成功-失败分界；在推理阶段，模型预测得到的 reward 则可以自然地作为 RL 的 reward 使用。实验结果表明，这些设计显著提升了视频 world model 的性能，并进一步支持了对 VLA policy 进行有效的 RL 后训练。

尽管上述设计已经取得了有希望的结果，但在完整学习系统层面仍存在另一项挑战。随着 RL 后

训练推进，VLA 的行为会随 policy 改善而发生变化：更新后的 policy 会产生不同类型的错误，从而以不同于 world model 初始拟合数据的方式对其施加压力。如果模拟器保持静态不变，它就可能无法对齐更新后 policy 的失败模式，进而导致预测轨迹与 reward 同时发生漂移。基于这一观察，我们提出了 World-VLA-Loop：一种建立在上述两个基础设计之上的、更高层次的协同演化范式。World-VLA-Loop 在模拟器与 policy 之间闭合了训练回路：经过改进的 world model 支持在虚拟环境中迭代式地对 VLA 进行后训练，而每轮更新后 policy 产生的 rollouts 又会被回流，用于扩充训练数据并微调 world model。结合前述数据集构建与 world-model 设计，这种 world modeling 与 policy learning 之间的闭环协同演化，将一次性的可靠仿真进一步提升为一个能够持续与当前训练中 policy 保持对齐的迭代系统。我们的贡献如下：

- 我们刻画了视频 world model 中的近成功失败模式，并构建了 SANS 数据集，以提升动作-结果对齐能力。

3 1 Introduction (part 2)

- 我们提出了一种状态感知的 world model。该模型通过在 diffusion latent 上联合施加 reward 与视频监督，同时具备较强的动作跟随精度以及原生的 reward 预测能力。




图 3: 当前的 world model 在准确模拟由轻微动作误差引发的失败情形时仍然存在困难，主要原因在于其对细粒度交互动力学以及精确动作条件的建模不足。图中的透明轨迹叠加表示真实的 gripper 运动轨迹，展示了机器人未能抓取到物体的情况。

- 我们提出了 World-VLA-Loop。这是一个 closed-loop 框架，通过迭代优化建立 world model 与 VLA policy 学习之间的协同演化循环。
- 我们在仿真与真实世界两种设置下进行了评估。结果表明，World-VLA-Loop 能够在仿真和物理部署中显著提升 VLA 的性能，同时降低对高成本真实世界交互的依赖。

3.1 相关工作

面向机器人操纵的 VLA 借助基础 VLM 的强先验, VLA 已成为机器人操纵中的主流范式。预训练 VLM 具备较强的泛化能力, 通常会进一步在机器人 demonstration 数据上进行微调 (fine-tuning), 以适配具体的动作空间 [7, 14, 18, 17, 3]。然而, 当前占主导地位的训练范式仍然是模仿学习。该范式一方面受限于数据稀缺, 另一方面在测试时容易出现误差累积 (compounding errors), 最终限制了模型的泛化能力。为缓解这些问题, 强化学习逐渐成为一种有吸引力的选择: 它使 policy 能够通过在线 rollout 学习, 而不再局限于静态的人类 demonstration。代表性工作包括 VLA-RL [25]、RL-VLA [23]、SimpleVLA-RL [19]、RLinf-VLA [36] 等。尽管如此, 将 RL post-training 适配到真实世界时仍面临一个根本瓶颈, 即高昂的成本: 大量 rollout、环境重置与人工监督带来的操作开销, 以及探索过程中的安全风险。针对这些问题, 我们的框架通过在高保真视频 world model 中模拟真实环境, 避免了物理交互成本, 从而实现高效的 policy RL。

面向机器人学的视频 world model 随着视频生成技术的快速进展 [32, 4], 基于可控视频的世界模型变得越来越可行。与仅依赖文本提示的标准生成模型不同, world model 会将动作序列作为条件信号输入。许多工作利用大规模预训练视频模型中的时空先验, 在游戏 [5, 35]、自动驾驶 [28, 11] 和机器人学 [20, 34, 29, 1, 37, 38, 9, 13] 等场景中实现动作条件的视频模拟。尽管取得了这些进展, 现有实证结果表明, 当前的视频 world model 在精确跟随动作方面仍然存在困难, 即预测帧与动作所隐含的真实结果之间容易出现不对齐。

为了将 world model 融入 VLA 训练, 尤其是 RL post-training, 研究者不仅需要视觉环境, 还需要可用的奖励信号。近期工作已探索了多种设计方案。VLA-RFT [20] 采用基于视觉相似度的启发式奖励; World-Env [34] 使用 VLM 根据 world model 的视觉预测来估计任务成功与否; WMPO [38] 则通过视频 encoder 加线性 head 来实现奖励模型。这类方法大多依赖额外训练的模块, 同时又建立在可能并不可靠的视觉预测之上。与之不同, 我们直接从 world model 的 latent 中预测奖励。联合训练不仅能够实现端到端的奖励预测, 也能反过来提升视觉预测分支的性能。同期工作如 WoVR [13] 和 VLAW [9] 同样注意到 world model 中 imagination 与真实 outcome 之间的不对齐问题, 并提出了与本文相近的、让 world model 与 VLA 共同演化的思路。然而, 这些方法仍然依赖外部奖励模型, 且没有进一步研究内在奖励 (intrinsic reward) 及其与 world state 之间的关系。




图 4: 我们提出框架的完整流程。整个过程包含四个阶段: 1) 通过人工 teleoperation 和 policy rollout 构建 SANS 数据集; 2) 在 SANS 上对动作条件的 world model 进行预训练, 并联合进行奖励与视频监督; 3) 在 world model 内执行 VLA policy rollout, 以开展 GRPO 优化; 4) 部署优化后的 policy, 收集新的失败与成功数据, 以进一步扩充 SANS。该循环实现了 world model 与 VLA policy 的联合优化, 并通过迭代持续提升二者性能。

4 3 方法

如图 3 所示, 我们的框架包含四个阶段。首先, 我们构建一个覆盖多种结果的数据集, 其中既包含成功轨迹, 也包含接近成功的轨迹。随后, 我们在 Cosmos-Predict [1] 的基础上训练一个带有 reward 监督的、由 action 条件驱动的视频 world model。训练完成后, 该模型可以利用少量 demonstration 高效适配到未见场景, 并可作为 policy 评估与 RL 后训练的虚拟环境。进一步地, 我们还使用真实世界中的 policy rollout 来扩充数据集。下面将详细介绍各个阶段。

4.1 3.1 Success and Near-Success Dataset

现有的开放式机器人数据集虽然包含 action-trajectory 标注, 且在任务与场景上具有一定多样性, 但由于主要服务于模仿学习, 整体上仍以成功执行的轨迹为主。这种数据构成限制了训练鲁棒 world model 所需的结果多样性, 因此模型往往难以在多种失败模式下模拟出物理上合理的结果。尽管近期工作如 RoboFAC [27] 和 AHA [8] 已开始关注失败数据, 但它们主要面向问答式推理, 缺乏 action 标注。此外, 这些数据集大多局限于仿真环境, 其实际应用价值仍有待进一步验证。

本文提出 Success and Near-Success Dataset (SANS)。该数据集重点利用那些几乎完成目标或子目标、但由于 end-effector 位姿存在细微误差而最终失败的轨迹。对于训练鲁棒 world model, 这类数据至关重要, 原因有二: 其一, 这些轨迹与成功执行往往难以区分, 因此会迫使 world model 关注空间动态中的细粒度差异; 其二, 机器人 policy 在实际执行中经常表现出这类 “near-success” 行为, 将其纳入数据集后, 虚拟环境便能更准确地反映 policy rollout 过程中真实出现的失败模式。我们分别在 ManiSkill [31]、LIBERO [22] 以及自建真实机器人场景中构建了 SANS 数据集。

对于 ManiSkill [31], 我们使用带有真实物体位姿信息的简单控制 policy 采集成功轨迹, 并通过对位姿施加扰动来生成失败轨迹。与此同时, 我们还从 policy rollout 中记录自然出现的失败模式。在 LIBERO 中, 我们采用 OpenVLA-OFT [17] 沿用这一策略; 在真实环境中, 则同时通过 teleoperation 和 OpenVLA-OFT rollout 采集数据。每条轨迹均包含视频、动作以及逐步的二值 reward 信号, 用于指示是否成功。

基于上述流程, 我们构建了一个用于 world model 预训练的大规模 ManiSkill 数据集, 覆盖 23 个任务, 共包含 35k 组 video-action 对, 且同时具有多样的成功与失败结果。对于 LIBERO 和真实机器人场景, 我们采集了规模较小的 SANS 数据集 (每个任务约 50 条成功轨迹和 50 条失败轨迹), 并表明预训练模型能够高效迁移到这些未见过的任务上。

4.2 3.2 状态感知的视频世界模拟器

我们在 Cosmos-Predict 2 [1] 的基础上构建视频世界模拟器。Cosmos-Predict 2 已在大规模具身相关视频数据上完成预训练, 并且可以进一步适配, 以融入机器人动作条件。给定前 h 个观测帧 $x_0, \dots, x_{h-1}$, 以及后续 T 个时间步的机器人动作 $a_1, \dots, a_T \in \mathbb{R}^6 \cup \{0, 1\}$ (表示为 6-DoF 的 end-effector 位姿与 gripper 的开/闭状态), 模型生成接下来 T 步的未来执行视频帧, 记为 $x_h, \dots, x_{h+T-1}$ 。

Cosmos-Predict 采用 Diffusion Transformer (DiT) 作为 backbone, 以自回归方式预测未来的视频 chunk。为适配动作模态, 作者使用一个 action embedder MLP 将每个输入位姿映射为潜在张量。随后, 这些 action embedding 被直接加到 diffusion timestamp embedding 上, 并注入各个 DiT 模块。这样的设计使模型能够在利用强大预训练生成先验的同时, 将视觉预测有效锚定到给定的控制序列上。

为了在不依赖外部奖励模型的情况下实现奖励预测, 我们在原始生成模型上加入了一个 reward prediction head, 如图 3 所示。DiT 模型输出 diffusion latent 后, 我们增加一个投影层, 将这些 latent 映射为一串奖励值; 监督信号来自 SANS 数据集中采集的真实奖励。具体而言, 对于每个采样时间步 t , 记最终步得到的去噪 latent 为 z_t 。reward head ϕ 预测标量奖励 $\hat{r}_t = \phi(z_t)$, 其中 ϕ 由一个轻量级 MLP 实现。训练时, 我们在原始 flow matching loss [21] 的基础上, 与 reward prediction head 进行联合优化:

$$\mathcal{L} = \mathcal{L}_{flow} + \lambda \sum_{t=1}^T \|\hat{\mathbf{r}}_t - \mathbf{r}_t\|^2,$$

其中, 权重因子 λ 按照 EDM 框架 [15], 根据采样噪声水平进行调制。这样可以保证 reward head 在去噪早期面对高方差 latent 时仍具有较好的鲁棒性。

这一设计带来两个关键优势。其一, 它在 world model 内部提供了可靠的奖励生成机制。由于奖励是基于生成视频对应的 latent state 预测得到的, 因此它与实际视觉结果天然对齐, 通常比低层启发式代理奖励或外部基于 VLM 的奖励模型更准确。其二, reward head 与视频模型的联合训练, 会促使生成器在不同动作条件下更好地区分成功执行与失败执行的结果。这进一步提升了未来视频预测的准确性, 而这恰恰是现有许多视频 world model 普遍缺失的一项关键能力。

在实际训练中, 我们从 Cosmos-Predict 的 checkpoint 初始化, 先在采集得到的 ManiSkill SANS 数据集上进行预训练, 再针对新场景中少量成功与近成功 demonstration 进行微调 (fine-tuning)。其中, 经过 ManiSkill 预训练的模型赋予了系统较强的动作跟随能力, 而后续微调则帮助模型掌握新环境、物体纹理以及任务特定交互的相关知识。

4.3 3.3 用于 policy RL 后训练的世界模拟器

当视频世界模型已经能够在给定动作输入条件下精确生成执行结果时，它就可以作为下游 policy 评估与 RL 后训练中的可靠虚拟环境。

我们采用 OpenVLA-OFT [17] 作为基础 policy，并参照 SimpleVLA-RL [19] 构建基于 GRPO 的后训练流程。对于每个目标任务，给定稀疏的 SANS 数据集（通常少于 50 条成功轨迹和 50 条近成功轨迹），我们首先将世界模型与 policy 微调（fine-tuning）到对应的具体场景。在 RL 过程中，学习得到的世界模型替代基于物理的模拟器；它以自回归方式，在 policy 动作的条件下生成多步视觉观测以及奖励预测。随后，这些预测结果以 closed-loop 形式反馈给 policy，从而支持完整 rollout 的生成。与此同时，世界模型还提供逐步奖励；这些奖励经阈值化后被转为二值成功信号，并用于在一组 rollouts 上计算 advantage，以更新 policy。

如图 3 所示，我们方法的一个关键优势在于，建立了一个同时面向世界模型与 VLA policy 的完整迭代式联合优化框架。在每一次 RL 更新之后，我们将新训练得到的 VLA policy 部署到其目标环境中，收集其生成的成功与近成功 rollouts。随后，这些 rollouts 被用于扩充 SANS 数据集，以支持后续迭代中的世界模型微调。这样的迭代式精炼使世界模型能够逐步提升其合成精确执行结果的能力，而这又会进一步增强下一阶段 VLA policy 的 RL 效果。实验部分验证了，这一联合优化过程确实能够带来更优的 VLA RL 性能。

5 4 实验

本节从多个维度对所提出的框架进行评估，以验证该方法的有效性及其更广泛的适用性。实验结果表明：

1. 该 world model 的平均视觉对齐度达到 88.5%，reward 对齐度达到 87.25%，说明它能够作为高保真模拟器，用于 VLA policy 的 rollout。
2. 通过在该模拟器中进行 RL 后训练，OpenVLA-OFT policy 在 LIBERO 基准上的平均成功率（success rate）提升了 12.7%，在真实世界场景中分别提升了 23.4% 和 13.3%。
3. 所提出的迭代式细化过程相较于第一个 RL checkpoint，进一步将真实世界任务的平均准确率提升了 13.3%，进一步说明了联合优化循环的有效性。

5.1 4.1 实验设置

实验场景。 我们在 LIBERO benchmark 上开展仿真实验，并搭建了自建实验平台，以评估方法在真实世界中的适用性。在两种设置下，系统均采用 Franka research arm [10] 以及一台固定安装的第三人称视角 RealSense D435 相机 [16] 作为观测输入。对于真实世界实验，我们设计了两项主要任务：Pick and Place Cup 和 Pushing Cube。仿真与真实世界中的所有任务均统一采用 24 的 chunk size。更多实现细节以及真实世界实验设置见附录 A。

评测方法。 我们从两个角度评估整条 pipeline。首先，评估 World-VLA-Loop world model 的生成性能，重点关注其视觉保真度以及动作跟随精度。在此基础上，我们进一步通过测量 VLA policy 在 RL post-training 过程中的成功率提升，量化该模型作为 simulator 的实际效用。

5.2 4.2 World Model 评估

为确保 world model 能够提供可靠的生成结果，从而支持准确的 policy rollout，我们首先评估其生成质量。具体而言，给定由图像-动作对组成的测试数据集，world model 以初始图像和一段机器人末端执行器绝对位姿序列作为输入，随后以自回归方式预测执行这些动作后对应的视频帧。我们从两个核心维度评估生成结果：视频质量，以及动作跟随精度。

视频质量 生成帧将作为 policy 的主要视觉观测，因此，为了维持 VLA 行为的稳定性，必须保证较高的视觉保真度。表 1 所示，World-VLA-Loop 的 world model 在仿真与真实场景中都取得了高质量的生成结果，生成视频具有较高保真度，几乎不存在明显的结构性或感知失真。LIBERO 与真实世界上的评测指标保持一致，说明我们的 world model 能够在不同环境间有效泛化，并为下游 policy rollout 提供可靠的视觉基础。

表 1: 视频生成性能。↑ 表示越高越好，↓ 表示越低越好。

Scenario	SSIM ↑	PSNR ↑	LPIPS ↓	MSE ↓
LIBERO	0.90	26.57	0.031	0.0024
Real-World	0.91	29.61	0.059	0.0019
Average	0.91	28.09	0.045	0.0022

表 2: 在若干 LIBERO 与真实世界任务上的结果对齐性能。每个任务在集合内评估 50 个样本，并汇报预测成功/失败与真实标签一致的样本比例。

Metric	LIBERO-Object		LIBERO-Goal		LIBERO-Spatial		Real-World	
	Task 1	Task 2	Task 1	Task 2	Task 1	Task 2	Place Cup	Push Cube
Visual Alignment	92%	90%	94%	78%	86%	94%	90%	84%
Reward Alignment	88%	90%	90%	76%	88%	94%	94%	78%

生成精度 对于 world simulator 而言，一个关键要求是能够忠实反映动作轨迹所导致的因果后果。尽管 MSE 这类像素级指标可以提供基础参考，但更稳健的评估方式是衡量生成结果与真实结果之间的对齐程度。为此，我们将每条轨迹的最终状态划分为成功或失败，并计算对齐率，即预测结果与真实结果一致的样本占比。由于我们的 world model 会同时生成视频帧和标量奖励，因此我们报告两种不同的对齐指标：

- **Visual Alignment:** 衡量像素级生成的真实性。通过评估最终生成的视频帧来判断任务结果，并据此确定成功或失败。

- **Reward Alignment:** 衡量 world model 的奖励预测性能。当生成的 reward 高于 0.9 阈值时, 将预测轨迹判定为成功。

如表 2 所示, 我们的方法能够在仿真和真实场景中有效区分成功轨迹与失败轨迹, 两项指标的平均对齐精度均超过 80%。此外, 基于 reward alignment 得到的结果与 visual alignment 的判断高度一致。这种强相关性进一步说明, 内部 reward prediction head 具有较高可靠性, 其学习到的成功判据与人类判断保持了良好一致。

5.3 4.3 用于 VLA 后训练的世界模拟器 (第一部分)

利用基础 RL 训练 凭借可靠的生成性能, World-VLA-Loop 的世界模型可以作为一个学习得到的模拟器, 用于 VLA policy 的后训练。对于每个任务, 我们首先分别对 OpenVLA policy 和世界模型进行任务特定的微调 (fine-tuning)。随后, 将该 policy 部署到世界模型构建的环境中, 执行 RL 后训练。我们采用 SimpleVLA-RL [?] 的 RL 流水线, 并将 rollout 过程改造为完全在神经模拟器内进行。在这一设定下, 只有初始帧来自原始数据集; 之后的所有观测都由世界模型基于 policy 预测的动作自回归生成。最后, RL 奖励由世界模型的 reward head 给出, 并通过阈值机制生成 group relative optimization [?] 所需的二值成功信号。

我们在 LIBERO benchmark 的三个任务套件以及真实世界任务上开展实验。由于 LIBERO-100 主要包含长时程任务, 通常需要生成超过 300 帧视频, 而当前的自回归视频模型在这种场景下往往会出现明显的质量漂移, 因此我们将其留作未来工作。对于每个任务, 我们使用 80–100 条成功或近成功轨迹来微调世界模型; 其中约 50 条成功轨迹进一步用于微调 OpenVLA policy。表 3 和图 4 表明, 无论是在 LIBERO 各任务套件上, 还是在真实世界任务上, 成功率 (success rate) 都在 RL 后训练过程中得到了显著提升。

表 3: OpenVLA-OFT 在 RL 训练前后的成功率。LIBERO 各任务套件的成功率基于 500 次 rollout 统计, 真实世界实验基于 30 次实体 rollout 统计。Oracle 结果是在 LIBERO simulator 中使用真实视频和真实奖励进行 RL 训练得到的, 表中数值为对应整个任务套件上的平均结果。

Model	LIBERO-Object		LIBERO-Goal		LIBERO-Spatial		Real-World	
	Task 1	Task 2	Task 1	Task 2	Task 1	Task 2	Place Cup	Push Cube
SFT Base	73.9%	73.9%	91.9%	86.1%	83.9%	87.9%	13.3%	26.7%
RL Post-Training (Ours)	97.9%	91.9%	100%	96.2%	93.9%	94.0%	36.7%	40.0%
Δ vs SFT	+24.0%	+18.0%	+8.1%	+10.1%	+10.0%	+6.1%	+23.4%	+13.3%
RL Post-Training (Oracle)	98.7%	98.7%	98.8%	98.8%	98.2%	98.2%		




图 5: (a) LIBERO-Object




图 6: (b) LIBERO-Goal




图 7: (c) LIBERO-Spatial




图 8: (d) Real-World

图 9: 随着 World-VLA-Loop 中 RL 训练步数增加, 成功率持续提升。

需要说明的是, 图 4 中真实世界任务的成功率曲线是在世界模拟器内评估得到的; 而表 3 中最终汇报的结果则来自真实物理实验。

通过 policy rollouts 进行迭代优化 如第 3.3 节所述, 一旦获得了可用的 policy, 就可以利用其 rollout 轨迹扩充 SANS 数据集, 并进一步用于优化世界模型, 从而提升其精度以及对动作的跟随能力。最终, 这一迭代循环能够整体提高 VLA 在神经模拟器中进行强化学习的效率。

5.4 4.3 用于 VLA 后训练的世界模拟器 (第 2 部分)

我们在真实世界环境中开展了迭代实验。在初始阶段 (Step 0), SUPA 数据集由人工采集的成功与近成功轨迹, 以及基于 SFT OpenVLA-OFT baseline 的 rollout 共同构成。进入下一轮迭代 (Step 1) 后, 数据集进一步扩展, 加入了由前一阶段通过 RL 优化得到的 policy 新生成的轨迹。两个 world model 均从 ManiSkill 预训练 checkpoint 初始化, 而各个 RL 阶段中的 VLA policy 则都从基础的 SFT 版本开始。

如图 1(b) 所示, 这种迭代式优化能够显著提升性能: 基础 SFT policy 在两个真实世界任务上的成功率 (success rate) 仅为 13.3% 和 26.7%; 经过我们闭环中的两轮 RL 迭代后, 最终分别提升至

50.0% 和 53.3%。这些结果表明，所提出的 closed-loop 框架能够持续改进 policy 与 world model，因而整体上是有效的。

5.5 4.4 消融实验

奖励预测头 我们通过消融实验验证奖励预测头的有效性。首先，我们考察去掉该模块后 world model 的性能变化。表 4 显示，在没有奖励监督的情况下，visual alignment 约下降了 30%，这表明将奖励头与 diffusion backbone 联合训练，能够显著提升模型区分不同行为结果的能力。

其次，我们将本文的奖励头与以 Qwen3-VL [?] 作为成功/失败判别器的方法进行比较。这是已有工作中一种常见做法。具体而言，我们将 world model 生成的视频帧输入 Qwen3-VL，并提示其判断任务最终是否成功。需要注意的是，这些视频帧与我们内部奖励预测所使用的输入完全相同。表 4 的结果表明，VLM 在某些场景中会出现 hallucination，因而准确率较低；与本文方法相比，它并不适合作为 RL 中可靠的奖励函数。尽管面向特定任务进行微调（fine-tuning）可能提升 VLM 的准确率，但这会显著增加整个流程的复杂度。相比之下，本文的奖励预测头与视频生成器共享 backbone，不仅预测更准确，还能通过联合训练进一步提升生成视频的质量。更多结果见附录 B。

world model 训练中的 near-success 数据 我们还在剔除 near-success 轨迹的条件下对 world model 进行了微调。表 4 表明，在这种设置下，生成视频的 visual alignment 明显下降。这说明 near-success 轨迹对 world model 训练不可或缺：它使模型能够内化 VLA 执行过程中可能出现的失败模式，从而更真实地反映动作带来的结果。

表 4: 消融实验结果。我们研究了不同设计选择对 world model 预测准确性的影响。

Metric	LIBERO-Object		Real-World
	Task 1	Task 2	
Visual Alignment			
w/o near-success data	60%	66%	54%
w/o reward prediction head	68%	70%	80%
ours	92%	90%	90%
Reward Alignment			
Qwen3-VL-8B-Instruct	84%	58%	84%
ours	88%	90%	94%




图 10: world model 生成 rollout 与真实执行视频示例, 分别展示了 SFT policy 和经 RL 后训练的 policy。policy rollout 可用于扩充 SANS 数据集, 以训练 world model; 而训练得到的 world model 又可作为更优的模拟器, 支持后续 RL 迭代, 最终带来更强的 policy。

5.6 4.5 定性结果

图 5 展示了合成的 world model rollout 与真实 VLA policy 执行结果的定性示例。借助迭代式细化循环, world model 逐步学会覆盖更广的动作空间, 并且能够更好地表征 VLA 探索过程中的随机性。

从 policy rollout 可以观察到, SFT-baseline 倾向于生成不够精确的推送位姿。虽然第一轮 RL 迭代在一定程度上缓解了这一问题, 但 policy 在初期会出现 reward hacking, 并收敛到次优行为, 例如移动到立方体前方。这是因为第一轮迭代得到的 world model 无法准确建模此类轨迹中的空间细节。在对 SANS 数据集进行扩充后, world model 对这些边缘情况形成了更细致的感知。因此, 在这一细化环境中训练得到的 VLA policy 能够生成显著更精确、更稳健的抓取位姿。更多定性示例见附录 C。

6 5 结论

我们提出了 World-VLA-Loop, 这是一种新颖的、基于 world model 的 VLA 强化学习框架, 其核心是在联合优化 world model 与 VLA policy 的过程中实现策略提升。借助使用近成功轨迹 (near-success trajectories) 构建的 SANS 数据集, 我们训练了一个高保真 world model, 并在其中集成 reward supervision, 从而能够在虚拟环境中有效地对 policy 进行精炼。进一步地, 我们的协同演化范式利用真实世界 rollout 持续扩充训练数据, 逐步提升 world model 的 groundedness 以及 policy 性能。实验结果表明, 该方法在仿真与真实世界基准上均显著提高了成功率 (success rate), 并通过减少对高成本物理交互的依赖, 为真实世界 RL 提供了一条更具可扩展性的方向。

局限性与未来工作: 当前的自回归视频模型仍然受到上下文记忆能力有限和生成质量漂移的影响, 因此在超过 300 帧的长时程任务中性能会明显下降。未来的研究将探索结合具备更强长期稳定性的视频 backbone。此外, 若将当前稀疏的终态 reward 进一步扩展为逐步的中间子目标 (sub-goals), 还有望提升 reward head 的预测精度, 并改善 RL 的收敛表现。

7 参考文献

参考文献条目较多，此处保留原论文英文文献列表，请参阅原文 PDF 的 References 一节。

[附录因公式排版问题从译本中省略，请参阅原文。]