

TwinRL: 面向真实世界机器人操纵的数字孪生驱动强化学习

Qinwen Xu^{1,*}, Jiaming Liu^{1,*†}, Rui Zhou^{4,*}, Shaojun Shi^{1,*}, Nuowei Han^{1,*}, Zhuoyang Liu¹, Cheny

¹ 北京大学计算机学院, 多媒体信息处理全国重点实验室 ² Simplicity Robotics ³ 清华大学 ⁴ 香港中文大学

项目主页: <https://twinrl.github.io>

* 共同第一作者 † 项目负责人 ^B 通讯作者

2026 年 8 月 17 日

1 TwinRL: 面向真实世界机器人操纵的数字孪生驱动强化学习




图 1: TwinRL 方法示意图。




图 2: 总体框架。(a) 为提升真实世界 RL 的效率与可靠性, 作者提出 TwinRL, 这是一个由数字孪生与真实世界协同驱动的三阶段框架: (i) SFT warm-up 将探索空间扩展到真实 demonstration 之外; (ii) twin RL warm-up 生成交互轨迹, 以稳定机器人本体上的学习; (iii) real-world RL 利用数字孪生中识别出的易失败构型, 开展有针对性的 HiL rollout。(b) 在四个任务上, TwinRL 收敛更快, 并且仅用 20 分钟机器人交互时间, 就能在分布内与分布外区域都达到接近 100% 的成功率 (success rate); HiL-SERL 仅在分布内区域评测。

摘要

尽管 Vision-Language-Action (VLA) 模型展现出较强的泛化能力, 但其性能仍然受限于专家 demonstration 成本高以及真实世界交互有限。在线强化学习 (RL) 虽已显示出潜力, 但在真实世界 VLA 操纵中的应用仍受到两方面制约: 一是探索效率较低, 二是探索覆盖范围有限。通过系统性的真实世界实验, 作者观察到, 在线 RL 的有效探索空间在很大程度上受监督微调 (supervised fine-tuning, SFT) 阶段所诱导的轨迹分布约束。基于这一观察, 本文提出 TwinRL: 一种数字孪生-真实世界协同的 post-training 框架, 通过三个阶段扩展并引导 VLA 模型的 RL 探索, 分别为 SFT warm-up、twin RL warm-up 和 real-world RL。

TwinRL 首先根据手机采集的场景重建高保真数字孪生。在 SFT 阶段, 作者提出一种探索空间扩展策略, 将轨迹分布的 support 扩展到真实 demonstration 之外, 从而重塑探索空间, 使后续 RL 更加有效。与其将数字孪生仅视为数据增强工具, 本文进一步提出 twin RL warm-up 策略, 使其作为真实世界 RL 的探索引导器。具体而言, TwinRL 在数字孪生中执行高效并行 RL, 生成交互轨迹并填充 replay buffer, 从而稳定后续真实世界 RL 的学习过程。该过程还能够识别出虽然容易失败、但信息量丰富的关键构型, 进而支持有针对性的 human-in-the-loop rollout, 进一步提升机器人本体上的训练效率。

在四个任务上, TwinRL 在分布内与分布外区域均取得接近 100% 的成功率, 并且仅需 20 分钟机器人交互时间, 相比以往真实世界 RL 方法实现了超过 30% 的更快收敛。

2 I. 引言

基于互联网规模预训练的 Vision-Language Models (VLMs) [1, 22, 56], Vision-Language-Action (VLA) 模型近年来已成为机器人操纵的重要研究范式 [5, 23]。通过在大规模机器人 demonstration 上训练, VLA 模型在机器人场景推理 [30, 31]、泛化 [18, 32] 以及精确操纵 [3, 4] 等方面取得了令人鼓舞的进展。尽管如此, 当前 VLA 模型仍然严重依赖成本高昂的专家 demonstration, 且真实世界交互数据有限, 这些因素共同限制了其在复杂物理环境中的鲁棒性。

强化学习 (RL) 提供了一种基于探索的优化框架, 通过对累积任务奖励重新加权, 已被证明能够显著提升通用 VLM 的推理能力 [46, 44, 47]。受这一进展启发, 近期研究开始将 RL 作为 VLA 模型的后训练阶段, 利用 offline RL 更新 [69, 17, 68] 或在仿真中进行 online exploration [33, 51, 37, 14] 来优化操纵 policy。尽管这些方法表明 RL 能够提高执行精度, 但 online RL 在真实世界操纵中的应用仍然十分受限。

首先, 与仿真环境不同, 真实机器人必须在安全约束下与物理对象进行序贯交互, 且无法进行并行实验, 因此 online 学习的效率会受到严重限制 [8]。现有方法虽然通过 warm-up 策略 [25, 27]、统一训练目标 [8], 或 human-in-the-loop (HiL) 反馈 [40] 提升了效率, 但它们仍然高度依赖 teleoperation demonstration 的质量、多样性和提供时机, 因此往往会导致收敛不稳定。其次, 通过系统性的真实世界实验, 我们识别出 VLA 模型在真实世界 RL 中的一个根本性限制: 有效探索空间受到监督微调 (SFT) 阶段所诱导轨迹分布的强烈约束。即使有 HiL 辅助, 由于奖励景观不利以及 replay buffer 分布失衡, 模型在分布外 (OOD) 区域中的学习依然十分困难。这一现象与通用领域中的已有发现 [66] 一致, 说明 RL 的主要作用更像是对已有行为重新加权, 而不是将行为扩展至其原有边界之外。该观察表明, 要实现高效后训练, 关键在于扩展 VLA 模型的探索空间。

为应对这一挑战, 我们提出 TwinRL: 一种数字孪生与真实世界协同的后训练框架, 在真实世界交互受限的条件下, 将数字孪生作为探索放大器与引导器。具体而言, 整体流程包括一个 SFT warm-up 阶段, 随后进入数字环境中的 RL warm-up 阶段以及真实世界 RL 阶段。在 SFT 期间, 我们提出了一种探索空间扩展策略: 通过在数字孪生中生成多样化的合成轨迹, 扩大轨迹分布的 support。对于分布内区域, 在匹配的配置条件下同时采集真实样本与合成样本, 以促进真实域与仿真域之间的对齐。对于 OOD 区域, 则对物体配置进行均匀采样, 从而系统性地促进平衡覆盖, 并使探索能够超越 demonstration 状态所带来的偏置。为了在新环境中构建数字孪生, 我们使用 3D Gaussian Splatting 从智能手机视频中重建高保真场景, 并将其转换为 mesh 表示 [65]。在该孪生环境中, 我们进一步估计以物体为中心的 6-DoF 位姿 [11], 从而为生成逼真的操纵轨迹提供几何交互表征。

3 引言 (第二部分)

在上述更充分的初始化基础上, 我们进一步提出一种双生强化学习预热 (twin RL warm-up) 策略, 使数字孪生能够在真实世界 RL 中充当探索引导器。TwinRL 不再仅仅作为数据增强工具, 而是将数字孪生交互与真实世界反馈统一到同一个后训练 (post-training) 流程中。具体来说, TwinRL 首先在数字孪生中高效并行地执行 RL rollout, 生成交互轨迹, 并用这些轨迹扩充真实世界 RL 的 replay buffer。这样可以缓解 SFT 数据与 RL 交互之间的分布失配, 从而在保留高精度行为、避免灾

难性遗忘的同时，更平稳地过渡到在线学习。尽管基于孪生体的 RL 能够支持可扩展的探索，真实世界交互仍然不可或缺，因为只有这样才能覆盖真实物理动力学。在真实世界 RL 阶段，TwinRL 利用大规模孪生 rollout 来识别那些虽然容易失败、但信息量很高的状态配置，并据此引导有针对性的 HiL rollout。这种方式避免了真实世界中低效的随机探索，显著提升了样本效率。

如图 1(b) 所示，我们基于共享的 VLA backbone [42]，在四个 manipulation 任务上评估了 TwinRL。在 SFT 阶段，仅相较于只使用真实世界 demonstration 进行训练，我们提出的探索空间扩展策略就将平均成功率（success rate）提升了 42%。在在线 RL 阶段，TwinRL 在分布内区域与空间 OOD 设定下均实现了接近 100% 的成功率；同时，相比以往方法 [8, 40]，真实世界交互时间至少减少了 30%。平均来看，TwinRL 在四个任务上的机器人实机交互时间总共仅需约 20 分钟。除了收敛速度与精度之外，我们还进一步表明，TwinRL 在此前未见过的条件下同样具有更强的鲁棒性，包括背景杂乱和光照变化等情况。

总的来说，我们的贡献如下：

- 我们发现，真实世界 VLA 强化学习中的探索过程，在很大程度上受 SFT 阶段诱导形成的轨迹分布所塑造。基于这一观察，我们提出 TwinRL：一个数字孪生与真实世界协同的后训练框架，将数字孪生同时用作探索放大器和探索引导器。
- 我们提出一种探索空间扩展策略，在数字孪生中生成多样化轨迹，以拓宽探索覆盖范围；同时，我们还给出了一套高保真数字孪生构建的高效流程。
- 我们提出双生强化学习预热策略，将孪生体交互与真实世界 RL 相结合：一方面，孪生 rollout 提供 RL 风格的经验，以稳定早期学习；另一方面，易失败配置可用于引导真实机器人上的定向 HiL 探索。

4 II. 相关工作

Vision-Language-Action (VLA) 模型 [23, 4, 28, 43, 32, 58, 6, 57, 35] 将高层语言指令 grounding 到 visuomotor control 中，使机器人能够在动态环境下完成任务。近期工作通常将 VLM 表征与专门设计的 action expert 相结合，例如基于 diffusion 的 head [34, 57, 28, 3, 67, 19, 13]，通过迭代去噪生成动作；或采用基于 flow 的建模形式 [4, 18, 49]。

尽管 VLA policy 通常通过监督微调（SFT）进行训练，但其对静态 demonstration 的依赖，使其难以在已观测状态之外进行有效探索。

4.1 用于 VLA 模型的强化学习

强化学习（RL）policy 可以在部署后继续通过在线交互和来自环境的反馈提升鲁棒性 [51]。现有面向 VLA 的 RL post-training 方法主要遵循两类范式。离线方法 [69, 68] 基于固定轨迹或偏好数据优化 policy，以增强对齐性与鲁棒性。另一类是在线方法 [37, 51, 9, 14, 8]，它们利用交互式模拟器 rollout 和迭代更新来提升任务性能与稳定性。近期研究开始将真实世界 RL 引入物理机器人，直接通过机器人本体交互训练 policy；这类方法通常结合 human-in-the-loop 反馈与安全感知的数据采集，以提高样本效率 [40, 8, 38, 41, 26, 39]。然而，这些方法通常需要大量真实世界交互和较长训练周期，代价高、吞吐低，并且还受到安全风险的进一步限制。不同于以往方法，本文系统分析了 SFT 轨迹分布如何约束真实世界 RL 中的有效探索，并利用高保真 digital twin 扩展探索空间，在联合仿真与真实世界 post-training 过程中提升效率。

4.2 基于 digital twin 的 sim-to-real 数据扩展

为了在缓解 sim-to-real gap 的同时，从有限的真实 demonstration 中生成更多训练数据，许多工作 [63, 36, 62, 60, 61] 采用了基于 digital twin 的 Real-to-Sim-to-Real 范式。DexMimicGen [21] 通过在仿真中组织资产，支持基于 demonstration 的 policy 学习。RoboVerse [12] 提供了更大规模的模拟交互，以促进 manipulation。RialTo [55] 和 CASHIER [54] 将真实观测与交互式仿真组件结合起来。RoboGSim [29] 将 3D Gaussian Splatting 与物理引擎结合，实现了可扩展的数据生成和强 sim-to-real 迁移。Real2Render2Real [65] 利用手机扫描和一段人类视频，通过 3D Gaussian Splatting 渲染机器人的训练 demonstration。进一步地，GSWorld [20] 将 3D Gaussian Splatting 与物理过程结合，实现了 closed-loop、逼真的仿真环境，可用于可复现实验评测和 sim-to-real policy 学习。

除在 SFT 阶段使用 digital twin 之外，SGFT [64] 在仿真中学习 value function，并利用其重塑奖励，从而引导高效的真实世界微调 (fine-tuning)。SLAC [16] 在仿真中学习及与任务无关的潜在动作空间，并将其用于下游真实世界 RL，以提升安全性。SimLauncher [59] 使用经过 digital twin 预训练的 policy 来 warm-start critic 学习，同时结合模拟与真实世界 demonstration，并在 RL 过程中提供动作 proposal。不同于现有工作，本文并不将 digital twin 仅仅视为数据增强工具，而是将其作为探索放大器与引导机制，用于提升真实世界 RL 的效率。

5 III. METHOD

5.1 A. 预备知识

Vision-Language-Action (VLA) policy 的动作生成。 VLA policy π_θ 在每个时间步 t 将语言指令 ℓ 与多视角图像 [formula] 映射为一个 7-DoF 的 end-effector 动作：[formula]。动作 $a_t = (\Delta p_t, \Delta r_t, g_t)$ 定义了 end-effector 的相对运动，其中包含 3 维平移增量 $\Delta p_t \in \mathbb{R}^3$ 、3 维旋转变化 $\Delta r_t \in \mathbb{R}^3$ ，以及二值 gripper 状态 $g_t \in \{0, 1\}$ 。我们将一条 rollout 轨迹记为 $\tau = \{(I_t, \ell, a_t)\}_{t=1}^T$ ，其终止条件为任务成功或达到时间上限。

强化学习 policy。 按照以往工作 [8, 40]，强化学习 (RL) 可视为一种交互式 post-training 范式：它利用环境反馈优化细粒度操纵能力，并通过探索扩展状态覆盖范围。机器人 RL 可形式化为一个 Markov decision process (MDP) $\mathcal{M} = \{\mathcal{S}, \mathcal{A}, \rho, \mathcal{P}, r, \gamma\}$ ，其中 $s \in \mathcal{S}$ 表示状态观测， $a \in \mathcal{A}$ 表示动作， $\rho(s_0)$ 是初始状态分布， $\mathcal{P}$ 是未知且可能具有随机性的转移动力学， $r : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ 是奖励函数， $\gamma \in (0, 1]$ 是折扣因子。在该设定下，为评估 policy π 的性能，我们将状态价值函数定义为

$$V^\pi(s) = \mathbb{E}_\pi \left[\sum_{t=0}^H \gamma^t r(s_t, a_t) \mid s_0 = s \right], \quad (1)$$

动作价值函数定义为

$$Q^\pi(s, a) = \mathbb{E}_\pi \left[\sum_{t=0}^H \gamma^t r(s_t, a_t) \mid s_0 = s, a_0 = a \right], \quad (2)$$

二者满足 $V^\pi(s) = \mathbb{E}_{a \sim \pi(\cdot|s)}[Q^\pi(s, a)]$ 。我们将最优 policy π^* 定义为：在由 $(\rho, \mathcal{P}, \pi)$ 诱导的轨迹分布上，使期望回报最大的 policy，即

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^H \gamma^t r(s_t, a_t) \right]. \quad (3)$$

$\pi_{\theta}(a|s)$ 由神经网络参数化；在连续控制场景中，它可以建模为高斯分布。

5.2 B. 动机

尽管在线 RL 为提升任务鲁棒性提供了一条可行路径，但其在真实硬件上的样本效率仍然是一个关键挑战。通过系统性的真实世界实验，我们发现，真实世界 VLA RL 能够有效探索的轨迹空间，受到 SFT 阶段所诱导空间支撑的严格限制。这种限制带来了两个瓶颈：（1）它限制了能够被可靠探索的状态集合；（2）即使引入人工干预，也会显著降低在线 RL 的效率。这些动机实验揭示了一个关键认识：要提高 RL 的探索效率，根本上需要扩展其底层轨迹分布。

实验设置. 如图 2(a) 所示，我们在一个高精度积木插入任务上开展全部实验，该任务要求较高的位置精度。所有 policy 均基于 Octo [52] 模型实例化。我们将工作空间划分为两个区域：分布内的区域 A，其被 demonstration 覆盖；以及分布外（OOD）的区域 B，该区域在 SFT 期间未被观测到。



图 3: 探索瓶颈。 (a) 我们将工作空间划分为分布内区域 A 和 OOD 区域 B。每个区域由任务完成时被操纵物体中心的位置定义。(b) 热力图展示了不同 policy 的性能。(c) 学习曲线给出了仅使用 A 区域数据训练的 policy 在两个区域中的在线 RL 训练动态。




图 4: 探索瓶颈实验的可视化结果。

瓶颈 I. 为隔离 SFT demonstration 的空间覆盖范围对 policy 泛化能力与自主在线 RL 的影响，我们改变了 SFT demonstration 的空间覆盖。具体而言，我们比较两种训练数据分布：(i) 仅 A 区域 (A-only)，即来自区域 A 的 30 条 demonstration；(ii) A+B，在前者基础上额外加入来自区域 B 的 30 条 digital-twin demonstration。我们首先评估由此得到的 SFT policy 的空间泛化能力。随后，为了衡量 demonstration 覆盖如何塑造有效探索空间，我们以 A-only 的 SFT 模型为初始化，在未见过的区域 B 中运行自主在线 RL。

发现 I. 如图 2(b) 所示，我们在每个网格单元内执行 10 次 rollout。在区域 B 中，A+B policy 的成功率 (success rate) 达到 62.5%，而 A-only policy 仍被限制在区域 A 内（在区域 B 中为 0%）。这一结果表明，标准 SFT policy 对于空间上未被覆盖区域的外推能力有限。更重要的是，从 A-only 模型出发在区域 B 中尝试自主在线 RL，会导致明显的探索死锁。当初始化于 OOD 配置时，该 policy 即使经过 40K 个训练步（约两小时），仍无法稳定获得正奖励。这些结果表明，与通用领域工作 [66] 的结论一致，在线 RL 的有效探索空间与 SFT 数据的空间覆盖范围密切相关。

瓶颈 II. 为缓解上述探索死锁，可以引入 Human-in-the-Loop (HiL) 干预，引导机器人成功完成任务 [40]。然而，一个重要问题仍然存在：在 OOD 场景下，人工引导的存在是否能够保证高效的在线适应？为回答这一问题，我们比较了两种设置：分布内后训练 (In-distribution Post-training)，即在熟悉的区域 A 中执行在线 RL；以及 OOD 后训练 (OOD Post-training)，即在陌生的区域 B 中执行在线 RL。所有模型都由同一个 A-only 的 SFT policy 初始化。

发现 II. 尽管在两种设置下，人工干预都能提供成功的纠正性 demonstration，但我们仍观察到显著的样本效率差异。如图 2(c) 所示，分布内后训练适应速度很快，在约 45 分钟（约 14k 交互步）内即可达到超过 90% 的成功率。相比之下，OOD 后训练在相同交互预算下收敛明显更慢，且表现出更强的不稳定性，未能达到可比性能。这些结果说明，即便引入 HiL 机制，在先前未见的区域 B 中学习仍然十分困难，其原因在于不利的奖励景观以及数据缓冲区中失衡的数据分布，这两者都会显著降低梯度效率。

5.3 B. 动机（第 2 部分）

结论。 上述观察表明，要同时突破这两个瓶颈，关键在于：在真实世界交互之前扩展探索覆盖范围，并引导人工干预以系统性提升在线效率，而不是依赖随机的 HiL。基于这一动机，我们提出 TwinRL——一个数字孪生与真实世界协同的 RL 框架。该框架将数字孪生同时作为探索放大器和在线 RL 的引导器。附录 A 进一步给出了该方法在其他任务上的动机实验。

5.4 C. 探索空间扩展策略

数字孪生构建。 我们构建了目标操纵环境的高保真数字孪生，作为 TwinRL 中探索空间扩展与虚拟 RL rollout 的核心载体。该数字孪生可由日常用智能手机拍摄的视频快速实例化：场景部分通过 3DGS 工具 [24] 重建（约 10 分钟），可操纵物体通过 SAM3D [7] 重建（约 5 秒），机器人则由其 URDF 模型导入。随后，我们将所有组件统一为基于 mesh 的资产，以便进行运动学装配，并集成到 Blender 或仿真环境 [53] 中。

为了实现双向知识迁移，我们在视觉层面和机器人状态层面同时对齐数字孪生与真实环境。对齐过程以 URDF 定义的机器人坐标系为锚点：首先通过点云配准（例如 ICP [2]）获得粗对齐，再结合可微 3DGS 渲染 [62]，通过对齐渲染观测与真实观测进一步精细校准，从而得到一致的坐标系。为加速重建，我们在数字孪生中采用了具备碰撞感知的运动学交互模型，优先保证与任务相关的视觉-几何一致性 [65]。被操纵物体被建模为运动学实体，物体-机器人交互通过逐帧姿态设定来定义，同时配合简化的代理碰撞几何体与工作空间约束。

为了在该模型下生成轨迹，我们采用以物体为中心的表征方式，通过 Any-Grasp [11] 估计被操纵物体的 6-DoF 抓取姿态，以此定义物体与 end-effector 之间的关系。在仅有一条成功物体轨迹的前提下，我们随后可通过逆运动学、运动规划或仿射变换生成多样化的执行轨迹。经验上，这一设计能够为探索空间扩展提供有效数据，并为真实世界 RL 提供可靠指导。更多细节见附录 C，其中包括定性可视化对比，以及人工工作量和运行时开销的总结。




图 5: TwinRL。阶段 I: 从人类 teleoperation 出发, 引入探索空间扩展策略, 合成多样化的数字孪生 demonstration, 以扩展 SFT 的覆盖范围。阶段 II: 随后, 在数字孪生中对经 SFT 初始化的 policy 进行可扩展、并行的在线 RL 训练, 以获取 RL 风格的 rollout; 这些数据被迁移用于初始化真实世界 replay buffer, 并稳定在线学习。阶段 III: 在真实世界在线 RL 期间, 数字孪生能够高效、持续地识别易失败但信息量高的物体构型, 并据此引导有针对性的 HiL rollout。

探索放大器。在预热阶段, 我们将数字孪生视为一种探索放大器, 通过提升轨迹多样性来扩展后续在线 RL 的有效探索空间。如图 3 的阶段 I 所示, 我们通过改变物体初始构型、目标姿态和运动路径, 生成以物体为中心的多样化合成轨迹, 使其覆盖范围超出真实 demonstration。给定物体初始位姿 $T_0 \in \text{SE}(3)$ 和目标位姿 $T_{\text{target}} \in \text{SE}(3)$, 二者均通过对位置与朝向进行随机扰动采样得到; 随后估计与任务一致的抓取姿态 T_{grasp} , 并据此得到轨迹边界处的 end-effector 位姿:

$$T_{\text{start}}^{\text{ee}} = T_0 \cdot T_{\text{grasp}}, \quad T_{\text{end}}^{\text{ee}} = T_{\text{target}} \cdot T_{\text{grasp}}. \quad (4)$$

中间轨迹则通过运动规划生成, 或对单条 demonstration 轨迹施加仿射变换得到, 从而保证轨迹质量。需要注意的是, 对于一个包含 30 个时间步的任务, 在并行处理条件下, 我们仅需约 1 分钟即可构建出一组数字孪生 demonstration。为了让 policy 吸收这些扩增行为, 我们在合并后的 buffer $\mathcal{D}$ 上执行一个 SFT 阶段, 并通过最小化模仿学习损失进行训练:

$$\mathcal{L}_{\pi}^{\text{IL}} = -\mathbb{E}(s, a) \sim \mathcal{D}[\log \pi_{\psi}(a|s)]. \quad (5)$$

5.5 C. 探索空间扩展策略 (第 2 部分)

我们使用数字孪生 (digital twin) 不仅是为了缓解在 OOD 区域中的探索死锁问题, 也用于采集额外的分布内数据 (in-distribution data), 从而缩小 sim-to-real gap。

5.6 D. 数字孪生 RL 预热

尽管阶段 I 扩展了 SFT 数据的空间覆盖范围, 但在真实机器人上直接启动在线 RL 仍然并不容易, 因为仅靠空间覆盖率并不能解决一个关键瓶颈: $\mathcal{D}_{\text{sft}}$ 与 RL 交互数据之间的轨迹风格不匹配。 $\mathcal{D}_{\text{sft}}$ 由被动的、目标导向的 demonstration 构成, 而在线 RL 为了实现可靠的价值估计, 需要具有交互性、包含试错过程的轨迹。因此, 在真实世界 RL 刚开始时, replay buffer 往往被被动的 expert 风

格数据主导，进而导致价值估计不稳定，并削弱早期阶段的探索能力。为解决这一不匹配问题，我们引入数字孪生中的 RL 预热阶段：在数字孪生环境中并行执行 RL rollout，生成更符合 RL 风格的交互数据，从而为 replay buffer 提供更好的初始化，并稳定后续的真机学习过程。

孪生在线 RL 阶段。 如图 3 的阶段 II 所示，我们在数字孪生中执行并行在线 RL。在该阶段中，policy π_ψ 由 SFT 模型初始化，并通过与 N 个并行孪生环境交互进行训练。为了在基于孪生环境的在线交互过程中稳定 policy 更新，我们采用了一个联合目标，将 RL 与基于模仿的正则项结合起来。其目标函数定义为：




图 6: 真实世界实验设置。我们考虑了四个任务：Pick-and-Place、Insert-Hexagon-Block、Insert-Triple Column-Block 和 Erase-Whiteboard，涵盖多步、精细以及接触丰富的操纵场景。红色和蓝色区域分别表示分布内 (ID) 与分布外 (OOD) 的评测区域。

$$\mathcal{L}_\pi^{twin}(\psi) = \beta \mathcal{L}_\pi^{IL} + \eta \mathcal{L}_\pi^{RL}, \quad (6)$$

其中， $\mathcal{L}_\pi^{IL}$ 与 SFT 中使用的损失相同； $\mathcal{L}_\pi^{RL}$ 是 RL 目标，定义为 [formula]，该目标鼓励 policy 选择 critic 估计 Q 值更高的动作 [15]。价值函数 Q_θ 通过标准的 temporal-difference learning 进行更新。

通过这一过程，孪生在线 RL 阶段能够高效收集多样化轨迹 τ_{twin} ，其中既包括成功执行，也包括失败和恢复行为；这些轨迹被存储到孪生 replay buffer $\mathcal{D}_{twin}$ 中。需要指出的是，并行处理使我们能够在大约 1 分钟内生成一批 rollout（例如，每个 episode 为 30 步）。由于 demonstration 数据与 RL 风格交互数据之间存在分布差异，早期在线学习可能表现出不稳定性。因此，在数字孪生中完成高效在线学习后，我们将来自孪生 buffer 的数据迁移到真实世界 replay buffer 中进行初始化，即 $\mathcal{D}_{real}^{init} \leftarrow \mathcal{D}_{twin}$ 。这种孪生 RL 预热机制会将 replay buffer 调整到一种与 RL 风格更兼容的初始化状态，从而提供更均衡的训练信号，降低从离线 SFT 过渡到真实世界在线 RL 过程中的不稳定性，并缓解性能退化。此外，这一策略还有助于在后续面向目标的 HiL 引导在线 RL 中，避免对那些已经表现较强的配置产生灾难性遗忘。

5.7 E. Sim-to-Real 引导的真实世界 RL

尽管 twin RL 能提供较强的初始化，但对于精确操纵与接触丰富任务而言，真实世界中的物理交互仍然至关重要。因此，我们利用 twin RL 的 rollout 来引导真实世界在线 RL，从而实现更有针对性的探索，并更高效地利用物理交互。如图 3 的 Stage III 所示，我们借助 digital twin 识别状态空间中易失败的区域，并据此引导真实世界在线 RL 的初始状态分布。不同于以往依赖真实世界 rollout 的 curriculum 或基于 reset 的策略 [40]，digital twin 能够在不消耗物理交互预算的前提下，以低成本、系统化的方式评估当前 policy 在大范围初始配置上的表现。具体而言，我们首先在 digital twin

中评估当前 policy, 并构建一个目标初始配置集合

$$S_{\text{target}} = \{s_0 \mid SR(s_0) < \tau\},$$

其中, $SR(s_0)$ 表示从状态 s_0 出发的经验成功率 (success rate), τ 为熟练度阈值。在真实世界在线交互过程中, episode 的 reset 会优先从 S_{target} 中采样, 从而使学习过程能够将有限的物理交互预算集中在更具挑战性的状态上。

为进一步降低在困难区域中探索的成本与风险, 我们在真实机器人训练阶段引入了 HiL 机制 [40]。由此得到的 intervention trajectory 会被存入 replay buffer, 并用于后续的 policy 更新。不同于现有基于 HiL 的方法, 我们提出了一种新的 twin guidance 机制: 在真实世界 RL 过程中, digital twin 持续指示应在何处施加 HiL intervention, 从而显著提升样本效率并加快收敛速度。

6 IV. 实验与结果

我们首先在第 IV-A 节介绍实验设置, 随后在第 IV-B 节将 TwinRL 与各类 baseline 进行充分的真实世界对比。接着, 我们在第 IV-C 节对 TwinRL 的各个组成部分开展消融实验, 并在第 IV-D 节进一步评估其在不同背景与光照条件下的鲁棒性。

6.1 A. 实验设置

硬件平台。 在真实世界操纵实验中, 我们在一台 7-DoF 的 Franka Emika Research 3 (FR3) 机器人上开展了系统性实验。整体系统采用双相机感知配置: 一个固定的第三人称视角相机用于提供全局上下文, 另一个安装在腕部的相机用于捕捉细粒度细节。关于实验装置的更多细节见附录 B。

实验协议。 如图 4 所示, 我们将每个任务的工作空间离散为网格, 并根据任务完成时被操纵物体的中心位置, 将每个 episode 分配到对应的网格单元中。图中红色区域表示: (1) 由采集到的真实世界 demonstration 覆盖的分布内 (in-distribution, ID) 区域; 蓝色区域表示: (2) 未被真实世界数据覆盖的分布外 (out-of-distribution, OOD) 区域。不同于以往主要将数字孪生用于数据增强的工作, 我们的目标是表明: 在真实世界数据未覆盖的区域中, 数字孪生可以作为真实世界 online RL 的高效放大器与引导器。对于时间统计, 我们将收敛时间定义为真实世界 online RL (Stage III) 的总墙钟时间 (wall-clock time): 从第一次真实机器人 rollout 开始计时, 直到 policy 在无人干预的情况下连续 10 个 episode 成功为止。




图 7: 真实世界实验。我们在四个操纵任务上, 同时报告了 ID 与 OOD 设置下 online RL 的成功率 (success rate) 曲线。纵轴为成功率, 横轴同时给出了 online 训练时间以及模型训练步数。

6.2 B. 真实世界实验

实现细节与 baseline. 我们在所有 baseline 中统一采用 Octo-Small [?] 作为共享的 VLA backbone, 并将每个任务定义为一条固定的语言指令。为保证比较公平, 我们严格控制所有方法在真实世界 demonstration 数据上的使用量。HiL-SERL [?] 将 policy 直接部署到真实机器人上, 执行 Human-in-the-Loop (HiL) 在线 RL 训练。ConRFT [?] 作为一个强 baseline, 使用来自 ID 区域的 30 条真实世界 demonstration; 其训练流程首先进行第一阶段的 Cal-ConRFT [?], 随后在真实世界中执行 HiL 在线 RL 微调 (fine-tuning)。所有损失监督均遵循对应论文的官方实现。

我们的方法使用相同的 30 条真实世界 demonstration, 并进一步将数字孪生用作探索放大器: 在 ID 区域额外加入 60 条合成轨迹, 在覆盖 OOD 区域的范围内再加入 30 条合成轨迹。我们报告两个变体: TwinRL w/o buffer 和 TwinRL。二者的区别在于: 是否使用通过数字孪生中并行在线 RL 收集得到的 twin replay buffer, 在真实世界在线 RL 开始之前对训练进行初始化。在真实世界 RL 过程中, 我们每 2k steps 对各个区域评估一次, 每次至少执行 10 个随机 rollouts。

指标与结果. 我们将成功率 (success rate, SR) 分别表示为真实世界训练时间与训练步数的函数, 用于比较各方法在 ID 与 OOD 区域中的收敛速度和最终性能。图 5 总结了四个任务上的在线训练曲线。

初始化 (0-step). 在真实世界在线 RL 刚开始时 (即尚未发生任何真实交互之前), TwinRL 的 SR 就显著高于其他方法。这一增益来自 SFT 阶段对探索空间的扩展: 数字孪生轨迹拓宽了预训练分布的支持范围, 从而带来更强的部署先验。

在 ID 区域中, TwinRL 与各 baseline 的关键差异在于是否具备 sim-to-real 引导的探索能力。大多数 TwinRL 变体的 SR 都超过了 90%, 且收敛速度明显快于 baseline, 这表明我们的数字孪生在线 rollout 策略能够为真实世界 RL 提供有效引导。TwinRL 通过在孪生环境中高效识别信息量更高的目标物体构型, 使 HiL 交互聚焦于高价值状态, 从而在保持较高执行精度的同时加速收敛。

在 OOD 区域中, 这一差距更加明显。TwinRL 用更少的真实世界交互就能达到较高 SR, 而在相同交互预算下, ConRFT 和 HiL-SERL 收敛更慢, 或者无法达到可比的性能。这说明 TwinRL 能

够有效地将探索扩展到真实 demonstration 的空间支持范围之外，并实现对先前未见构型的快速自适应。

稳定性. 所有方法在从离线 SFT 过渡到在线学习时都表现出明显的 SR 下降，这表明从 SFT 数据到 RL 风格数据的分布迁移会带来不稳定性。TwinRL 将这一性能落差降到最低，并且恢复速度明显更快，最终达到 100% SR。该稳定性提升与将数字孪生中的 RL rollouts 迁移到真实 replay buffer 以进行初始化是一致的；这种做法弥合了离线到在线的过渡，并缓解了训练早期的性能崩塌。

最后，我们在 RL 训练完成后，对全部四个任务进行了五轮评估；每一轮在 ID 和 OOD 区域各执行 10 次 rollout。TwinRL 的平均 SR 达到 95%，标准差为 6.71。失败案例分析见附录 E。更多指标（episode length 和 intervention rate）以及可视化结果见附录 D1、D2 和 D6。演示视频可在项目主页获取。

表 1: 探索空间扩展的消融实验。我们在 SFT warm-up 阶段改变加入的数字孪生生成轨迹数量，并测量所得成功率（SR）。

数据量		In-Distribution	Out-of-Distribution	Avg.
In	Out	SR ($\uparrow$ Δ)	SR ($\uparrow$ Δ)	SR ($\uparrow$ Δ)
0	0	40%	0%	27%
30	30	70% (+30%)	30% (+30%)	57% (+30%)
60	30	80% (+40%)	40% (+40%)	67% (+40%)
30	60	70% (+30%)	70% (+70%)	70% (+43%)

6.3 B. 真实世界实验（第二部分）

表 2: Twin buffer 的消融实验。我们报告成功率（success rate, SR）以及 RL 训练步数。S 和 F 分别表示用于填充 replay buffer 的成功与失败 twin RL 轨迹。

消融项	设置	在线步数	成功率
Twin Buffer	0 S / 0 F	5.0k	90%
Twin Buffer	20 S / 0 F	3.5k	100%
Twin Buffer	30 S / 0 F	4.0k	90%
Twin Buffer	20 S / 20 F	4.5k	90%
Twin Buffer	20 S / 40 F	7.0k	70%

6.4 C. 消融实验

我们选择 Insert-Hexagon-Block 任务开展消融实验。如图 4 所示，评测设置与主体实验保持一致。

6.4.1 探索空间扩展的影响

我们分析 twin data 的规模与分布如何影响 warm-up 阶段的性能。表 I 报告了在不同 ID/OOD synthetic-trajectory augmentation 设置下的成功率 (success rate)。与 base model 相比，在包含 30 条 ID 与 30 条 OOD twin trajectory 的均衡设置下，成功率达到 57.0% (+30%)。这表明，即便对于这类对精度要求很高的任务，我们的 digital-twin pipeline 依然能够在整个工作空间内生成高质量轨迹。

进一步增加 twin data 的数量还能继续提升性能：当 ID 数据翻倍 (60/30) 时，增益最大，ID 区域的成功率峰值达到 80%；而增加 OOD 数据 (30/60) 时，成功率提升至 70%。总体而言，这些结果不仅验证了 digital twin 所生成数据的质量，也说明我们提出的探索空间扩展策略能够有效提升空间覆盖范围。更多 synthetic data 还可能带来进一步收益，但同时也会增加 SFT 时间，因此存在精度与效率之间的权衡。




图 8: Sim-to-Real-Guided HiL 的消融实验。该引导机制显著加速了 RL 学习，在约 4k steps（约 14 分钟）时达到 100% 成功率。

6.4.2 Twin RL Replay Buffer 的影响

如图 5 所示，我们已经证明了 twin RL replay buffer 对稳定早期学习的重要作用。这里，我们进一步研究 replay buffer 的组成如何影响 online RL 的效率与稳定性。具体而言，我们改变存入 buffer 的成功 twin rollout 与失败 twin rollout 的比例，范围从仅包含成功样本的 buffer，到逐步加入更多失败样本的设置。

表 II 显示，大多数设置最终都能在 ID 和 OOD 区域达到超过 90% 的成功率。这说明，用成功轨迹初始化 twin buffer 能够显著加速 online RL 训练。然而，与我们的预期相反，加入更多失败 rollout 反而降低了 online RL 的效率。我们认为，原因在于 digital twin 中采样得到的失败轨迹，往往反映的是随机失败模式，而不是在真实 HiL 交互过程中出现的、与任务相关且有实际指导意义的失败情形，因此无法有效帮助 policy 学会规避失败状态。未来工作中，我们将在 online RL 之前探索更系统的方法，以纳入更具信息量的失败样本。

6.4.3 Sim-to-Real-Guided HiL 的效率

最后，我们评估 digital-twin-guided HiL 在真实世界 online RL 中的作用。如图 6 所示，我们比较了带有和不带有所提出引导机制的 TwinRL。该机制利用 digital-twin rollout 识别信息量更高的初始物体配置，并在必要时触发 HiL 干预。

结果表明，twin-guided intervention 显著减少了真实世界训练步数，并提升了收敛速度和成功率。即使初始化条件与 replay buffer 完全相同，缺少该引导时，适应过程仍然更慢，sample efficiency 也更低。这些发现说明，在 TwinRL 中，digital twin 不仅能在部署前扩展探索支持范围，还能够在

online learning 过程中主动将学习引导至状态空间中更具信息量的区域。

更多消融实验见附录 D3 与 D4，其中包括 twin data 分布如何影响 SFT 性能，以及 digital twin 上的评估是否与真实世界性能保持一致的分析。



图 9: 消融实验相关图示。

6.5 C. 消融实验（第二部分）




图 10: 鲁棒性。我们比较了 SFT policy 与 TwinRL 引导的在线 RL policy 在未见过的环境扰动下的表现；上排给出了若干示例。

6.6 D. 鲁棒性分析

我们在零样本鲁棒性评测中，将 SFT policy 与 TwinRL 引导的在线 RL policy 进行比较。评测中引入了此前未见过的环境扰动，包括背景杂乱和光照变化。如图 7 所示，我们考虑了三种测试条件：**Background**（加入与任务无关的物体以制造背景杂乱）、**Darker lighting**（均匀的照明变化）以及 **Dynamic lighting**（带有移动光照模式的动态彩色光照）。所有扰动均施加在六边形积木插入任务上。

结果表明，尽管观测分布发生了偏移，TwinRL 的性能仅出现轻微下降，而仅采用 SFT 的模型则表现出明显更大的性能退化。该结果凸显了真实世界 RL（Stage III）的重要性：它能够推动 policy 在物理环境中形成更稳定的控制行为，以及对噪声更具容忍性的决策边界。结果同时表明，TwinRL

系统是有效的；它通过 twin-guided HiL 将真实世界交互聚焦到高信息量构型上，从而进一步提升了鲁棒性。关于 Pick-and-Place 任务的更多鲁棒性结果见附录 D5。

7 V. 结论与局限性

本文指出了真实世界 VLA 强化学习中的一个关键瓶颈：有效探索空间在很大程度上受 SFT 阶段诱导的轨迹分布所塑造，因此，对于 SFT 数据未覆盖区域，即使引入 HiL，也依然难以实现有效适应。为应对这一挑战，我们提出 TwinRL。这是一个数字孪生与真实世界协同的框架。该方法并不只是将数字孪生用作模拟器，而是进一步将其作为探索放大器与引导器，以加速真实世界中的在线强化学习。

TwinRL 包含两项核心设计：其一，探索空间扩展策略。该策略在数字孪生中合成多样化轨迹，从而扩展 SFT 的覆盖范围；其二，孪生 RL warm-up 策略。该策略利用并行的数字孪生 rollout 初始化真实世界的 replay buffer，并识别出信息量高且容易失败的配置，以便进行有针对性的 HiL 干预。

在四项真实世界 manipulation 任务上的实验表明，TwinRL 能够显著提升样本效率与鲁棒性。总体来看，TwinRL 为在线 RL 在物理机器人上的部署提供了一条实用且新颖的路径。尽管该方法缓解了从离线到在线的迁移鸿沟，但在训练早期仍可能存在轻微的性能差距。未来工作将进一步利用数字孪生 RL 中具有高信息量的轨迹，以提升训练稳定性。

8 参考文献

参考文献条目较多，此处保留原论文英文文献列表，请参阅原文 PDF 的 References 一节。

[附录因公式排版问题从译本中省略，请参阅原文。]