

1 BORA：连接离线强化学习与在线残差自适应的真实世界灵巧 VLA 模型

摘要

Vision-Language-Action (VLA) 模型已成为一种很有前景的范式，能够将视觉-语言理解落地到真实世界机器人操纵中。然而，由于灵巧手控制具有高维特性，且执行误差会不断累积，灵巧操纵对 VLA policy 而言仍然极具挑战。因此，要弥合“视觉驱动的动作生成”与“物理上可靠的灵巧执行”之间的差距，面向真实世界的强化学习 (RL) 后训练至关重要。然而，在真实世界中进行高维灵巧探索，往往会带来时序不一致、样本效率低以及硬件风险等问题。

为应对这些挑战，我们提出 BORA，一个面向真实世界灵巧 VLA 模型的离线到在线 RL 后训练框架。在离线阶段，BORA 构建了一个 critic，其输入同时包含 VLM 的 cognition tokens 和 action chunks。这一设计提供了以动作为条件的价值引导 (action-conditioned value guidance)，使 critic 能够超越单纯视觉上下文，对灵巧手运动进行评估。在随后的在线阶段，BORA 冻结 VLA base，并引入一种轻量级、Human-in-the-Loop (HiL) 的 chunk-wise 残差自适应机制，以缓解真实世界中的执行误差，并在实际物理环境中进一步修正离线学习得到的意图。通过继承离线 critic 并结合由干预驱动奖励，BORA 在保留预训练 policy 作为稳定先验的同时，能够有效校正执行偏差，并适应真实世界中的物理变化。

在五项复杂真实世界灵巧任务上的大量评测表明，BORA 显著优于纯模仿学习方法以及传统的解耦式 RL baseline：在标准设置下，平均成功率 (success rate) 绝对提升 33%；在未见物体泛化场景中，性能提升最高可达 43%。项目主页见 <https://chenzhongxi-sjtu.github.io/BORA/>。

关键词：灵巧操纵，后训练，VLA 模型

2 1 Introduction

尽管 Vision-Language-Action (VLA) 模型已经成为实现可泛化机器人控制的一类强大范式，但在真实世界灵巧操纵中，它们仍面临严峻挑战，原因在于这类任务通常涉及极高的自由度 (DoFs)。此外，灵巧任务天然具有动作多样性：同一任务往往可以通过多种不同的手部姿态与构型成功完成。在这种噪声很强且具有多模态特性的连续动作空间中，模仿学习 (Imitation Learning, IL) 难以提炼出可泛化的物理交互意图。因此，要进一步突破真实世界灵巧控制的能力边界，亟需一种高效的强化学习 (Reinforcement Learning, RL) 后训练框架：一方面从离线数据中蒸馏意图理解能力，另一方面结合在线微调 (fine-tuning) 进行修正。



图 1: BORA: 面向真实世界灵巧 VLA 模型的离线强化学习与在线残差自适应桥接框架。本文提出一种从离线到在线的 RL 后训练框架, 用于灵巧 VLA, 将语义意图与物理动力学联系起来, 从而显著提升真实部署的可靠性与任务成功率 (success rate)。

然而, 现有 VLA 后训练方案 [1, 2] 在应用于灵巧操纵时会遇到两个根本性问题。第一个问题是动作生成中的 credit assignment 失效。主流生成式动作架构 (如 Diffusion Models 或 Flow Matching) 通常依赖跨越数十步甚至上百步的去噪链。考虑到离线灵巧数据往往包含冗余或非意图性的微动作 [3], 同时动作本身又具有很强的多样性, 因此由此得到的 RL 梯度天然带有显著噪声。当这些梯度需要通过跨越上千步的时序计算图进行反向传播时, 噪声会严重累积, 使模型难以有效提取能够指导底层动作流形的高层意图 [4]。第二个问题出现在感知层面, 即视觉遮挡。灵巧操纵过程中常常伴随严重遮挡; 在真实机器人 RL 训练中, 传统的解耦 critic 容易过拟合背景中的视觉伪迹。这样一来, 它们评估的并非动作带来的真实物理接触后果, 而是向灵巧 VLA 模型提供了错误的指导。

除了上述离线训练阶段的困难之外, 真实世界部署还不可避免地会引入由复杂摩擦与接触动力学导致的执行误差, 从而使系统状态偏离离线数据分布, 并造成动作结果与离线经验不匹配。因此, 离线学得的意图必须持续自适应, 才能在这类分布偏移下继续保持有效。尽管在线微调能够通过强化意图指导来缓解这些问题, 但直接更新 VLA 模型的全部参数并不现实。其主要原因在于, 脆弱的灵巧硬件限制了大规模数据采集, 而在线干预得到的数据往往噪声较大, 同时混杂了最优与次优轨迹。在传统的离线到在线 RL 设定下 [5], 训练早期的分布偏移和噪声梯度很容易在预训练 VLM 中引发灾难性特征漂移 [6]。因此, 我们需要一种新的框架: 既能够在全参数更新过程中避免灾难性遗忘, 又能在在线估计时将 Q-network 约束在离线流形附近, 同时保留足够的探索能力。

3 Introduction (第 2 部分)

为应对上述挑战, 我们提出 BORA (Bridging Offline RL and Online Residual Adaptation), 这是一个专为灵巧操作 VLA 设计的 RL 后训练与自适应框架, 覆盖从 offline 到 online 的完整过程。在 offline 阶段, BORA 采用 Consistency Policy [7, 8] 作为 action expert, 仅需 1-3 步即可生成连续的 action chunk, 并通过截断计算图实现高效的梯度反向传播。与此同时, 为减轻视觉遮挡带来的影响, 并避免 critic 过拟合背景伪特征, 我们设计了一种 critic 结构, 将连续 action chunk 与 VLM 的 cognition token 显式融合。这样, value estimation 便能够从根本上锚定于真实物理交互, 而非偶然相关的视觉特征。

在随后的 online 阶段, BORA 冻结 offline 阶段训练得到的 VLA base, 以避免灾难性特征漂移; 同时引入一种轻量级、Human-in-the-Loop (HiL) 的 chunk-wise residual 自适应机制。该机制直接继承 offline critic, 以保证 value estimation 的稳定性, 并利用这一稳定信号引导 residual actor 从

人类干预数据中安全提取纠正性先验，从而稳健补偿真实世界中的执行偏差与意图不匹配问题。总的来说，我们的主要贡献体现在以下三个方面：

- **面向灵巧操作的 Action-Conditioned Critic**：我们设计了一种 critic 架构，将连续 action chunk 与 VLM 的 cognition token 进行融合。该设计能够提供精确的、action-conditioned 的 value guidance，其评估依据是真实物理执行后果，而不仅仅是视觉上下文。
- **轻量级残差式 Online 自适应**：我们面向真实世界部署阶段提出了一种 HiL 的 chunk-wise residual RL 机制。通过冻结 VLA base、继承 offline critic，并利用由干预驱动的 reward，我们实现了安全且高样本效率的 online 自适应。该设计既能有效纠正执行错误，又能避免预训练表征发生灾难性遗忘。
- **BORA 统一框架**：我们提出了一个面向灵巧操作 VLA 的、完整的 offline-to-online RL 后训练框架。BORA 利用 consistency policy 解决生成式 credit assignment 问题，并通过渐进式优化衔接 offline 意图学习与 online 物理执行，显著提升了真实世界部署的鲁棒性：平均成功率（success rate）绝对提升了 33%，在未见过物体上的泛化性能最高提升 43%。

4 2 Related Work

4.1 用于灵巧操纵的 Vision-Language-Action 模型

Vision-Language-Action (VLA) 模型已成为机器人操纵中的一种强大范式。其典型做法是将预训练 VLM 的视觉-语言表征适配到机器人控制中，并通过 action head 输出动作。早期 VLA 模型多采用自回归的离散 token 化动作 [9, 10, 11]；近年来，action head 逐步发展为基于 diffusion 或 flow 的连续 policy [12, 13]，并进一步演进到 consistency 风格的少步生成，以实现高效的 closed-loop 控制 [14, 15]。这一进展也推动了面向灵巧操作的 VLA 或 vision-language-grasp 模型的发展。相较于并联夹爪，灵巧手在精细化和接触丰富的操纵任务中具有显著更强的能力 [16, 17, 18]。近期工作如 Being-H0 [19] 和 VITRA [12] 研究了基于人类数据的预训练，而 Being-H0.5 [16] 则进一步探索了跨不同灵巧手 embodiment 的迁移。然而，现有灵巧操作 VLA 模型在真实世界中的成功率（success rate）仍然有限，其主要原因在于手臂联合动作空间维度高、接触动力学复杂，以及灵巧操纵数据噪声较大，这些因素都会使离线 post-training 变得不稳定且低效。

4.2 Vision-Language-Action Policy 的后训练与适配

post-training 已成为将预训练 VLA policy 适配到下游机器人平台和任务域中的关键步骤。不同于 VLM 的 post-training——后者通常可以在静态数据上进行偏好优化——机器人的 post-training 需要在稀疏奖励、分布偏移以及真实世界样本有限的条件下，优化 closed-loop 的物理交互。现有方法大体可以分为离线与在线两类范式。离线 RL 以及基于模仿的微调（fine-tuning）能够复用已采集的机器人数据，因此具有较好的可扩展性；但由于 demonstration 质量不佳、动作多模态性，以及离线轨迹与实际部署动力学之间存在失配，它们带来的性能提升往往有限 [20]。在线 RL 则直接在目标环境中优化任务成功，已在机器人操纵中展现出较强潜力；然而，其代价高且训练不稳定，尤其是在高 DoF 的灵巧手场景中，探索既样本效率低，又可能带来安全风险 [21, 22, 23]。近期一些 offline-to-online RL 方法尝试结合离线数据的可扩展性与在线交互的自适应性 [24, 25]。不过，现有大多数 post-training 与 residual adaptation 方法主要面向机械臂或并联夹爪，这些系统的动作空间

相对低维，接触不确定性也更容易处理。对于灵巧操作 VLA policy 而言，高维手臂联合动作、严重的手-物体遮挡以及带噪声的修正数据，都会显著破坏 value estimation 与 policy update 的稳定性。因此，直接将传统离线或在线 RL 的 post-training 方法应用于真实世界灵巧操纵，通常会导致训练低效，且成功率提升有限。




图 2: BORA 框架示意图。BORA 将离线 token-action 强化学习与在线 residual adaptation 连接起来, 用于真实世界的灵巧操作 VLA policy。在离线阶段, VLM encoder 与 action expert 生成共享的 VLM cognition tokens 和 action chunks, 并由集成 critic Q_ϕ 在语义锚定与基于 IQL 的 policy 优化下进行联合评估。右侧子图给出了 action-conditioned critic 的细节: 该模块基于 VLM tokens、action chunks 与 position embeddings, 预测每一步的 Q 和 V 值, 并通过 shifted value bootstrap 在每个 chunk 内传播 credit。在在线阶段, 离线训练得到的 base VLA 保持冻结, 同时训练一个轻量级 residual chunk actor π_{res} , 训练信号来自继承的 critic 反馈、稀疏任务奖励以及 human-in-the-loop 干预信号。最终的动作 chunk 通过残差组合得到, 即 $A_{final} = A_{base} + \lambda A_{res}$ [26], 从而以较低成本实现物理环境下的自适应, 并提升灵巧执行性能。

5 方法

本文提出 BORA: 一个面向灵巧操纵中 Vision-Language-Action (VLA) 模型的完整 offline-to-online 强化学习框架。BORA 的核心思想是构建两阶段适配流程: 首先通过 offline RL 提取基础操纵技能; 随后在真实机器人上引入 Human-in-the-Loop (HiL) 在线 residual RL 适配, 以补偿真实执行过程中产生的误差。

5.1 3.1 带动作条件 Critic 与一致性 Policy 的离线强化学习 (第 1 部分)

现有的生成式动作架构通常依赖迭代去噪过程, 这会在连续控制中进一步加剧 credit assignment 失败问题 [27]。这一瓶颈在灵巧操纵任务中尤为严重: 由于系统具有极高的 DoFs, 动作流形天然呈现多模态特性, 并且充斥着大量冗余、与任务无关的微动作。在这样一个噪声很强的动作空间中, 如果需要跨越数百个时间步的去噪过程反向传播 RL 信号, 几乎不可避免地会造成严重的噪声累积。其结果是, 基础 VLM 无法接收到有效梯度, 从而破坏高层任务表征与底层动作执行之间的对齐。

为此, 我们将 actor 参数化为 consistency policy, 使其仅需 1-3 个去噪步即可生成高保真的 action chunk [7,8]。这种形式通过截断计算图, 保证了信息量更高的梯度能够高效地回传至 VLM,

从而支持稳定的离线优化。进一步地，为避免在奖励设计中依赖特权信息（privileged information）[28]，我们采用一种极简的稀疏奖励形式：仅包含终止时的成功奖励以及逐步累积的时间惩罚。然而，在这种稀疏奖励下评估高维 action chunk 本身就很困难；若再叠加严重的视觉遮挡，解耦式 critic 很容易过拟合到伪相关的背景伪迹，而非真实的物理交互。

动作条件 Critic. 为缓解这种视觉过拟合，并处理 chunk 级评估的高维问题，我们令 critic 以 VLM 语义 token $z_t = \Phi_{\text{VLM}}(s_t)$ 为条件，并将 chunk 级评估分解为原子级、逐步的打分。具体而言，我们的 critic 输出一个 k 维价值向量： $Q_\phi(s_t, A_t) = [q_\phi(z_t, a_{t+i}, i)]_{i=0}^{k-1} \in \mathbb{R}^k$ 以及 $V_\psi(s_t) = [v_\psi(z_t, i)]_{i=0}^{k-1} \in \mathbb{R}^k$ ，其中下标 i 表示由可学习位置 embedding 编码的相对位置。为了在这一向量化时域上约束时间一致性，我们通过移位的 value bootstrap 在 chunk 内部反向传播 credit：

$$y_{t,i} = [\text{formula}] \quad (1)$$

critic 参数 ϕ 和 ψ 的优化由 masked Bellman residual 与 IQL 风格的 expectile value objective 共同完成；后者可从次优的离线数据中提取更保守的 value target（细节见附录 A）。

保守的 Policy 改进. 我们不再使用彼此孤立的逐步残差，而是借助 chunk 内部的动作级 GAE 递推来平滑优化信号： $\hat{A}_{t,i} = \delta_{t,i} + \gamma\lambda(1-d_{t+i})\hat{A}_{t,i+1}$ 且 $\hat{A}_{t,k} = 0$ ，其中 $\delta_{t,i} = q_\phi(z_t, a_{t+i}, i) - v_\psi(z_t, i)$ 表示瞬时 advantage。基于 consistency 的 policy π_θ 在每个原子动作步上定义一个高斯动作分布。通过重要性采样比率 [formula] 来模拟 policy 更新，我们使用带有效性 mask 的 clipped PPO surrogate objective 来优化 actor：

$$\mathcal{L}_{\text{PPO}}(\theta) = -\mathbb{E}_{(s_t, A_t) \sim \mathcal{D}} \left[\frac{1}{|M_t|} \sum_{i=0}^{k-1} m_{t,i} \min \left(r_{t,i} \hat{A}_{t,i}, \text{clip}(r_{t,i}, 1 - \epsilon, 1 + \epsilon) \hat{A}_{t,i} \right) \right] \quad (2)$$

5.2 Offline RL with Action-Conditioned Critic and Consistency Policy（第二部分）

其中， $m_{t,i}$ 表示有效性 mask，[formula] 为有效的 chunk 长度。为保证 policy 的保守性并避免偏离分布外（out-of-distribution）区域，完整的优化目标将 PPO 与作用在归一化 action chunk 上的 Behavior Cloning（BC）正则项结合起来：

$$\mathcal{L}_{\text{actor}} = \lambda_{\text{ppo}} \mathcal{L}_{\text{PPO}} + \lambda_{\text{bc}} \mathcal{L}_{\text{BC}}$$

5.3 弥合部署鸿沟：HiL 残差 chunk 自适应

尽管离线 RL 为 VLA 模型提供了较强的行为先验，但一旦直接部署到真实物理环境中，复杂接触动力学所引发的执行漂移会不断累积，使 policy 不可避免地偏离原有轨迹。与此同时，对全参数进行在线微调（fine-tuning）不仅计算代价高昂，还很容易导致预训练视觉-语言表征发生灾难性特征漂移，以及 value collapse [6]。

为了在保留基础模型先验的同时实现快速、样本高效的真实世界自适应，BORA 冻结了离线训练得到的 VLA 基座，并引入一个轻量级的残差 Chunk Actor π_{res} （由 MLP 参数化）。 π_{res} 直接工作在连续时间域中，并在 action chunk 层面生成补偿量。给定 proprioceptive 状态 s_{prop} 、基座动作 chunk A_{base} 以及 VLM token z_{VLM} ，最终部署时使用的组合 chunk 定义为

$$A_{\text{final}} = A_{\text{base}} + \lambda_{\text{res}} \cdot \pi_{\text{res}}(s_{\text{prop}}, A_{\text{base}}, z_{\text{VLM}}),$$

其中, λ_{res} 是一个缩放系数, 用于限制残差干预的幅度, 从而保证动作流形的平滑性。

在线自适应阶段, BORA 将 Critic Inheritance 与一种 Intervention-Driven 的 RLPD 流程结合起来, 以稳定优化动态。离线训练得到的 critic Q_ϕ 被用来初始化在线 value function, 从而保留一个预先塑形好的价值地形。为保证 policy 改进的单调性, 残差 actor 优化一个保守的 value guidance 目标 (见附录 B.3), 对那些性能劣于冻结 VLA 基座的残差动作进行惩罚。与此同时, 人工纠正通过 RLPD 协议被纳入训练, 该协议在静态离线数据集与一个由人工干预动态扩充的在线缓冲区之间维持 1:1 的采样比例 [25]。这种基于混合数据流的联合优化能够对抗在线轨迹的非平稳性, 并使模型可以更精确地校准残差动作所带来的优势。

在上述稳定化方法的基础上, 作者进一步设计了一个遵循 DexHiL [2] 的 Human-in-the-Loop (HiL) 干预系统。具体而言, 当模型在任务执行中出现失败时 (例如手指闭合不完全, 或手腕位姿放置错误), BORA 允许人工操作员接管控制并将任务恢复到可继续执行的状态。为减轻从自主执行切换到人工接管过程中可能出现的运动学不连续性, 系统采用了基于线性插值的动作平滑机制, 以保证手部位姿在时间上的一致性。

最后, 为了给 Intervention-Driven RLPD 流程提供核心优化信号, 作者设计了一个非对称的 Intervention-Driven Reward 函数。如果 policy 发生 OOD 漂移并触发人工干预, 则立即施加一个惩罚 r_{int} 。相反, 当人工纠正动作完成后, 系统会给予一个正向恢复奖励 r_{rec} 。这种非对称奖励机制可直接指导 RLPD 的 value 更新: 一方面, 它促使残差 policy 强烈惩罚高风险状态; 另一方面, 它又能够高效利用高质量的恢复轨迹进行学习。最终, 系统以尽可能少的真实世界交互代价闭合了物理部署中的自适应回路。

6 实验

本节围绕以下 3 个问题设计了一系列实验, 以系统考察所提出的 BORA:

- **RQ1:** 在高维动作生成与视觉遮挡的条件下, BORA 能否通过提供动作条件价值引导, 提升灵巧操作 VLA policy 的离线强化学习 (offline RL) 后训练效果?
- **RQ2:** 所提出的在线自适应方法如何以高样本效率的方式弥合真实世界部署中的性能鸿沟?
- **RQ3:** 在在线微调 (fine-tuning) 过程中, 继承得到的动作条件 critic 如何支持残差 policy 学习?

6.1 4.1 Experimental Setup

如附录 C 所述, 我们将 BORA 部署到一个真实世界灵巧操纵平台上。该平台由一台 Franka 机械臂和一只 12-DoF 灵巧手组成。我们在以下五项任务上评估各模型: 抓取毛绒玩具 (Pick the plush toy)、抓取并放置 (Pick and Place)、打开盒子 (Open the box)、抽取纸巾 (Pull the tissue) 以及按下按钮 (Press the button)。对于每个任务, 我们都在标准配置下进行 20 次试验, 并在包含新物体、即训练中未见物体的设置下再进行 20 次试验, 以评估 BORA 的泛化能力。

为了系统地对框架进行消融分析, 我们将 BORA 与四种 baseline 设置进行比较。这些 baseline 都建立在预训练的 VITRA VLM 之上, 并统一采用 VLA 架构:

- **VITRA (Fine-tuned Base) [12]:** 在原始预训练 VITRA 权重基础上进行微调 (fine-tuning) 的 baseline, 由多模态 VLM backbone 与 Diffusion Action Expert 组成。

- **CP Base** (consistency policy): 一个模仿学习 (Imitation Learning) baseline, 使用 consistency policy 作为 action expert, 不进行任何强化学习微调。
- **Decoupled-Critic Baseline [29]**: 一个离线强化学习 (offline RL) baseline, 其 critic 单独训练, 且不会对 VLM cognition tokens 与生成的 action chunks 进行联合条件建模。
- **BORA-Offline (Ours)**: 我们的离线 RL 框架, 采用 action-conditioned critic, 对 VLM cognition tokens 与连续 action chunks 进行联合评估。

进一步地, 我们的完整设置 **BORA-Full (Ours)** 包含完整训练流程: 先执行 BORA-Offline, 再通过两轮真实世界物理强化学习, 进行 HiL 在线残差 chunk 自适应 (online residual chunk adaptation)。包含上述组件的在线训练过程已在算法 1 中形式化总结。

表 1: 标准配置下真实世界灵巧操纵任务的成功率 (success rate)

任务	纯模仿学习 (IL)		强化学习 (RL) 微调		
	VITRA (Diffusion)	CP Base	CP + Decoupled Critic	BORA-Offline	BORA-Full (Ours)
抓取毛绒玩具	14/20 (70%)	12/20 (60%)	10/20 (50%)	17/20 (85%)	20/20 (100%)
抓取并放置	9/20 (45%)	10/20 (50%)	8/20 (40%)	14/20 (70%)	18/20 (90%)
打开盒子	12/20 (60%)	11/20 (55%)	5/20 (25%)	11/20 (55%)	15/20 (75%)
抽取纸巾	9/20 (45%)	7/20 (35%)	10/20 (50%)	12/20 (60%)	16/20 (80%)
按下按钮	10/20 (50%)	13/20 (65%)	12/20 (60%)	13/20 (65%)	17/20 (85%)

表 2: 未见物体设置下真实世界灵巧操纵任务的成功率 (success rate)

任务	纯模仿学习 (IL)		强化学习 (RL) 微调		
	VITRA (Diffusion)	CP Base	CP + Decoupled Critic	BORA-Offline	BORA-Full (Ours)
抓取毛绒玩具	9/20 (45%)	7/20 (35%)	11/20 (55%)	15/20 (75%)	17/20 (85%)
抓取并放置	6/20 (30%)	6/20 (30%)	8/20 (40%)	9/20 (45%)	14/20 (70%)
打开盒子	2/20 (10%)	3/20 (15%)	1/20 (5%)	7/20 (35%)	10/20 (50%)
抽取纸巾	7/20 (35%)	3/20 (15%)	10/20 (50%)	10/20 (50%)	14/20 (70%)
按下按钮	9/20 (45%)	8/20 (40%)	11/20 (55%)	11/20 (55%)	15/20 (75%)

6.2 4.2 主要结果与分析

我们在表 1 和表 2 中报告主要的定量结果, 并在图 3 中给出可视化总结。表中展示了各任务、各设置下 20 次真实世界试验中的精确成功次数, 柱状图则概括了不同 baseline 之间的相对趋势。附录中的图 5 进一步展示了五个评测任务上的代表性真实机器人结果。


带动作条件价值引导的离线意图对齐 (RQ1) 如表 1 和表 2 所示, CP Base 在标准设置下的平均成功率达到 53.0%, 但在 object-unseen 评测下下降到 27.0%, 说明其在高维、多模态灵巧动作空间中的泛化能力有限。BORA-Offline 在极少步数内将信息量更高的 policy gradient 回传至基础 VLM, 从而提取高保真的物理意图, 使两种设置下的平均成功率分别提升至 67.0% 和 52.0%; 相较于标准设

置提升了 14 个百分点，在 object-unseen 评测下提升了 25 个百分点。这表明，尽管标准 diffusion 架构由于长链条去噪迭代中的严重梯度消失，难以直接进行离线 RL 微调 (fine-tuning)，但我们提出的截断 consistency policy 形式能够有效缓解这一瓶颈。

更关键的是,这种架构层面的协同使模型能够有效抵御视觉遮挡。传统的 critic 解耦架构(Decoupled-Critic baseline) 容易对原始像素值和伪相关背景特征过拟合，并将错误梯度传播回 VLM backbone。在标准设置下，Decoupled-Critic baseline 的平均表现甚至低于 CP Base。在 object-unseen 评测下，尽管它在部分任务上优于 CP Base，但在 Open-the-Box 任务上出现明显失效，说明在严重遮挡条件下，其价值引导并不稳定。相比之下，BORA-Offline 将 Integrated Critic 直接条件化于 VLM 的语义 token (z_t)，从而将价值更新严格约束在多模态潜在空间内。

这一点也得到了附录图 8 中 t-SNE 可视化结果的定性支持：在离线 RL 之后，BORA-Offline 更接近 SFT/BC manifold，说明其对 policy 动作表征结构的保持更好。附录图 9 和图 10 进一步表明，BORA 会对灵巧手以及任务相关的接触区域赋予更强的显著性响应，而解耦 critic 的响应则更多分散在桌面、背景以及其他非接触区域。

高样本效率的在线物理自适应 (RQ2) 尽管离线阶段已经建立了意图感知能力，真实世界部署仍会引入 covariate shift、执行误差以及复杂的接触摩擦，从而导致模型在 object-unseen 任务上的性能下降。为弥合这种从离线到在线的差距，BORA-Full 中的在线 residual chunk 自适应提供了一种高样本效率的解决方案。具体而言，BORA-Full 在最初两轮在线强化学习内就表现出快速的性能收敛，此后进一步提升已较为有限。在实际使用中，人类操作员每个任务通常只需干预 1-2 次，额外时间投入仅约为在线轨迹执行时长的 20%。得益于这种 residual 训练方式以及人类干预价值引导机制，BORA-Full 在 Standard 设置下将总体平均成功率提升到 86.0%，并在 Object-Unseen 配置下将成功率从 52.0% 进一步提高到 70.0%。这种高效自适应在灵巧执行任务上取得了所评测 baseline 中的最佳性能，同时避免了冻结的预训练 VLM 基座发生表征漂移。



Object-Unseen




图 3: 真实世界灵巧操纵结果的可视化总结。在标准设置与 object-unseen 设置下, 展示了五个任务上的成功率。BORA-Offline 相较于模仿学习和解耦 critic baseline 均有提升, 而 BORA-Full 则通过在线 residual 自适应进一步提升了性能。

6.3 Critic 继承机制分析 (RQ3)

为理解快速在线自适应背后的内在机制, 我们进一步分析了继承得到的 value function 的行为; 更多 value profile 可视化结果见附录图 11。经验性的 value profile 表明: 离线训练得到的 action-conditioned critic 与在线阶段非对称、由 intervention 驱动的 reward 相结合后, 能够提供稳定且响应灵敏的 value estimation。

在自主执行过程中, 继承的 critic 表现出清晰的判别能力: 沿着成功轨迹时, 它始终保持较高的 value 置信度; 而沿着失败轨迹时, 其 Q-value 估计则持续处于较低水平。更重要的是, 这种判别能力即便在视觉上非常相似的状态下也能得以保留, 例如多指手在严重遮挡条件下抓取物体时。尽管原始相机像素看起来与 decoupled baseline 中的对应场景几乎一致, 但从离线阶段继承而来的 action-conditioned critic 仍能在结构语义层面上评估 state-action pair。

因此, 继承的 critic 能够缓解表层视觉歧义, 对高风险执行状态施加惩罚, 并以较少的真实物理交互引导轻量级 residual policy π_{res} 融合人类纠正先验。

6.4 5 局限性

尽管 BORA 展现出了较强的性能, 但仍存在两点主要局限。首先, 该框架依赖视觉-proprioception 输入, 尚未纳入稠密的 tactile 反馈。在严重视觉遮挡的情况下, 若能将高保真 tactile 阵列进一步整合为 VLM token, 或可进一步强化感知-动作闭环。其次, 我们的真实机器人评估仅限于单一的机械臂-手拓扑。未来一个重要的扩展方向, 是在运动学结构与自由度 (DoF) 各异的多指手平台上, 验证 BORA 的跨 embodiment 泛化能力。

7 6 结论

本文提出了 BORA，这是一种面向真实世界灵巧操作 VLA 模型、专门设计的 offline-to-online RL 后训练框架。BORA 将离线对齐与高效在线微调 (fine-tuning) 无缝衔接，针对灵巧操作 VLA 后训练中的若干关键挑战给出了解决方案，包括 critic 对视觉伪影的过拟合、真实环境执行偏差，以及灾难性特征漂移。我们在五项复杂的真实世界灵巧操作任务上进行了大规模评估，结果表明，BORA 相比模仿学习和解耦式 RL baseline 均具有显著优势：平均成功率 (success rate) 绝对提升 33%，在未见过物体上的泛化性能最高提升 43%。

未来，我们计划将该框架进一步拓展到高精度灵巧技能，并研究其在结构复杂、长时程操作任务上的可扩展性。

8 参考文献

参考文献条目较多，此处保留原论文英文文献列表，请参阅原文 PDF 的 References 一节。

[附录因公式排版问题从译本中省略，请参阅原文。]